

Inferencia en Ecuaciones Diferenciales Estocásticas: MLE vía Lamperti–Girsanov

Yofre H. García

Facultad de Ciencias en Física y Matemáticas
Benemérita Universidad Autónoma de Chiapas (B - UNACH)

Segundo congreso multidisciplinario
LGAC: Modelos estocásticos, optimización y control

Tuxtla Gutiérrez, 30 de octubre de 2025

¿Por qué inferencia en SDEs?

- **Motivación:** datos continuos o de alta frecuencia, ruido inevitable, y decisiones bajo incertidumbre en finanzas, biología, e ingeniería.
- **Modelo SDE base (1D):**

$$dX_t = b(X_t, \theta) dt + \sigma(X_t, \theta) dW_t, \quad X_0 = x_0.$$

Observación: trayectoria en $[0, T]$ (o muestras discretas $t_i = i\Delta$).

- **Meta inferencial:** estimar θ maximizando una verosimilitud bien definida (log-verosimilitud $\ell_T(\theta)$ basada en la trayectoria).

Mensaje clave

La inferencia en SDEs requiere explotar la estructura estocástica del modelo (drift/difusión). Más adelante: *Lamperti* $\rightarrow$ (log-)Girsanov para construir $\ell_T(\theta)$.

¿Por qué inferencia en SDEs?

- **Motivación:** datos continuos o de alta frecuencia, ruido inevitable, y decisiones bajo incertidumbre en finanzas, biología, e ingeniería.
- **Modelo SDE base (1D):**

$$\text{OU: } dX_t = -\kappa(X_t - \mu)dt + \sigma dW_t, \quad X_0 = x_0, \quad \Theta = (\mu, \kappa, \sigma).$$

Observación: trayectoria en $[0, T]$ (o muestras discretas $t_i = i\Delta$).

- **Meta inferencial:** estimar θ maximizando una verosimilitud bien definida (log-verosimilitud $\ell_T(\theta)$ basada en la trayectoria).

Mensaje clave

La inferencia en SDEs requiere explotar la estructura estocástica del modelo (drift/difusión). Más adelante: *Lamperti* $\rightarrow$ (log-)Girsanov para construir $\ell_T(\theta)$.

¿Por qué inferencia en SDEs?

- **Motivación:** datos continuos o de alta frecuencia, ruido inevitable, y decisiones bajo incertidumbre en finanzas, biología, e ingeniería.
- **Modelo SDE base (1D):**

$$\text{SIS: } dI_t = I_t \left([\beta(t)(1 - I_t) - \gamma] dt + \sigma(t)(1 - I_t) dW_t \right), \quad \beta(t) \in [\underline{\beta}, \bar{\beta}], \quad \sigma(t) \in [\underline{\sigma}, \bar{\sigma}].$$

$$\Theta_t = (\beta(t), \gamma, \sigma(t))$$

Observación: trayectoria en $[0, T]$ (o muestras discretas $t_i = i\Delta$).

- **Meta inferencial:** estimar θ maximizando una verosimilitud bien definida (log-verosimilitud $\ell_T(\theta)$ basada en la trayectoria).

Mensaje clave

La inferencia en SDEs requiere explotar la estructura estocástica del modelo (drift/difusión). Más adelante: *Lamperti* $\rightarrow$ (log-)Girsanov para construir $\ell_T(\theta)$.

MLE - variables aleatorias absolutamente continuas

Sea X una variable aleatoria con **densidad** $f(x; \theta)$, $\theta \in \Theta$. Dada una muestra i.i.d. $x_1, \dots, x_n$ de X , la **función de verosimilitud** y la **log-verosimilitud** (equivalente para maximizar) son respectivamente

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta), \quad \ell(\theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Un **estimador de máxima verosimilitud (MLE)**¹ de θ se define como

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} L(\theta) \quad (\text{equivalente a maximizar } \ell(\theta)).$$

conexión con SDEs: para procesos de Markov (p. ej., difusiones muestreadas cada Δt), $f(x_i; \theta)$ se reemplaza por la *densidad de transición* $p_\theta(\Delta, x_{i-1}, x_i)$; con trayectoria continua, la verosimilitud se expresa vía Lamperti $\rightarrow$ Girsanov como integrales de trayectoria.

¹Casella, G. & Berger, R. L. (2002), *Statistical Inference* (2nd ed.), Duxbury/Thomson, cap. 7.

Dos obstáculos clásicos & la alternativa Lamperti–Girsanov

- **Obstáculo:** la densidad de transición $p_\theta(t, x, y)$ rara vez está en forma cerrada.

Para una SDE 1-Dimensional (**1D**), el núcleo de transición es

$$P_\theta(t, x, A) = \mathbb{P}_\theta(X_t \in A \mid X_0 = x).$$

Si $P_\theta(t, x, \cdot)$ es absolutamente continuo respecto a Lebesgue, existe la *densidad de transición* $p_\theta(t, x, y)$ tal que

$$P_\theta(t, x, dy) = p_\theta(t, x, y) dy.$$

salvo casos especiales (OU, GBM, CIR, ...), p_θ **no tiene forma cerrada**.

Relación con MLE: Verosimilitud con datos discretos: Si observamos $x_0, \dots, x_n$ con paso fijo Δ ,

$$L(\theta) = \prod_{i=1}^n p_\theta(\Delta, x_{i-1}, x_i), \quad \ell(\theta) = \sum_{i=1}^n \log p_\theta(\Delta, x_{i-1}, x_i).$$

Problema práctico: para maximizar $L(\theta)$ necesitamos evaluar $p_\theta(\Delta, \cdot, \cdot)$, que rara vez es disponible sin usar herramientas más avanzadas

Dos obstáculos clásicos & la alternativa Lamperti–Girsanov

- **Obstáculo:** la densidad de transición $p_\theta(t, x, y)$ rara vez está en forma cerrada.
- **Idea clave:** evitar p_θ construyendo el *cociente de verosimilitudes* vía **cambio de medida** (Girsanov) después de **Lamperti** (difusión unitaria).

▮ **Lamperti (1D).** Si $\sigma(x, \theta) > 0$,

$$Y_t = \Lambda_\theta(X_t) = \int_{x^*}^{X_t} \frac{1}{\sigma(u, \theta)} du, \quad dY_t = \alpha(Y_t, \theta) dt + dW_t,$$

$$\alpha(y, \theta) = \frac{b(x, \theta)}{\sigma(x, \theta)} - \frac{1}{2} \partial_x \sigma(x, \theta) \Big|_{x=\Lambda_\theta^{-1}(y)}.$$

└

Itô sobre $Y_t = \Lambda_\theta(X_t)$: con $f' = \frac{1}{\sigma}$, $f'' = -\frac{\partial_x \sigma}{\sigma^2}$ y $a = \sigma^2$,

$$dY_t = \left[f'(X_t) dX_t + \frac{1}{2} f''(X_t) a(X_t) dt \right] = \left(\frac{b}{\sigma} - \frac{1}{2} \partial_x \sigma \right)(X_t, \theta) dt + dW_t.$$





Reescrito como función de y (vía $x = \Lambda_\theta^{-1}(y)$):

Requisitos típicos: σ separada de cero y suave; identificabilidad de $\alpha(\cdot, \theta)$; condiciones de martingala para Girsanov.

Ilustración gráfica: Transformación de Lamperti

Experimento (OU - $\sigma_1 \neq \sigma_2$): $dX_t^{(1)} = -\kappa(X_t^{(1)} - \mu)dt + \sigma_i dW_t$,
 $\kappa = 1$, $\mu = 0$, $\sigma_1 = 0.5$, $\sigma_2 = 1.5$.

Parámetros de simulación: horizonte $T = 10$, paso $\Delta t = 10^{-3}$, $N = T/\Delta t = 10,000$ pasos. **Esquema:** Euler-Maruyama. **Transformación de Lamperti** (OU): $Y_t^{(k)} = X_t^{(k)} / \sigma_k$ (difusión unitaria: $dY_t^{(k)} = -\kappa(Y_t^{(k)} - \mu/\sigma_k)dt + dW_t$). RQV = variación cuadrática realizada $\sum_{i \leq k} (\Delta \cdot)_i^2$



¿Qué es $\alpha(Y_t, \theta)$ en Lamperti?

- Es el **drift del proceso transformado** $Y_t = \Lambda_\theta(X_t)$ con difusión unitaria.

$$\Lambda'_\theta(x) = \frac{1}{\sigma(x, \theta)}, \quad \Lambda''_\theta(x) = -\frac{\partial_x \sigma(x, \theta)}{\sigma(x, \theta)^2}.$$

$$dY_t = \left(\frac{b}{\sigma} - \frac{1}{2} \partial_x \sigma \right)(X_t, \theta) dt + dW_t \quad \Rightarrow \quad \alpha(y, \theta) = \frac{b(x, \theta)}{\sigma(x, \theta)} - \frac{1}{2} \partial_x \sigma(x, \theta), \quad x = \Lambda_\theta^{-1}(y).$$

Por el teorema de la función inversa, si σ es C^1 y está separada de 0, entonces

$$\frac{d}{dy} \Lambda_\theta^{-1}(y) = \sigma(\Lambda_\theta^{-1}(y), \theta).$$

Nota: si σ se anula o cambia de signo, la transf. Lamperti puede fallar (no hay inverso global).

Comentario

El término b/σ proviene del “*inverso multiplicativo*” en $\Lambda'_\theta(x) = 1/\sigma$, y $-\frac{1}{2} \partial_x \sigma$ es la **corrección de Itô** por la curvatura de Λ_θ . En Stratonovich, la corrección desaparece: $\alpha^\circ = b/\sigma$.

Cambio de medida: Teorema de Girsanov

Propósito: comparar dos modelos de difusión con distintos parámetros θ y θ_0 .

$$\begin{aligned}dY_t &= \alpha_\theta(Y_t) dt + dW_t^{(\theta)}, & Y_0 &= y_0, \\dY_t &= \alpha_{\theta_0}(Y_t) dt + dW_t^{(\theta_0)}, & Y_0 &= y_0.\end{aligned}$$

Idea intuitiva:

Cada parámetro θ define una *media local diferente* del movimiento. El término de drift $\alpha_\theta(Y_t) dt$ actúa como un “empuje promedio” que orienta las trayectorias del mismo ruido browniano.

- Al cambiar θ , no se altera la naturaleza aleatoria del ruido, sino la dirección promedio en la que evoluciona el proceso.
- Dos procesos con igual difusión pero distinto drift generan *leyes de probabilidad distintas* sobre las trayectorias.
- El cambio de medida de Girsanov proporciona la densidad de **Radon–Nikodym** que ajusta precisamente esa diferencia de medias.

Definición: Derivada de Radon–Nikodym (RN)

Definición. Sean $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0})$ un espacio de probabilidad filtrado y dos medidas de probabilidad $\mathbb{P}_\theta$ y $\mathbb{P}_{\theta_0}$ tales que

$$\mathbb{P}_\theta \ll \mathbb{P}_{\theta_0} \quad \text{en } \mathcal{F}_T \iff (\text{Si } A \in \mathcal{F}_T \text{ y } \mathbb{P}_{\theta_0}(A) = 0, \quad \text{entonces } \mathbb{P}_\theta(A) = 0)$$

Entonces existe una variable aleatoria no negativa Z_T (llamada *derivada de Radon–Nikodym*) tal que:

$$\left. \frac{d\mathbb{P}_\theta}{d\mathbb{P}_{\theta_0}} \right|_{\mathcal{F}_T} = Z_T, \quad \mathbb{E}_{\theta_0}[Z_T] = 1.$$

Interpretación:

- Z_T actúa como una *densidad* que reescala probabilidades de eventos cuando cambiamos de $\mathbb{P}_{\theta_0}$ a $\mathbb{P}_\theta$.
- Permite escribir, para cualquier variable integrable F ,

$$\mathbb{E}_\theta[F] = \mathbb{E}_{\theta_0}[F Z_T].$$

- En el contexto de difusiones, Z_T será la *exponencial estocástica* que aparece en la fórmula de Girsanov.

Teorema de Girsanov: Cambio de medida

Sea $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P}_0)$ un espacio filtrado que satisface las condiciones usuales, y sea $W = (W_t)_{t \in [0, T]}$ un movimiento browniano estándar bajo $\mathbb{P}_0$. Sea $\lambda = (\lambda_t)_{t \in [0, T]}$ un proceso progresivamente medible tal que

$$\int_0^T \lambda_t^2 dt < \infty \quad \text{a.s.}$$

y que cumple la condición de Novikov: $\mathbb{E}_0 \left[\exp \left(\frac{1}{2} \int_0^T \lambda_t^2 dt \right) \right] < \infty$.

Considere la exponencial de Doléans–Dade

$$Z_t := \exp \left(\int_0^t \lambda_s dW_s - \frac{1}{2} \int_0^t \lambda_s^2 ds \right), \quad t \in [0, T].$$

Entonces (Z_t) es una martingala positiva con $\mathbb{E}_0[Z_T] = 1$ y, definiendo una medida $\mathbb{P}$ en $\mathcal{F}_T$ por $d\mathbb{P} = Z_T d\mathbb{P}_0$, se tiene:

$$W_t^{\mathbb{P}} := W_t - \int_0^t \lambda_s ds, \quad t \in [0, T],$$

es un movimiento browniano estándar (adaptado a $(\mathcal{F}_t)$) bajo $\mathbb{P}$. Además, $\mathbb{P} \sim \mathbb{P}_0$ sobre $\mathcal{F}_T$ (equivalencia de medidas).

Uso en la construcción de log -Girsanov

Supuestos:

- Si $dY_t = \alpha_{\theta_0}(Y_t) dt + dW_t^{(\theta_0)}, \quad dY_t = \alpha_{\theta}(Y_t) dt + dW_t^{(\theta)},$ con mismo ruido Browniano.
- Sea $\lambda_t = (\alpha_{\theta} - \alpha_{\theta_0})(Y_t)$ y supongamos que se cumple la condición de Novikov.

Entonces:

1. La variable (Cambio de medida) $Z_T = \exp\left(\int_0^T \lambda_s dW_s^{(\theta_0)} - \frac{1}{2} \int_0^T \lambda_s^2 ds\right)$ (Martingala).
define una nueva medida $d\mathbb{P}_{\theta} = Z_T d\mathbb{P}_{\theta_0}$ sobre $\mathcal{F}_T$.
2. Bajo la nueva medida $\mathbb{P}_{\theta}$, el proceso

$$W_t^{(\theta)} = W_t^{(\theta_0)} - \int_0^t \lambda_s ds$$

es un **proceso Browniano**, y el proceso Y_t satisface:

$$dY_t = \alpha_{\theta}(Y_t) dt + dW_t^{(\theta)}.$$

Forma relativa y forma observacional (log-Girsanov)

Forma relativa (dos parámetros θ, θ_0):

$$Z_T = L_T(\theta) = \log \frac{d\mathbb{P}_\theta}{d\mathbb{P}_{\theta_0}} \Big|_{\mathcal{F}_T} = \int_0^T (\alpha_\theta - \alpha_{\theta_0})(Y_t) dW_t^{(\theta_0)} - \frac{1}{2} \int_0^T (\alpha_\theta^2 - \alpha_{\theta_0}^2)(Y_t) dt.$$

Fijando θ_0 (por ejemplo, “drift 0”) y usando $dW_t = dY_t - \alpha_{\theta_0}(Y_t) dt$:

$$\ell_T(\theta) = \log L_T(\theta) = \int_0^T \alpha_\theta(Y_t) dY_t - \frac{1}{2} \int_0^T \alpha_\theta(Y_t)^2 dt.$$

- La primera expresión relaciona las medidas bajo dos parámetros distintos.
- La segunda es la **log-verosimilitud continua** observable del modelo.
- El estimador de máxima verosimilitud satisface:

$$\hat{\theta}_T = \arg \max_{\theta} \ell_T(\theta).$$

La forma observacional surge al reemplazar la dinámica del proceso en la integral estocástica.

Uso en SIS: Estimador MLE consistente de tasa de infección $\beta(t_j)$

SIS: $dI_t = I_t([\beta(t)(1 - I_t) - \gamma] dt + \sigma(t)(1 - I_t) dW_t)$, $\beta(t) \in [\underline{\beta}, \bar{\beta}]$, $\sigma(t) \in [\underline{\sigma}, \bar{\sigma}]$,
Supongamos que se dispone de

$$I_{t_1}, I_{t_2}, \dots, I_{t_k} \longrightarrow \hat{I}_{t_{k+1}}, \hat{I}_{t_{k+2}}, \dots, \hat{I}_{t_{k+s}}.$$

$$\frac{d\mathbb{P}_{\hat{\beta}_j}}{d\mathbb{P}_{\beta_j}} = \exp\left(\int_{t_{j-1}}^{t_j} \frac{\hat{\beta}_j - \beta_j}{\sigma_j^2 I_s(1 - I_s)} dI_s - \frac{1}{2} \int_{t_{j-1}}^{t_j} \frac{((\hat{\beta}_j)^2 - (\beta_j)^2)(1 - I_s) - 2\gamma(\hat{\beta}_j - \beta_j)}{\sigma_j^2(1 - I_s)} ds\right)$$


Criterios de optimización sobre β_j de primera y segunda derivada

$$0 = \frac{1}{\sigma_j^2} \int_{t_{j-1}}^{t_j} \frac{1}{I_s(1 - I_s)} dI_s - \frac{\hat{\beta}_j(t_j - t_{j-1})}{\sigma_j^2} + \frac{\gamma}{\sigma_j^2} \int_{t_{j-1}}^{t_j} \frac{1}{1 - I_s} ds, \quad (1)$$


Se obtiene el **estimador consistente** $\left(\lim_{t_j \rightarrow \infty} MLE(\beta_j) = \beta_j, \quad \text{prob. 1.}\right)$

$$MLE(\beta_j) = \frac{1}{t_j - t_{j-1}} \left(\int_{t_{j-1}}^{t_j} \frac{1}{I_s(1 - I_s)} dI_s + \gamma \int_{t_{j-1}}^{t_j} \frac{1}{1 - I_s} ds \right)$$

Comportamiento numérico del estimador



(a) $\beta(t)$ function



(b) $MLE(\beta)(t)$ function

Figura: Comparación $\beta(t)$ y $MLE(\beta)(t)$



Stochastic perturbation of SIS model with bounded time-dependent parameters: formulation and numerical approximation

Yofre H. García^{1,2}  · Flor A. Gómez²

Received: 3 April 2025 / Revised: 15 July 2025 / Accepted: 22 September 2025

© The Author(s) under exclusive licence to Sociedade Brasileira de Matemática Aplicada e Computacional 2025

Abstract

En memoria de Myriam Muñoz de Özak



Maestra incansable, testimonio de que la luz más pura no se opaca ni por las sombras más profundas. Su existencia fue una sinfonía de amor, ciencia y resiliencia; una afirmación serena de que el cuerpo puede flaquear, pero el espíritu del pensamiento nunca cede.

Su palabra, su risa y su ejemplo seguirán multiplicándose en cada aula, en cada mente que se atreva a mirar el mundo con compasión y razón, como ella lo hizo.

Algo de su obra: Tesis doctoral y línea de investigación

- **Tesis:** *Nonstandard Construction of Brownian Motion and Martingales on Lie Groups.*

Ruhr-Universität Bochum, 1996.

Director: Prof. Sergio Albeverio.

- **Campo de investigación:**

Probabilidad y análisis estocástico, teoría no estándar, martingalas, procesos de Markov y ecuaciones diferenciales estocásticas (EDE).

Su trabajo abordó:

- Construcción del movimiento browniano sobre grupos de Lie mediante técnicas no estándar.
- Desarrollo de bases teóricas para martingalas internas y teoremas de levantamiento en dos parámetros.
- Aplicaciones a la formulación y existencia de soluciones de EDE y al estudio del espacio de probabilidad de Loeb.

- **Impacto académico:**

Sus aportes sentaron vínculos entre el análisis funcional, la probabilidad abstracta y las construcciones infinitesimales en espacios medibles, influyendo en la enseñanza y divulgación del análisis estocástico en América Latina.

Algo de su obra: Principales artículos

- ❶ **Discrete-time Markov control processes with discounted unbounded costs: Optimality criteria** — *Kybernetika* 28(3):191–212, 1992 (con Onésimo Hernández-Lerma).
<https://dblp.org/pid/172/2588> 44 citas - google scholar
- ❷ **Lifting theorems for some classes of two parameter martingales** — *Revista Colombiana de Matemáticas*, 1998. <https://www.researchgate.net/scientific-contributions/Myriam-Munoz-de-Oezak-18112958> 3 citas - google scholar
- ❸ **Nonstandard definition of the Stratonovich integral** — *Revista Colombiana de Estadística* 22:17–25, 1998. <https://distantreader.org/stacks/journals/estad/estad-31801.pdf>
3 citas - google scholar
- ❹ **The probability space of Loeb** — *Revista Colombiana de Estadística*, 1984.
<https://distantreader.org/stacks/journals/estad/estad-10121.pdf>
- ❺ **Existence of solutions of stochastic differential equations** — *Revista Colombiana de Matemáticas*, 1985.
- ❻ **Stopping domains** — *Boletín de Matemáticas* (1997).
- ❼ **Two parameter internal martingales** — *Dialnet*, entrada catalogada.
<https://dialnet.unirioja.es/descarga/articulo/6950858.pdf>

Algo de su obra: Libros y textos docentes


Análisis estocástico

L. Blanco Castañeda & M. Muñoz de Özak.

Contenido: Procesos Estocásticos, Martingalas, Movimiento Browniano, Ecuaciones Diferenciales Estocásticas.

<https://www.researchgate.net/scientific-contributions/Myriam-Munoz-de-Oezak-18112958>

Perdón mi profe ... no solo han sido útiles, son un ancla en mis propósitos



Algo de su obra: Libros y textos docentes


Introducción a la teoría avanzada de la probabilidad 36 citas - google scholar

M. Muñoz de Özak & L. Blanco Castañeda.

Contenido: Teoría de la medida, Integración de Lebesgue y convergencia de funciones, Espacios de probabilidad y variables aleatorias, Cadenas de Markov en tiempo discreto.

ResearchGate.

<https://www.researchgate.net/scientific-contributions/Myriam-Munoz-de-Oezak-18112958>



The proof of Theorem 4.2.3 requires several lemmas. The first is a general result [from Hernández-Lerma and Muñoz de Ozak (1992)] on the interchange of limits and minima, which is interesting in itself.

4.2.4 Lemma. Let u and u_n ($n = 1, 2, \dots$) be l.s.c. functions, bounded below, and inf-compact on $\mathbb{K}$. If $u_n \uparrow u$, then

$$\lim_{n \rightarrow \infty} \min_{A(x)} u_n(x, a) = \min_{A(x)} u(x, a) \quad \forall x \in X.$$

Tomado de: Hernández-Lerma, O. & Lasserre, J. B. (1996). *Discrete-Time Markov Control Processes: Basic Optimality Criteria*. Applications of Mathematics, Vol. 30. Springer Science+Business Media, New York. ISBN 978-1-4612-6884-0. DOI: 10.1007/978-1-4612-0729-0.