

Fitted Q-Iteration: Estimación de niveles de presas

Benemérita UNACH - FCFM - Convención Internacional UNACH CIU 2026
3^{er} Congreso Internacional Multidisciplinario en Física y Matemáticas
LGAC: Matemáticas: Análisis, Optimización, Control y sus Aplicaciones
Autor: Erika Rubí Jiménez Guzmán. Asesor: Yofre H. García.



1. Introducción

La operación eficiente de presas es fundamental para gestionar recursos hídricos en contextos de múltiples demandas: riego, generación hidroeléctrica, control de inundaciones y conservación ambiental. Un desafío central es regular de forma óptima el nivel del embalse, lo cual depende de decisiones diarias de descarga ante condiciones hidrológicas inciertas y cambiantes.

El presente trabajo se centra en el análisis y comparación de dos metodologías para la estimación y control de niveles de embalses: el método clásico de Programación Dinámica Estocástica (PDE) y el enfoque innovador de aprendizaje por refuerzo mediante Fitted Q-Iteration (FQI). Para evaluar su desempeño, se tomó como caso de estudio el sistema hidroeléctrico compuesto por las presas La Angostura y Malpaso, utilizando datos históricos de operación. Mientras que la PDE requiere modelos hidrodinámicos exhaustivos y está limitada por un alto costo computacional ante sistemas complejos (la maldición de la dimensionalidad), el FQI permite aproximar políticas óptimas directamente a partir de la experiencia y simulaciones simples.


2. Formulación del problema (MDP)

Proceso de Decisión de Markov (MDP)

El problema se formuló como un **MDP** $(T, \mathcal{S}, \mathcal{A}, P, \mathcal{R})$ para dos presas del estado de Chiapas: La Angostura y Malpaso. Se analizó un horizonte de 50 años históricos, 1959 – 2008, los cuales fueron divididos en 24 quincenas y agrupados en 6 etapas hidrológicas.

El objetivo es maximizar la generación de energía (E) aplicando penalizaciones por derrames (Π_{derr}), déficit de agua (Π_{def}), violación de la curva guía (referencia para saber si una presa está en riesgo o no) (Π_{CG}) y niveles críticos (Π_{crit}). Así, la función de recompensa se define finalmente como

$$\mathcal{R}(s, a, s') = E - \Pi_{derr} - \Pi_{def} - \Pi_{CG} - \Pi_{crit}$$



Niveles de presas.

$$s' = \min \{ \max \{ s - a + \xi, 0 \}, S_{\max} \}$$

3. Fitted Q-Iteration

El Q-learning es un algoritmo de aprendizaje por refuerzo basado en la idea de aprendizaje mediante ensayo y error. A diferencia del Q-learning clásico, que actualiza la tabla $Q(s, a)$ de manera incremental después de cada interacción, Fitted Q-iteration utiliza todos los datos disponibles en conjunto para aproximar la función de valor acción óptima V^* a partir de un conjunto de transiciones empíricas. Esto se hace aplicando métodos de regresión (por ejemplo, árboles de decisión, redes neuronales u otros modelos) para estimar la relación entre estados, acciones y recompensas esperadas.

5. Política óptima

Una vez obtenida la función de valor de acción óptima V^* , se deriva la política óptima $\pi^* : \mathcal{S} \rightarrow \mathcal{A}$ que asigna a cada estado s la acción a que maximiza el valor de acción


$$\pi^*(s) := \arg \max_{a \in \mathcal{A}} V^*(s, a),$$

es decir, para cada estado s , la política óptima $\pi^*(s)$ indica la acción que se debe tomar para maximizar el valor de acción estimado.

4. Extra Trees

En la práctica, se utiliza el algoritmo de ExtraTrees (árboles extremadamente aleatorizados), que como propone Ernst et al. (2005), el cual argumenta que ofrece gran flexibilidad para aproximar funciones de valor en espacios continuos o de alta dimensionalidad.

La modelación mediante ExtraTrees compuesto por 300 árboles de decisión, con una profundidad máxima de 14 y un mínimo de 5 muestras por hoja. Cada árbol de decisión particiona el espacio estado-acción en regiones homogéneas, (grupo de (s, a) similares) y proporciona una estimación local de la función de valor. La predicción final corresponde al promedio de las predicciones individuales de todos los árboles de decisión.




$Q_h(s, a) = r(s, a) + \gamma \max_{a'} Q_{h-1}(s', a')$. En cada interacción h , se construye $y_i = r_i + \gamma \max_{a'} Q_{h-1}(s'_i, a')$ y se ajusta un regresor f_{θ_h} para aproximar $Q_h(s, a)$.

6. Simulación operativa

Finalmente, se valida la política óptima π^* mediante simulación en lazo cerrado, es decir, se simula la operación del sistema hidroeléctrico utilizando la política π^* para tomar decisiones de turbinado en cada estado observado durante las trayectorias históricas.

La evaluación de la política se realiza mediante un recorrido determinista sobre la serie histórica completa. El algoritmo opera de la siguiente manera:



8. Agradecimientos

Este trabajo forma parte del proyecto de Ciencia Básica y Frontera SECITHI-2025 titulado: **Teoría y aplicaciones de control óptimo estocástico CBF-2025-I-4436**, etapa I.