

Reconocimiento de caracteres manuscritos usando HMM

Mariana Belén Cruz Rodríguez

Benemérita UNACH - FCFM

3er congreso multidisciplinario FCFM. Benemérita UNACH

LGAC: Matemáticas: Análisis, Optimización, Control y sus Aplicaciones

Asesor: Dr. Yofre Hernán García Gómez


Convención internacional CIU 2026



1. Introducción.

La digitalización de documentos manuscritos presenta diversos desafíos debido a la variabilidad entre escritores, diferencias en tamaño, inclinación y proporción, así como distorsiones y ruido en las imágenes. Por esta razón, reconocer un carácter manuscrito no consiste únicamente en comparar dos imágenes; se necesita una representación que describa la información presente y considere la incertidumbre inherente al proceso.


El objetivo es determinar a cuál de las clases disponibles pertenece una imagen observada ($O \rightarrow \{A, B, C, \dots, Z\}$). En lugar de tomar decisiones deterministas, el enfoque probabilístico evalúa la compatibilidad de la observación con cada posible clase, permitiendo inferir el carácter más probable dado un conjunto de observaciones.



2. Marco Teórico.

PROCESOS ESTOCÁSTICOS:


Un proceso estocástico modela la evolución de un sistema sujeto a incertidumbre a lo largo del tiempo o del espacio. Para nuestro problema, una imagen puede ser recorrida espacialmente y transformada en una secuencia de observaciones $O = (o_1, o_2, \dots, o_T)$.



Múltiples trayectorias posibles debido a la incertidumbre

CADENAS DE MARKOV:

Para modelar la dependencia probabilística, nos basamos en las Cadenas de Markov, donde la idea fundamental es que el futuro depende del **estado actual**, pero no directamente de toda la historia anterior (pérdida de memoria). De este método probabilístico surgen los Modelos Ocultos de Markov (HMM).




Transiciones probabilísticas que dependen únicamente del estado actual

3. Modelo Oculto de Markov.

¿Qué es un HMM?

Un Modelo Oculto de Markov (HMM) es un modelo estadístico en el que el sistema se considera como un proceso de Markov cuyos estados **no son directamente observables**. En el reconocimiento, no vemos la estructura interna de la letra, sino características secuenciales extraídas de su imagen mediante ventanas deslizantes.



4. Inferencia y Aprendizaje.

Para aplicar un HMM a un problema real de reconocimiento se deben resolver tres problemas fundamentales:

- 1. Algoritmo Forward (Evaluación)** → Probabilidad de observación $P(O|\lambda)$
- 2. Algoritmo Viterbi (Decodificación)** → Secuencia oculta óptima $Q^* = \arg \max P(Q, O|\lambda)$
- 3. Alg. Baum-Welch (Aprendizaje)** → Ajuste de parámetros $\lambda^* = (A, B, \pi)$

Un HMM $\lambda = (A, B, \pi)$ se entrena de forma independiente para cada letra ($\lambda_A, \dots, \lambda_Z$). La clasificación de una nueva imagen se realiza evaluando la secuencia de observaciones frente a todos los modelos y seleccionando la clase $\hat{c}$ que maximice la probabilidad $P(O|\lambda_i)$.





Figura 3. Proceso de clasificación HMM.

5. Procesamiento y Topología.

PREPROCESAMIENTO DE IMÁGENES:

Para utilizar un HMM, antes de la extracción de características, la imagen original (p. ej., EMNIST) debe ser procesada.


Objetivo: Reducir la variabilidad irrelevante asociada a la posición y escala, favoreciendo que el modelo capture características de la estructura del carácter y no aspectos accidentales de adquisición.



TOPOLOGÍA DE BAKIS:

Una vez procesada la imagen, ésta se recorre con una ventana deslizante vertical para convertir la información bidimensional en una secuencia matemática observable.

Para modelar esta secuencia, se emplea una topología izquierda-derecha (**Modelo de Bakis**). Esta estructura restringe las transiciones (impidiendo volver a estados anteriores), lo cual es perfectamente coherente con el recorrido espacial continuo que realiza la ventana sobre el carácter.



6. Resultados.

El sistema se evaluó utilizando 26 clases (alfabeto latino). El análisis de la matriz de confusión revela que el desempeño varía en base a la similitud visual; por ejemplo, la letra T obtuvo un 91.00% de precisión. Globalmente, el sistema logró un *accuracy* del 76.12%.

7. Referencias.

- Rabiner, L. R. (1989). *A tutorial on hidden Markov models and selected applications in speech recognition*. Proceedings of the IEEE, 77(2), 257-286.
- Cohen, G., Afshar, S., Tapson, J., & van Schaik, A. (2017). *EMNIST: An extension of MNIST to handwritten letters*. arXiv preprint arXiv:1702.05373.
- Chen, J., Zhang, B., Prasad, R., Cao, H., & Natarajan, P. (2012). *Applying discriminatively optimized feature transform for HMM-based off-line handwriting recognition*. 2012 Int. Conf. on Frontiers in Handwriting Recognition (IEEE).

8. Agradecimientos

Este trabajo forma parte del proyecto de Ciencia Básica y Frontera SECITHI-2025 titulado: **Teoría y aplicaciones de control óptimo estocástico CBF-2025-I-4436, etapa I.**