

Guía de estudio: Martingalas, movimiento browniano e introducción al cálculo de Itô

Yofre H. García

Curso de Ecuaciones Diferenciales Estocásticas — Maestría en Ciencias Matemáticas —
Agosto—Diciembre 2025

Benemérita Universidad Autónoma de Chiapas Maestría en Ciencias Matemáticas

Propósito de la guía. Este material organiza los fundamentos probabilísticos que sostienen el estudio de las ecuaciones diferenciales estocásticas. La secuencia parte de espacios de probabilidad, filtraciones y esperanza condicional; continúa con procesos estocásticos y martingalas; y culmina con la construcción de la integral de Itô. Los ejemplos y fragmentos de código en R se conservan como apoyo computacional para que el estudiante contraste propiedades teóricas con simulaciones.

Nivel y uso. La guía está dirigida a estudiantes de maestría en matemáticas aplicadas. Se espera familiaridad con teoría de la medida, integración de Lebesgue, probabilidad elemental y ecuaciones diferenciales ordinarias. El énfasis está en comprender las hipótesis, justificar cada paso y reconocer qué resultados serán reutilizados posteriormente en existencia, unicidad y aproximación numérica de soluciones de ecuaciones diferenciales estocásticas.

Índice

1 Estructura del curso	3
1.1 Introducción	3
1.2 Fundamentos de probabilidad y procesos estocásticos	3
1.3 Integración estocástica	3
1.4 Ecuaciones Diferenciales Estocásticas tipo Itô	3
1.5 Métodos numéricos para EDE tipo Itô	4
1.6 Ecuaciones Diferenciales Estocásticas con saltos	4
1.7 Métodos numéricos para EDE con saltos	4
1.8 Aplicaciones	4
1.9 Ejercicios y proyectos	4
2 Introducción	5
3 Fundamentos de probabilidad y procesos estocásticos	6
3.1 Espacio de probabilidad	6
3.2 Variables aleatorias	7
3.3 Independencia de variables aleatorias	7
3.3.1 Interpretación	8

3.4	Filtraciones	8
3.5	Observaciones adicionales	8
3.5.1	Interpretación	9
3.5.2	Extensión	10
3.6	Valor esperado condicional y propiedades clave	10
3.6.1	Definición: Valor esperado condicional	10
3.6.2	Ejemplo (discreto)	10
3.6.3	Nota: ¿Qué significa que $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$? : definición, norma y estructura . .	10
3.6.4	Definición informal	11
3.6.5	Definición formal como espacio cociente	11
3.6.6	Norma L^1	11
3.6.7	Métrica inducida	11
3.6.8	Interpretación probabilística	12
3.6.9	Ejemplo contrastante	12
3.6.10	Interpretación	12
3.6.11	Ejemplo	12
3.6.12	Propiedades fundamentales de la esperanza condicional	12
3.6.13	Martingalas: conexión	13
3.7	Procesos estocásticos	13
3.7.1	Definición general	13
3.7.2	Ejemplo 1: Proceso de conteo	14
3.7.3	Ejemplo 2: Proceso de Poisson	14
3.7.4	Ejemplo 3: Movimiento browniano (proceso de Wiener)	14
3.7.5	Comparación	15
3.7.6	Ejemplos de procesos estocásticos que son martingalas:	15
3.8	Ejemplos clásicos de martingalas discretas	15
3.8.1	Ejemplo 1: Juego justo con monedas (suma de variables independientes con esperanza cero)	15
3.8.2	Ejemplo 2: Proporción de caras en lanzamientos independientes	16
3.8.3	Ejemplo 3: Proceso constante	16
3.8.4	Ejemplo 4: Proceso con expectativa decreciente (contraejemplo)	16
3.8.5	Ejemplo 5: Producto de variables independientes con media uno	17
3.8.6	Ejemplo 6: El movimiento browniano es una martingala	17
3.8.7	Paso 1: Adaptación a la filtración	17
3.8.8	Paso 2: Integrabilidad	17
3.8.9	Paso 3: Esperanza condicional igual al valor presente	17
3.9	Ejemplo 7: El proceso de Poisson no es martingala	18
3.9.1	No es martingala: $\{N_t\}$	18
3.10	Ejemplo 8: El proceso de Poisson compensado sí es martingala	18
3.10.1	Paso 1: Adaptación	19
3.10.2	Paso 2: Integrabilidad	19
3.10.3	Paso 3: Condición de martingala	19
3.10.4	Interpretación	19
3.10.5	Observaciones visuales	20
4	Cálculo de Itô	21
4.1	Definición del conjunto de integrandos	21
4.1.1	Espacio $L^2_{\text{ad}}([0, T] \times \Omega)$	21

4.1.2	¿Por qué este conjunto?	21
4.2	Definición final	22
4.3	Comentario	22
4.4	Lema: Definición de la integral de Itô	22
4.4.1	Demostración	23
5	suplementos	26
5.1	Desigualdad del resto de la formula de Taylor - forma integral (demostración teorema 32 - protter)	26
5.2	1. Teorema de Taylor con resto integral	26
5.3	2. Estimación del resto	26
5.4	3. Conclusión	26
5.5	1. Uniforme continuidad $\Rightarrow$ función de módulo	27
5.6	2. Aplicación en la desigualdad	27
5.7	3. El teorema de referencia	27

1 Estructura del curso

1.1 Introducción

- Motivación: ¿Por qué estudiar ecuaciones diferenciales estocásticas?
- Breve historia del cálculo estocástico.
- Aplicaciones en finanzas, física, biología y epidemiología.

1.2 Fundamentos de probabilidad y procesos estocásticos

- Espacios de probabilidad y filtraciones.
- Procesos estocásticos: definiciones, propiedades.
- Movimiento browniano y proceso de Poisson.
- Ejemplos y visualizaciones en R.

1.3 Integración estocástica

- Integral de Itô: definición, propiedades.
- Fórmula de Itô (una y varias dimensiones).
- Comparación con la integral clásica de Riemann.
- Integral con respecto al proceso de Poisson (saltos).
- Compensación del proceso de Poisson.

1.4 Ecuaciones Diferenciales Estocásticas tipo Itô

- Definición general:

$$dX_t = \mu(t, X_t) dt + \sigma(t, X_t) dW_t$$

- Solución explícita vs solución débil.
- Teorema de existencia y unicidad.
- Ejemplos clásicos: movimiento geométrico browniano, ecuación de Langevin.

1.5 Métodos numéricos para EDE tipo Itô

- Esquema de Euler–Maruyama.
- Análisis de convergencia.
- Simulación en R paso a paso.
- Comparación con soluciones analíticas.

1.6 Ecuaciones Diferenciales Estocásticas con saltos

- Procesos con saltos finitos: ecuaciones impulsadas por Poisson.
- EDE de la forma:

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t + \gamma(t, X_{t-}) dN_t$$

- Medida de Poisson y medida compensada.
- Integración con respecto a medidas aleatorias.

1.7 Métodos numéricos para EDE con saltos

- Discretización de integrales con saltos.
- Adaptaciones de Euler para procesos con Poisson.
- Código R con simulaciones de trayectorias.

1.8 Aplicaciones

- Modelos epidemiológicos con ruido y saltos.
- Modelos financieros (ej. Merton, jump-diffusion).
- Biología matemática (ej. potencial de membrana neuronal).

1.9 Ejercicios y proyectos

- Ejercicios guiados por sección.
- Mini-proyectos de modelación y simulación.
- Propuesta de casos de estudio (por ejemplo: SIS estocástico).

2 Introducción

Las Ecuaciones Diferenciales Estocásticas (EDE) constituyen un marco matemático fundamental para modelar sistemas dinámicos que evolucionan en el tiempo bajo la influencia de la incertidumbre. A diferencia de las ecuaciones diferenciales ordinarias (EDO), que describen procesos deterministas, las EDE incorporan términos aleatorios que representan ruido o perturbaciones estocásticas, ya sea continuas como el movimiento browniano, o discontinuas como los saltos del proceso de Poisson. Esta estructura les permite capturar con realismo fenómenos observados en diversas disciplinas, donde la evolución de un sistema está sujeta tanto a fuerzas deterministas como a fluctuaciones impredecibles.

A lo largo de este curso, exploraremos dos tipos principales de EDE: las ecuaciones tipo Itô, que integran el ruido continuo del movimiento browniano, y las ecuaciones con saltos, que incorporan eventos súbitos mediante procesos de Poisson. También abordaremos modelos híbridos que combinan ambos tipos de perturbaciones. A continuación, motivamos su estudio mediante ejemplos representativos de cuatro áreas clave: finanzas, sismología, epidemiología y física.

En el contexto financiero, el movimiento browniano proporciona una representación natural de la variabilidad continua en los precios de los activos, dando lugar al modelo de Black-Scholes. Esta formulación estocástica permite modelar la incertidumbre inherente a los mercados mediante ecuaciones del tipo

$$dS_t = \mu S_t dt + \sigma S_t dW_t,$$

donde μ representa la tasa de crecimiento esperada y σ la volatilidad. No obstante, los precios financieros también experimentan variaciones abruptas debidas a crisis, anuncios o eventos geopolíticos. Para modelar estas discontinuidades, se introducen procesos de Poisson en modelos con saltos del tipo

$$dS_t = \mu S_t dt + \sigma S_t dW_t + S_{t-} dJ_t.$$

Los modelos combinados tipo jump-diffusion permiten capturar de manera más realista la dinámica de activos, las primas de riesgo, y la valoración de derivados en condiciones de mercado extremas.

En sismología, los procesos de Poisson tienen un papel central en la modelación de terremotos. La energía liberada en una zona geológica puede acumularse de manera continua, pero liberarse súbitamente mediante un salto. Las EDE con saltos permiten representar estas liberaciones abruptas, como en el modelo

$$dE_t = -\alpha E_t dt + \beta dN_t,$$

, donde E_t es la energía acumulada y N_t un proceso de Poisson. El modelado de terremotos y réplicas con procesos estocásticos permite estudiar la frecuencia, magnitud y tiempos entre eventos sísmicos, crucial para el análisis del riesgo geológico. Modelos híbridos, que combinan el estrés tectónico continuo y la liberación discontinua de energía, ofrecen un marco más completo y útil en predicción sísmica probabilística.

En epidemiología, los modelos compartimentales deterministas como SIR o SEIRS resultan insuficientes para representar la variabilidad observada en brotes reales. Las EDE tipo Itô permiten incorporar ruido demográfico o ambiental, representando incertidumbres en los contactos, tasas de recuperación o transmisibilidad mediante términos estocásticos como

$$dI_t = (\beta S_t I_t - \gamma I_t) dt + \sigma I_t dW_t.$$

Además, eventos externos como la aparición de nuevas variantes, campañas masivas de vacunación o políticas públicas pueden modelarse mediante saltos estocásticos. Las EDE con Poisson permiten representar estas intervenciones o perturbaciones súbitas. En escenarios modernos, modelos combinados permiten estudiar la coexistencia del ruido continuo natural y de los choques abruptos, siendo herramientas poderosas para la planificación sanitaria y simulación de políticas públicas.

En física, las EDE tipo Itô emergen naturalmente en la descripción de sistemas sometidos a ruido térmico, como el movimiento browniano o la difusión de partículas. La ecuación de Langevin, por ejemplo, modela la evolución de la velocidad de una partícula bajo fricción y agitación térmica como una EDE. Estas ecuaciones también se usan en dinámica molecular, teoría de fluctuaciones, y sistemas cuánticos abiertos. Por otra parte, existen fenómenos físicos que presentan cambios instantáneos, como transiciones de fase abruptas, desintegraciones nucleares, o rupturas estructurales, los cuales pueden modelarse mediante procesos con saltos. Incluso en sistemas neuronales o canales iónicos, los cambios de estado repentinos tienen una naturaleza estocástica discontinua que puede ser representada por términos impulsivos. En muchas situaciones físicas reales, la presencia simultánea de ruido térmico y transiciones discretas requiere el uso de EDE híbridas.

En todos estos contextos —finanzas, sismología, epidemiología y física— las EDE permiten una representación rica y realista de la dinámica de sistemas complejos. Su versatilidad para incorporar tanto la variabilidad continua como los eventos abruptos las convierte en herramientas fundamentales para el modelado, análisis y simulación en múltiples disciplinas científicas y aplicadas. A lo largo del curso se desarrollarán los fundamentos teóricos y computacionales necesarios para formular, analizar y resolver este tipo de ecuaciones, y se presentarán ejemplos numéricos en R que ilustran su implementación práctica.

Los conceptos anteriores motivan una formulación rigurosa de la información y la aleatoriedad. Antes de estudiar martingalas e integración estocástica, conviene fijar el lenguaje probabilístico que permitirá distinguir entre variables observables, información disponible y evolución temporal.

3 Fundamentos de probabilidad y procesos estocásticos

3.1 Espacio de probabilidad

Un **espacio de probabilidad** es un sistema matemático que modela experimentos aleatorios. Se define como una tríada:

$$(\Omega, \mathcal{F}, \mathbb{P})$$

donde:

- Ω es el **espacio muestral**, es decir, el conjunto de todos los posibles resultados de un experimento.
- $\mathcal{F}$ es una σ -**álgebra** de subconjuntos de Ω , cuyos elementos son los **eventos medibles**.
- $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ es una **medida de probabilidad**, que satisface:
 - $\mathbb{P}(\Omega) = 1$
 - $\mathbb{P}$ es σ -**aditiva**, es decir:

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) \quad \text{para } A_n \in \mathcal{F} \text{ disjuntos}$$

Ejemplo: Lanzamiento de un dado justo:

- $\Omega = \{1, 2, 3, 4, 5, 6\}$
- $\mathcal{F} = 2^{\Omega}$ (el conjunto de todas las partes de Ω)
- $\mathbb{P}(\{i\}) = \frac{1}{6}$ para $i = 1, \dots, 6$

3.2 Variables aleatorias

Una **variable aleatoria** es una función medible:

$$X : \Omega \rightarrow \mathbb{R}$$

tal que para todo $B \in \mathcal{B}(\mathbb{R})$ (la σ -álgebra de Borel), se cumple que:

$$X^{-1}(B) \in \mathcal{F}$$

Es decir, una variable aleatoria es una forma de asignar números reales a los resultados de un experimento aleatorio, preservando la estructura medible.

Ejemplo: En el lanzamiento del dado anterior, definamos $X(\omega) = \omega^2$. Entonces X es una variable aleatoria discreta con valores en $\{1, 4, 9, 16, 25, 36\}$.

3.3 Independencia de variables aleatorias

Dos variables aleatorias X y Y definidas en el mismo espacio de probabilidad se dicen **independientes** si para todo par de conjuntos $A, B \in \mathcal{B}(\mathbb{R})$:

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B)$$

Esta definición se extiende naturalmente a familias de variables aleatorias.

Ejemplo: Sea X el número obtenido al lanzar el primer dado y Y el número del segundo dado, en un experimento de lanzar dos dados justos. Entonces X y Y son independientes, ya que el resultado de un dado no afecta al otro.

En cambio, si definimos $Z = X + Y$, entonces X y Z **no son independientes**, pues el valor de Z depende directamente de X .

```
set.seed(123)
```

```
# Simulacion: X ~ N(0,1), Y ~ Exp(1), independientes
```

```
n <- 1000
```

```
X <- rnorm(n, mean = 0, sd = 1)
```

```
Y <- rexp(n, rate = 1)
```

```
# Graficar el par (X, Y)
```

```
library(ggplot2)
df <- data.frame(X = X, Y = Y)

ggplot(df, aes(x = X, y = Y)) +
  geom_point(alpha = 0.4, color = "darkblue") +
  labs(title = "Simulación de variables independientes en  $\mathbb{R}^2$ ",
        subtitle = "X ~ Normal(0,1), Y ~ Exponencial(1)",
        x = "X", y = "Y") +
  theme_minimal(base_size = 14)
```

3.3.1 Interpretación

- Las variables X y Y tienen distribuciones diferentes (normal y exponencial) y fueron generadas **independientemente**.
- En el gráfico, no se observa ninguna estructura ni patrón (no hay dependencia funcional entre X y Y).
- Si deseamos comprobarlo de manera numérica, podemos usar:

```
cor.test(X, Y)
```

3.4 Filtraciones

Una **filtración** es una familia creciente de σ -álgebras:

$$\{\mathcal{F}_t\}_{t \geq 0}$$

tal que $\mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F}$ para todo $0 \leq s \leq t$. Cada $\mathcal{F}_t$ representa la **información disponible hasta el tiempo t** .

En el contexto de procesos estocásticos, una filtración es esencial para formalizar el concepto de que el proceso “no puede ver el futuro”, es decir, debe ser **adaptado** a la filtración.

Ejemplo: Sea $(B_t)_{t \geq 0}$ un movimiento browniano definido sobre $(\Omega, \mathcal{F}, \mathbb{P})$. La filtración natural asociada es:

$$\mathcal{F}_t = \sigma(B_s : 0 \leq s \leq t)$$

es decir, la menor σ -álgebra que hace medible a todas las variables aleatorias B_s para $s \leq t$. Esta filtración contiene toda la información acumulada del proceso hasta el instante t .

3.5 Observaciones adicionales

- En el modelado estocástico es habitual trabajar con espacios de probabilidad enriquecidos con filtraciones, denotados:

$$(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, \mathbb{P})$$

- Esta estructura es fundamental para definir integración estocástica, ecuaciones diferenciales estocásticas, martingalas, tiempos de parada, y otras nociones clave.

- Un proceso estocástico $X = \{X_t\}_{t \geq 0}$ se dice **adaptado** a la filtración $\{\mathcal{F}_t\}$ si X_t es $\mathcal{F}_t$ -medible para cada $t \geq 0$, es decir, su valor en el tiempo t es completamente determinado por la información disponible hasta ese instante.

```
# Simulacion de un proceso de conteo finito
set.seed(123)
n_eventos <- 5
tiempos_evento <- sort(runif(n_eventos, min = 0, max = 10)) # Tiempos aleatorios

# Funcion de conteo: N(t) = numero de eventos ocurridos hasta t
tiempo_sim <- seq(0, 10, length.out = 500)
N_t <- sapply(tiempo_sim, function(t) sum(tiempos_evento <= t))

# Visualizacion del proceso de conteo
library(ggplot2)

# Datos para graficar el proceso de conteo
df <- data.frame(
  tiempo = tiempo_sim,
  N = N_t
)

# Datos de los eventos para ilustrar filtraciones
eventos <- data.frame(
  t_evento = tiempos_evento,
  id = paste0("E", 1:n_eventos)
)

# Visualizacion
ggplot(df, aes(x = tiempo, y = N)) +
  geom_step(color = "steelblue", size = 1) +
  geom_vline(data = eventos, aes(xintercept = t_evento),
             linetype = "dotted", color = "red") +
  geom_text(data = eventos, aes(x = t_evento, y = 0.3, label = id),
            angle = 90, vjust = -0.5, hjust = 0.5, size = 3) +
  labs(title = "Proceso de conteo finito y filtraciones",
       subtitle = "Cada salto representa un nuevo evento observado",
       x = "Tiempo t", y = expression(N[t])) +
  theme_minimal(base_size = 14)
```

3.5.1 Interpretación

- La curva escalonada muestra el número de eventos N_t que han ocurrido hasta cada tiempo t .
- Las líneas verticales rojas indican los momentos exactos de los eventos $t_1 < t_2 < \dots < t_n$.
- La **filtración** $\mathcal{F}_t$ contiene, para cada t , la información sobre **qué eventos ya ocurrieron** y cuántos han sido observados hasta ese instante.
- Conforme avanza el tiempo, la filtración crece y se vuelve más informativa. Al inicio $\mathcal{F}_0$ es trivial (ningún evento observado), y al final $\mathcal{F}_{10}$ contiene todo lo que ocurrió en los 10 segundos simulados.

3.5.2 Extensión

Este código y visualización son ideales para introducir de manera intuitiva el concepto de filtración antes de pasar al proceso de Poisson, donde los saltos ocurren aleatoriamente en tiempo continuo pero con distribución exponencial entre eventos.

La noción de filtración permite formalizar la información disponible en cada instante. El siguiente paso consiste en introducir la esperanza condicional, herramienta que conecta dicha información con la predicción probabilística y que será esencial para formular la propiedad de martingala.

3.6 Valor esperado condicional y propiedades clave

3.6.1 Definición: Valor esperado condicional

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, y $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ una variable aleatoria integrable. Si $\mathcal{G} \subseteq \mathcal{F}$ es una sub- σ -álgebra, el **valor esperado condicional de X dado $\mathcal{G}$** , denotado $\mathbb{E}[X | \mathcal{G}]$, es la variable aleatoria Z tal que:

1. Z es $\mathcal{G}$ -medible,
2. Para todo $A \in \mathcal{G}$,

$$\int_A Z d\mathbb{P} = \int_A X d\mathbb{P}$$

Es decir, $\mathbb{E}[X | \mathcal{G}]$ es la mejor “aproximación” de X usando solo la información contenida en $\mathcal{G}$.

3.6.2 Ejemplo (discreto)

Sea $\Omega = \{\omega_1, \omega_2, \omega_3, \omega_4\}$, con probabilidad uniforme $\mathbb{P}(\omega_i) = \frac{1}{4}$. Sea:

$$X(\omega) = \begin{cases} 1 & \text{si } \omega = \omega_1, \omega_2 \\ 2 & \text{si } \omega = \omega_3, \omega_4 \end{cases}$$

y la σ -álgebra $\mathcal{G} = \sigma(\{\omega_1, \omega_2\}, \{\omega_3, \omega_4\})$. Entonces,

$$\mathbb{E}[X | \mathcal{G}](\omega) = \begin{cases} 1 & \text{si } \omega = \omega_1, \omega_2 \\ 2 & \text{si } \omega = \omega_3, \omega_4 \end{cases}$$

Aquí, $\mathbb{E}[X | \mathcal{G}]$ toma el valor esperado de X en cada clase de $\mathcal{G}$, es decir, condicional a la información agrupada.

Para que la esperanza condicional esté bien definida es necesario precisar el espacio de variables aleatorias integrables. Conviene, por tanto, detenerse brevemente en la estructura de L^1 , tanto desde el punto de vista analítico como probabilístico.

3.6.3 Nota: ¿Qué significa que $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$?: definición, norma y estructura

En teoría de la probabilidad y análisis funcional, el espacio L^1 juega un papel central como el dominio natural de las variables aleatorias **integrables**, es decir, aquellas cuya esperanza absoluta es finita.

Este espacio es esencial para definir **esperanza condicional**, **martingalas**, y para formular de manera rigurosa diversos resultados en integración estocástica.

3.6.4 Definición informal

Una variable aleatoria $X : \Omega \rightarrow \mathbb{R}$ pertenece al espacio $L^1(\Omega, \mathcal{F}, \mathbb{P})$ si es medible y su **valor absoluto tiene esperanza finita**:

$$X \in L^1(\Omega, \mathcal{F}, \mathbb{P}) \iff \mathbb{E}[|X|] = \int_{\Omega} |X(\omega)| d\mathbb{P}(\omega) < \infty$$

Esta condición garantiza que $\mathbb{E}[X]$ está bien definido y es finito.

3.6.5 Definición formal como espacio cociente

Sea $\mathcal{M}$ el conjunto de funciones reales medibles $X : \Omega \rightarrow \mathbb{R}$ tales que $\int_{\Omega} |X| d\mathbb{P} < \infty$. Definimos una relación de equivalencia sobre $\mathcal{M}$:

$$X \sim Y \text{ si y solo si } \mathbb{P}(\{\omega \in \Omega : X(\omega) \neq Y(\omega)\}) = 0$$

Es decir, **dos funciones son equivalentes si son iguales casi seguramente**.

Entonces, el espacio $L^1(\Omega, \mathcal{F}, \mathbb{P})$ se define como el **espacio cociente**:

$$L^1(\Omega, \mathcal{F}, \mathbb{P}) := \mathcal{M} / \sim$$

Sus elementos son clases de equivalencia de funciones medibles integrables, donde dos funciones representan el **mismo elemento de L^1** si difieren solo en un conjunto de medida nula. Esta formalización evita ambigüedades en el tratamiento de funciones definidas “casi en todas partes”.

3.6.6 Norma L^1

La función:

$$\|X\|_1 := \int_{\Omega} |X(\omega)| d\mathbb{P}(\omega)$$

define una **norma bien definida** sobre el espacio de clases L^1 , ya que:

- Si $X \sim Y$, entonces $\|X\|_1 = \|Y\|_1$
- $\|X\|_1 = 0$ si y solo si $X = 0$ casi seguramente

Esta norma mide la “magnitud promedio” de la variable aleatoria en valor absoluto.

3.6.7 Métrica inducida

La **métrica asociada** al espacio L^1 es:

$$d_1(X, Y) := \|X - Y\|_1 = \mathbb{E}[|X - Y|]$$

Esta métrica convierte a L^1 en un **espacio métrico completo**, es decir, un **espacio de Banach**. Esto significa que toda sucesión de Cauchy en L^1 converge a un elemento del mismo espacio.

3.6.8 Interpretación probabilística

- En el contexto de probabilidad, L^1 contiene aquellas variables aleatorias para las cuales **esperanza y esperanza condicional son finitas**.
- La condición $X \in L^1$ es mínima para que la esperanza condicional $\mathbb{E}[X \mid \mathcal{G}]$ esté bien definida.
- Además, muchas propiedades fundamentales, como la **ley de la iteración** o la **definición de martingalas**, solo tienen sentido si $X \in L^1$.

3.6.9 Ejemplo contrastante

- Si $X \sim \text{Cauchy}(0, 1)$, entonces $X \notin L^1$, porque $\mathbb{E}[|X|] = \infty$.
- Si $X \sim \mathcal{N}(0, 1)$, entonces $\mathbb{E}[|X|] = \sqrt{2/\pi} < \infty$, y por lo tanto $X \in L^1$.

Esto muestra que no toda variable aleatoria con densidad es integrable: la cola de la distribución es crítica.

3.6.10 Interpretación

- El hecho de que $X \in L^1$ garantiza que su **valor esperado es bien definido y finito**, lo cual es una condición **mínima** para trabajar con **esperanzas condicionales, martingalas, o procesos integrables**.
- Si $X \notin L^1$, entonces $\mathbb{E}[X]$ no existe como número real finito, y no podemos aplicar la teoría de esperanza condicional ni definir estructuras como $\mathbb{E}[X \mid \mathcal{F}_t]$.

3.6.11 Ejemplo

Sea $X \sim \text{Cauchy}(0, 1)$, una variable aleatoria de distribución de Cauchy estándar. Entonces:

- X es **medible**, pero
- $\mathbb{E}[|X|] = \infty$, por lo tanto, $X \notin L^1$.

Esto significa que no podemos trabajar con $\mathbb{E}[X]$, ni mucho menos con $\mathbb{E}[X \mid \mathcal{F}]$.

En cambio, si $X \sim \text{Normal}(0, 1)$, entonces:

- $\mathbb{E}[|X|] < \infty$
- $X \in L^1$, $\mathbb{E}[X] = 0$

?Deseas que extienda esto a los espacios L^2 y L^∞ , que también son importantes en procesos estocásticos y teoría de martingalas?

3.6.12 Propiedades fundamentales de la esperanza condicional

Estas propiedades son esenciales para la teoría de martingalas y procesos adaptados:

3.6.12.1 1. Linealidad Si $X, Y \in L^1$ y $a, b \in \mathbb{R}$, entonces:

$$\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}]$$

3.6.12.2 2. Reducción cuando X es $\mathcal{G}$ -medible Si X es $\mathcal{G}$ -medible, entonces:

$$\mathbb{E}[X \mid \mathcal{G}] = X \quad \text{casi seguramente}$$

3.6.12.3 3. Lema de la torre (ley de la iteración) Si $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$, entonces:

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}] = \mathbb{E}[X \mid \mathcal{H}]$$

3.6.12.4 4. Extracción de constantes Si Z es $\mathcal{G}$ -medible y acotada, entonces:

$$\mathbb{E}[ZX \mid \mathcal{G}] = Z \mathbb{E}[X \mid \mathcal{G}]$$

3.6.12.5 5. Conservación de la esperanza

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] = \mathbb{E}[X]$$

Estas propiedades permiten manipular valores esperados condicionales con seguridad algebraica, lo cual es crucial para demostrar si un proceso es una martingala.

3.6.13 Martingalas: conexión

Sea $\{X_t\}_{t \geq 0}$ un proceso estocástico adaptado a una filtración $\{\mathcal{F}_t\}$. Se dice que X_t es una **martingala** si:

1. $X_t \in L^1$ para todo t
2. $\mathbb{E}[X_t \mid \mathcal{F}_s] = X_s \quad \forall s < t$

Esta definición **usa directamente** el valor esperado condicional respecto a una filtración creciente.

Una vez establecidos los conceptos de información, integrabilidad y esperanza condicional, podemos pasar de variables aleatorias aisladas a familias indexadas por el tiempo. Esta transición conduce naturalmente a los procesos estocásticos y, posteriormente, a las martingalas.

3.7 Procesos estocásticos

3.7.1 Definición general

Un **proceso estocástico** es una colección de variables aleatorias indexadas por el tiempo (o algún otro parámetro), que describe la evolución aleatoria de un sistema dinámico. Formalmente:

$$\{X_t\}_{t \in T} \quad \text{es un proceso estocástico si} \quad X_t : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (E, \mathcal{E}) \quad \text{para cada } t \in T$$

donde:

- $T \subseteq \mathbb{R}_+$ es el conjunto de tiempos (discreto o continuo).
- E es el **espacio de estados** (por ejemplo, $\mathbb{R}$, $\mathbb{Z}$, $\mathbb{R}^d$, etc.).
- Cada X_t es una variable aleatoria que representa el estado del sistema en el instante t .

Se dice que el proceso es **adaptado** a una filtración $\{\mathcal{F}_t\}$ si X_t es $\mathcal{F}_t$ -medible para cada t . Este es un requisito fundamental para estudiar integrales estocásticas y martingalas.

3.7.2 Ejemplo 1: Proceso de conteo

Un **proceso de conteo** es un proceso estocástico $\{N_t\}_{t \geq 0}$ que toma valores en $\mathbb{N}_0$ (enteros no negativos) y representa el número acumulado de ciertos eventos ocurridos hasta el tiempo t . Cumple:

1. $N_0 = 0$
2. N_t tiene trayectorias no decrecientes
3. $N_t \in \mathbb{N}_0$ para todo t

Este tipo de procesos es muy utilizado para modelar llegadas en colas, llamadas en telecomunicaciones, fallos en sistemas, etc.

Ejemplo sencillo: Un proceso que cuenta el número de veces que una máquina falla hasta el tiempo t , donde las fallas se producen aleatoriamente en el tiempo.

3.7.3 Ejemplo 2: Proceso de Poisson

El **proceso de Poisson** es un caso particular de proceso de conteo con propiedades adicionales de independencia e incrementos estacionarios. Formalmente, $\{N_t\}_{t \geq 0}$ es un **proceso de Poisson homogéneo** de intensidad $\lambda > 0$ si:

1. $N_0 = 0$
2. Tiene incrementos independientes: para todo $0 \leq t_1 < t_2 < \dots < t_n$, los incrementos $N_{t_2} - N_{t_1}, \dots, N_{t_n} - N_{t_{n-1}}$ son independientes.
3. Tiene incrementos estacionarios: $N_{t+s} - N_s \sim \text{Poisson}(\lambda t)$
4. Tiene trayectorias en saltos de tamaño 1 (cambios discretos): $\mathbb{P}(N_{t+h} - N_t = 1) = \lambda h + o(h)$
 $\mathbb{P}(N_{t+h} - N_t \geq 2) = o(h)$

Entonces, $N_t \sim \text{Poisson}(\lambda t)$ para cada $t \geq 0$, y los tiempos entre saltos son variables exponenciales independientes con parámetro λ .

Aplicaciones: Modelado de llamadas telefónicas, llegadas de clientes, eventos sísmicos, aparición de mutaciones, entre otros.

3.7.4 Ejemplo 3: Movimiento browniano (proceso de Wiener)

El **movimiento browniano** o **proceso de Wiener** $\{B_t\}_{t \geq 0}$ es un proceso estocástico continuo que modela la evolución de una partícula sometida a ruido térmico o incertidumbre aleatoria acumulada. Es un proceso clave en el cálculo estocástico y se caracteriza por:

1. $B_0 = 0$ casi seguramente
2. Incrementos independientes: para $0 \leq s < t$, el incremento $B_t - B_s$ es independiente de $\mathcal{F}_s$
3. Incrementos gaussianos: $B_t - B_s \sim \mathcal{N}(0, t - s)$
4. Trayectorias continuas: $t \mapsto B_t(\omega)$ es continua para casi toda $\omega \in \Omega$

Se puede construir formalmente como límite de procesos de caminatas aleatorias. El browniano es una **martingala**, un proceso **gaussiano**, **Markoviano** y tiene varianza lineal.

Aplicaciones:

- Finanzas: modelo de precios de activos (modelo de Black-Scholes)
- Física: movimiento browniano de partículas suspendidas
- Biología: dispersión de genes, dinámica estocástica
- Ingeniería: ruido blanco acumulado

3.7.5 Comparación

Proceso	Estado	Trayectoria	Incrementos	Ejemplo típico
Proceso de conteo	$\mathbb{N}_0$	Escalonada	Monótonos	Número de fallas
Proceso de Poisson	$\mathbb{N}_0$	Escalonada	Independientes y estacionarios	Llegadas aleatorias
Movimiento browniano	$\mathbb{R}$	Continua	Independientes, normales	Posición de partícula

3.7.6 Ejemplos de procesos estocásticos que son martingalas:

Es necesario introducir ejemplos **más simples y discretos** de **martingalas** antes de entrar al caso continuo del **movimiento browniano**. cada uno con su justificación clara de por qué cumple la propiedad de martingala:

3.8 Ejemplos clásicos de martingalas discretas

Antes de abordar martingalas continuas como el movimiento browniano, es útil estudiar procesos discretos que satisfacen la propiedad fundamental de las martingalas: **la esperanza condicional de su valor futuro, dado el pasado, es igual al valor actual**.

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = X_n$$

Aquí algunos ejemplos ilustrativos:

3.8.1 Ejemplo 1: Juego justo con monedas (suma de variables independientes con esperanza cero)

Sea $\{X_n\}_{n \geq 1}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) tales que:

$$\mathbb{P}(X_n = 1) = \mathbb{P}(X_n = -1) = \frac{1}{2}$$

y definimos la suma acumulada:

$$S_n = \sum_{k=1}^n X_k$$

Entonces, el proceso $\{S_n\}_{n \geq 0}$, con $S_0 = 0$, es una **martingala** con respecto a la filtración natural:

$$\mathcal{F}_n = \sigma(X_1, X_2, \dots, X_n)$$

Justificación:

- $S_n \in L^1$ (es finito para cada n)
- S_n es $\mathcal{F}_n$ -adaptado

•

$$\mathbb{E}[S_{n+1} \mid \mathcal{F}_n] = \mathbb{E}[S_n + X_{n+1} \mid \mathcal{F}_n] = S_n + \mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = S_n + 0 = S_n$$

3.8.2 Ejemplo 2: Proporción de caras en lanzamientos independientes

Sean $X_1, X_2, \dots$ i.i.d. con $\mathbb{P}(X_i = 1) = p$, $\mathbb{P}(X_i = 0) = 1 - p$. Definimos:

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Este proceso **no es una martingala**, pero el numerador sí lo es:

$$S_n = \sum_{i=1}^n (X_i - p)$$

es una **martingala centrada**, porque:

$$\mathbb{E}[X_i - p] = 0 \quad \Rightarrow \quad \mathbb{E}[S_{n+1} \mid \mathcal{F}_n] = S_n$$

3.8.3 Ejemplo 3: Proceso constante

Sea $X_n = c$ una constante para todo n . Entonces $\{X_n\}$ es trivialmente una martingala.

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = c = X_n$$

Esto muestra que las constantes son martingalas degeneradas.

3.8.4 Ejemplo 4: Proceso con expectativa decreciente (contraejemplo)

Sea $X_n = \frac{1}{n}$. Entonces:

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = \frac{1}{n+1} \neq \frac{1}{n}$$

Este proceso **no** es martingala, aunque es determinista. Tampoco es submartingala ni supermartingala, ya que:

$$\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] < X_n$$

3.8.5 Ejemplo 5: Producto de variables independientes con media uno

Sea $\{Y_n\}$ una sucesión i.i.d. positivas con $\mathbb{E}[Y_n] = 1$, por ejemplo $Y_n \sim \text{Bernoulli}(p)$ con $p = 1$. Define:

$$M_n = \prod_{k=1}^n Y_k$$

Entonces $\mathbb{E}[M_{n+1} \mid \mathcal{F}_n] = M_n \mathbb{E}[Y_{n+1}] = M_n$, y el proceso $\{M_n\}$ es martingala.

El movimiento browniano constituye el ejemplo continuo fundamental para el curso. Verificar directamente que es una martingala permite reunir en un solo argumento las nociones de adaptación, integrabilidad, incrementos independientes y esperanza condicional.

3.8.6 Ejemplo 6: El movimiento browniano es una martingala

Sea $\{B_t\}_{t \geq 0}$ un **movimiento browniano estándar** definido sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, \mathbb{P})$, con filtración natural $\mathcal{F}_t = \sigma(B_s : s \leq t)$. Queremos demostrar que $\{B_t\}$ es una **martingala**, es decir:

$$\mathbb{E}[B_t \mid \mathcal{F}_s] = B_s \quad \text{para todo } 0 \leq s \leq t$$

La verificación de la propiedad de martingala se organiza en las tres condiciones de la definición: adaptación, integrabilidad y estabilidad de la esperanza condicional.

3.8.7 Paso 1: Adaptación a la filtración

Condición: B_t debe ser $\mathcal{F}_t$ -medible.

Justificación: Por construcción, B_t está contenido en la filtración $\mathcal{F}_t = \sigma(B_s : s \leq t)$, ya que $B_t \in \mathcal{F}_t$. **Cumple.**

3.8.8 Paso 2: Integrabilidad

Condición: $\mathbb{E}[|B_t|] < \infty$ para todo $t \geq 0$

Justificación: Dado que $B_t \sim \mathcal{N}(0, t)$, entonces:

$$\mathbb{E}[|B_t|] = \sqrt{\frac{2t}{\pi}} < \infty$$

El movimiento browniano tiene todos los momentos finitos. **Cumple.**

3.8.9 Paso 3: Esperanza condicional igual al valor presente

Condición: $\mathbb{E}[B_t \mid \mathcal{F}_s] = B_s$

Justificación:

El movimiento browniano tiene incrementos independientes y estacionarios. Entonces:

$$B_t = B_s + (B_t - B_s)$$

con $B_t - B_s$ independiente de $\mathcal{F}_s$ y $B_t - B_s \sim \mathcal{N}(0, t - s)$.

Como $B_t - B_s$ es independiente de $\mathcal{F}_s$, se tiene:

$$\mathbb{E}[B_t \mid \mathcal{F}_s] = \mathbb{E}[B_s + (B_t - B_s) \mid \mathcal{F}_s] = \mathbb{E}[B_s \mid \mathcal{F}_s] + \mathbb{E}[B_t - B_s \mid \mathcal{F}_s] = B_s + 0 = B_s$$

Cumple.

El proceso de Poisson ofrece un contraste instructivo con el movimiento browniano. Los siguientes ejemplos permiten identificar el papel del término de compensación en la construcción de martingalas:

- El **incremento del proceso de Poisson** no es martingala.
- Pero el **proceso de Poisson compensado** sí lo es.

La comparación entre el proceso de Poisson y su versión compensada permite observar cómo la eliminación de la deriva media transforma un proceso de conteo creciente en una martingala.

3.9 Ejemplo 7: El proceso de Poisson no es martingala

Sea $\{N_t\}_{t \geq 0}$ un **proceso de Poisson homogéneo** con intensidad $\lambda > 0$, definido sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, y sea $\mathcal{F}_t = \sigma(N_s : s \leq t)$ su filtración natural.

El objetivo es determinar si el proceso de conteo posee la propiedad de martingala y, en caso contrario, identificar la corrección que elimina su deriva media.

3.9.1 No es martingala: $\{N_t\}$

Paso 1: Adaptación: Sí, N_t es $\mathcal{F}_t$ -medible.

Paso 2: Integrabilidad: Sí, $\mathbb{E}[N_t] = \lambda t < \infty$

Paso 3: Esperanza condicional: ¿Se cumple que $\mathbb{E}[N_t \mid \mathcal{F}_s] = N_s$? Sabemos que:

$$N_t = N_s + (N_t - N_s), \quad \text{con } N_t - N_s \sim \text{Poisson}(\lambda(t - s))$$

y además $N_t - N_s$ es independiente de $\mathcal{F}_s$, entonces:

$$\mathbb{E}[N_t \mid \mathcal{F}_s] = N_s + \lambda(t - s) \neq N_s$$

Conclusión: $\{N_t\}$ **no es una martingala**, porque **crece en promedio** con el tiempo. Es un submartingala.

3.10 Ejemplo 8: El proceso de Poisson compensado sí es martingala

Definimos el **proceso de Poisson compensado** como:

$$M_t := N_t - \lambda t$$

Este proceso representa el número de eventos observados menos su valor esperado. Queremos demostrar que $\{M_t\}_{t \geq 0}$ es una martingala con respecto a la filtración natural $\{\mathcal{F}_t\}$.

3.10.1 Paso 1: Adaptación

$M_t = N_t - \lambda t$ es $\mathcal{F}_t$ -medible, ya que N_t lo es y $t \mapsto \lambda t$ es determinista.

3.10.2 Paso 2: Integrabilidad

$$\mathbb{E}[|M_t|] \leq \mathbb{E}[|N_t|] + \lambda t = 2\lambda t < \infty$$

porque $\mathbb{E}[N_t] = \lambda t$. Por tanto, $M_t \in L^1$

3.10.3 Paso 3: Condición de martingala

Queremos probar que:

$$\mathbb{E}[M_t | \mathcal{F}_s] = M_s \quad \text{para todo } 0 \leq s \leq t$$

Desarrollamos:

$$\begin{aligned} \mathbb{E}[M_t | \mathcal{F}_s] &= \mathbb{E}[N_t - \lambda t | \mathcal{F}_s] = \mathbb{E}[N_s + (N_t - N_s) | \mathcal{F}_s] - \lambda t \\ &= N_s + \mathbb{E}[N_t - N_s] - \lambda t = N_s + \lambda(t - s) - \lambda t = N_s - \lambda s = M_s \end{aligned}$$

Conclusión: El proceso $\{M_t = N_t - \lambda t\}$ **sí es una martingala**, conocida como el **proceso de Poisson compensado**.

3.10.4 Interpretación

- N_t **no es martingala** porque su **valor esperado crece con t** .
- $M_t = N_t - \lambda t$ **centra el proceso** y elimina su crecimiento esperado, haciendo que su valor futuro condicional sea igual al valor presente.

```
set.seed(123)
```

```
# Parametros
lambda <- 2          # Intensidad del proceso de Poisson
T <- 10              # Tiempo final
n <- 500             # Puntos en el eje temporal
t_vals <- seq(0, T, length.out = n)
```

```
# Simular proceso de Poisson con funcion base R
eventos <- cumsum(rexp(100, rate = lambda))
eventos <- eventos[eventos <= T]
```

```
# Calcular N(t): numero de eventos hasta t
N_t <- sapply(t_vals, function(t) sum(eventos <= t))
```

```

# Calcular  $M(t)$ : proceso compensado
M_t <- N_t - lambda * t_vals

# DataFrame para graficar
df <- data.frame(
  tiempo = t_vals,
  Nt = N_t,
  Mt = M_t
)

# Visualizacion con ggplot2
library(ggplot2)

ggplot(df, aes(x = tiempo)) +
  geom_step(aes(y = Nt), color = "firebrick", size = 1,
            alpha = 0.8, direction = "hv") +
  geom_line(aes(y = Mt), color = "steelblue", size = 1, linetype = "dashed") +
  labs(title = "Proceso de Poisson vs Proceso Compensado",
        subtitle = expression(N[t]~"y"~M[t] == N[t] - lambda * t),
        x = "Tiempo", y = "Valor del proceso") +
  scale_y_continuous(breaks = seq(0, max(df$Nt), by = 1)) +
  theme_minimal(base_size = 14) +
  theme(legend.position = "none")

```

3.10.5 Observaciones visuales

- La curva roja escalonada representa el proceso de Poisson N_t , que crece en saltos.
- La curva azul punteada representa el proceso compensado M_t , que oscila alrededor de 0.
- Esto ilustra que N_t no es martingala, mientras que M_t sí lo es.

```
library(ggplot2)
```

```
# Parametros
```

```
mu <- 0      # media de la normal
```

```
sigma <- 1   # desviacion estandar
```

```
# Dominio
```

```
x <- seq(-3, 3, length.out = 500) # para normal
```

```
x_pos <- seq(0.01, 20, length.out = 500) # para log-normal
```

```
# Densidades
```

```
dens_normal <- dnorm(x, mean = mu, sd = sigma)
```

```
dens_lognorm <- dlnorm(x_pos, meanlog = mu, sdlog = sigma)
```

```
# Dataframe
```

```
df1 <- data.frame(x = x, dens = dens_normal, tipo = "Normal")
```

```
df2 <- data.frame(x = x_pos, dens = dens_lognorm, tipo = "Log-normal")
```

```
# Combinar
df_all <- rbind(df1, df2)

# Graficar
ggplot(df_all, aes(x = x, y = dens, color = tipo)) +
  geom_line(size = 1.2) +
  labs(title = "Comparacion entre densidad Normal y Log-normal",
        x = "x", y = "Densidad f(x)", color = "Distribucion") +
  scale_color_manual(values = c("steelblue", "darkorange")) +
  theme_minimal(base_size = 14)
```

4 Cálculo de Itô

La transición desde martingalas hacia el cálculo de Itô exige precisar primero qué procesos pueden utilizarse como integrandos. Esta cuestión es esencial: la clase de integrandos determina el espacio funcional en el que la integral estocástica se construye por aproximación y continuidad.

4.1 Definición del conjunto de integrandos

Sea $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, \mathbb{P})$ un espacio de probabilidad filtrado, y sea W_t un **movimiento browniano estándar** adaptado a $\{\mathcal{F}_t\}$.

4.1.1 Espacio $L^2_{\text{ad}}([0, T] \times \Omega)$

Definimos el conjunto:

$$\mathcal{H}^2[0, T] = \left\{ X : [0, T] \times \Omega \rightarrow \mathbb{R} \left| \begin{array}{l} X \text{ es progresivamente medible,} \\ \mathbb{E} \left[\int_0^T X_t^2 dt \right] < \infty \end{array} \right. \right\}$$

4.1.1.1 Condiciones clave:

1. **Adaptación / progresiva medibilidad:** X_t debe ser $\mathcal{F}_t$ -adaptado (o progresivamente medible), lo que significa que la información que usa hasta tiempo t no depende del futuro.
2. **Integrabilidad cuadrática:**

$$\mathbb{E} \left[\int_0^T X_t^2 dt \right] < \infty$$

Esto asegura que la integral tenga sentido en $L^2(\Omega)$.

4.1.2 ¿Por qué este conjunto?

- Para funciones **simples** adaptadas:

$$X_t(\omega) = \sum_{j=0}^{n-1} X_{t_j}(\omega) \mathbf{1}_{(t_j, t_{j+1}]}(t)$$

con X_{t_j} $\mathcal{F}_{t_j}$ -medible y $\mathbb{E}[X_{t_j}^2] < \infty$, la integral se define como:

$$\int_0^T X_t dW_t := \sum_{j=0}^{n-1} X_{t_j} (W_{t_{j+1}} - W_{t_j})$$

- Luego se **extiende por completitud** en la norma:

$$\|X\|_{\mathcal{H}^2} := \left(\mathbb{E} \left[\int_0^T X_t^2 dt \right] \right)^{1/2}$$

a todos los procesos en $\mathcal{H}^2[0, T]$.

4.2 Definición final

Definición: La **integral de Itô** $\int_0^T X_t dW_t$ está bien definida para todo $X \in \mathcal{H}^2[0, T]$, el espacio de procesos $\mathcal{F}_t$ -adaptados, progresivamente medibles, y cuadráticamente integrables sobre $[0, T]$.

4.3 Comentario

En el caso del **proceso de Poisson** o integrales con saltos, el conjunto de integrandos cambia: hay que imponer integrabilidad en L^1 respecto a la medida de compensación (y L^2 para la parte martingala).

La definición anterior puede justificarse mediante una construcción por aproximación. El siguiente resultado resume el paso desde integrandos simples adaptados hasta procesos cuadráticamente integrables.

4.4 Lema: Definición de la integral de Itô

Lema: Sea $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, \mathbb{P})$ un espacio de probabilidad filtrado que satisface la condición usual, y sea W_t un movimiento browniano estándar adaptado a $\{\mathcal{F}_t\}$.

Definimos:

$$\mathcal{H}^2[0, T] := \left\{ X \left| \begin{array}{l} X \text{ es progresivamente medible,} \\ \mathbb{E} \left[\int_0^T X_t^2 dt \right] < \infty \end{array} \right. \right\}$$

Entonces, la **integral de Itô**

$$I_T(X) := \int_0^T X_t dW_t$$

está bien definida para todo $X \in \mathcal{H}^2[0, T]$ como un elemento de $L^2(\Omega)$, y satisface la **isometría de Itô**:

$$\mathbb{E} \left[\left(\int_0^T X_t dW_t \right)^2 \right] = \mathbb{E} \left[\int_0^T X_t^2 dt \right]$$

4.4.1 Demostración

4.4.1.1 1. Caso base: funciones simples adaptadas Sea X de la forma:

$$X_t(\omega) = \sum_{j=0}^{n-1} \xi_j(\omega) \mathbf{1}_{(t_j, t_{j+1}]}(t),$$

donde $0 = t_0 < t_1 < \dots < t_n = T$ y cada ξ_j es $\mathcal{F}_{t_j}$ -medible y satisface $\mathbb{E}[\xi_j^2] < \infty$.

Definimos:

$$\int_0^T X_t dW_t := \sum_{j=0}^{n-1} \xi_j (W_{t_{j+1}} - W_{t_j}).$$

4.4.1.2 2. Isometría en el caso simple Como ξ_j es $\mathcal{F}_{t_j}$ -medible y $W_{t_{j+1}} - W_{t_j} \sim \mathcal{N}(0, t_{j+1} - t_j)$ es independiente de $\mathcal{F}_{t_j}$, tenemos:

$$\begin{aligned} \mathbb{E} \left[\left(\int_0^T X_t dW_t \right)^2 \right] &= \mathbb{E} \left[\sum_{j=0}^{n-1} \xi_j^2 (t_{j+1} - t_j) \right] \\ &= \mathbb{E} \left[\int_0^T X_t^2 dt \right]. \end{aligned}$$

Esto muestra que la integral está bien definida para funciones simples adaptadas y cumple la isometría.

4.4.1.3 3. Extensión por densidad El espacio de funciones simples adaptadas es **denso** en $\mathcal{H}^2[0, T]$ respecto a la norma:

$$\|X\|_{\mathcal{H}^2} := \left(\mathbb{E} \left[\int_0^T X_t^2 dt \right] \right)^{1/2}.$$

Para $X \in \mathcal{H}^2[0, T]$, tomamos una sucesión (X^n) de funciones simples adaptadas tal que:

$$\|X^n - X\|_{\mathcal{H}^2} \rightarrow 0.$$

Usando la isometría en el caso simple, obtenemos que $\left(\int_0^T X_t^n dW_t \right)$ es una sucesión de Cauchy en $L^2(\Omega)$, y por tanto converge en L^2 a un límite que **definimos** como $\int_0^T X_t dW_t$.

4.4.1.4 4. Unicidad y propiedades La isometría de Itô se preserva en el límite:

$$\mathbb{E} \left[\left(\int_0^T X_t dW_t \right)^2 \right] = \mathbb{E} \left[\int_0^T X_t^2 dt \right],$$

y la definición es única en $L^2(\Omega)$.

Conclusión: La integral de Itô está bien definida para todo proceso adaptado y cuadráticamente integrable $X \in \mathcal{H}^2[0, T]$, y satisface la isometría de Itô.

■

```
set.seed(123)
```

```
library(ggplot2)
```

```
# Parametros
```

```
Tfin <- 1
```

```
Nfine <- 4096
```

```
# malla fina (potencia de 2 para facilitar agrega
```

```
dt <- Tfin/Nfine
```

```
t_fine <- seq(0, Tfin, length.out = Nfine + 1)
```

```
# Simular un Browniano en la malla fina
```

```
dW <- sqrt(dt) * rnorm(Nfine)
```

```
W <- c(0, cumsum(dW)) # W[1]=0 corresponde a t=0
```

```
# Valor "verdadero" de la integral de Ito para  $H_t = W_t$ :
```

```
ito_true <- 0.5*(tail(W,1)^2 - Tfin)
```

```
# Conjuntos de particiones (divisores de Nfine)
```

```
m_set <- 2^(3:8) # 8,16,32,64,128,256
```

```
res_list <- lapply(m_set, function(m){
```

```
  # indices de particion en la malla fina (enteros exactos)
```

```
  step <- Nfine/m
```

```
  idx <- seq(0, Nfine, by = step) # longitud m+1
```

```
  # DeltaW por bloque y valores izquierdos del integrando (W en  $t_{j-1}$ )
```

```
  dW_blk <- W[idx[-1] + 1] - W[idx[-length(idx)] + 1]
```

```
  W_left <- W[idx[-(m+1)] + 1]
```

```
  ito_sum <- sum(W_left * dW_blk) # suma estocastica de Ito (izquierda)
```

```
  data.frame(
```

```
    m = m,
```

```
    mesh = Tfin/m,
```

```
    ito_sum = ito_sum,
```

```
    ito_true = ito_true,
```

```
    abs_error = abs(ito_sum - ito_true)
```

```
  )
```

```
})
```

```
tbl <- do.call(rbind, res_list)
```

```

# ——— Grafico 1: error vs tamaño de malla (log-log) —————
p_err <- ggplot(tbl, aes(x = mesh, y = abs_error)) +
  geom_point() + geom_line() +
  scale_x_log10() + scale_y_log10() +
  labs(title = "Convergencia de sumas de Ito (H_t=W_t)",
        subtitle = expression(paste("Error absoluto vs malla(",
                                     Delta,
                                     "t) en escala log-log")),
        x = expression(Delta*t),
        y = "|Suma(Ito) - Valor verdadero|") +
  theme_minimal(base_size = 13)

# ——— Grafico 2: visualización geométrica del integrando escalonado —————
# Elegimos una partición moderada para visualizar "rectángulos" estocásticos
m_show <- 32
step_show <- Nfine/m_show
idx_show <- seq(0, Nfine, by = step_show)
t_show <- t_fine[idx_show + 1]
W_left <- W[idx_show[-(m_show+1)] + 1]
# proceso escalonado  $H^{\{(n)\}}(t) = W_{\{t_{j-1}\}}$ 
df_step <- data.frame(
  t0 = t_show[-length(t_show)],
  t1 = t_show[-1],
  H = W_left
)
# datos de trayectoria W(t)
df_W <- data.frame(t = t_fine, W = W)

p_geom <- ggplot() +
  geom_line(data = df_W, aes(x = t, y = W), linewidth = 0.9, alpha = 0.9) +
  geom_segment(data = df_step, aes(x = t0, xend = t1, y = H, yend = H),
              linewidth = 1.1, linetype = 1, alpha = 0.9) +
  labs(
    title = expression("Integrando simple adaptado"
                       * H[t] == W[t[j-1]]
                       * "sobre la misma trayectoria"),
    subtitle = paste0("Partición con m=", m_show, "( ",
                      format(Tfin/m_show, digits = 3),
                      " por tramo);",
                      "cada peldano evalúa W en el extremo izquierdo"),
    x = "t",
    y = "valor"
  ) +
  theme_minimal(base_size = 13)

# Mostrar resultados numéricos y gráficos
print(tbl)
p_err

```

5 suplementos

5.1 Desigualdad del resto de la formula de Taylor - forma integral (demostración teorema 32 - protter)

Ese pasaje de Protter se apoya en la versión **con resto integral** del teorema de Taylor y en un argumento de compacidad. Vamos a desglosarlo.

5.2 1. Teorema de Taylor con resto integral

Si $f \in C^2(\mathbb{R})$, para $x, y \in \mathbb{R}$ se tiene la identidad exacta

$$f(y) - f(x) = f'(x)(y - x) + \frac{1}{2}f''(x)(y - x)^2 + R(x, y),$$

con

$$R(x, y) = \int_0^1 (1 - \theta) \left(f''(x + \theta(y - x)) - f''(x) \right) (y - x)^2 d\theta.$$

5.3 2. Estimación del resto

Tomemos valor absoluto:

$$|R(x, y)| \leq |y - x|^2 \int_0^1 (1 - \theta) |f''(x + \theta(y - x)) - f''(x)| d\theta.$$

Sea $u = |y - x|$. Si f'' es continua en un compacto $K \subset \mathbb{R}$ que contiene todos los puntos x, y considerados, entonces f'' es **uniformemente continua** en K .

Esto significa: para todo $\varepsilon > 0$ existe $\delta > 0$ tal que si $|z - x| < \delta$ entonces $|f''(z) - f''(x)| < \varepsilon$.

Por tanto, existe una función $r : \mathbb{R}_+ \rightarrow \mathbb{R}_+$ creciente con $\lim_{u \downarrow 0} r(u) = 0$ tal que

$$|f''(x + \theta(y - x)) - f''(x)| \leq r(|y - x|).$$

5.4 3. Conclusión

Sustituyendo en la cota:

$$|R(x, y)| \leq |y - x|^2 \int_0^1 (1 - \theta) r(|y - x|) d\theta = r(|y - x|) |y - x|^2 \int_0^1 (1 - \theta) d\theta.$$

Y como $\int_0^1 (1 - \theta) d\theta = \frac{1}{2}$, absorbemos la constante en r redefiniéndola si se quiere, obteniendo:

$$\boxed{|R(x, y)| \leq r(|y - x|) (y - x)^2, \quad \lim_{u \rightarrow 0} r(u) = 0.}$$

En síntesis:

- La desigualdad para el resto se prueba **a partir de la fórmula integral del resto de Taylor**.
- El paso clave es la **uniforme continuidad de f''** en compactos, que nos da una función de control $r(u) \rightarrow 0$ cuando $u \rightarrow 0$.
- Esto es justo lo que se usa en la demostración de Itô con saltos: controlar términos de orden $o((y-x)^2)$.

La estimación anterior se apoya en un resultado elemental de análisis real.

Lo que Protter usa aquí es un hecho general de análisis: **toda función continua en un compacto es uniformemente continua**, y de esa uniformidad se construye justamente la función de control r .

5.5 1. Uniforme continuidad $\Rightarrow$ función de módulo

Sea $g = f''$ continua en un compacto K . Entonces:

- Por definición, g es **uniformemente continua**: $\forall \varepsilon > 0, \exists \delta > 0$ tal que si $|z - x| < \delta$ y $x, z \in K$, entonces $|g(z) - g(x)| < \varepsilon$.
- A partir de aquí se define el **módulo de continuidad**:

$$\omega(u) := \sup\{|g(z) - g(x)| : |z - x| \leq u, x, z \in K\}.$$

- Propiedades de ω :
 1. $\omega(u)$ es no decreciente.
 2. $\omega(u) \rightarrow 0$ cuando $u \downarrow 0$ (esto es exactamente la uniforme continuidad).

Así, basta tomar

$$r(u) := \omega(u).$$

5.6 2. Aplicación en la desigualdad

De la definición de ω :

$$|f''(x + \theta(y - x)) - f''(x)| \leq \omega(|y - x|) =: r(|y - x|).$$

Esto es justo lo que aparece en la imagen de Protter: el resto queda acotado por

$$|R(x, y)| \leq r(|y - x|) (y - x)^2, \quad \lim_{u \rightarrow 0} r(u) = 0.$$

5.7 3. El teorema de referencia

El resultado de que “**una función continua en un compacto admite un módulo de continuidad**” es un corolario clásico del **Teorema de Heine–Cantor**:

Heine–Cantor: Si g es continua en un conjunto compacto $K \subset \mathbb{R}^n$, entonces g es uniformemente continua en K .

Y la construcción explícita de $\omega(u)$ se suele llamar el **módulo de continuidad** de g .

Resumiendo:

- Sí, es un teorema conocido: **Heine–Cantor**.
- La función $r(u)$ que pide Protter es exactamente el **módulo de continuidad** de f'' en un compacto.
- Por eso la desigualdad para el resto se garantiza siempre que $f \in C^2$.