

Introducción al Aprendizaje Causal

DAG, intervenciones, confusión, identificación y g-computation

FCFM–UNACH
Licenciatura en Matemáticas Aplicadas
Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. 1. Variable aleatoria y ecuación estructural	3
3. 2. Asociación frente a causalidad	4
4. 3. Modelos Estructurales Causales	4
5. 4. Notación $do(X = x)$	5
5.1. Ejemplo	5
6. 5. DAG: grafo acíclico dirigido	5
7. 6. Variables del sistema de cadena de frío	6
7.1. 6.1 Entorno y operación	6
7.2. 6.2 Producto	6
7.3. 6.3 Resultado principal	6
8. 7. DAG mínimo del sistema	7
9. 8. Factorización de la distribución conjunta	7
10.9. Confusión	7
10.1. 9.1 Ejemplo	7
11.10. Consistencia del DAG y del concepto de confusor	8
12.11. Caminos causales y caminos no causales	8
12.1. 11.1 Camino causal directo	8
12.2. 11.2 Camino mediado	8
12.3. 11.3 Camino de confusión	8
13.12. D-separación	9
13.1. 12.1 Cadena	9
13.2. 12.2 Tenedor	9
13.3. 12.3 Collider	9
14.13. Propiedad de Markov local	9
15.14. Criterio back-door	10

16.15. Back-door en el ejemplo	10
17.16. Front-door	10
17.1. 16.1 Ejemplo conceptual	11
18.17. g-Computation	11
19.18. ATE	11
19.1. 18.1 Ejemplo	11
20.19. Modelo físico de degradación	12
21.20. DAG y representación matricial	12
22.21. Modelos dinámicos	12
23.22. Aprendizaje causal frente a aprendizaje predictivo	13
24.23. Aprendizaje estructural y conocimiento experto	13
25.24. Propensity score y otras estrategias	13
26.25. Preguntas de autoevaluación	14
27.26. Ejercicios propuestos	14
28.27. Actividad integradora	15
29.28. Ideas esenciales para recordar	16
30.29. Bibliografía recomendada	16

1. Propósito de esta guía

El aprendizaje estadístico tradicional se ocupa, en gran medida, de describir asociaciones y construir predictores. El aprendizaje causal persigue una pregunta diferente: estudiar cómo cambiaría un resultado si una variable fuese modificada mediante una intervención.

Esta diferencia puede resumirse mediante las expresiones

$$P(Y \mid X = x)$$

y

$$P(Y \mid do(X = x)).$$

La primera es observacional: describe cómo se distribuye Y entre unidades donde se observa $X = x$. La segunda es intervencional: describe qué ocurriría con Y si forzáramos externamente el valor $X = x$.

En esta guía se utiliza como hilo conductor un sistema de cadena de frío para vacunas, donde interesa estudiar cómo la temperatura de almacenamiento S influye sobre la degradación D .

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Diferenciar asociación estadística de efecto causal.
2. Interpretar una ecuación estructural causal.
3. Construir y leer un DAG.
4. Identificar padres, descendientes, mediadores y confusores.
5. Explicar la notación $do(X = x)$.
6. Reconocer caminos causales y caminos de tipo back-door.
7. Aplicar conceptualmente los criterios back-door y front-door.
8. Formular la g-computation para un efecto causal promedio.
9. Relacionar un DAG con una factorización probabilística.
10. Comprender la conexión entre modelos causales estáticos y dinámicos.

2. 1. Variable aleatoria y ecuación estructural

En probabilidad, una variable aleatoria es una función medible

$$X : \Omega \longrightarrow \mathcal{X},$$

definida sobre un espacio de probabilidad

$$(\Omega, \mathcal{F}, \mathbb{P}).$$

En un **modelo estructural causal** (SCM), la variable no se describe únicamente por su distribución. También se especifica cómo se genera a partir de otras variables:

$$X_i := f_i(\text{Pa}(X_i), U_i), \tag{1}$$

donde

- $\text{Pa}(X_i)$ es el conjunto de padres causales de X_i ;
- U_i representa factores exógenos o perturbaciones no modeladas explícitamente.

En el ejemplo de cadena de frío, la temperatura de almacenamiento puede escribirse esquemáticamente como

$$S = f_S(A, P, M, H, R, T, B, U_S),$$

donde las variables de entrada representan factores ambientales y operativos.

Interpretación

En un modelo predictivo podemos preguntar qué variables ayudan a anticipar S . En un modelo causal preguntamos además cuáles de esas variables participan en el mecanismo que genera S .

3. 2. Asociación frente a causalidad

Decimos que X tiene un efecto causal sobre Y si una intervención sobre X modifica la distribución de Y .

Una manera de expresarlo es

$$P(Y \mid \text{do}(X = x)) \neq P(Y \mid \text{do}(X = x')).$$

La operación $\text{do}(X = x)$ representa una intervención externa que fija X en el valor x . Esto debe distinguirse de

$$P(Y \mid X = x),$$

que sólo condiciona sobre el valor observado de X .

Interpretación

Correlación significa que dos variables cambian conjuntamente. Causalidad significa que al modificar una de ellas mediante intervención, cambia la distribución de la otra.

4. 3. Modelos Estructurales Causales

Un SCM está formado por un conjunto de ecuaciones estructurales

$$X_j := f_j(\text{Pa}(X_j), U_j), \quad j = 1, \dots, n.$$

Estas ecuaciones describen mecanismos locales.

Por ejemplo, para el sistema de cadena de frío pueden distinguirse:

- un mecanismo que genera la temperatura de almacenamiento S ;
- un mecanismo que genera la degradación D ;
- mecanismos para variables ambientales y operativas.

La ventaja de esta formulación es que una intervención puede representarse modificando una de las ecuaciones.

5. 4. Notación $do(X = x)$

Una intervención

$$do(X = x)$$

reemplaza la ecuación estructural de X por la asignación

$$X := x.$$

Si originalmente

$$X = f_X(\text{Pa}(X), U_X),$$

después de la intervención se elimina ese mecanismo y se fija

$$X = x.$$

Formalmente,

$$M^{do(X=x)} = \{X := x, Y_j := f_j(\text{Pa}(Y_j), U_j), \forall Y_j \neq X\}.$$

5.1. Ejemplo

La intervención

$$do(S = 4)$$

puede interpretarse como:

forzar el sistema de refrigeración para mantener la temperatura de almacenamiento en 4°C, independientemente de las condiciones que normalmente determinan S .

Punto de atención

Condicionar en $S = 4$ y realizar $do(S = 4)$ no son operaciones equivalentes. Al intervenir se eliminan las flechas que entran a S .

6. 5. DAG: grafo acíclico dirigido

Un DAG se define como

$$G = (V, E),$$

donde

$$V = \{X_1, \dots, X_n\}$$

es el conjunto de nodos y

$$E \subseteq V \times V$$

es el conjunto de aristas dirigidas.

El grafo es acíclico: no existe una secuencia

$$X_{i_1} \rightarrow X_{i_2} \rightarrow \dots \rightarrow X_{i_k} \rightarrow X_{i_1}.$$

Una arista

$$X_i \rightarrow X_j$$

indica que X_i es una causa directa de X_j dentro del modelo asumido.

7. 6. Variables del sistema de cadena de frío

Consideremos

$$\mathbf{X} = (A, SZN, P, R, T, M, H, B, V, L, S, D).$$

Las variables se organizan en tres grupos.

7.1. 6.1 Entorno y operación

- A : temperatura ambiente;
- SZN : estacionalidad;
- P : cortes de energía;
- R : aperturas de puerta;
- T : tiempo de traslado;
- M : estado o antigüedad del equipo;
- H : capacitación o manejo;
- B : calibración del sensor.

Estas variables pueden influir sobre

$$S = \text{temperatura de almacenamiento.}$$

7.2. 6.2 Producto

- V : tipo de vacuna;
- L : lote de producción.

Estas variables pueden modificar la susceptibilidad a la degradación.

7.3. 6.3 Resultado principal

$$D = \text{degradación.}$$

El camino causal principal de interés es

$$S \rightarrow D.$$

8. 7. DAG mínimo del sistema

Una primera estructura, presente en el material base, es

$$A, SZN, P, R, T, M, H, B \longrightarrow S \longrightarrow D,$$

junto con

$$V \rightarrow D, \quad L \rightarrow D.$$

En este DAG, la temperatura S media el efecto de varios factores operativos sobre la degradación.

9. 8. Factorización de la distribución conjunta

El DAG induce la factorización

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i)).$$

Para el DAG mínimo anterior,

$$\begin{aligned} &P(A, SZN, P, R, T, M, H, B, V, L, S, D) \\ &= P(A)P(SZN)P(P)P(R)P(T)P(M)P(H)P(B)P(V)P(L) \\ &\quad \times P(S \mid A, SZN, P, R, T, M, H, B) \\ &\quad \times P(D \mid S, V, L). \end{aligned}$$

Interpretación

La factorización traduce la estructura gráfica a una representación probabilística: cada nodo se condiciona únicamente en sus padres.

10. 9. Confusión

Una variable Z actúa como confusor del efecto de X sobre Y cuando genera una ruta no causal que entra en X .

El patrón clásico es

$$X \leftarrow Z \rightarrow Y.$$

En ese caso puede ocurrir

$$P(Y \mid X) \neq P(Y \mid do(X)).$$

10.1. 9.1 Ejemplo

Si el manejo H afecta tanto a la temperatura S como a la degradación D ,

$$H \rightarrow S, \quad H \rightarrow D,$$

entonces aparece el camino

$$S \leftarrow H \rightarrow D.$$

Este camino induce asociación entre S y D que no corresponde exclusivamente al efecto causal directo $S \rightarrow D$.

11. 10. Consistencia del DAG y del concepto de confusor

Nota de consistencia causal

En el DAG mínimo,

$$H, M, SZN$$

apuntan únicamente a S . Con esa estructura no son confusores de $S \rightarrow D$, porque no existe una segunda ruta desde ellos hacia D .

Si se desea tratarlos como confusores, como propone otra parte del material base, el DAG debe ampliarse incorporando, por ejemplo,

$$H \rightarrow D, \quad M \rightarrow D, \quad SZN \rightarrow D.$$

A partir de esta sección distinguiremos entre:

- **DAG mínimo:** estas variables sólo explican S ;
- **DAG ampliado:** algunas también influyen directamente sobre D y entonces sí pueden actuar como confusores.

Esta distinción es importante porque el conjunto de variables que debe ajustarse depende del DAG asumido.

12. 11. Caminos causales y caminos no causales

12.1. 11.1 Camino causal directo

$$S \rightarrow D.$$

Representa el efecto de la temperatura de almacenamiento sobre la degradación.

12.2. 11.2 Camino mediado

$$A \rightarrow S \rightarrow D.$$

La temperatura ambiente modifica S , y S modifica D .

12.3. 11.3 Camino de confusión

En el DAG ampliado,

$$S \leftarrow H \rightarrow D.$$

Éste es un camino no causal entre S y D .

Interpretación

No toda asociación entre dos variables se transmite por una flecha causal directa. Los DAG permiten enumerar las rutas alternativas responsables de asociaciones observadas.

13. 12. D-separación

La d-separación permite determinar si un conjunto de variables bloquea todos los caminos relevantes entre dos nodos.

Si Z d-separa X de Y , el DAG implica

$$X \perp\!\!\!\perp Y \mid Z.$$

Para analizar caminos conviene reconocer tres estructuras elementales:

13.1. 12.1 Cadena

$$X \rightarrow Z \rightarrow Y.$$

Condicionar en Z bloquea el camino.

13.2. 12.2 Tenedor

$$X \leftarrow Z \rightarrow Y.$$

Condicionar en Z bloquea el camino.

13.3. 12.3 Collider

$$X \rightarrow Z \leftarrow Y.$$

El camino está bloqueado mientras no se condicione en Z ni en un descendiente suyo.

Punto de atención

Ajustar por más variables no siempre mejora una estimación causal. Condicionar en un collider puede abrir una ruta que originalmente estaba bloqueada.

14. 13. Propiedad de Markov local

La propiedad de Markov local establece que

$$X_i \perp\!\!\!\perp \text{Nd}(X_i) \mid \text{Pa}(X_i),$$

donde $\text{Nd}(X_i)$ representa los no descendientes de X_i , excluyendo sus padres cuando corresponde a la formulación usual.

La idea es que, dados sus padres, una variable es independiente de sus no descendientes no padres.

Nota de consistencia causal

No debe afirmarse que

$$S \perp\!\!\!\perp D \mid \text{Pa}(S)$$

si existe la flecha

$$S \rightarrow D,$$

porque D es descendiente de S . La propiedad de Markov local no implica independencia entre un nodo y sus descendientes.

15. 14. Criterio back-door

Un conjunto Z satisface el criterio back-door para el efecto de X sobre Y si:

1. ningún elemento de Z es descendiente de X ;
2. Z bloquea todos los caminos entre X y Y que entran en X .

Cuando se cumplen estas condiciones,

$$P(Y \mid do(X = x)) = \sum_z P(Y \mid X = x, Z = z)P(Z = z). \quad (2)$$

16. 15. Back-door en el ejemplo

Si utilizamos el DAG ampliado con

$$H \rightarrow S, \quad H \rightarrow D,$$

$$M \rightarrow S, \quad M \rightarrow D,$$

$$SZN \rightarrow S, \quad SZN \rightarrow D,$$

entonces estos nodos generan caminos back-door.

Un conjunto de ajuste posible podría incluir

$$Z = \{H, M, SZN, \dots\},$$

siempre que efectivamente bloquee todas las rutas no causales y no incorpore descendientes de S .

Punto de atención

El conjunto de ajuste correcto no se determina por una lista fija de variables “importantes”. Se determina a partir del DAG asumido.

17. 16. Front-door

Supongamos que Z es un mediador entre X y Y .

El criterio front-door requiere, en términos conceptuales:

1. que Z intercepte todos los caminos causales de X a Y ;
2. ausencia de confusión no controlada entre X y Z ;
3. bloqueo adecuado de las rutas no causales entre Z y Y , una vez ajustado por X .

Cuando se cumplen las condiciones,

$$P(Y \mid do(X = x)) = \sum_z P(Z = z \mid X = x) \sum_{x'} P(Y \mid Z = z, X = x')P(X = x'). \quad (3)$$

17.1. 16.1 Ejemplo conceptual

Si

$$A \rightarrow S \rightarrow D$$

representa todo el efecto de A sobre D , entonces S puede actuar como mediador.

La identificación front-door sólo es válida si se verifican las condiciones gráficas correspondientes.

Interpretación

Front-door es una estrategia alternativa de identificación. No basta con que exista un mediador: deben cumplirse condiciones adicionales sobre confusión.

18. 17. g-Computation

La fórmula g permite calcular el resultado esperado bajo una intervención.

Si Z es un conjunto suficiente de ajuste,

$$\mathbb{E}[Y \mid do(X = x)] = \sum_z \mathbb{E}[Y \mid X = x, Z = z]P(Z = z). \quad (4)$$

Para variables continuas, la suma se sustituye por una integral.

19. 18. ATE

Sea x_1 una exposición y x_0 una referencia.

El efecto promedio puede expresarse como

$$ATE = \mathbb{E}[Y \mid do(X = x_1)] - \mathbb{E}[Y \mid do(X = x_0)].$$

Si se dispone de un modelo

$$m(x, z) = \mathbb{E}[Y \mid X = x, Z = z],$$

una aproximación muestral es

$$\widehat{ATE} = \frac{1}{n} \sum_{i=1}^n [m(x_1, Z_i) - m(x_0, Z_i)]. \quad (5)$$

19.1. 18.1 Ejemplo

Si X es el tiempo fuera del rango térmico, podrían compararse

$$x_1 = 4 \text{ h}, \quad x_0 = 2 \text{ h}.$$

La diferencia de predicciones estandarizadas aproxima el cambio esperado en degradación bajo ambas intervenciones.

20. 19. Modelo físico de degradación

El material base conecta el efecto térmico con una relación tipo Arrhenius. La tasa instantánea de degradación puede escribirse como

$$\lambda(t) = k_0 \exp \left(-\frac{E_a}{R[S(t) + 273.15]} \right).$$

El daño acumulado se representa mediante

$$D = 1 - \exp \left(-\int_0^T \lambda(t) dt \right).$$

Aquí:

- k_0 : factor preexponencial;
- E_a : energía de activación;
- R : constante de los gases;
- $S(t)$: temperatura de almacenamiento;
- D : fracción degradada.

Conexión con aprendizaje máquina

Un modelo causal puede combinar conocimiento mecanicista con relaciones aprendidas estadísticamente. La causalidad no se limita a regresiones lineales.

21. 20. DAG y representación matricial

Si las variables se enumeran como

$$\mathbf{X} = (A, SZN, P, R, T, M, H, B, V, L, S, D),$$

el DAG puede representarse mediante una matriz de adyacencia

$$A_G = [a_{ij}],$$

con

$$a_{ij} = \begin{cases} 1, & \text{si existe } X_i \rightarrow X_j, \\ 0, & \text{en otro caso.} \end{cases}$$

Esta representación es útil en software para redes bayesianas y aprendizaje estructural.

22. 21. Modelos dinámicos

La estructura causal también puede extenderse a sistemas dependientes del tiempo. Por ejemplo, la temperatura puede modelarse mediante

$$dS_t = \kappa(\theta - S_t) dt + \sigma dW_t + \delta(R_t, P_t, T_t) dt. \quad (6)$$

El daño puede evolucionar como

$$dD_t = \lambda(S_t) dt. \quad (7)$$

En tiempo discreto, una estructura natural es

$$S_{t_k} \rightarrow D_{t_{k+1}}.$$

Esto conduce a una red bayesiana dinámica.

Interpretación

El DAG estático describe relaciones entre variables. En un sistema dinámico, las flechas pueden conectar estados en tiempos sucesivos.

23. 22. Aprendizaje causal frente a aprendizaje predictivo

Una distinción central para el curso es:

Aspecto	Aprendizaje predictivo	Aprendizaje causal
Pregunta	¿qué valor tendrá Y ?	¿qué pasaría si modifico X ?
Objeto	$P(Y X)$	$P(Y do(X))$
Meta	predicción	efecto de intervención
DAG requerido	no siempre	típicamente sí
Confusión	puede no afectar predicción	puede sesgar el efecto causal

Conexión con aprendizaje máquina

Un modelo puede predecir muy bien y, al mismo tiempo, dar una estimación causal incorrecta. La precisión predictiva no sustituye la identificación causal.

24. 23. Aprendizaje estructural y conocimiento experto

En aprendizaje causal existen dos tareas diferentes:

1. **aprendizaje estructural**: proponer la estructura del grafo a partir de datos y restricciones;
2. **estimación causal**: cuantificar efectos suponiendo una estructura suficiente para identificar el parámetro causal.

El conocimiento del dominio es especialmente importante porque múltiples DAG pueden ser compatibles con la misma distribución observacional.

25. 24. Propensity score y otras estrategias

Una vez identificado un efecto, pueden utilizarse distintos métodos de estimación. Entre ellos:

- g-computation;
- propensity score;
- inverse probability weighting;
- matching;
- estimadores doblemente robustos.

Estos métodos no sustituyen el paso de identificación.

Punto de atención

Primero se pregunta si el efecto causal es identificable bajo el DAG y los supuestos. Después se selecciona un estimador.

26. 25. Preguntas de autoevaluación

1. ¿Cuál es la diferencia entre

$$P(Y \mid X = x)$$

y

$$P(Y \mid do(X = x))?$$

2. ¿Qué representa U_i en una ecuación estructural?
3. ¿Qué significa una flecha $X \rightarrow Y$ en un DAG causal?
4. ¿Qué es un confusor?
5. ¿Qué patrón gráfico caracteriza un back-door simple?
6. ¿Qué ocurre con las flechas que entran a X bajo $do(X = x)$?
7. ¿Por qué no se debe ajustar automáticamente por todas las variables disponibles?
8. ¿Qué diferencia existe entre cadena, tenedor y collider?
9. ¿Qué condiciones exige el criterio back-door?
10. ¿Qué condiciones conceptuales exige front-door?
11. ¿Qué calcula g-computation?
12. ¿Qué representa el ATE?
13. ¿Por qué un DAG mínimo y uno ampliado pueden conducir a conjuntos de ajuste distintos?
14. ¿Por qué la propiedad de Markov local no implica

$$S \perp\!\!\!\perp D \mid \text{Pa}(S)$$

cuando $S \rightarrow D$?

15. ¿Qué diferencia hay entre identificación y estimación?

27. 26. Ejercicios propuestos

Ejercicio 1. DAG básico.

Dibuje

$$A \rightarrow S \rightarrow D, \quad V \rightarrow D.$$

Liste los padres de cada nodo.

Ejercicio 2. Factorización.

Escriba la distribución conjunta correspondiente al DAG anterior.

Ejercicio 3. Confusión.

Añada

$$H \rightarrow S, \quad H \rightarrow D.$$

Identifique el camino back-door entre S y D .

Ejercicio 4. Ajuste.

Explique por qué condicionar en H bloquea

$$S \leftarrow H \rightarrow D.$$

Ejercicio 5. Collider.

Considere

$$X \rightarrow Z \leftarrow Y.$$

Explique por qué condicionar en Z puede crear asociación entre X y Y .

Ejercicio 6. Intervención.

Describe qué ecuación estructural cambia bajo

$$do(S = 4).$$

Ejercicio 7. g-computation.

Para una variable binaria Z , expanda explícitamente

$$\mathbb{E}[D \mid do(S = s)].$$

Ejercicio 8. ATE.

Suponga que un modelo produce

$$m(s_1, Z_i) \quad \text{y} \quad m(s_0, Z_i).$$

Escriba el estimador estandarizado del ATE.

Ejercicio 9. Front-door.

Para

$$A \rightarrow S \rightarrow D,$$

enumere qué condiciones adicionales deben cumplirse antes de aplicar (3).

Ejercicio 10. DAG dinámico.

Proponga un DAG de dos tiempos con

$$S_t, \quad D_t, \quad S_{t+1}, \quad D_{t+1}.$$

28. 27. Actividad integradora

Considere el objetivo:

estimar el efecto causal de mantener la temperatura de almacenamiento en rango sobre la degradación de una vacuna.

Construya una propuesta completa que incluya:

1. variable de exposición;
2. variable resultado;

3. posibles confusores;
4. DAG;
5. caminos back-door;
6. conjunto de ajuste;
7. expresión

$$P(D \mid do(S = s));$$

8. estimador mediante g-computation;
9. interpretación de un contraste

$$s_1 \text{ vs. } s_0.$$

Después discuta qué cambiaría si algunas variables operativas fueran mediadores en lugar de confusores.

29. 28. Ideas esenciales para recordar

- Asociación no implica causalidad.
- Un SCM describe mecanismos mediante ecuaciones estructurales.
- Un DAG representa relaciones causales asumidas.
- La intervención $do(X = x)$ modifica el mecanismo generador de X .
- La identificación causal depende de la estructura del grafo.
- Los confusores abren caminos no causales de tipo back-door.
- Ajustar por una variable inadecuada puede introducir sesgo.
- Back-door y front-door son criterios de identificación.
- g-computation convierte una identificación causal en una fórmula estimable.
- Predicción e inferencia causal responden preguntas diferentes.
- En modelos dinámicos, la estructura causal puede extenderse entre tiempos.
- Antes de estimar un efecto debe verificarse que el DAG y los supuestos sean internamente consistentes.

30. 29. Bibliografía recomendada

Referencias

- [1] J. Pearl, *Causality: Models, Reasoning and Inference*, 2a ed., Cambridge University Press, 2009.
- [2] M. A. Hernán y J. M. Robins, *Causal Inference: What If*, Chapman & Hall/CRC, 2020.
- [3] P. Spirtes, C. Glymour y R. Scheines, *Causation, Prediction, and Search*, MIT Press, 2000.
- [4] S. L. Lauritzen, *Graphical Models*, Oxford University Press, 1996.

- [5] D. Koller y N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- [6] J. M. Robins, “A new approach to causal inference in mortality studies with sustained exposure periods”, *Mathematical Modelling*, 7(9–12), 1986.