

Aprendizaje causal

YofreH

2025-10-14

Glosario técnico del aprendizaje causal (contexto: temperatura y degradación de vacunas)

1. Variable

Una **variable aleatoria** $X : \Omega \rightarrow \mathcal{F}$ es una función medible definida sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.

En un modelo causal, cada variable X_i se describe mediante una **ecuación estructural**:

$$X_i := f_i(\text{Pa}(X_i), U_i),$$

donde $\text{Pa}(X_i)$ son los **padres** (variables que influyen directamente sobre X_i) y U_i es un término exógeno o perturbación aleatoria.

Ejemplo:

La temperatura de almacenamiento S puede modelarse como

$$S = f_S(A, P, M, H, R, T, B, U_S),$$

donde A es la temperatura ambiente, P cortes de energía, M antigüedad del equipo, H manejo, etc.

2. Causalidad

Decimos que X **causa** Y si intervenir exógenamente sobre X modifica la distribución de Y :

$$P(Y \mid \text{do}(X = x)) \neq P(Y \mid \text{do}(X = x')).$$

En el marco de los **Modelos Estructurales Causales (SCM)**, cada variable satisface una ecuación determinista más un término de ruido. Intervenir en X significa **reemplazar su ecuación** $X = f_X(\text{Pa}(X), U_X)$ por la asignación $X := x$.

Interpretación:

La causalidad describe cómo cambia Y cuando **forzamos** X ; la correlación describe cómo varían juntos X y Y sin intervenir.

3. DAG (grafo acíclico dirigido)

Un **DAG** es un par (V, E) , donde $V = \{X_1, \dots, X_n\}$ es un conjunto de vértices (variables) y $E \subseteq V \times V$ es un conjunto de aristas dirigidas sin ciclos.

Cada arista $X_i \rightarrow X_j$ expresa una relación causal directa.

El DAG implica la factorización:

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i)).$$

Ejemplo:

$$A, P, M, H, R, T, B \rightarrow S \rightarrow D,$$

donde S (temperatura de almacenamiento) media el efecto de las condiciones ambientales y operativas sobre la degradación D .

4. Confusor

Una variable Z es un **confusor** entre X y Y si:

- Z afecta tanto a X como a Y , y
- Z no se encuentra en la cadena causal $X \rightarrow Y$.

En términos del grafo, Z deja **abierto** un camino de tipo *back-door* entre X y Y , produciendo

$$P(Y \mid X) \neq P(Y \mid \text{do}(X)).$$

Ejemplo:

El manejo deficiente H puede aumentar la temperatura S y la degradación D ; si no se ajusta por H , se sobreestima el efecto de S sobre D .

5. Notación $\text{do}(X = x)$

Introducida por Pearl (1995), la operación $\text{do}(X = x)$ representa una **intervención exógena** que fija el valor de X y elimina todas las aristas que apuntan a X .

Formalmente, en un modelo estructural M :

$$M^{\text{do}(X = x)} = \{X := x, Y_i := f_i(\text{Pa}(Y_i, U_i), \forall i \text{ for all } Y_i \neq X)\}.$$

La distribución post-intervención es

$$P(Y \mid \text{do}(X = x)) = \sum_z P(Y \mid X = x, Z = z) P(Z = z),$$

si el conjunto Z cumple el **criterio back-door**.

Ejemplo:

$\text{do}(S = 4)$ significa “forzar el sistema de refrigeración a mantener 4 °C”, independientemente del ambiente o del estado del equipo.

6. Criterio Back-door

Sea X una causa y Y un efecto.

Un conjunto de variables Z satisface el **criterio back-door** respecto a (X, Y) si:

- Ninguna variable de Z es descendiente de X , y
- Z bloquea todas las rutas entre X y Y que **entran** en X (rutas no causales).

Entonces el efecto causal se identifica por:

$$P(Y \mid \text{do}(X)) = \sum_z P(Y \mid X, Z = z) P(Z = z).$$

Ejemplo:

Para estimar el efecto de la temperatura S sobre la degradación D , un posible conjunto de ajuste es $Z = \{H, M, B, \text{SZN}, V, L\}$.

7. Criterio Front-door

Sea Z un **mediador** entre X y Y .

Z satisface el **criterio front-door** si:

- Z intercepta todas las rutas causales de X a Y ;
- No existe confusión entre X y Z ;
- No existe confusión entre Z y Y una vez controlado X .

En ese caso:

$$P(Y \mid \text{do}(X = x)) = \sum_z P(Z = z \mid X = x) \sum_{x'} P(Y \mid Z = z, X = x') P(X = x').$$

Ejemplo:

Si la temperatura ambiente A afecta la degradación D sólo a través de la temperatura de almacenamiento S , y no hay confusores, S cumple el criterio front-door para identificar $A \rightarrow D$.

8. g-Computation (fórmula g)

La **fórmula g** (Robins, 1986) permite expresar el valor esperado del resultado Y bajo una intervención $\text{do}(X = x)$ como:

$$E[Y \mid \text{do}(X = x)] = \sum_z E[Y \mid X = x, Z = z] P(Z = z).$$

Si se dispone de un modelo paramétrico $m(X, Z) = E[Y \mid X, Z]$, entonces:

$$\widehat{\text{ATE}} = \frac{1}{n} \sum_{i=1}^n \text{Big}[m(x_1, Z_i) - m(x_0, Z_i)]$$

donde x_1 y x_0 son los niveles de tratamiento o exposición.

Ejemplo:

Reducir el tiempo sobre rango térmico (TAR) de $x_1 = 4$ h a $x_0 = 2$ h se traduce en una disminución esperada de la probabilidad de degradación de las vacunas, estimada mediante el modelo $m(S, Z)$.

9. Conexión entre los conceptos

Concepto	Marco teórico	Representación	Propósito
Variable	Probabilidad y teoría de la medida	Nodo del DAG	Unidad analítica
Causalidad	Modelos estructurales	Arco dirigido	Direccionalidad de influencia
DAG	Teoría de grafos acíclicos	$G = (V, E)$	Representar dependencias
Confusor	Caminos no causales	Nodos comunes	Fuente de sesgo
$\text{do}(X = x)$	Intervención	Reemplaza ecuación estructural	Definir contrafactual

Back-door	Identificación	Subconjunto $\setminus(Z)$	Ajuste por confusión
Front-door	Mediación	Nodo $\setminus(Z)$ intermedio	Identificación alternativa
g-Computation	Fórmula de Robins	Integral o suma	Estimación numérica del efecto causal

10. Referencias

- Pearl, J. (2009). *Causality: Models, Reasoning and Inference*. Cambridge University Press.
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search*. MIT Press.
- Robins, J. M. (1986). *A new approach to causal inference in mortality studies with sustained exposure periods*. *Mathematical Modelling*, 7(9–12), 1393–1512.
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.

2. El mapa causal (DAG) y su formalización matemática

2.1 Definición del sistema causal

Denotemos por $\mathbf{X} = (A, \text{SZN}, P, R, T, M, H, B, V, L, S, D)$ el conjunto de variables aleatorias que describen el sistema de cadena de frío.

Estas variables se pueden agrupar conceptualmente en tres bloques:

- Entorno y operación (causas exógenas de la temperatura de almacenamiento):**
 - Temperatura ambiente: A
 - Estacionalidad: SZN
 - Cortes de energía eléctrica: P
 - Frecuencia de aperturas de puerta: R
 - Tiempo en traslado: T
 - Estado del equipo (antigüedad o mantenimiento): M
 - Calibración del sensor: B
 - Capacitación del personal (manejo): H

Estas variables influyen directamente sobre la temperatura de almacenamiento S .

$$A, \text{SZN}, P, R, T, M, H, B \rightarrow S$$

- Producto (susceptibilidad de las vacunas):**
 - Tipo de vacuna: V
 - Identificador o lote de producción: L

Ambas influyen sobre la probabilidad de degradación D (ya que la estabilidad térmica varía por formulación).

$$V, L \rightarrow D$$

- Camino principal de interés:**

La temperatura de almacenamiento S actúa como causa directa de la degradación D :

$$S \rightarrow D$$

2.2 DAG formal y factorización de la distribución conjunta

El grafo acíclico dirigido (DAG) $G = (V, E)$ contiene los nodos anteriores y los arcos:

$$E = \{ (A, S), (\text{SZN}, S), (P, S), (R, S), (T, S), (M, S), (H, S), (B, S), (S, D), (V, D), (L, D) \}$$

De acuerdo con la semántica de independencia condicional inducida por el DAG, la distribución conjunta de todas las variables factoriza como:

$$\begin{aligned} P(A, \text{SZN}, P, R, T, M, H, B, V, L, S, D) &= P(A) P(\text{SZN}) P(P) P(R) P(T) P(M) P(H) P(B) P(V) P(L) \\ &\quad \times P(S \mid A, \text{SZN}, P, R, T, M, H, B) \times P(D \mid S, V, L). \end{aligned}$$

Cada término $P(X_i \mid \text{Pa}(X_i))$ representa la ecuación estructural correspondiente a la variable X_i .

2.3 Interpretación de los caminos causales

Camino causal directo:

El arco $(S \rightarrow D)$ representa el efecto **físico-químico de la temperatura** sobre la degradación de la vacuna, expresado mediante relaciones tipo Arrhenius:

$$\lambda(t) = k_0 \exp\left(-\frac{E_a}{R(S(t) + 273.15)}\right), \quad D = 1 - \exp\left(-\int_0^T \lambda(t) dt\right),$$

donde: $\lambda(t)$ es la tasa instantánea de degradación, E_a la energía de activación, R la constante de gas, $S(t)$ la temperatura de almacenamiento en °C, D el daño acumulado (fracción degradada).

Caminos de confusión:

Variables como el manejo (H) , la estacionalidad (SZN) o el mantenimiento (M) pueden afectar tanto (S) como (D) :

$$H \rightarrow S, \quad H \rightarrow D, \quad M \rightarrow S, \quad M \rightarrow D, \quad SZN \rightarrow S, \quad SZN \rightarrow D.$$

Estos constituyen **rutas de confusión** o *back-door paths* del tipo:

$$S \leftarrow H \rightarrow D, \quad S \leftarrow M \rightarrow D, \quad S \leftarrow SZN \rightarrow D.$$

Para estimar el efecto causal puro de (S) sobre (D) , deben **bloquearse** mediante ajuste estadístico.

2.4 Criterio de identificación (back-door)

El conjunto $Z = \{H, M, SZN, B, V, L\}$ cumple el **criterio back-door** respecto a (S, D) , pues:

- 1. Ninguna variable de (Z) es descendiente de (S) , y
- 2. (Z) bloquea todas las rutas que **entran** a (S) y terminan en (D) .

Por tanto, el efecto causal es identificable como:

$$P(D \mid do(S)) = \sum_z P(D \mid S, Z = z), \quad P(Z = z).$$

El valor esperado (efecto promedio del tratamiento, ATE) se calcula como:

$$ATE = E[D \mid do(S = s_1)] - E[D \mid do(S = s_0)],$$

donde (s_1) y (s_0) representan niveles altos o bajos de exposición térmica (por ejemplo, $(s_1 =)$ “fuera de rango”, $(s_0 =)$ “en rango”).

2.5 Criterio front-door (alternativo)

Si se desea estudiar el efecto de una variable del **ambiente** (A) sobre la degradación (D) , pero existe confusión no medida (por ejemplo, variaciones estacionales no observadas), puede aplicarse el **criterio front-door** utilizando (S) como mediador.

En ese caso:

$$P(D \mid do(A = a)) = \sum_s P(S = s \mid A = a) \sum_{a'} P(D \mid S = s, A = a') P(A = a').$$

Esto permite identificar el efecto $(A \rightarrow D)$ a través del canal $(A \rightarrow S \rightarrow D)$, aun en presencia de confusores no medidos entre (A) y (D) , siempre que se cumplan las condiciones de no confusión directa en los arcos $(A \rightarrow S)$ y $(S \rightarrow D)$.

2.6 Interpretación física y operativa

- **Camino causal principal:**
Temperatura de almacenamiento $(S) \rightarrow$ Degradación (D) .
Controlar (S) equivale a controlar la estabilidad del producto.
- **Camino mediado por ambiente:**
 $(A \rightarrow S \rightarrow D)$.
La variabilidad ambiental afecta la temperatura interna, y ésta afecta la estabilidad.
- **Confusores operativos:**
 $(M), (H), (B)$ y (SZN) actúan como fuentes de sesgo si no se incluyen en el modelo estadístico.

2.7 Representación esquemática

El DAG completo puede representarse como:

$$\begin{array}{ccccccccccc} A & SZN & P & R & T & M & H & B & & & & \\ \downarrow & \nearrow & \swarrow & \searrow & \swarrow & \downarrow & \nearrow & \searrow & \nearrow & \searrow & \nearrow & \\ & & S & & & & & D & & & & \\ & & & & V & L & & & & & & \end{array}$$

Cada flecha representa una ecuación estructural en el sistema causal, y las dependencias se evalúan bajo el marco de independencia condicional inducido por el DAG.

2.8 Implicaciones para la inferencia causal

- El DAG define la estructura necesaria para decidir **qué variables ajustar** y **cómo interpretar los coeficientes** del modelo estadístico.
- Permite distinguir entre **efecto directo** ($S \rightarrow D$) y **efectos indirectos** (mediados por $S \rightarrow V \rightarrow D$) o por otras rutas).
- Facilita la implementación de algoritmos de **g-computation**, **propensity score** o **redes bayesianas estructuradas** para evaluar políticas de control térmico.

2.9 Resumen

Tipo de variable	Símbolo	Papel causal	Ejemplo o interpretación
Temperatura ambiente	A	causa exógena	Clima externo
Estacionalidad	SZ_N	confusor	Mes o estación
Cortes eléctricos	P	causa exógena	Interrupciones
Aperturas de puerta	R	causa exógena	Manejo operativo
Traslado	T	causa exógena	Transporte intermedio
Estado del equipo	M	confusor	Antigüedad del refrigerador
Calibración sensor	B	confusor	Error de medición térmica
Capacitación del personal	H	confusor	Calidad del manejo
Temperatura almacenamiento	S	variable de tratamiento	Temperatura interna
Tipo de vacuna	V	modificador	Diferente estabilidad
Lote	L	variación intrínseca	Diferente fabricación
Degradación	D	resultado	Pérdida de potencia o descarte

3. Grafo acíclico dirigido (DAG) y su estructura causal

3.1 Definición formal

Sea un conjunto de variables aleatorias $V = \{A, SZ_N, P, R, T, M, H, B, V, L, S, D\}$, V que describen las condiciones de almacenamiento, operación y producto dentro del sistema de cadena de frío.

Un **grafo acíclico dirigido (DAG)** se define como un par:

$$G = (V, E)$$

donde:

- V es el conjunto de **nodos** (variables del sistema),
- $E \subseteq V \times V$ es el conjunto de **aristas dirigidas**,
- y el grafo es **acíclico**, es decir, no existe una secuencia de aristas $X_{i_1} \rightarrow X_{i_2} \rightarrow \dots \rightarrow X_{i_k} \rightarrow X_{i_1}$ que forme un ciclo.

Cada arista dirigida $X_i \rightarrow X_j$ expresa una **relación causal directa**: el valor de X_j depende funcionalmente de X_i , con posible presencia de ruido exógeno U_j .

Formalmente, el DAG G se asocia a un **modelo estructural causal (SCM)** de la forma:

$$X_j := f_j(\text{Pa}(X_j), U_j), \quad j = 1, \dots, n$$

donde $\text{Pa}(X_j)$ denota el conjunto de padres (nodos que apuntan a X_j) en el grafo.

3.2 Factorización de la distribución conjunta

El DAG G codifica independencias condicionales entre las variables y, por tanto, induce la factorización:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i))$$

Esta factorización permite descomponer la distribución conjunta en términos de los **mecanismos locales** de cada variable y sus padres causales.

En el contexto del sistema de almacenamiento de vacunas, la factorización explícita es:

$$\begin{aligned} P(A, SZ_N, P, R, T, M, H, B, V, L, S, D) &= P(A) \cdot P(SZ_N) \cdot P(P) \cdot P(R) \cdot P(T) \cdot P(M) \cdot P(H) \cdot P(B) \cdot P(V) \cdot P(L) \\ &\quad \cdot P(S \mid A, SZ_N, P, R, T, M, H, B) \cdot P(D \mid S, V, L). \end{aligned}$$

Cada término $P(X_i \mid \text{Pa}(X_i))$ puede interpretarse como una **ecuación física o logística** dentro del sistema de la cadena de frío.

3.3 Estructura causal específica del sistema

El conjunto de aristas dirigidas se define como:

$$\mathcal{E} = \{ (A,S), (SZN,S), (P,S), (R,S), (T,S), (M,S), (H,S), (B,S), (S,D), (V,D), (L,D) \}.$$

Por tanto, la estructura causal puede representarse esquemáticamente como:

$$A, SZN, P, R, T, M, H, B \rightarrow S \rightarrow D,$$

junto con las contribuciones directas del tipo de vacuna V y el lote L hacia D :

$$V \rightarrow D, \quad L \rightarrow D.$$

Interpretación física:

- Los nodos que apuntan a S (p. ej., A , P , R) representan **factores que elevan o reducen la temperatura interna**.
- El nodo S transmite su efecto térmico hacia D (degradación).
- Los nodos V y L modulan la **susceptibilidad térmica** de cada vacuna.

3.4 Propiedad de Markov local

El DAG G define un conjunto de independencias condicionales mediante la **propiedad de Markov local**:

$$X_i \perp\!\!\!\perp \mathbf{Nd}(X_i) \mid \mathbf{Pa}(X_i),$$

donde $\mathbf{Nd}(X_i)$ representa los **no descendientes** de X_i en el grafo.

Esto significa que, dado el conocimiento de los padres $\mathbf{Pa}(X_i)$, la variable X_i es independiente de todas las demás que no son sus efectos directos o indirectos.

Ejemplo:

En nuestro modelo, la temperatura de almacenamiento S es independiente de la degradación D condicionalmente a sus padres $(A, SZN, P, R, T, M, H, B)$:

$$S \perp\!\!\!\perp D \mid (A, SZN, P, R, T, M, H, B).$$

Sin embargo, una vez ocurrida la intervención $(do(S = s))$, esta independencia se rompe y S pasa a ser una **causa activa** de D .

3.5 Caminos causales y no causales

- Camino causal directo:** $S \rightarrow D$.
Refleja la acción termodinámica sobre la degradación de proteínas o ácidos nucleicos en la vacuna.
- Caminos indirectos o mediadores:**
 $A \rightarrow S \rightarrow D$, donde el ambiente influye a través del estado térmico.
- Caminos de confusión:**
 $S \leftarrow H \rightarrow D$, $S \leftarrow M \rightarrow D$, $S \leftarrow SZN \rightarrow D$, que deben bloquearse mediante ajuste estadístico.

Formalmente, un camino p entre X y Y está **bloqueado** por un conjunto de nodos Z si cumple las condiciones de **d-separación**; en ese caso, se garantiza la independencia condicional:

$$X \perp\!\!\!\perp Y \mid Z.$$

3.6 Propiedades derivadas del DAG

- Factorización de la distribución conjunta:**
Cada nodo depende sólo de sus padres.
- Criterio de d-separación:**
Permite deducir independencias condicionales directamente del grafo sin cálculos probabilísticos.
- Base para la identificación causal:**
El DAG es el punto de partida para aplicar las reglas de cálculo de intervención (*do-calculus*).
- Interpretación física y operacional:**
El DAG traduce la dinámica térmica y logística del sistema en una estructura matemática verificable.

3.7 Representación matricial (opcional)

Si se enumeran las variables como $\mathbf{X} = (A, SZN, P, R, T, M, H, B, V, L, S, D)$, el DAG se puede representar mediante una **matriz de adyacencia** $A_G = [a_{ij}]$, donde:

$$a_{ij} = \begin{cases} 1, & \text{si existe una arista } X_i \rightarrow X_j, \\ 0, & \text{en caso contrario.} \end{cases}$$

Por ejemplo, los elementos $a_{A,S}=1$, $a_{S,D}=1$, $a_{V,D}=1$ indican las conexiones causales presentes.

Esta forma matricial es útil para el aprendizaje estructural en software como bnLearn , donde los valores 1 y 0 definen las listas blanca y negra de arcos permitidos.

3.8 Relación con modelos estructurales continuos

En modelos dinámicos, la temperatura S_t puede ser un proceso estocástico (por ejemplo, Ornstein–Uhlenbeck):

$$dS_t = \kappa(\theta - S_t)dt + \sigma dW_t + \delta(R_t, P_t, T_t)dt,$$

y el daño térmico acumulado D_t evoluciona como:

$$dD_t = \lambda(S_t)dt, \quad \lambda(S_t) = k_0 \exp\left(-\frac{E_a}{R(S_t + 273.15)}\right).$$

El DAG sigue siendo válido: en cada tiempo discreto t_k , el par (S_{t_k}, D_{t_k}) mantiene la estructura causal $S_{t_k} \rightarrow D_{t_{k+1}}$, definiendo así una **red bayesiana dinámica (DBN)**.

3.9 Resumen conceptual

Elemento	Símbolo	Naturaleza	Ejemplo físico	Papel en el DAG
Nodo	X_i	Variable aleatoria	Temperatura o degradación	Representa un estado del sistema
Arista	$X_i \rightarrow X_j$	Relación causal	“El ambiente afecta la temperatura”	Conexión dirigida
Padres	$\text{Pa}(X_j)$	Conjunto de causas directas	$\text{Pa}(S) = \{A, SZN, P, R, T, M, H, B\}$	Determinan la ecuación estructural
Descendientes	$\text{De}(X_i)$	Efectos de X_i	$\text{De}(S) = \{D\}$	Resultado del proceso
Independencia condicional	$X_i \perp\!\!\!\perp Y_j \mid Z$	Propiedad probabilística	D-separación	Define el Markov del DAG

3.10 Referencias

- Pearl, J. (2009). *Causality: Models, Reasoning and Inference*. Cambridge University Press.
- Lauritzen, S. L. (1996). *Graphical Models*. Oxford University Press.
- Koller, D., & Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. MIT Press.