

Boostraping_ML

YofreH

2025-09-05

Boostraping

1. Motivación

En machine learning y estadística, muchas veces queremos **estimar la variabilidad** de un estimador (media, varianza, regresión, error de un modelo, etc.). El problema:

- Sabemos calcular la media muestral fácilmente.
- Pero, ¿cómo sabemos **qué tan confiable** es esa media?
- Es decir, ¿qué tan variable sería si repitiésemos el experimento muchas veces?

El método clásico usa teoría de probabilidad (como el Teorema Central del Límite). Pero si la distribución de los datos es complicada o desconocida, eso se vuelve difícil.

Bootstrap es una técnica computacional (propuesta por Efron en 1979) que resuelve este problema al “simular” tener muchas muestras, **reutilizando solo los datos observados**.

2. Idea fundamental del bootstrap

1. Tenemos una muestra de tamaño (n) , por ejemplo $(x_1, x_2, \dots, x_n)$.
2. Consideramos que esta muestra representa lo que sabemos de la población.
3. Para imitar nuevas muestras, **re-muestreamos con reemplazo** de los mismos datos, generando una muestra del mismo tamaño (n) .
4. En cada remuestreo calculamos el estadístico de interés (media, varianza, mediana, etc.).
5. Repetimos esto muchas veces (100, 1000, ...).
6. Observamos la distribución de esos estadísticos: esa distribución “bootstrap” aproxima la distribución muestral del estimador.

3. Ejemplo numérico sencillo (sin software)

Supongamos que tenemos un pequeño conjunto de datos:

$x = \{2, 4, 5\}$

de tamaño $(n = 3)$.

Queremos estimar la **media poblacional** (μ) .

- La media muestral original es:
 $\bar{x} = \frac{2+4+5}{3} = \frac{11}{3} \approx 3.67$

Paso 1: Generar remuestreos con reemplazo

Cada bootstrap consiste en elegir 3 datos al azar de $(\{2,4,5\})$, **con reemplazo**.

Ejemplos de remuestreos posibles:

1. $(\{2, 2, 4\}) \rightarrow \text{media} = \frac{8}{3} = 2.67$
2. $(\{5, 4, 5\}) \rightarrow \text{media} = \frac{14}{3} \approx 4.67$
3. $(\{2, 4, 5\}) \rightarrow \text{media} = \frac{11}{3} \approx 3.67$
4. $(\{2, 2, 2\}) \rightarrow \text{media} = 2$
5. $(\{4, 4, 5\}) \rightarrow \text{media} = \frac{13}{3} \approx 4.33$

Paso 2: Construir distribución bootstrap

Imaginemos que hacemos **todas las combinaciones posibles** (con reemplazo). Número total de posibles muestras $= (3^3 = 27)$.

Las diferentes medias posibles son:

Muestra bootstrap	Media
{2,2,2}	2.00
{2,2,4}	2.67
{2,2,5}	3.00

{2,4,4}	3.33
{2,4,5}	3.67
{2,5,5}	4.00
{4,4,4}	4.00
{4,4,5}	4.33
{4,5,5}	4.67
{5,5,5}	5.00
... (otras permutaciones dan los mismos valores)	

Si contamos frecuencias, obtenemos una **distribución empírica de las medias bootstrap**.

Paso 3: Interpretación

- La media de esas medias será aproximadamente $\sqrt{3.67}$, consistente con la muestra original.
- Pero lo importante es la **dispersión**: podemos calcular la desviación estándar de esas medias (se llama *error estándar bootstrap*).
- Esa desviación nos dice **qué tan inestable es la media muestral**.
- También podemos usar los percentiles de esta distribución bootstrap para construir intervalos de confianza para la media.

4. Aplicación a machine learning

En machine learning, bootstrap se usa en:

- **Estimación de la variabilidad del error de predicción**.
- **Bagging** (bootstrap aggregating), base de Random Forests: entrenar modelos en múltiples remuestreos bootstrap y luego promediar.
- Validación cruzada tipo bootstrap para medir performance del modelo.

Bootstrap es una técnica para **estimar incertidumbre** sin fórmulas complicadas de probabilidad, simplemente “re-usando” los datos con reemplazo.

Bootstrap en contexto: Videojuegos

el bootstrap puede usarse en el contexto de videojuegos, pero no para “jugar mejor directamente”, sino para mejorar la estimación de desempeño de una estrategia. Te explico con calma:

1. Idea general

En un videojuego con estrategia (por ejemplo ajedrez digital, un MOBA, un shooter táctico), queremos evaluar si una **estrategia A** es mejor que una **estrategia B**.

- Jugamos 20 partidas con A y medimos la puntuación media.
- Jugamos 20 partidas con B y medimos su media.

Problema: esas medias son **ruidosas** porque las partidas tienen azar (enemigos, mapas, decisiones del rival). Entonces, ¿cómo sabemos si la diferencia observada es “real” o es solo azar?

2. Cómo ayuda bootstrap

Aquí entra bootstrap:

1. Recolectamos los resultados de las partidas de cada estrategia. Ejemplo (estrategia A, puntuaciones): $\{50, 55, 60, 48, 62\}$.
2. Queremos saber la **distribución de la media** de esas puntuaciones.
3. Aplicamos bootstrap:
 - Re-muestreamos con reemplazo muchas veces de esos 5 resultados.
 - Calculamos la media en cada resample.
 - Obtenemos una distribución bootstrap de la media.
4. Repetimos lo mismo con la estrategia B.
5. Comparamos las distribuciones (media, varianza, intervalos de confianza).

3. Interpretación en videojuegos

- Si el **intervalo bootstrap** de A está siempre por encima del de B, podemos decir con confianza que A es mejor.
 - Si se solapan mucho, quizá no hay evidencia clara de que A supere a B.
- Esto es útil porque en juegos **el azar afecta mucho** (mapa, rivales, equipo). El bootstrap nos permite **cuantificar la incertidumbre** y tomar decisiones basadas en evidencia.

4. Ir más allá: mejorar estrategias

- Aunque el bootstrap **no inventa nuevas jugadas**, sí puede ayudar en:
- **Selección de estrategias:** elegir entre varias la que tiene desempeño más robusto.
 - **Hibridación adaptativa:** si tienes varias heurísticas, puedes usar bootstrap para estimar cuál funciona mejor en condiciones actuales del juego (ej. mapa A vs mapa B).
 - **Machine Learning en videojuegos:** en métodos como *reinforcement learning*, se puede usar bootstrap para evaluar la política aprendida y decidir si conviene explorar más o explotar.

5. Ejemplo

un **ejemplo completamente manual** para mostrar cómo el **bootstrap** sirve para evaluar si una estrategia de videojuego “A” supera a otra “B”. No usaremos software; todo se hará con aritmética elemental.

0) Planteamiento (qué queremos medir)

Tienes resultados (puntajes) de 3 partidas con cada estrategia:

- Estrategia **A** (agresiva): $x = \{80, 75, 90\}$
- Estrategia **B** (defensiva): $y = \{70, 65, 78\}$

Nuestro **estadístico de interés** es la **media** de cada estrategia y, sobre todo, la **diferencia de medias** $(D = \bar{x} - \bar{y})$.

Medias muestrales (de la muestra original):

$$\bar{x} = \frac{80+75+90}{3} = \frac{245}{3} \approx 81.667, \quad \bar{y} = \frac{70+65+78}{3} = \frac{213}{3} = 71.$$

Diferencia observada:

$$D_{\text{obs}} = \bar{x} - \bar{y} = \frac{245}{3} - 71 = \frac{32}{3} \approx 10.667.$$

1) Idea del bootstrap (remuestreo con reemplazo)

Para cada estrategia, **simulamos** “nuevas muestras” del **mismo tamaño** $(n=3)$ sacando con reemplazo **solo** de los datos observados. Cada remuestreo produce una media; **la colección de esas medias** aproxima la distribución muestral del estimador.

Con $(n=3)$ y 3 valores posibles, el número **total de remuestreos distintos** (ordenados) es $(3^3=27)$. Podemos **enumerarlos** sin software, pero aprovecharemos simetrías (cuentas multinomiales) para no listar 27 filas una por una.

2) Distribución bootstrap de la media de A (exacta, sin software)

Sea $x = \{80, 75, 90\}$. Un remuestreo de tamaño 3 se caracteriza por el **vector de conteos** $((k_1, k_2, k_3))$ con $(k_1+k_2+k_3=3)$, donde (k_j) es cuántas veces aparece el (j) -ésimo valor (80, 75, 90). Cada vector tiene probabilidad

$$P(k_1, k_2, k_3) = \frac{3!}{k_1! k_2! k_3!} \left(\frac{1}{3}\right)^3 = \frac{1}{27} \cdot \frac{3!}{k_1! k_2! k_3!}.$$

La **media bootstrap** correspondiente es

$$\bar{x}^{\text{ast}} = \frac{80 \cdot k_1 + 75 \cdot k_2 + 90 \cdot k_3}{3}.$$

Todos los patrones posibles de $((k_1, k_2, k_3))$ (con sus probabilidades agregadas por valor de la media) son:

$(\bar{x}^{\text{ast}})$	Cómo se obtiene	Probabilidad total
75	(0,3,0)	$(1/27)$
$(230/3 \approx 76.667)$	(1,2,0)	$(1/9)$
$(235/3 \approx 78.333)$	(2,1,0)	$(1/9)$
80	(3,0,0) o (0,2,1)	$(1/27 + 1/9 = 4/27)$
$(245/3 \approx 81.667)$	(1,1,1)	$(2/9)$
$(250/3 \approx 83.333)$	(2,0,1)	$(1/9)$
85	(0,1,2)	$(1/9)$

$\sqrt[260]{3} \approx 86.667$	(1,0,2)	$\sqrt[1]{9}$
90	(0,0,3)	$\sqrt[1]{27}$

(La suma de probabilidades es 1.)

3) Distribución bootstrap de la media de B (exacta)

Ahora $y=\{70,65,78\}$. Análogo al caso anterior, la **media bootstrap** es

$$\bar{y}=\frac{70+65+78}{3}, \text{quad } \ell_1+\ell_2+\ell_3=3,$$

con $P(\ell_1,\ell_2,\ell_3)=\frac{1}{27}\cdot\frac{3!}{\ell_1!\ell_2!\ell_3!}$.

Obtenemos:

$\bar{y}$	Cómo se obtiene	Probabilidad
65	(0,3,0)	$\sqrt[1]{27}$
$\sqrt[200]{3} \approx 66.667$	(1,2,0)	$\sqrt[1]{9}$
$\sqrt[205]{3} \approx 68.333$	(2,1,0)	$\sqrt[1]{9}$
$\sqrt[208]{3} \approx 69.333$	(0,2,1)	$\sqrt[1]{9}$
70	(3,0,0)	$\sqrt[1]{27}$
71	(1,1,1)	$\sqrt[2]{9}$
$\sqrt[218]{3} \approx 72.667$	(2,0,1)	$\sqrt[1]{9}$
$\sqrt[221]{3} \approx 73.667$	(0,1,2)	$\sqrt[1]{9}$
$\sqrt[226]{3} \approx 75.333$	(1,0,2)	$\sqrt[1]{9}$
78	(0,0,3)	$\sqrt[1]{27}$

4) Diferencia de medias por bootstrap: $D=\bar{x}-\bar{y}$

Para comparar estrategias con bootstrap **sin software**, hay dos caminos:

A) p-valor (prueba de una cola: “A es mejor que B”) Queremos $P(D\leq 0)$ bajo el remuestreo independiente de x e y . Como $\bar{x}$ y $\bar{y}$ son independientes,

$$P(D\leq 0)=\sum_i\sum_j \mathbb{1}\{a_i\leq b_j\}p_iq_j,$$

donde a_i y b_j recorren los valores posibles de $\bar{x}$ y $\bar{y}$ con probabilidades p_i y q_j .

Observación clave (mirando las tablas):

- El **máximo** de $\bar{y}$ es 78.
- En $\bar{x}$, casi todos los valores son **mayores que 78**, salvo 75 y $\sqrt[76.667]{3}$ y $\sqrt[78.333]{3}$. Como $\sqrt[78.333]{3}>78$, solo **75 y $\sqrt[76.667]{3}$** pueden generar $D\leq 0$.

Calculemos exactamente esas masas (todo en “veintisietavos” para facilitar):

- $P(\bar{x}=75)=1/27$. Dado $\bar{x}=75$, $D\leq 0$ ocurre si $\bar{y}\geq 75$. En la tabla de B , los valores ≥ 75 son $\sqrt[75.333]{3}$ (prob $\sqrt[3]{27}$) y 78 (prob $\sqrt[1]{27}$), total $\sqrt[4]{27}$. Aporte: $\sqrt[1]{27}\cdot\sqrt[4]{27}=4/729$.
- $P(\bar{x}=\sqrt[76.667]{3})=3/27$. Dado $\bar{x}=\sqrt[76.667]{3}$, $D\leq 0$ requiere $\bar{y}\geq \sqrt[76.667]{3}$, y el único valor de B por encima es 78 con prob $\sqrt[1]{27}$. Aporte: $\sqrt[3]{27}\cdot\sqrt[1]{27}=3/729$.

Sumando:

$$P(D\leq 0)=\frac{4+3}{729}=\frac{7}{729}\approx 0.0096.$$

Interpretación: Con bootstrap exacto, la probabilidad de que “A no supere a B” es $\approx 0.96\%$. En una **prueba de una cola** (hipótesis $H_0:\bar{x}\leq \bar{y}$ vs $H_1:\bar{x}>\bar{y}$), el **p-valor ≈ 0.0096** , por debajo de 0.05 $\Rightarrow$ **evidencia fuerte** de que **A es mejor**.

B) Intervalo de confianza (IC) aproximado para D Podemos aproximar un IC con una cuenta cerrada muy simple: bajo remuestreo iid desde la distribución empírica,

$$\mathrm{Var}(\bar{X})=\frac{\mathrm{Var}_{\text{emp}}(X)}{n}, \text{quad } \mathrm{Var}(\bar{Y})=\frac{\mathrm{Var}_{\text{emp}}(Y)}{n}.$$

Calculamos las varianzas empíricas (alrededor de la media muestral, con peso $\sqrt[1]{3}$ por punto):

Para (A) : $(\bar{x}=81.667)$. Desviaciones: $((-1.667)^2=2.778)$, $((-6.667)^2=44.444)$, $((8.333)^2=69.444)$. $(\text{Var}(\bar{X})=\frac{2.778+44.444+69.444}{3}=38.889)$. $(\Rightarrow \text{Var}(\bar{X})=38.889/3=12.963 \Rightarrow \text{EE}_A \approx 3.601)$.

Para (B) : $(\bar{y}=71)$. Desviaciones: $((-1)^2=1)$, $((-6)^2=36)$, $((7)^2=49)$. $(\text{Var}(\bar{Y})=86/3=28.667)$. $(\Rightarrow \text{Var}(\bar{Y})=28.667/3=9.556 \Rightarrow \text{EE}_B \approx 3.092)$.

Como $(D=\bar{X}-\bar{Y})$ y los remuestreos son independientes,

$$[\text{EE}_D = \sqrt{\text{EE}_A^2 + \text{EE}_B^2} \approx \sqrt{(3.601)^2 + (3.092)^2} \approx 4.746.]$$

IC del 95% (aprox. normal):

$$[D_{\text{obs}} \pm 1.96 \cdot \text{EE}_D \approx 10.667 \pm 1.96(4.746) = [1.36, 19.97].]$$

Conclusión del IC: el 95% CI está **por encima de 0**, coherente con la prueba bootstrap exacta.

Nota docente: también puede construirse un IC conservador por percentiles separados $([Q_{2.5\%}(\bar{x}) - Q_{97.5\%}(\bar{y}), Q_{97.5\%}(\bar{x}) - Q_{2.5\%}(\bar{y})])$, que aquí da $([-3, 25])$. Es más ancho y no es el ideal para (D) , pero se puede explicar como paso pedagógico.

5) ¿Qué aprendemos para videojuegos y ML?

- El **bootstrap** nos permite **medir la incertidumbre** del rendimiento de una estrategia con **muy pocos datos** y sin suposiciones fuertes sobre distribuciones.
- Con los cálculos **exactos** arriba (nada de software), vimos que A supera a B con p-valor ≈ 0.0096 , y el efecto esperado ronda **10-11 puntos** con un IC razonable.
- En **machine learning**, esta misma lógica se usa para:
 - **Selección de estrategias/modelos** por desempeño **robusto** (no solo por la media, sino por su **variabilidad**).
 - **Bagging/ensembles** (entrenar en remuestreos bootstrap y promediar).
 - **Evaluación de políticas** en *reinforcement learning* (intervalos y tests sobre el retorno).

6) Resumen operativo (receta sin software)

1. Define el **estadístico** que te importa (aquí, diferencia de medias).
2. Para **cada** estrategia, **enumera** (o simetriza por conteos) los remuestreos con reemplazo de tamaño (n) .
3. Calcula cada **media bootstrap** y su **probabilidad** $(\frac{1}{k_1!k_2!k_3!} \cdot \frac{1}{27})$.
4. Para el **p-valor de "A mejor que B"**, suma $(p_i - q_j)$ solo sobre pares con $(a_i \leq b_j)$.
5. (Opcional) Calcula un **IC** aproximado para (D) con la fórmula de errores estándar mostrada.