

Remuestreo Bootstrap

Guía de estudio: incertidumbre, error estándar, intervalos y aplicaciones en aprendizaje máquina

FCFM-UNACH
Licenciatura en Matemáticas Aplicadas
Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. Motivación	3
3. Idea fundamental del bootstrap	4
4. Distribución empírica	4
5. ¿Por qué el muestreo es con reemplazo?	5
6. Primer ejemplo manual	5
6.1. Algunas remuestras posibles	5
7. Número total de remuestras ordenadas	6
8. Distribución bootstrap de la media	6
9. Error estándar bootstrap	6
10. Sesgo bootstrap	7
11. Intervalos de confianza por percentiles	7
12. Bootstrap y aprendizaje máquina	7
12.1. Estimación de incertidumbre	8
12.2. Bagging	8
12.3. Random Forest	8
13. Ejemplo contextual: evaluación de estrategias	8
14. Bootstrap exacto de la media de A	9
15. Bootstrap exacto de la media de B	9
16. Distribución bootstrap de la diferencia	10
17. Error estándar bootstrap de la diferencia	10
18. Intervalo normal aproximado	11

19.Intervalo bootstrap directo para la diferencia	12
20.Qué aprendemos del ejemplo	12
21.Bootstrap no paramétrico y paramétrico	12
21.1. No paramétrico	12
21.2. Paramétrico	12
22.Bootstrap y bagging	13
23.Observaciones fuera de bolsa	13
24.Limitaciones del bootstrap	14
25.Datos dependientes	14
26.Receta computacional general	15
27.Preguntas de autoevaluación	15
28.Ejercicios propuestos	16
29.Actividad integradora	16
30.Ideas esenciales para recordar	17
31.Bibliografía recomendada	18

1. Propósito de esta guía

En estadística y aprendizaje máquina, no basta con calcular un estimador. También es necesario saber qué tan variable, estable o confiable es.

Si observamos una sola muestra, podemos calcular fácilmente una media, una mediana, una varianza o una medida de error. Sin embargo, aparece una pregunta más difícil:

¿cómo cambiaría ese estimador si repitiéramos el experimento?

La teoría clásica responde mediante distribuciones muestrales, el Teorema Central del Límite y resultados específicos para determinados estimadores. Pero cuando la distribución de los datos es desconocida o el estimador es complicado, obtener fórmulas analíticas puede ser difícil.

El método **bootstrap**, introducido por Efron, ofrece una estrategia computacional: reutilizar los datos observados para construir muchas muestras artificiales y estudiar cómo cambia el estadístico de interés.

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Explicar la motivación estadística del bootstrap.
2. Construir remuestras bootstrap con reemplazo.
3. Diferenciar entre muestra original, remuestra bootstrap y distribución bootstrap.
4. Estimar el error estándar de un estadístico mediante bootstrap.
5. Construir intervalos de confianza bootstrap sencillos.
6. Enumerar exactamente remuestreos cuando n es pequeño.
7. Comparar dos estrategias utilizando diferencias de medias remuestreadas.
8. Explicar la relación entre bootstrap, bagging y Random Forests.
9. Reconocer cuándo el bootstrap estima incertidumbre y cuándo se requiere un procedimiento adicional para una prueba de hipótesis.

2. Motivación

Supongamos que observamos

$$x_1, \dots, x_n$$

y calculamos un estadístico

$$T = T(x_1, \dots, x_n).$$

Puede ser:

- una media;
- una mediana;
- una varianza;
- un coeficiente de regresión;

- una métrica de error;
- una diferencia entre dos métodos.

La dificultad aparece porque el valor calculado depende de la muestra observada. Si repitiéramos el experimento muchas veces, obtendríamos diferentes valores de T . La colección teórica de esos valores define la **distribución muestral** del estadístico.

Interpretación

El bootstrap intenta aproximar esa distribución muestral sin disponer de nuevas observaciones de la población.

3. Idea fundamental del bootstrap

Partimos de la muestra observada

$$x_1, \dots, x_n.$$

El bootstrap no paramétrico sigue la siguiente idea:

1. Considerar la muestra observada como representación empírica de la población.
2. Extraer n observaciones **con reemplazo**.
3. Calcular el estadístico de interés en esa nueva muestra.
4. Repetir el procedimiento muchas veces.
5. Estudiar la distribución de los estadísticos resultantes.

Una remuestra bootstrap se denota típicamente por

$$X_1^*, \dots, X_n^*.$$

Si el estadístico original es

$$T = T(X_1, \dots, X_n),$$

su versión bootstrap es

$$T^* = T(X_1^*, \dots, X_n^*).$$

4. Distribución empírica

El bootstrap no paramétrico puede formularse mediante la distribución empírica

$$\hat{F}_n.$$

Esta distribución asigna masa

$$\frac{1}{n}$$

a cada observación.

Formalmente,

$$P^*(X^* = x_i) = \frac{1}{n}.$$

Por tanto, una remuestra bootstrap consiste en generar

$$X_1^*, \dots, X_n^* \stackrel{\text{iid}}{\sim} \hat{F}_n.$$

Interpretación

En lugar de suponer una distribución normal, exponencial o de otro tipo, el bootstrap usa directamente la distribución empírica construida con los datos.

5. ¿Por qué el muestreo es con reemplazo?

El reemplazo es esencial.

Si se tomara una muestra de tamaño n sin reemplazo a partir de los mismos n datos, siempre se recuperarían exactamente las mismas observaciones, quizá en distinto orden.

No habría variabilidad nueva.

Con reemplazo, en cambio:

- algunas observaciones pueden repetirse;
- otras pueden no aparecer;
- el estadístico cambia entre remuestras.

Esta variabilidad permite aproximar la incertidumbre del estimador.

6. Primer ejemplo manual

Consideremos

$$x = \{2, 4, 5\}$$

con

$$n = 3.$$

Queremos estudiar la media.

La media original es

$$\bar{x} = \frac{2 + 4 + 5}{3} = \frac{11}{3} \approx 3.67.$$

6.1. Algunas remuestras posibles

Cada remuestra contiene tres extracciones con reemplazo.

Por ejemplo:

$$\{2, 2, 4\} \implies \bar{x}^* = \frac{8}{3} \approx 2.67,$$

$$\{5, 4, 5\} \implies \bar{x}^* = \frac{14}{3} \approx 4.67,$$

$$\{2, 4, 5\} \implies \bar{x}^* = \frac{11}{3} \approx 3.67,$$

$$\{2, 2, 2\} \implies \bar{x}^* = 2.$$

7. Número total de remuestras ordenadas

Hay tres posibilidades en cada una de las tres extracciones.
Por tanto,

$$3^3 = 27$$

remuestras ordenadas posibles.
Muchas producen la misma media.
Por ejemplo,

$$(2, 2, 4), \quad (2, 4, 2), \quad (4, 2, 2)$$

son remuestras distintas como secuencias, pero producen el mismo valor

$$\bar{x}^* = \frac{8}{3}.$$

8. Distribución bootstrap de la media

Algunas medias posibles son:

Composición	Media
$\{2, 2, 2\}$	2.00
$\{2, 2, 4\}$	2.67
$\{2, 2, 5\}$	3.00
$\{2, 4, 4\}$	3.33
$\{2, 4, 5\}$	3.67
$\{2, 5, 5\}$	4.00
$\{4, 4, 4\}$	4.00
$\{4, 4, 5\}$	4.33
$\{4, 5, 5\}$	4.67
$\{5, 5, 5\}$	5.00

Las frecuencias de estas medias forman una distribución empírica bootstrap.

9. Error estándar bootstrap

Supongamos que generamos

$$B$$

remuestras y obtenemos

$$T_1^*, \dots, T_B^*.$$

Definimos

$$\bar{T}^* = \frac{1}{B} \sum_{b=1}^B T_b^*.$$

El error estándar bootstrap se estima mediante

$$\widehat{\text{SE}}_{\text{boot}}(T) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (T_b^* - \bar{T}^*)^2}. \quad (1)$$

Interpretación

El error estándar bootstrap mide cuánto cambia el estimador cuando la muestra observada se perturba mediante remuestreo.

10. Sesgo bootstrap

El bootstrap también permite aproximar el sesgo del estimador. Si el valor observado es

$$\hat{\theta} = T(x_1, \dots, x_n),$$

se estima

$$\widehat{\text{Bias}}_{\text{boot}} = \bar{T}^* - \hat{\theta}. \quad (2)$$

Un valor cercano a cero indica que el centro de la distribución bootstrap está cerca del estimador observado.

11. Intervalos de confianza por percentiles

Una de las construcciones más sencillas es el intervalo percentil. Para un nivel de confianza del 95 %, se toman los percentiles

$$Q_{0.025}(T^*)$$

y

$$Q_{0.975}(T^*).$$

El intervalo es

$$[Q_{0.025}(T^*), Q_{0.975}(T^*)]. \quad (3)$$

Punto de atención

El intervalo percentil es sencillo, pero no siempre es el método bootstrap más preciso. Existen alternativas como el intervalo básico y el BCa. Para una primera introducción, el percentil es suficiente.

12. Bootstrap y aprendizaje máquina

En aprendizaje máquina, el bootstrap aparece en varios contextos.

12.1. Estimación de incertidumbre

Puede utilizarse para estudiar la variabilidad de:

- accuracy;
- RMSE;
- AUC;
- error de predicción;
- coeficientes;
- importancia de variables.

12.2. Bagging

El *bootstrap aggregating* consiste en:

1. generar múltiples remuestras bootstrap;
2. entrenar un modelo en cada una;
3. combinar las predicciones.

En regresión, suele promediarse.

En clasificación, puede utilizarse votación o promediado de probabilidades.

12.3. Random Forest

Random Forest combina dos fuentes de aleatoriedad:

- remuestreo bootstrap de observaciones;
- selección aleatoria de variables candidatas en cada división.

Conexión con aprendizaje máquina

El bootstrap no sólo sirve para estimar incertidumbre. También puede utilizarse como mecanismo de construcción de modelos ensamblados.

13. Ejemplo contextual: evaluación de estrategias

Supongamos que dos estrategias de un videojuego producen puntuaciones distintas.

La estrategia A produce

$$x = \{80, 75, 90\}.$$

La estrategia B produce

$$y = \{70, 65, 78\}.$$

Nuestro estadístico de interés será la diferencia de medias

$$D = \bar{x} - \bar{y}.$$

Las medias observadas son

$$\bar{x} = \frac{245}{3} \approx 81.667,$$

$$\bar{y} = \frac{213}{3} = 71.$$

Por tanto,

$$D_{\text{obs}} = \frac{32}{3} \approx 10.667.$$

14. Bootstrap exacto de la media de A

Un remuestreo de tamaño 3 puede describirse mediante conteos

$$(k_1, k_2, k_3),$$

con

$$k_1 + k_2 + k_3 = 3.$$

La probabilidad es multinomial:

$$P(k_1, k_2, k_3) = \frac{3!}{k_1!k_2!k_3!} \left(\frac{1}{3}\right)^3. \quad (4)$$

La media correspondiente es

$$\bar{x}^* = \frac{80k_1 + 75k_2 + 90k_3}{3}.$$

Agrupando por valor de la media:

$\bar{x}^*$	Conteo típico	Probabilidad total
75	(0, 3, 0)	1/27
230/3	(1, 2, 0)	1/9
235/3	(2, 1, 0)	1/9
80	(3, 0, 0) o (0, 2, 1)	4/27
245/3	(1, 1, 1)	2/9
250/3	(2, 0, 1)	1/9
85	(0, 1, 2)	1/9
260/3	(1, 0, 2)	1/9
90	(0, 0, 3)	1/27

15. Bootstrap exacto de la media de B

Para

$$y = \{70, 65, 78\},$$

la media bootstrap es

$$\bar{y}^* = \frac{70\ell_1 + 65\ell_2 + 78\ell_3}{3},$$

con

$$\ell_1 + \ell_2 + \ell_3 = 3.$$

La distribución agrupada es:

$\bar{y}^*$	Conteo típico	Probabilidad
65	(0, 3, 0)	1/27
200/3	(1, 2, 0)	1/9
205/3	(2, 1, 0)	1/9
208/3	(0, 2, 1)	1/9
70	(3, 0, 0)	1/27
71	(1, 1, 1)	2/9
218/3	(2, 0, 1)	1/9
221/3	(0, 1, 2)	1/9
226/3	(1, 0, 2)	1/9
78	(0, 0, 3)	1/27

16. Distribución bootstrap de la diferencia

Si los dos grupos se remuestran independientemente,

$$D^* = \bar{X}^* - \bar{Y}^*.$$

La distribución de D^* se obtiene combinando todas las parejas posibles de valores bootstrap de A y B.

Por ejemplo,

$$P(D^* \leq 0) = \sum_i \sum_j \mathbf{1}\{a_i \leq b_j\} p_i q_j.$$

En este ejemplo, sólo los valores bootstrap más bajos de A pueden quedar por debajo de algunos valores de B.

Del cálculo exacto se obtiene

$$P(D^* \leq 0) = \frac{7}{729} \approx 0.0096.$$

Nota de precisión estadística

Esta cantidad describe la masa de la *distribución bootstrap empírica de la diferencia* que queda en $D^* \leq 0$, al remuestrear cada grupo desde su propia distribución empírica. No debe identificarse automáticamente con un p-valor válido para la hipótesis

$$H_0 : \mu_A \leq \mu_B.$$

Una prueba bootstrap formal requiere construir la distribución bajo la hipótesis nula, por ejemplo mediante centrado, remuestreo bajo una restricción nula o un esquema de permutación apropiado. Para fines introductorios, $P(D^* \leq 0)$ puede interpretarse como una medida descriptiva de la incertidumbre bootstrap sobre el signo de la diferencia.

17. Error estándar bootstrap de la diferencia

Bajo remuestreo independiente,

$$\text{Var}(D^*) = \text{Var}(\bar{X}^*) + \text{Var}(\bar{Y}^*).$$

Para A, utilizando la varianza empírica con divisor n ,

$$\text{Var}_{\text{emp}}(X) = 38.889.$$

Por tanto,

$$\text{Var}(\bar{X}^*) = \frac{38.889}{3} = 12.963,$$

y

$$\text{SE}_A \approx 3.601.$$

Para B,

$$\text{Var}_{\text{emp}}(Y) = 28.667,$$

de modo que

$$\text{Var}(\bar{Y}^*) = \frac{28.667}{3} = 9.556,$$

y

$$\text{SE}_B \approx 3.092.$$

Entonces,

$$\text{SE}_D = \sqrt{\text{SE}_A^2 + \text{SE}_B^2} \approx 4.746.$$

18. Intervalo normal aproximado

Una aproximación normal sencilla es

$$D_{\text{obs}} \pm 1.96 \text{SE}_D.$$

Sustituyendo,

$$10.667 \pm 1.96(4.746).$$

Esto produce aproximadamente

$$[1.36, 19.97].$$

Punto de atención

Este intervalo utiliza una aproximación normal basada en el error estándar estimado. No es lo mismo que un intervalo bootstrap percentil construido directamente a partir de los cuantiles de D^* .

19. Intervalo bootstrap directo para la diferencia

Si generamos muchas diferencias

$$D_1^*, \dots, D_B^*,$$

podemos construir directamente

$$[Q_{0.025}(D^*), Q_{0.975}(D^*)].$$

Esta construcción es preferible a combinar por separado percentiles de $\bar{X}^*$ y $\bar{Y}^*$.

Interpretación

Cuando el objeto de interés es

$$D = \bar{X} - \bar{Y},$$

lo natural es remuestrear y estudiar directamente la distribución de

$$D^*.$$

20. Qué aprendemos del ejemplo

El ejemplo ilustra varias ideas:

- el bootstrap puede construirse exactamente cuando n es muy pequeño;
- la distribución bootstrap de un estadístico puede ser discreta;
- la variabilidad del estadístico se observa directamente en sus remuestras;
- para comparar dos métodos conviene remuestrear el estadístico de diferencia;
- la interpretación inferencial depende de cómo se construye la distribución bootstrap.

21. Bootstrap no paramétrico y paramétrico

El material anterior corresponde a bootstrap **no paramétrico**.

21.1. No paramétrico

Se remuestra directamente de los datos observados:

$$X^* \sim \hat{F}_n.$$

No se especifica una familia paramétrica.

21.2. Paramétrico

Primero se ajusta un modelo, por ejemplo

$$X \sim \mathcal{N}(\mu, \sigma^2),$$

se estiman

$$\hat{\mu}, \hat{\sigma},$$

y después se generan datos desde

$$X^* \sim \mathcal{N}(\hat{\mu}, \hat{\sigma}^2).$$

Interpretación

El bootstrap paramétrico incorpora más supuestos, pero puede ser útil cuando existe un modelo probabilístico bien justificado.

22. Bootstrap y bagging

Supongamos que disponemos de un conjunto

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n.$$

Generamos

$$B$$

datasets bootstrap

$$\mathcal{D}_1^*, \dots, \mathcal{D}_B^*.$$

Entrenamos un predictor

$$\hat{f}_b$$

en cada conjunto.

En regresión, el predictor bagging es

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x).$$

En clasificación pueden promediarse probabilidades o utilizarse votos.

Conexión con aprendizaje máquina

Bagging usa bootstrap no para estimar directamente un error estándar, sino para generar diversidad entre modelos y después reducir variabilidad mediante agregación.

23. Observaciones fuera de bolsa

En una remuestra bootstrap de tamaño n , algunas observaciones no aparecen.

Estas observaciones se denominan *out-of-bag* (OOB).

La probabilidad de que una observación específica no sea seleccionada en una extracción es

$$1 - \frac{1}{n}.$$

Después de n extracciones,

$$P(\text{no aparecer}) = \left(1 - \frac{1}{n}\right)^n.$$

Cuando n es grande,

$$\left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1} \approx 0.368.$$

Por tanto, alrededor del 36.8 % de las observaciones quedan fuera de una remuestra bootstrap típica.

En consecuencia, alrededor del

$$1 - e^{-1} \approx 0.632$$

de las observaciones originales aparecen al menos una vez.

Interpretación

Este resultado explica el conocido “0.632” asociado al bootstrap y permite utilizar observaciones OOB como conjunto de evaluación en métodos ensamblados.

24. Limitaciones del bootstrap

El bootstrap es poderoso, pero no universal.

Puede presentar dificultades cuando:

- la muestra es extremadamente pequeña;
- los datos tienen fuerte dependencia temporal o espacial;
- el estadístico es muy irregular;
- existen valores extremos dominantes;
- la muestra observada representa mal a la población;
- se remuestrea ignorando la estructura del experimento.

25. Datos dependientes

Si los datos son una serie de tiempo, remuestrear observaciones individuales puede destruir la dependencia temporal.

En ese caso se utilizan métodos como:

- block bootstrap;
- moving block bootstrap;
- stationary bootstrap.

La idea es remuestrear bloques y no puntos aislados.

Punto de atención

La regla “muestrear con reemplazo observaciones individuales” es adecuada para datos aproximadamente i.i.d. No debe aplicarse mecánicamente a cualquier conjunto de datos.

26. Receta computacional general

Para estimar la incertidumbre de un estadístico T :

1. Calcular

$$\hat{\theta} = T(x_1, \dots, x_n).$$

2. Para

$$b = 1, \dots, B,$$

generar una remuestra

$$x_1^{*(b)}, \dots, x_n^{*(b)}.$$

3. Calcular

$$T_b^*.$$

4. Estudiar

$$T_1^*, \dots, T_B^*.$$

5. Estimar error estándar, sesgo o intervalos.

En aplicaciones reales suelen emplearse cientos o miles de remuestras.

27. Preguntas de autoevaluación

1. ¿Qué problema intenta resolver el bootstrap?
2. ¿Por qué es necesario remuestrear con reemplazo?
3. ¿Qué diferencia existe entre muestra original y remuestra bootstrap?
4. ¿Qué representa la distribución bootstrap?
5. ¿Qué es el error estándar bootstrap?
6. ¿Qué representa el sesgo bootstrap?
7. ¿Cómo se construye un intervalo percentil?
8. ¿Por qué $3^3 = 27$ en el ejemplo con tres datos?
9. ¿Qué función cumplen los conteos multinomiales?
10. ¿Por qué conviene estudiar directamente D^* cuando interesa una diferencia de medias?
11. ¿Qué diferencia existe entre bootstrap no paramétrico y paramétrico?
12. ¿Qué relación existe entre bootstrap y bagging?
13. ¿Qué significa que una observación sea OOB?
14. ¿Por qué aproximadamente el 36.8% queda fuera de una remuestra bootstrap?
15. ¿Por qué un bootstrap ordinario puede ser inadecuado para series de tiempo?

28. Ejercicios propuestos

Ejercicio 1. Enumeración exacta.

Para

$$x = \{1, 3\},$$

enumere todas las remuestras bootstrap de tamaño 2 y construya la distribución exacta de la media.

Ejercicio 2. Media con tres observaciones.

Para

$$x = \{2, 4, 5\},$$

calcule las probabilidades exactas de todas las medias bootstrap.

Ejercicio 3. Error estándar.

A partir de la distribución exacta anterior, calcule el error estándar bootstrap de $\bar{x}$.

Ejercicio 4. Sesgo.

Compare

$$\mathbb{E}^*[\bar{X}^*]$$

con

$$\bar{x}.$$

Ejercicio 5. Mediana.

Repita el ejemplo para el estadístico mediana.

Ejercicio 6. Diferencia de medias.

Para los datos A y B de esta guía, enumere la distribución exacta de

$$D^*.$$

Ejercicio 7. Intervalo percentil.

Utilice la distribución exacta de D^* para construir un intervalo percentil.

Ejercicio 8. OOB.

Demuestre que

$$\left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1}.$$

Ejercicio 9. Bagging.

Explique por qué promediar modelos puede reducir varianza cuando los modelos individuales son inestables.

Ejercicio 10. Dependencia temporal.

Explique por qué no sería recomendable remuestrear días individuales de una serie temporal con fuerte autocorrelación.

29. Actividad integradora

Suponga que dos algoritmos de aprendizaje máquina se evalúan sobre el mismo conjunto de casos y producen errores

$$e_{A,1}, \dots, e_{A,n},$$

$$e_{B,1}, \dots, e_{B,n}.$$

Diseñe un procedimiento bootstrap para estudiar la diferencia

$$\Delta = \bar{e}_A - \bar{e}_B.$$

Debe especificar:

1. qué unidad debe remuestrearse;
2. por qué el remuestreo debe preservar el emparejamiento si ambos modelos se evalúan en los mismos casos;
3. qué estadístico calcular en cada iteración;
4. cómo estimar el error estándar;
5. cómo construir un intervalo percentil;
6. cómo interpretar un intervalo que contiene al cero.

Conexión con aprendizaje máquina

Este ejemplo muestra una idea fundamental: el esquema de remuestreo debe respetar la estructura del problema. Si los errores A y B corresponden al mismo caso, deben remuestrearse como pares.

30. Ideas esenciales para recordar

- Bootstrap aproxima la distribución muestral reutilizando los datos observados.
- El remuestreo no paramétrico se realiza con reemplazo desde la distribución empírica.
- El error estándar bootstrap mide variabilidad del estimador.
- Los percentiles bootstrap pueden utilizarse para construir intervalos de confianza.
- En muestras pequeñas, la distribución bootstrap puede enumerarse exactamente.
- Para comparar dos métodos conviene remuestrear directamente el estadístico de interés.
- Bootstrap y pruebas de hipótesis no son automáticamente lo mismo: la distribución nula debe construirse adecuadamente.
- Bagging utiliza remuestras bootstrap para generar diversidad entre modelos.
- Las observaciones OOB ofrecen una fuente natural de evaluación.
- El esquema de remuestreo debe respetar independencia, emparejamiento y dependencia temporal o espacial de los datos.

31. Bibliografía recomendada

Referencias

- [1] B. Efron, “Bootstrap Methods: Another Look at the Jackknife”, *The Annals of Statistics*, 7(1), 1979.
- [2] B. Efron y R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall/CRC, 1993.
- [3] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2a ed., Springer, 2009.
- [4] G. James, D. Witten, T. Hastie y R. Tibshirani, *An Introduction to Statistical Learning*, Springer.