

```

---
title: "Biomedicina: Mezcla Gaussiana (GMM) con Área y Circularidad Celular – Ejemplo mínimo"
author: "FCFM-UNACH | Matemáticas Aplicadas"
date: "2025-08-26"
output:
  html_document:
    toc: true
    toc_float: true
    df_print: paged
  pdf_document: default
fontsize: 11pt
---

```

Motivación

En análisis de imágenes biomédicas (microscopía), es común describir células por **medidas morfológicas**:

- **Área** (μm^2),
- **Circularidad** (0–1; 1 = círculo perfecto, valores pequeños = formas alargadas).

En muchos cultivos coexisten **dos fenotipos**:

1. **Células pequeñas y redondeadas**,
2. **Células más grandes y alargadas**.

Para **distinguir automáticamente** estos fenotipos sin forzar un único promedio, modelaremos las observaciones $((\text{Área}, \text{Circularidad}))$ con un **Modelo de Mezcla Gaussiana (GMM)** de **dos componentes** y estimaremos sus parámetros mediante **EM (Expectation–Maximization)**. Empezaremos con un **ejemplo mínimo** que permite **hacer cuentas a mano** y verificar cada paso, y luego contrastaremos con `mclust`.

Formulación (2D) y algoritmo EM

Sea $X \in \mathbb{R}^2$ el vector $((\text{Área}, \text{Circularidad}))$. Modelo:

$$p(x|\text{Theta}) = \sum_{k=1}^2 \pi_k \mathcal{N}(x|\mu_k, \Sigma_k), \quad \pi_k > 0, \quad \pi_1 + \pi_2 = 1.$$

- $\mu_k \in \mathbb{R}^2$ (media vectorial),
- $\Sigma_k \in \mathbb{R}^{2 \times 2}$ (covarianza).

Variables latentes: $Z_i \in \{1, 2\}$ indica el componente generador de (x_i) . **E-step** (responsabilidades/posteriores):

$$\gamma_{ik} = \frac{\pi_k \phi_2(x_i; \mu_k, \Sigma_k)}{\sum_{j=1}^2 \pi_j \phi_2(x_i; \mu_j, \Sigma_j)}.$$

M-step:

$$N_k = \sum_i \gamma_{ik}, \quad \pi_k^{\text{new}} = \frac{N_k}{N}, \quad \mu_k^{\text{new}} = \frac{1}{N_k} \sum_i \gamma_{ik} x_i, \quad \Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_i \gamma_{ik} (x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^{\text{top}}.$$

Para **cálculo manual** usaremos Σ_k **diagonal** (independencia entre Área y Circularidad dentro de cada componente), lo que simplifica ϕ_2 a producto de normales 1D.

Datos (6 observaciones)

Tomamos **N = 6** células con $((\text{Área} \sim \mu \text{ m}^2, \text{Circularidad}))$:

```

X <- matrix(c(
  130, 0.92,
  145, 0.88,
  190, 0.74, # frontera
  200, 0.70, # frontera
  230, 0.68,
  245, 0.60
), ncol = 2, byrow = TRUE)
colnames(X) <- c("Area", "Circ")
(DF <- data.frame(i = 1:nrow(X), X))

```

```

##   i Area Circ
## 1 1  130 0.92
## 2 2  145 0.88
## 3 3  190 0.74
## 4 4  200 0.70
## 5 5  230 0.68
## 6 6  245 0.60

```

“**Verdad terreno**” (para evaluar ARI; aquí solo con fines docentes):

- Pequeñas/redondeadas = clase **S** para $i = 1,2$
- Grandes/alargadas = clase **L** para $i = 3,4,5,6$

```
truth <- factor(c("S","S","L","L","L","L"))
truth
```

```
## [1] S S L L L L
## Levels: L S
```

Inicialización (intuitiva, diagonal)

- Pesos: $\pi_1 = \pi_2 = 0.5$
- Medias:

$$\mu_1 = (140, 0.89), \mu_2 = (240, 0.62)$$
- Desviaciones estándar (por dimensión):

$$\sigma_1 = (15, 0.05), \sigma_2 = (20, 0.06)$$
- Covarianzas: $\Sigma_k = \text{diag}(\sigma_{k,1}^2, \sigma_{k,2}^2)$.

```
pi1 <- 0.5; pi2 <- 0.5
mu1 <- c(140, 0.89); mu2 <- c(240, 0.62)
sd1 <- c(15, 0.05); sd2 <- c(20, 0.06)
```

E-step (una vuelta): responsabilidades γ_{ik}

Con Σ_k diagonal:

$$\phi_2(x; \mu_k, \Sigma_k) = \prod_{d=1}^2 \phi(x^{(d)}; \mu_k^{(d)}, \sigma_k^{(d)})$$

y

$$\gamma_{i1} = \frac{\pi_1 \prod_d \phi(x_i^{(d)}; \mu_1^{(d)}, \sigma_1^{(d)})}{\pi_1 \prod_d \phi(x_i^{(d)}; \mu_1^{(d)}, \sigma_1^{(d)}) + \pi_2 \prod_d \phi(x_i^{(d)}; \mu_2^{(d)}, \sigma_2^{(d)})}, \quad \gamma_{i2} = 1 - \gamma_{i1}$$

```
# densidad 2D con covarianza diagonal (producto de dnorm)
d2_diag <- function(x, mu, sd) dnorm(x[1], mu[1], sd[1]) * dnorm(x[2], mu[2], sd[2])

num1 <- apply(X, 1, function(x) pi1 * d2_diag(x, mu1, sd1))
num2 <- apply(X, 1, function(x) pi2 * d2_diag(x, mu2, sd2))
den   <- num1 + num2

gamma1 <- num1 / den
gamma2 <- 1 - gamma1

E_table <- data.frame(
  i      = 1:nrow(X),
  Area   = X[,1],
  Circ   = X[,2],
  gamma_1 = signif(gamma1, 4),
  gamma_2 = signif(gamma2, 4)
)
E_table
```

```
##   i Area Circ  gamma_1  gamma_2
## 1 1  130 0.92 1.000e+00 9.400e-13
## 2 2  145 0.88 1.000e+00 7.108e-10
## 3 3  190 0.74 1.142e-02 9.886e-01
## 4 4  200 0.70 7.060e-06 1.000e+00
## 5 5  230 0.68 6.726e-12 1.000e+00
## 6 6  245 0.60 1.980e-18 1.000e+00
```

Referencia (aprox.): $\gamma_{11} \approx (1.0000, 1.0000, \mathbf{0.0114}, \mathbf{0.0000071}, 0, 0)$. Observa cómo las dos observaciones “frontera” (190, 0.74) y (200, 0.70) muestran **probabilidades blandas**.

M-step: actualización (π, μ, Σ)

```

N1 <- sum(gamma1); N2 <- sum(gamma2)
pi1_new <- N1/nrow(X); pi2_new <- N2/nrow(X)

mu1_new <- colSums(gamma1 * X) / N1
mu2_new <- colSums(gamma2 * X) / N2

# Covarianzas diagonales actualizadas (varianzas por dimensión)
var1_new <- colSums(gamma1 * (X - matrix(mu1_new, nrow(X), 2, byrow=TRUE))^2) / N1
var2_new <- colSums(gamma2 * (X - matrix(mu2_new, nrow(X), 2, byrow=TRUE))^2) / N2
sd1_new <- sqrt(var1_new); sd2_new <- sqrt(var2_new)

M_table <- data.frame(
  componente = c("1 (S pequeñas/redondas)", "2 (L grandes/alargadas)"),
  N_k = c(N1, N2),
  pi_k = c(pi1_new, pi2_new),
  mu_Area = c(mu1_new[1], mu2_new[1]),
  mu_Circ = c(mu1_new[2], mu2_new[2]),
  sd_Area = c(sd1_new[1], sd2_new[1]),
  sd_Circ = c(sd1_new[2], sd2_new[2]),
  stringsAsFactors = FALSE
)

# Redondear solo numéricas
nums <- sapply(M_table, is.numeric)
M_table_round <- M_table
M_table_round[, nums] <- lapply(M_table_round[, nums], round, 4)
M_table_round

```

```

##           componente      N_k   pi_k  mu_Area mu_Circ sd_Area sd_Circ
## 1 1 (S pequeñas/redondas) 2.0114 0.3352 137.7984 0.8991 8.4563 0.0233
## 2 2 (L grandes/alargadas) 3.9886 0.6648 216.3252 0.6798 22.1725 0.0510

```

Valores de referencia (aprox.): $\pi_1^{\text{new}} \approx 0.3352$, $\mu_1^{\text{new}} \approx (137.7984, 0.8991)$, $\sigma_1^{\text{new}} \approx (8.4563, 0.02329)$, $\pi_2^{\text{new}} \approx 0.6648$, $\mu_2^{\text{new}} \approx (216.3252, 0.67983)$, $\sigma_2^{\text{new}} \approx (22.1725, 0.05096)$

Verificación: mejora de log-verosimilitud

```

loglik <- function(X, p1, m1, s1, p2, m2, s2){
  sum(log( p1 * apply(X, 1, function(x) d2_diag(x, m1, s1)) +
            p2 * apply(X, 1, function(x) d2_diag(x, m2, s2)) ))
}

ll0 <- loglik(X, pi1, mu1, sd1, pi2, mu2, sd2)
ll1 <- loglik(X, pi1_new, mu1_new, sd1_new, pi2_new, mu2_new, sd2_new)
c(ll_inicial = round(ll0, 4), ll_despues_EM = round(ll1, 4))

```

```

##      ll_inicial ll_despues_EM
##      -24.5320   -17.6169

```

Deberías observar un aumento claro (p. ej., de ≈ -24.5320 a ≈ -17.6169).

Visualización: responsabilidades (color) y clases


Coloreamos por γ_{i1} (probabilidad de componente 1) y superponemos las etiquetas verdaderas (S/L) para inspección visual.

```

library(ggplot2)

viz <- data.frame(DF, truth = truth, gamma1 = gamma1)
ggplot(viz, aes(Area, Circ)) +
  geom_point(aes(color = gamma1), size = 3) +
  geom_text(aes(label = truth), nudge_y = 0.007, size = 3) +
  scale_color_gradient(name = "P(comp 1)", low = "steelblue", high = "tomato") +
  labs(title = "Células: Área vs Circularidad – color = responsabilidad de componente 1",
       x = "Área ( $\mu\text{m}^2$ )", y = "Circularidad") +
  theme_minimal()

```



Las observaciones de **frontera** deberían mostrar color intermedio (mayor incertidumbre).

Confirmación con mclust y ARI

Usamos `Mclust` para ajustar un GMM **2D** automáticamente (elige `\(G\)` con BIC) y comparamos con la **verdad terreno** mediante **ARI** (Adjusted Rand Index).

```
# install.packages("mclust") # si hace falta
library(mclust)
```

```
## Package 'mclust' version 6.1.1
## Type 'citation("mclust")' for citing this R package in publications.
```

```
fit <- Mclust(X, G = 1:3) # selección de G por BIC
summary(fit)
```

```
## -----
## Gaussian finite mixture model fitted by EM algorithm
## -----
##
## Mclust EEE (ellipsoidal, equal volume, shape and orientation) model with 3
## components:
##
## log-likelihood n df      BIC      ICL
##      -6.246555 6 11 -32.20246 -32.20246
##
## Clustering table:
## 1 2 3
## 2 2 2
```

```
pred <- factor(fit$classification)
table(truth, pred)
```

```
##      pred
## truth 1 2 3
##      L 0 2 2
##      S 2 0 0
```

```
# ARI (1 = concordancia perfecta; 0 = aleatorio; <0 peor que aleatorio)
ARI <- adjustedRandIndex(truth, pred)
ARI
```

```
## [1] 0.4444444
```

Al ser un ejemplo muy separado, el ARI suele ser **alto** (cercano a 1). No esperes coincidencia exacta con **una sola** vuelta manual de EM: `Mclust` itera hasta converger y puede asignar etiquetas de componente intercambiadas (label switching).

Ejercicios sugeridos

1. Repite **E-step** con (π, μ, Σ) **actualizados** para confirmar que la **log-verosimilitud** vuelve a aumentar.
2. Cambia la **inicialización** (por ejemplo, $\pi_1=0.7, \pi_2=0.3$) o medias más cercanas) y discute el impacto en las responsabilidades de los puntos frontera.
3. Permite Σ_k **no diagonal** (usa `McLust` y compara BIC entre modelos `EEE`, `VVV`, etc.).
4. Genera un **dataset sintético** mayor con dos gaussianas 2D (100–200 puntos) y repite el flujo: responsabilidades “suaves”, log-verosimilitud vs iteraciones, ARI.

Prepara un **dataset sintético** grande (con control de solapamiento) y una **lámina** de clase (PDF) con las fórmulas del EM y el mapa de responsabilidades.