

Biomedicina: Modelos de Mezcla Gaussiana (GMM)

Área y circularidad celular como ejemplo de clasificación no supervisada

FCFM-UNACH

Licenciatura en Matemáticas Aplicadas

Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. Motivación biomédica	3
3. Representación matemática de las observaciones	4
3.1. Interpretación de los pesos	4
4. La variable latente	5
5. El algoritmo Expectation–Maximization	5
5.1. Paso E: responsabilidades	5
5.2. Paso M: actualización de parámetros	6
6. Simplificación: covarianzas diagonales	6
7. Datos del ejemplo	7
8. Inicialización del modelo	7
8.1. ¿Por qué importa la inicialización?	8
9. Primera iteración: paso E	8
9.1. Lectura probabilística	9
10. Primera iteración: paso M	10
10.1. ¿Qué cambió después de una iteración?	11
11. Log-verosimilitud y criterio de mejora	11
12. Visualización de las responsabilidades	12
13. Del agrupamiento suave a una clasificación	13
14. Ajuste automático con mclust	13
15. Evaluación con Adjusted Rand Index	13
15.1. Label switching	14
16. Esquema completo del algoritmo EM	14
17. Código compacto para una iteración	15

18.Preguntas de autoevaluación	16
19.Ejercicios propuestos	16
20.Extensiones naturales	17
21.Ideas esenciales para recordar	17
22.Bibliografía recomendada	18

1. Propósito de esta guía

Los *Modelos de Mezcla Gaussiana* (Gaussian Mixture Models, GMM) constituyen una herramienta probabilística para describir poblaciones heterogéneas. A diferencia de un modelo basado en una sola distribución normal, un GMM permite representar los datos como una combinación de varias subpoblaciones, cada una con su propia media, dispersión y peso relativo.

En esta guía se estudia un ejemplo biomédico sencillo en el que cada célula es descrita mediante dos características morfológicas: su área y su circularidad. El objetivo no es únicamente ejecutar un algoritmo en R, sino comprender la estructura probabilística del modelo, interpretar las probabilidades de pertenencia a cada componente y seguir manualmente una iteración del algoritmo EM.

Objetivos de aprendizaje

Al finalizar el estudio de este material, el estudiante deberá ser capaz de:

1. Formular un modelo de mezcla Gaussiana bidimensional con dos componentes.
2. Explicar el papel de la variable latente que identifica el componente generador.
3. Calcular e interpretar las responsabilidades del paso E del algoritmo EM.
4. Actualizar pesos, medias y covarianzas en el paso M.
5. Relacionar el algoritmo EM con la maximización de la log-verosimilitud.
6. Interpretar una clasificación “suave” frente a una clasificación determinista.
7. Comparar un cálculo manual con el ajuste automático proporcionado por `mclust`.

2. Motivación biomédica

En análisis de imágenes biomédicas, especialmente en microscopía, es frecuente resumir la morfología de una célula mediante variables cuantitativas. Dos medidas particularmente útiles son:

- **Área** (μm^2): aproxima el tamaño de la célula observado en la imagen.
- **Circularidad**: toma valores entre 0 y 1; valores cercanos a 1 corresponden a formas aproximadamente circulares, mientras que valores menores suelen asociarse con formas más alargadas o irregulares.

Supongamos que en un cultivo celular coexisten dos fenotipos principales:

1. células pequeñas y relativamente redondeadas;
2. células más grandes y alargadas.

Si los dos fenotipos son mezclados en una misma muestra, el cálculo de una sola media global puede ocultar la existencia de ambas poblaciones. Un GMM permite modelar explícitamente esta heterogeneidad.

Interpretación

El interés del modelo no consiste solamente en “separar puntos”. Cada componente Gaussiano representa una distribución probabilística asociada a una subpoblación. Por ello, para una célula localizada cerca de la frontera entre dos grupos, el modelo puede asignar probabilidades intermedias de pertenencia en lugar de imponer una decisión rígida.

3. Representación matemática de las observaciones

Cada célula será representada mediante un vector bidimensional

$$X = \begin{pmatrix} \text{Área} \\ \text{Circularidad} \end{pmatrix} \in \mathbb{R}^2.$$

Para la i -ésima célula escribiremos

$$x_i = \begin{pmatrix} x_{i1} \\ x_{i2} \end{pmatrix},$$

donde x_{i1} corresponde al área y x_{i2} a la circularidad.

En lugar de asumir que todos los datos provienen de una única normal bidimensional, consideraremos una mezcla de dos distribuciones Gaussianas:

$$p(x \mid \Theta) = \sum_{k=1}^2 \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad (1)$$

con

$$\pi_k > 0, \quad \pi_1 + \pi_2 = 1.$$

El conjunto de parámetros puede escribirse como

$$\Theta = \{\pi_1, \pi_2, \mu_1, \mu_2, \Sigma_1, \Sigma_2\}.$$

Aquí:

- π_k es el peso o proporción del componente k ;
- $\mu_k \in \mathbb{R}^2$ es el vector de medias;
- $\Sigma_k \in \mathbb{R}^{2 \times 2}$ es la matriz de covarianza.

3.1. Interpretación de los pesos

Los parámetros π_1 y π_2 pueden interpretarse como probabilidades *a priori* de pertenecer a cada componente. Por ejemplo, si

$$\pi_1 = 0.35, \quad \pi_2 = 0.65,$$

el modelo describe una población en la que aproximadamente el 35 % de las observaciones procede del primer componente y el 65 % del segundo, antes de considerar las características morfológicas particulares de una célula.

4. La variable latente

Para formular el modelo de manera más explícita introducimos una variable no observada

$$Z_i \in \{1, 2\}.$$

La interpretación es

$$Z_i = k \iff \text{la observación } x_i \text{ fue generada por el componente } k.$$

La variable Z_i es llamada **latente** porque no se observa directamente. En una imagen microscópica medimos área y circularidad, pero no necesariamente conocemos el fenotipo verdadero de cada célula.

Esta ausencia de información es precisamente la razón por la que se utiliza el algoritmo EM.

Punto de atención

Si los valores de Z_i fueran conocidos para todas las observaciones, el problema sería mucho más sencillo: bastaría estimar una media y una covarianza para cada grupo. EM se utiliza porque la pertenencia a los grupos es desconocida.

5. El algoritmo Expectation–Maximization

El algoritmo EM alterna dos operaciones:

Paso E: estima probabilísticamente la pertenencia de cada observación a cada componente.

Paso M: utiliza esas probabilidades como pesos para actualizar los parámetros del modelo.

El procedimiento se repite hasta que los parámetros o la log-verosimilitud cambian muy poco.

5.1. Paso E: responsabilidades

Definimos

$$\gamma_{ik} = P(Z_i = k \mid X_i = x_i, \Theta).$$

Por el teorema de Bayes,

$$\gamma_{ik} = \frac{\pi_k \phi_2(x_i; \mu_k, \Sigma_k)}{\sum_{j=1}^2 \pi_j \phi_2(x_i; \mu_j, \Sigma_j)}, \quad (2)$$

donde ϕ_2 es la densidad de una normal bidimensional.

Para cada observación se cumple

$$\gamma_{i1} + \gamma_{i2} = 1.$$

Por tanto, γ_{ik} puede interpretarse como la probabilidad posterior de que la observación i pertenezca al componente k .

5.2. Paso M: actualización de parámetros

Una vez calculadas las responsabilidades, definimos el tamaño efectivo del componente k :

$$N_k = \sum_{i=1}^N \gamma_{ik}. \quad (3)$$

A continuación se actualizan los pesos:

$$\pi_k^{\text{new}} = \frac{N_k}{N}. \quad (4)$$

Las medias se actualizan mediante un promedio ponderado:

$$\mu_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} x_i. \quad (5)$$

Finalmente,

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^{\top}. \quad (6)$$

Interpretación

Observe que el paso M se parece al cálculo usual de medias y covarianzas, pero cada observación participa con un peso γ_{ik} . Una célula con $\gamma_{i1} = 0.95$ influye fuertemente en el componente 1, mientras que otra con $\gamma_{i1} = 0.10$ tiene una contribución mucho menor.

6. Simplificación: covarianzas diagonales

Para realizar cálculos manuales suponemos matrices de covarianza diagonales:

$$\Sigma_k = \begin{pmatrix} \sigma_{k,1}^2 & 0 \\ 0 & \sigma_{k,2}^2 \end{pmatrix}.$$

Esta elección equivale a suponer independencia condicional entre área y circularidad dentro de cada componente.

En este caso,

$$\phi_2(x; \mu_k, \Sigma_k) = \prod_{d=1}^2 \phi\left(x^{(d)}; \mu_k^{(d)}, \sigma_k^{(d)}\right). \quad (7)$$

Esto evita trabajar con determinantes e inversas de matrices en el primer ejemplo y permite concentrarse en la lógica del algoritmo EM.

Punto de atención

La hipótesis de covarianza diagonal es una simplificación pedagógica, no una propiedad necesaria de los GMM. En datos reales el área y la circularidad pueden estar correlacionadas dentro de un mismo fenotipo.

7. Datos del ejemplo

Consideremos seis células:

i	Área (μm^2)	Circularidad
1	130	0.92
2	145	0.88
3	190	0.74
4	200	0.70
5	230	0.68
6	245	0.60

Las observaciones 3 y 4 se han elegido para funcionar como puntos cercanos a una zona de transición entre grupos.

El conjunto de datos puede introducirse en R mediante:

```
1 X <- matrix(c(  
2   130, 0.92,  
3   145, 0.88,  
4   190, 0.74,  
5   200, 0.70,  
6   230, 0.68,  
7   245, 0.60  
8 ), ncol = 2, byrow = TRUE)  
9  
10 colnames(X) <- c("Area", "Circ")  
11 DF <- data.frame(i = 1:nrow(X), X)  
12 DF
```

Para evaluar posteriormente el ajuste, en este ejemplo docente se supone conocida una “verdad terreno”:

S = células pequeñas/redondeadas, L = células grandes/alargadas.

Usaremos

$$(1, 2) \in S, \quad (3, 4, 5, 6) \in L.$$

En R:

```
1 truth <- factor(c("S", "S", "L", "L", "L", "L"))
```

Punto de atención

La verdad terreno no participa en el entrenamiento del GMM. El ajuste es no supervisado. Las etiquetas se introducen únicamente para evaluar posteriormente la concordancia de la clasificación obtenida.

8. Inicialización del modelo

EM requiere valores iniciales. Consideremos

$$\pi_1 = \pi_2 = 0.5.$$

Las medias iniciales son

$$\mu_1 = (140, 0.89), \quad \mu_2 = (240, 0.62),$$

y las desviaciones estándar por dimensión:

$$\sigma_1 = (15, 0.05), \quad \sigma_2 = (20, 0.06).$$

Por tanto,

$$\Sigma_1 = \text{diag}(15^2, 0.05^2),$$

$$\Sigma_2 = \text{diag}(20^2, 0.06^2).$$

En R:

```
1 pi1 <- 0.5
2 pi2 <- 0.5
3
4 mu1 <- c(140, 0.89)
5 mu2 <- c(240, 0.62)
6
7 sd1 <- c(15, 0.05)
8 sd2 <- c(20, 0.06)
```

8.1. ¿Por qué importa la inicialización?

La función de verosimilitud de una mezcla Gaussiana puede tener varios máximos locales. Por ello, distintas inicializaciones pueden producir trayectorias distintas del algoritmo y, en algunos problemas, soluciones diferentes.

En este ejemplo se eligen valores iniciales cercanos a la interpretación visual de los dos fenotipos para que los cálculos sean transparentes.

9. Primera iteración: paso E

Para una observación x_i , calculamos primero

$$a_{i1} = \pi_1 \phi_2(x_i; \mu_1, \Sigma_1),$$

$$a_{i2} = \pi_2 \phi_2(x_i; \mu_2, \Sigma_2).$$

Entonces

$$\gamma_{i1} = \frac{a_{i1}}{a_{i1} + a_{i2}}, \quad \gamma_{i2} = \frac{a_{i2}}{a_{i1} + a_{i2}} = 1 - \gamma_{i1}.$$

Con covarianzas diagonales, la densidad puede calcularse como producto de dos densidades normales unidimensionales:

```
1 d2_diag <- function(x, mu, sd) {
2   dnorm(x[1], mu[1], sd[1]) *
3   dnorm(x[2], mu[2], sd[2])
4 }
```

Ahora calculamos los numeradores:

```

1 num1 <- apply(
2   X, 1,
3   function(x) pi1 * d2_diag(x, mu1, sd1)
4 )
5
6 num2 <- apply(
7   X, 1,
8   function(x) pi2 * d2_diag(x, mu2, sd2)
9 )
10
11 den <- num1 + num2
12
13 gamma1 <- num1 / den
14 gamma2 <- 1 - gamma1

```

Una tabla útil para inspeccionar el resultado es:

```

1 E_table <- data.frame(
2   i = 1:nrow(X),
3   Area = X[,1],
4   Circ = X[,2],
5   gamma_1 = signif(gamma1, 4),
6   gamma_2 = signif(gamma2, 4)
7 )
8
9 E_table

```

Como referencia, se obtienen aproximadamente

$$\gamma_{i1} \approx (1.0000, 1.0000, 0.0114, 0.0000071, 0, 0).$$

9.1. Lectura probabilística

Para la primera célula,

$$\gamma_{11} \approx 1,$$

por lo que, con los parámetros iniciales, el componente 1 explica mucho mejor esa observación. Para la tercera célula,

$$\gamma_{31} \approx 0.0114, \quad \gamma_{32} \approx 0.9886.$$

Aunque la probabilidad del componente 2 es dominante, el modelo conserva explícitamente una pequeña incertidumbre.

Interpretación

Ésta es una diferencia central entre un GMM y muchos algoritmos de agrupamiento determinista: la pertenencia no tiene que ser únicamente 0 o 1. Las responsabilidades contienen información sobre la incertidumbre de la clasificación.

Actividad para el estudiante

Elija la observación $x_3 = (190, 0.74)$ y calcule manualmente:

$$\phi(190; 140, 15), \quad \phi(0.74; 0.89, 0.05),$$

$$\phi(190; 240, 20), \quad \phi(0.74; 0.62, 0.06).$$

Multiplique las densidades por los pesos π_1 y π_2 , y verifique el valor aproximado de γ_{31} .

10. Primera iteración: paso M

Una vez calculadas las responsabilidades, estimamos

$$N_1 = \sum_{i=1}^6 \gamma_{i1}, \quad N_2 = \sum_{i=1}^6 \gamma_{i2}.$$

Estos valores no tienen por qué ser enteros: representan el tamaño efectivo de cada componente. En R:

```
1 N1 <- sum(gamma1)
2 N2 <- sum(gamma2)
3
4 pi1_new <- N1 / nrow(X)
5 pi2_new <- N2 / nrow(X)
```

Las medias actualizadas son

```
1 mu1_new <- colSums(gamma1 * X) / N1
2 mu2_new <- colSums(gamma2 * X) / N2
```

Para mantener la hipótesis diagonal, actualizamos por separado las varianzas de cada coordenada:

```
1 var1_new <- colSums(
2   gamma1 *
3   (X - matrix(mu1_new, nrow(X), 2, byrow = TRUE))^2
4 ) / N1
5
6 var2_new <- colSums(
7   gamma2 *
8   (X - matrix(mu2_new, nrow(X), 2, byrow = TRUE))^2
9 ) / N2
10
11 sd1_new <- sqrt(var1_new)
12 sd2_new <- sqrt(var2_new)
```

Los valores de referencia son aproximadamente

$$\pi_1^{\text{new}} \approx 0.3352, \quad \pi_2^{\text{new}} \approx 0.6648,$$

$$\mu_1^{\text{new}} \approx (137.7984, 0.8991),$$

$$\mu_2^{\text{new}} \approx (216.3252, 0.67983),$$

$$\sigma_1^{\text{new}} \approx (8.4563, 0.02329),$$

$$\sigma_2^{\text{new}} \approx (22.1725, 0.05096).$$

10.1. ¿Qué cambió después de una iteración?

La primera componente queda concentrada alrededor de las dos células pequeñas y redondeadas. La segunda absorbe prácticamente las cuatro observaciones restantes.

El algoritmo también modifica los pesos: el componente 1 pasa de 0.5 a aproximadamente 0.335, mientras que el componente 2 pasa a aproximadamente 0.665.

Esto ilustra una característica importante de EM: los pesos no se mantienen fijos, sino que se estiman junto con las medias y covarianzas.

11. Log-verosimilitud y criterio de mejora

Para datos independientes $x_1, \dots, x_N$, la verosimilitud del modelo es

$$L(\Theta) = \prod_{i=1}^N p(x_i | \Theta).$$

En mezclas Gaussianas es más conveniente trabajar con la log-verosimilitud:

$$\ell(\Theta) = \sum_{i=1}^N \log \left[\sum_{k=1}^2 \pi_k \phi_2(x_i; \mu_k, \Sigma_k) \right]. \quad (8)$$

El algoritmo EM está construido de forma que, bajo sus actualizaciones estándar,

$$\ell(\Theta^{(t+1)}) \geq \ell(\Theta^{(t)}).$$

Por tanto, después de una iteración debe observarse una log-verosimilitud igual o mayor.

En R:

```

1 loglik <- function(X, p1, m1, s1, p2, m2, s2) {
2   sum(log(
3     p1 * apply(X, 1, function(x) d2_diag(x, m1, s1)) +
4     p2 * apply(X, 1, function(x) d2_diag(x, m2, s2))
5   ))
6 }
7
8 ll0 <- loglik(
9   X,
10  pi1, mu1, sd1,
11  pi2, mu2, sd2
12 )
13
14 ll1 <- loglik(
15   X,
16  pi1_new, mu1_new, sd1_new,
17  pi2_new, mu2_new, sd2_new
18 )
19
20 c(
21   ll_inicial = round(ll0, 4),
22   ll_despues_EM = round(ll1, 4)
23 )

```

Para estos datos se observa aproximadamente un cambio de

$$-24.5320 \quad \text{a} \quad -17.6169.$$

Como $-17.6169 > -24.5320$, la log-verosimilitud aumentó.

Punto de atención

Un valor de log-verosimilitud negativo no significa que el modelo sea “malo”. Las densidades pueden tomar valores menores que 1, y sus logaritmos son entonces negativos. Lo importante durante EM es la comparación entre iteraciones.

12. Visualización de las responsabilidades

Una forma útil de visualizar una mezcla es representar cada observación en el plano área–circularidad y utilizar el color para codificar una responsabilidad.

Por ejemplo, podemos usar γ_{i1} :

```
1 library(ggplot2)
2
3 viz <- data.frame(
4   DF,
5   truth = truth,
6   gamma1 = gamma1
7 )
8
9 ggplot(viz, aes(Area, Circ)) +
10   geom_point(aes(color = gamma1), size = 3) +
11   geom_text(
12     aes(label = truth),
13     nudge_y = 0.007,
14     size = 3
15   ) +
16   scale_color_gradient(
17     name = "P(comp 1)",
18     low = "steelblue",
19     high = "tomato"
20   ) +
21   labs(
22     title = paste(
23       "Celulas: Area vs Circularidad",
24       "color = responsabilidad del componente 1"
25     ),
26     x = "Area (micrometros cuadrados)",
27     y = "Circularidad"
28   ) +
29   theme_minimal()
```

La escala de color permite distinguir tres situaciones conceptualmente diferentes:

- $\gamma_{i1} \approx 1$: fuerte asociación con el componente 1;
- $\gamma_{i1} \approx 0$: fuerte asociación con el componente 2;
- valores intermedios: mayor incertidumbre en la clasificación.

13. Del agrupamiento suave a una clasificación

Un GMM genera probabilidades de pertenencia. Si se desea una etiqueta única, puede utilizarse la regla

$$\hat{z}_i = \arg \max_{k \in \{1,2\}} \gamma_{ik}.$$

Para dos componentes,

$$\hat{z}_i = \begin{cases} 1, & \gamma_{i1} > 0.5, \\ 2, & \gamma_{i1} < 0.5. \end{cases}$$

Sin embargo, al aplicar esta regla se pierde parte de la información de incertidumbre.

Por ejemplo, clasificar una célula con probabilidades (0.51, 0.49) y otra con (0.999, 0.001) produce en ambos casos la etiqueta 1, aunque el grado de certeza es muy diferente.

Interpretación

En aplicaciones biomédicas esta diferencia puede ser importante. Las observaciones con responsabilidades cercanas a 0.5 pueden señalar casos ambiguos, fenotipos transicionales, datos ruidosos o la necesidad de introducir variables adicionales.

14. Ajuste automático con `mclust`

Hasta ahora sólo realizamos una iteración de EM para comprender el mecanismo. En una aplicación real, el algoritmo se ejecuta repetidamente hasta alcanzar un criterio de convergencia.

El paquete `mclust` implementa modelos de mezcla Gaussianos y permite comparar distintas parametrizaciones de las matrices de covarianza.

```
1 # install.packages("mclust") # ejecutar solo si hace falta
2 library(mclust)
3
4 fit <- Mclust(X, G = 1:3)
5 summary(fit)
```

La opción

```
1 G = 1:3
```

indica que se consideren modelos con uno, dos o tres componentes. La selección puede hacerse mediante BIC.

Las clases estimadas se obtienen con

```
1 pred <- factor(fit$classification)
2 table(truth, pred)
```

15. Evaluación con Adjusted Rand Index

Cuando se dispone de etiquetas verdaderas con fines de evaluación, puede utilizarse el *Adjusted Rand Index* (ARI).

En R:

```
1 ARI <- adjustedRandIndex(truth, pred)
2 ARI
```

De forma interpretativa:

- ARI cercano a 1: alta concordancia;
- ARI cercano a 0: concordancia comparable con una partición aleatoria;
- ARI negativo: concordancia inferior a la esperada por azar bajo el ajuste utilizado por el índice.

En este ejemplo, debido a la separación entre grupos, suele obtenerse un valor alto.

15.1. Label switching

Los componentes de un GMM no poseen nombres intrínsecos. Por ello, dos ajustes equivalentes pueden intercambiar las etiquetas 1 y 2.

Por ejemplo, un algoritmo puede llamar “componente 1” a las células pequeñas, mientras que otro puede llamarles “componente 2”. Esto no implica que los ajustes sean distintos desde el punto de vista probabilístico.

16. Esquema completo del algoritmo EM

Para consolidar el procedimiento, una versión esquemática es:

Paso 1. Elegir parámetros iniciales

$$\Theta^{(0)} = \{\pi_k^{(0)}, \mu_k^{(0)}, \Sigma_k^{(0)}\}.$$

Paso 2. Para $t = 0, 1, 2, \dots$, calcular en el paso E

$$\gamma_{ik}^{(t)} = P(Z_i = k \mid x_i, \Theta^{(t)}).$$

Paso 3. Calcular

$$N_k^{(t)} = \sum_i \gamma_{ik}^{(t)}.$$

Paso 4. Actualizar en el paso M

$$\pi_k^{(t+1)} = \frac{N_k^{(t)}}{N},$$

$$\mu_k^{(t+1)} = \frac{\sum_i \gamma_{ik}^{(t)} x_i}{N_k^{(t)}},$$

y

$$\Sigma_k^{(t+1)} = \frac{\sum_i \gamma_{ik}^{(t)} (x_i - \mu_k^{(t+1)})(x_i - \mu_k^{(t+1)})^\top}{N_k^{(t)}}.$$

Paso 5. Evaluar la log-verosimilitud.

Paso 6. Detener cuando

$$|\ell(\Theta^{(t+1)}) - \ell(\Theta^{(t)})| < \varepsilon$$

para una tolerancia pequeña.

17. Código compacto para una iteración

El siguiente fragmento reúne el cálculo principal del ejemplo:

```
1  # Datos
2  X <- matrix(c(
3    130, 0.92,
4    145, 0.88,
5    190, 0.74,
6    200, 0.70,
7    230, 0.68,
8    245, 0.60
9  ), ncol = 2, byrow = TRUE)
10
11 # Inicializacion
12 pi1 <- 0.5
13 pi2 <- 0.5
14
15 mu1 <- c(140, 0.89)
16 mu2 <- c(240, 0.62)
17
18 sd1 <- c(15, 0.05)
19 sd2 <- c(20, 0.06)
20
21 # Densidad normal 2D diagonal
22 d2_diag <- function(x, mu, sd) {
23   dnorm(x[1], mu[1], sd[1]) *
24   dnorm(x[2], mu[2], sd[2])
25 }
26
27 # Paso E
28 num1 <- apply(
29   X, 1,
30   function(x) pi1 * d2_diag(x, mu1, sd1)
31 )
32
33 num2 <- apply(
34   X, 1,
35   function(x) pi2 * d2_diag(x, mu2, sd2)
36 )
37
38 gamma1 <- num1 / (num1 + num2)
39 gamma2 <- 1 - gamma1
40
41 # Paso M
42 N1 <- sum(gamma1)
43 N2 <- sum(gamma2)
44
45 pi1_new <- N1 / nrow(X)
46 pi2_new <- N2 / nrow(X)
47
48 mu1_new <- colSums(gamma1 * X) / N1
49 mu2_new <- colSums(gamma2 * X) / N2
50
51 var1_new <- colSums(
52   gamma1 *
53   (X - matrix(mu1_new, nrow(X), 2, byrow = TRUE))^2
54 ) / N1
55
```

```

56 var2_new <- colSums(
57   gamma2 *
58   (X - matrix(mu2_new, nrow(X), 2, byrow = TRUE))^2
59 ) / N2
60
61 sd1_new <- sqrt(var1_new)
62 sd2_new <- sqrt(var2_new)

```

18. Preguntas de autoevaluación

Antes de continuar con conjuntos de datos mayores, el estudiante debería poder responder:

1. ¿Por qué una mezcla de dos Gaussianas puede describir mejor una población heterogénea que una única Gaussiana?
2. ¿Cuál es la diferencia entre π_k y γ_{ik} ?
3. ¿Por qué N_k puede no ser entero?
4. ¿Qué interpretación tiene una responsabilidad $\gamma_{i1} = 0.52$?
5. ¿Por qué el paso M utiliza promedios ponderados?
6. ¿Qué información se pierde al reemplazar las responsabilidades por etiquetas duras?
7. ¿Qué significa que la log-verosimilitud aumente después de una iteración?
8. ¿Por qué diferentes inicializaciones pueden producir soluciones distintas?
9. ¿Qué limitación introduce la hipótesis de covarianza diagonal?
10. ¿Por qué el intercambio de etiquetas de los componentes no cambia el modelo probabilístico?

19. Ejercicios propuestos

Ejercicio 1. Segunda iteración de EM.

Utilice los parámetros actualizados después del primer paso M y repita el paso E. Calcule nuevamente la log-verosimilitud y verifique si vuelve a aumentar.

Ejercicio 2. Sensibilidad a la inicialización.

Reemplace

$$\pi_1 = 0.5, \quad \pi_2 = 0.5$$

por

$$\pi_1 = 0.7, \quad \pi_2 = 0.3.$$

Compare las nuevas responsabilidades, especialmente para las observaciones 3 y 4.

Ejercicio 3. Medias iniciales más próximas.

Elija dos medias iniciales menos separadas y describa cómo cambia la primera iteración del algoritmo.

Ejercicio 4. Covarianzas completas.

Utilice `Mclust` para comparar modelos que permitan covarianzas no diagonales. Analice modelos como `EEE` y `VVV` mediante BIC.

Ejercicio 5. Datos sintéticos.

Genere entre 100 y 200 observaciones a partir de dos Gaussianas bidimensionales. Ajuste un GMM y represente:

- las responsabilidades;
- la clasificación final;
- la log-verosimilitud por iteración;
- el ARI cuando conozca las etiquetas generadoras.

Ejercicio 6. Puntos ambiguos.

Construya artificialmente varias observaciones entre las medias de los dos componentes. Identifique cuáles tienen responsabilidades más próximas a 0.5 y explique por qué.

Ejercicio 7. Discusión biomédica.

Suponga que aparecen muchas células con probabilidades cercanas a $(0.5, 0.5)$. Proponga al menos tres explicaciones posibles desde el punto de vista estadístico o biomédico.

20. Extensiones naturales

El ejemplo presentado es deliberadamente pequeño. A partir de esta base pueden estudiarse extensiones importantes:

- más de dos componentes;
- más de dos características celulares;
- matrices de covarianza completas;
- selección del número de componentes mediante BIC;
- estandarización de variables;
- detección de observaciones atípicas;
- comparación con k -means;
- interpretación probabilística de fenotipos intermedios.

Una cuestión particularmente relevante para aprendizaje máquina estadístico es comparar GMM y k -means. Mientras k -means produce una partición basada en distancias a centroides, un GMM introduce una distribución probabilística para cada grupo y permite diferentes geometrías mediante las matrices de covarianza.

21. Ideas esenciales para recordar

- Un GMM representa una población como combinación de varias distribuciones Gaussianas.
- Las etiquetas de los componentes son variables latentes.
- El paso E calcula probabilidades posteriores de pertenencia.
- El paso M actualiza los parámetros mediante promedios ponderados.
- EM alterna ambos pasos hasta converger.
- La log-verosimilitud constituye una herramienta natural para seguir la mejora del ajuste.

- La clasificación probabilística conserva información de incertidumbre que se pierde al usar etiquetas duras.
- En aplicaciones biomédicas, una observación ambigua puede ser científicamente informativa y no debe interpretarse automáticamente como un error.

22. Bibliografía recomendada

Referencias

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [2] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2a ed., Springer, 2009.
- [3] G. McLachlan y D. Peel, *Finite Mixture Models*, Wiley, 2000.
- [4] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- [5] L. Scrucca, M. Fop, T. B. Murphy y A. E. Raftery, “mclust 5: Clustering, Classification and Density Estimation Using Gaussian Finite Mixture Models”, *The R Journal*, 8(1), 2016.