

Modelos de Mezcla Gaussiana para el análisis de microclimas

Temperatura, humedad, responsabilidades y algoritmo EM

FCFM-UNACH

Licenciatura en Matemáticas Aplicadas
Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de la guía	3
2. Motivación: dos microclimas coexistentes	3
3. Representación matemática de las observaciones	4
4. Modelo de Mezcla Gaussiana	4
4.1. Pesos de mezcla	5
4.2. Medias	5
4.3. Covarianzas	5
5. Variable latente	5
6. Algoritmo Expectation–Maximization	6
6.1. Paso E: responsabilidades	6
6.2. Paso M: actualización de parámetros	6
7. Simplificación para cálculo manual	7
8. Datos mínimos	7
9. Inicialización del modelo	8
9.1. Lectura de la inicialización	8
10. Primera iteración: paso E	9
10.1. Cómo interpretar una responsabilidad	9
11. Primera iteración: paso M	10
11.1. Qué significa la actualización	11
12. Verificación mediante log-verosimilitud	12
13. Visualización en el plano temperatura–humedad	13
13.1. Qué debe observarse en la gráfica	14
14. Clasificación dura a partir de responsabilidades	14
15. Confirmación con <code>mclust</code>	14

16.Adjusted Rand Index	15
16.1. Label switching	15
17.Coordenadas espaciales de los sensores	15
18.Agrupamiento climático no es lo mismo que modelo espacial	16
19.Posibles extensiones espaciales	16
20.Interpretación de medias y covarianzas	17
21.Fronteras probabilísticas	17
22.Preguntas de autoevaluación	18
23.Ejercicios sugeridos	18
24.Actividad integradora	19
25.Ideas esenciales para recordar	20
26.Bibliografía recomendada	20

1. Propósito de la guía

En una misma región geográfica pueden coexistir condiciones ambientales diferentes a escalas relativamente pequeñas. Zonas sombreadas, cercanas a cuerpos de agua o protegidas por la topografía pueden presentar combinaciones de temperatura y humedad distintas de aquellas observadas en laderas soleadas o terrenos más expuestos.

Cuando se dispone de una red de sensores, cada punto de medición puede describirse mediante variables ambientales. En esta guía utilizaremos dos de ellas:

$$X = \begin{pmatrix} \text{Temperatura} \\ \text{Humedad} \end{pmatrix}.$$

El propósito será identificar, de manera no supervisada, patrones compatibles con dos microclimas:

1. **húmedo-fresco;**
2. **seco-cálido.**

En lugar de imponer una frontera determinista desde el inicio, utilizaremos un **Modelo de Mezcla Gaussiana** (GMM), que asigna a cada observación probabilidades de pertenencia a los distintos componentes.

Objetivos de aprendizaje

Al finalizar este material, el estudiante deberá ser capaz de:

1. Representar observaciones de temperatura y humedad como vectores en $\mathbb{R}^2$.
2. Formular un GMM de dos componentes para describir dos microclimas.
3. Interpretar pesos, medias, covarianzas y variables latentes.
4. Calcular responsabilidades en el paso E del algoritmo EM.
5. Actualizar parámetros en el paso M.
6. Verificar el incremento de la log-verosimilitud.
7. Interpretar una clasificación probabilística de los sensores.
8. Comparar el cálculo manual con un ajuste automático mediante `mclust`.
9. Distinguir entre agrupamiento climático y modelación espacial.

2. Motivación: dos microclimas coexistentes

Supongamos que una pequeña red de sensores registra temperatura media y humedad relativa en un valle. Algunas estaciones se encuentran en zonas con sombra y cercanas a cuerpos de agua; otras se ubican en sectores más soleados.

Una descripción global basada únicamente en promedios podría ocultar esta heterogeneidad. Por ejemplo, una temperatura media regional de 24°C no indica si todas las estaciones tienen condiciones parecidas o si, en realidad, coexisten dos grupos claramente distintos.

Un GMM permite modelar la distribución conjunta de temperatura y humedad como una combinación de varias poblaciones probabilísticas.

Interpretación

En este contexto, cada componente Gaussiano debe interpretarse como un *régimen estadístico* o patrón ambiental. El algoritmo no “sabe” qué significa húmedo-fresco o seco-cálido; esos nombres se asignan después, al interpretar las medias y dispersiones estimadas.

3. Representación matemática de las observaciones

Para el sensor i , escribimos

$$x_i = \begin{pmatrix} T_i \\ H_i \end{pmatrix} \in \mathbb{R}^2,$$

donde:

- T_i es la temperatura en grados Celsius;
- H_i es la humedad relativa normalizada al intervalo $[0, 1]$.

La normalización de humedad se realiza mediante

$$H_i = \frac{\text{Humedad en \%}}{100}.$$

Así, una humedad de 80 % se representa como 0.80.

Punto de atención

La normalización de humedad no hace que temperatura y humedad tengan exactamente la misma escala estadística, pero evita manejar simultáneamente valores alrededor de 20–30 y valores entre 50–80. Si se usaran porcentajes sin normalizar, deberían ajustarse también las desviaciones estándar iniciales.

4. Modelo de Mezcla Gaussiana

Supondremos que la distribución de las observaciones puede representarse mediante dos Gaussianas:

$$p(x \mid \Theta) = \sum_{k=1}^2 \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad (1)$$

con

$$\pi_k > 0, \quad \pi_1 + \pi_2 = 1.$$

El conjunto de parámetros es

$$\Theta = \{\pi_1, \pi_2, \mu_1, \mu_2, \Sigma_1, \Sigma_2\}.$$

4.1. Pesos de mezcla

Los parámetros π_k representan las proporciones relativas de los componentes:

$$\pi_k = P(Z_i = k).$$

Por ejemplo, si después del ajuste se obtiene

$$\pi_1 = 0.35, \quad \pi_2 = 0.65,$$

el modelo sugiere que aproximadamente el 35 % de la población observada pertenece al primer régimen y el 65 % al segundo.

4.2. Medias

Para cada componente,

$$\mu_k = \begin{pmatrix} \mu_{k,T} \\ \mu_{k,H} \end{pmatrix}.$$

Estas coordenadas describen las condiciones centrales del componente.

Si

$$\mu_1 = (21, 0.80),$$

su interpretación natural sería una región alrededor de 21°C y 80 % de humedad relativa.

4.3. Covarianzas

La matriz

$$\Sigma_k = \begin{pmatrix} \sigma_{k,T}^2 & \sigma_{k,TH} \\ \sigma_{k,TH} & \sigma_{k,H}^2 \end{pmatrix}$$

describe la variabilidad interna del componente y, cuando el término fuera de la diagonal es distinto de cero, la asociación entre temperatura y humedad.

5. Variable latente

Introducimos una variable no observada

$$Z_i \in \{1, 2\}.$$

La interpretación es

$$Z_i = k \iff x_i \text{ fue generado por el componente } k.$$

En los datos reales no conocemos directamente Z_i . Sólo observamos la temperatura y la humedad.

Esta falta de información es lo que motiva el algoritmo EM.

Conexión con aprendizaje máquina

El problema es no supervisado porque el algoritmo recibe los valores ambientales, pero no las etiquetas “húmedo-fresco” o “seco-cálido”. Las etiquetas se interpretan después de estimar los componentes.

6. Algoritmo Expectation–Maximization

El algoritmo EM alterna dos pasos.

6.1. Paso E: responsabilidades

Para cada observación i y componente k , definimos

$$\gamma_{ik} = P(Z_i = k \mid X_i = x_i, \Theta).$$

Por el teorema de Bayes,

$$\gamma_{ik} = \frac{\pi_k \phi_2(x_i; \mu_k, \Sigma_k)}{\sum_{j=1}^2 \pi_j \phi_2(x_i; \mu_j, \Sigma_j)}. \quad (2)$$

Para cada observación,

$$\gamma_{i1} + \gamma_{i2} = 1.$$

Interpretación

Una responsabilidad $\gamma_{i1} = 0.95$ indica que, con los parámetros actuales, la observación es explicada casi completamente por el componente 1. En cambio, un valor cercano a 0.5 señala un punto de transición o solapamiento entre los dos regímenes.

6.2. Paso M: actualización de parámetros

Primero se calcula el tamaño efectivo de cada componente:

$$N_k = \sum_{i=1}^N \gamma_{ik}.$$

Después,

$$\pi_k^{\text{new}} = \frac{N_k}{N}, \quad (3)$$

$$\mu_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} x_i, \quad (4)$$

y

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^T. \quad (5)$$

La idea esencial es que cada observación participa en la actualización de todos los componentes, pero con un peso distinto.

7. Simplificación para cálculo manual

Para el primer ejemplo supondremos matrices de covarianza diagonales:

$$\Sigma_k = \begin{pmatrix} \sigma_{k,T}^2 & 0 \\ 0 & \sigma_{k,H}^2 \end{pmatrix}.$$

Entonces,

$$\phi_2(x; \mu_k, \Sigma_k) = \phi(T; \mu_{k,T}, \sigma_{k,T}) \phi(H; \mu_{k,H}, \sigma_{k,H}). \quad (6)$$

Esta simplificación permite realizar los cálculos utilizando densidades normales unidimensionales.

Punto de atención

Suponer covarianza diagonal equivale a ignorar la dependencia lineal entre temperatura y humedad dentro de cada componente. Esto facilita el cálculo manual, pero no debe asumirse automáticamente en un análisis aplicado.

8. Datos mínimos

Trabajaremos con seis observaciones:

i	Temperatura (°C)	Humedad (%)	Humedad normalizada
1	20	80	0.80
2	21	78	0.78
3	24	70	0.70
4	25	65	0.65
5	28	55	0.55
6	30	50	0.50

En R:

```
1 X_raw <- data.frame(  
2   Temp = c(20, 21, 24, 25, 28, 30),  
3   HumP = c(80, 78, 70, 65, 55, 50)  
4 )  
5  
6 X <- cbind(  
7   Temp = X_raw$Temp,  
8   Hum = X_raw$HumP / 100  
9 )  
10  
11 DF <- data.frame(  
12   i = 1:nrow(X),  
13   X  
14 )  
15  
16 DF
```

Para fines exclusivamente docentes se introduce una “verdad terreno”:

H = húmedo-fresco, S = seco-cálido.

Se consideran

$$i = 1, 2 \in H, \quad i = 3, 4, 5, 6 \in S.$$

En R:

```
1 truth <- factor(
2   c("H", "H", "S", "S", "S", "S")
3 )
4
5 truth
```

Punto de atención

Estas etiquetas no se utilizan para estimar el GMM. Sólo sirven posteriormente para evaluar si el agrupamiento coincide con la partición que se eligió para este ejemplo docente.

9. Inicialización del modelo

Tomaremos inicialmente

$$\pi_1 = \pi_2 = 0.5.$$

Las medias son

$$\mu_1 = (21, 0.80), \quad \mu_2 = (29, 0.52).$$

Las desviaciones estándar son

$$\sigma_1 = (1.5, 0.04), \quad \sigma_2 = (2.0, 0.05).$$

En R:

```
1 pi1 <- 0.5
2 pi2 <- 0.5
3
4 mu1 <- c(21, 0.80)
5 mu2 <- c(29, 0.52)
6
7 sd1 <- c(1.5, 0.04)
8 sd2 <- c(2.0, 0.05)
```

9.1. Lectura de la inicialización

El primer componente comienza centrado en condiciones relativamente frescas y húmedas. El segundo comienza en condiciones más cálidas y secas.

La inicialización es deliberadamente intuitiva para que la primera iteración sea fácil de interpretar.

Interpretación

En aplicaciones reales, las medias iniciales pueden obtenerse a partir de conocimiento previo, de una partición aleatoria o de un algoritmo como k -means. EM puede ser sensible al punto inicial porque la función de verosimilitud de una mezcla puede tener máximos locales.

10. Primera iteración: paso E

Con covarianzas diagonales, definimos

$$a_{i1} = \pi_1 \phi_2(x_i; \mu_1, \Sigma_1),$$

$$a_{i2} = \pi_2 \phi_2(x_i; \mu_2, \Sigma_2).$$

Las responsabilidades son

$$\gamma_{i1} = \frac{a_{i1}}{a_{i1} + a_{i2}}, \quad \gamma_{i2} = 1 - \gamma_{i1}.$$

En R:

```
1 d2_diag <- function(x, mu, sd){
2   dnorm(x[1], mu[1], sd[1]) *
3   dnorm(x[2], mu[2], sd[2])
4 }
5
6 num1 <- apply(
7   X, 1,
8   function(x)
9     pi1 * d2_diag(x, mu1, sd1)
10 )
11
12 num2 <- apply(
13   X, 1,
14   function(x)
15     pi2 * d2_diag(x, mu2, sd2)
16 )
17
18 den <- num1 + num2
19
20 gamma1 <- num1 / den
21 gamma2 <- 1 - gamma1
```

Organizamos los resultados:

```
1 E_table <- data.frame(
2   i = 1:nrow(X),
3   Temp = X[,1],
4   Hum = X[,2],
5   gamma_H = signif(gamma1, 4),
6   gamma_S = signif(gamma2, 4)
7 )
8
9 E_table
```

10.1. Cómo interpretar una responsabilidad

La responsabilidad γ_{i1} puede leerse como la probabilidad posterior de que el sensor i pertenezca al régimen asociado con el primer componente.

Por ejemplo:

$$\gamma_{i1} \approx 1$$

indica una fuerte asociación con el régimen húmedo-fresco, mientras que

$$\gamma_{i1} \approx 0$$

indica una fuerte asociación con el segundo régimen.

Los puntos intermedios, en particular

$$(24, 0.70) \quad \text{y} \quad (25, 0.65),$$

son especialmente interesantes porque pueden encontrarse cerca de una zona de transición entre ambos patrones.

Actividad para el estudiante

Calcule manualmente las dos densidades ponderadas para

$$x_3 = (24, 0.70).$$

Compare

$$\pi_1 \phi_2(x_3; \mu_1, \Sigma_1) \quad \text{y} \quad \pi_2 \phi_2(x_3; \mu_2, \Sigma_2),$$

y después obtenga γ_{31} y γ_{32} .

11. Primera iteración: paso M

A partir de las responsabilidades calculamos

$$N_1 = \sum_i \gamma_{i1}, \quad N_2 = \sum_i \gamma_{i2}.$$

En R:

```
1 N1 <- sum(gamma1)
2 N2 <- sum(gamma2)
3
4 pi1_new <- N1 / nrow(X)
5 pi2_new <- N2 / nrow(X)
```

Las medias actualizadas son

```
1 mu1_new <- colSums(gamma1 * X) / N1
2 mu2_new <- colSums(gamma2 * X) / N2
```

Para mantener la simplificación diagonal:

```
1 var1_new <- colSums(
2   gamma1 *
3   (X - matrix(
4     mu1_new,
5     nrow(X),
6     2,
7     byrow = TRUE
8   ))^2
9 ) / N1
10
11 var2_new <- colSums(
12   gamma2 *
13   (X - matrix(
14     mu2_new,
15     nrow(X),
```

```

16     2,
17     byrow = TRUE
18   ))^2
19 ) / N2
20
21 sd1_new <- sqrt(var1_new)
22 sd2_new <- sqrt(var2_new)

```

Podemos organizar los parámetros:

```

1 M_table <- data.frame(
2   componente = c(
3     "1 (Humedo-fresco)",
4     "2 (Seco-calido)"
5   ),
6   N_k = c(N1, N2),
7   pi_k = c(pi1_new, pi2_new),
8   mu_Temp = c(
9     mu1_new[1],
10    mu2_new[1]
11  ),
12  mu_Hum = c(
13    mu1_new[2],
14    mu2_new[2]
15  ),
16  sd_Temp = c(
17    sd1_new[1],
18    sd2_new[1]
19  ),
20  sd_Hum = c(
21    sd1_new[2],
22    sd2_new[2]
23  ),
24  stringsAsFactors = FALSE
25 )
26
27 nums <- sapply(
28   M_table,
29   is.numeric
30 )
31
32 M_table_round <- M_table
33
34 M_table_round[, nums] <-
35   lapply(
36     M_table_round[, nums],
37     round,
38     4
39   )
40
41 M_table_round

```

11.1. Qué significa la actualización

La media del primer componente se desplaza hacia las observaciones con mayores responsabilidades para el régimen húmedo-fresco. La del segundo hace lo mismo hacia los puntos asociados con condiciones más secas y cálidas.

Interpretación

Los parámetros estimados no deben interpretarse como fronteras rígidas. El GMM representa regiones de alta probabilidad en el plano temperatura-humedad. La superposición entre componentes es precisamente lo que permite expresar incertidumbre.

12. Verificación mediante log-verosimilitud

Para datos independientes,

$$L(\Theta) = \prod_{i=1}^N p(x_i | \Theta).$$

Es más conveniente utilizar

$$\ell(\Theta) = \sum_{i=1}^N \log \left[\sum_{k=1}^2 \pi_k \phi_2(x_i; \mu_k, \Sigma_k) \right]. \quad (7)$$

En R:

```
1 loglik <- function(  
2   X,  
3   p1, m1, s1,  
4   p2, m2, s2  
5 ){  
6   dens1 <- apply(  
7     X, 1,  
8     function(x)  
9       d2_diag(x, m1, s1)  
10  )  
11  
12  dens2 <- apply(  
13    X, 1,  
14    function(x)  
15      d2_diag(x, m2, s2)  
16  )  
17  
18  sum(  
19    log(  
20      p1 * dens1 +  
21      p2 * dens2  
22    )  
23  )  
24 }  
25  
26 ll0 <- loglik(  
27   X,  
28   pi1, mu1, sd1,  
29   pi2, mu2, sd2  
30 )  
31  
32 ll1 <- loglik(  
33   X,  
34   pi1_new, mu1_new, sd1_new,  
35   pi2_new, mu2_new, sd2_new  
36 )  
37
```

```

38 c(
39   ll_inicial = round(ll0, 4),
40   ll_despues_EM = round(ll1, 4)
41 )

```

Una propiedad fundamental de EM es

$$\ell(\Theta^{(t+1)}) \geq \ell(\Theta^{(t)}).$$

Por tanto, la comparación entre $\ell(\Theta^{(0)})$ y $\ell(\Theta^{(1)})$ proporciona una verificación natural de la primera iteración.

Punto de atención

La log-verosimilitud puede ser negativa. Esto no implica un ajuste incorrecto. Lo importante en este punto es verificar que no disminuya después de la actualización.

13. Visualización en el plano temperatura–humedad

Una manera natural de interpretar el GMM consiste en representar cada observación en el plano

(Temperatura, Humedad)

y utilizar el color para codificar γ_{i1} .

En R:

```

1 library(ggplot2)
2
3 viz <- data.frame(
4   DF,
5   truth = truth,
6   gammaH = gamma1
7 )
8
9 ggplot(
10  viz,
11  aes(Temp, Hum)
12 ) +
13  geom_point(
14    aes(color = gammaH),
15    size = 3
16  ) +
17  geom_text(
18    aes(label = truth),
19    nudge_y = 0.01,
20    size = 3
21  ) +
22  scale_color_gradient(
23    name = "P(Humedo)",
24    low = "steelblue",
25    high = "tomato"
26  ) +
27  labs(
28    title =
29      "Microclimas: Temperatura vs Humedad",
30    subtitle =
31      "Color = responsabilidad del componente H",

```

```

32 x = "Temperatura (grados C)",
33 y = "Humedad (0-1)"
34 ) +
35 theme_minimal()

```

13.1. Qué debe observarse en la gráfica

Una visualización de responsabilidades permite distinguir:

- observaciones claramente asociadas con un componente;
- observaciones de transición;
- solapamiento entre microclimas;
- coherencia entre la separación estadística y las etiquetas docentes.

14. Clasificación dura a partir de responsabilidades

Aunque el GMM produce probabilidades, puede construirse una etiqueta única mediante

$$\hat{z}_i = \arg \max_{k \in \{1,2\}} \gamma_{ik}.$$

Para dos componentes,

$$\hat{z}_i = \begin{cases} 1, & \gamma_{i1} > 0.5, \\ 2, & \gamma_{i1} < 0.5. \end{cases}$$

Esta regla facilita la comparación con una partición de referencia, pero elimina información.

Interpretación

No es equivalente clasificar un sensor con probabilidades (0.99, 0.01) y otro con (0.51, 0.49). Ambos recibirían la misma etiqueta, pero el segundo se encuentra en una zona mucho más ambigua.

15. Confirmación con `mclust`

El cálculo anterior muestra una sola iteración. En un ajuste real, EM se repite hasta alcanzar convergencia.

El paquete `mclust` permite automatizar este procedimiento:

```

1 # install.packages("mclust")
2 library(mclust)
3
4 fit <- Mclust(
5   X,
6   G = 1:3
7 )
8
9 summary(fit)

```

Aquí se permiten modelos con uno, dos o tres componentes.
El número final puede seleccionarse utilizando BIC.

16. Adjusted Rand Index

Como en este ejemplo disponemos de etiquetas docentes, podemos comparar la partición estimada con la referencia.

```
1 pred <- factor(  
2   fit$classification  
3 )  
4  
5 table(  
6   truth,  
7   pred  
8 )  
9  
10 ARI <- adjustedRandIndex(  
11   truth,  
12   pred  
13 )  
14  
15 ARI
```

El *Adjusted Rand Index* mide concordancia entre dos particiones.

De forma orientativa:

- ARI cercano a 1: fuerte concordancia;
- ARI cercano a 0: concordancia comparable con el azar;
- valores negativos: concordancia menor que la esperada bajo el ajuste del índice.

16.1. Label switching

Los números asignados a los componentes no tienen significado intrínseco.

Por ejemplo, el componente 1 de una corrida puede corresponder al componente 2 de otra. Este fenómeno se denomina *label switching*.

Interpretación

El intercambio de etiquetas no modifica la distribución ajustada. Por eso una medida como ARI es apropiada: compara particiones sin depender del nombre numérico de los grupos.

17. Coordenadas espaciales de los sensores

Hasta ahora el GMM utiliza únicamente temperatura y humedad. Si además conocemos la posición de cada sensor, podemos representar espacialmente las probabilidades estimadas.

Tomemos coordenadas ficticias:

```
1 coords <- data.frame(  
2   i = 1:6,  
3   x = c(  
4     1.0, 1.5, 2.5,  
5     3.0, 3.8, 4.2  
6   ),  
7   y = c(  
8     4.0, 3.6, 3.0,  
9     2.6, 2.2, 1.8  
10  )  
11 )
```

Combinamos coordenadas y responsabilidades:

```
1 mapdf <- merge(  
2   viz,  
3   coords,  
4   by = "i"  
5 )  
6  
7 ggplot(  
8   mapdf,  
9   aes(x, y)  
10 ) +  
11 geom_point(  
12   aes(color = gammaH),  
13   size = 4  
14 ) +  
15 scale_color_gradient(  
16   name = "P(Humedo)",  
17   low = "steelblue",  
18   high = "tomato"  
19 ) +  
20 labs(  
21   title =  
22     "Mapa de sensores",  
23   subtitle =  
24     "Color = pertenencia al microclima H",  
25   x = "x (km)",  
26   y = "y (km)"  
27 ) +  
28 theme_minimal()
```

18. Agrupamiento climático no es lo mismo que modelo espacial

Es importante distinguir dos ideas.

El GMM utilizado hasta ahora modela

$$p(T, H),$$

es decir, la distribución conjunta de temperatura y humedad.

No modela directamente

$$p(T, H \mid x, y),$$

ni incorpora la distancia entre sensores.

Por tanto, dos sensores muy alejados geográficamente pueden ser asignados al mismo componente si presentan condiciones ambientales similares.

Punto de atención

Representar γ_H sobre un mapa no convierte al GMM en un modelo espacial. El mapa sólo muestra espacialmente el resultado de un agrupamiento obtenido con temperatura y humedad.

19. Posibles extensiones espaciales

Si la ubicación geográfica es relevante, existen varias extensiones posibles.

Una opción sencilla es aumentar el vector de características:

$$x_i = (T_i, H_i, \lambda x_i, \lambda y_i),$$

donde $\lambda > 0$ controla el peso de la proximidad espacial.

Otra posibilidad es modelar temperatura y humedad sobre el espacio mediante técnicas geoestadísticas, por ejemplo kriging, y aplicar posteriormente un GMM a predictores locales.

Conexión con aprendizaje máquina

Estas extensiones permiten pasar de un problema de agrupamiento climático a uno donde también importa la continuidad espacial. Sin embargo, introducen nuevas decisiones de modelado que deben justificarse según el objetivo del estudio.

20. Interpretación de medias y covarianzas

Después de la convergencia, las medias

$$\hat{\mu}_1 = \begin{pmatrix} \hat{T}_1 \\ \hat{H}_1 \end{pmatrix}, \quad \hat{\mu}_2 = \begin{pmatrix} \hat{T}_2 \\ \hat{H}_2 \end{pmatrix}$$

pueden interpretarse como condiciones típicas de los dos regímenes.

Las desviaciones estándar indican cuánto varían temperatura y humedad dentro de cada microclima.

Si se utilizan covarianzas completas,

$$\hat{\Sigma}_k = \begin{pmatrix} \hat{\sigma}_{T,k}^2 & \hat{\sigma}_{TH,k} \\ \hat{\sigma}_{TH,k} & \hat{\sigma}_{H,k}^2 \end{pmatrix},$$

el término $\hat{\sigma}_{TH,k}$ permite describir si temperaturas mayores tienden a asociarse con humedades mayores o menores dentro del mismo régimen.

21. Fronteras probabilísticas

Con dos componentes, la frontera de decisión MAP está formada por los puntos donde

$$P(Z = 1 \mid X = x) = P(Z = 2 \mid X = x).$$

Equivalentemente,

$$\pi_1 \phi_2(x; \mu_1, \Sigma_1) = \pi_2 \phi_2(x; \mu_2, \Sigma_2).$$

Con covarianzas iguales, esta frontera tiene una estructura relativamente simple. Con covarianzas distintas puede ser curva.

Interpretación

La frontera no debe verse como una separación física exacta entre dos microclimas. Es una frontera estadística determinada por el modelo ajustado y por las variables incluidas.

22. Preguntas de autoevaluación

Antes de continuar con conjuntos de datos mayores, el estudiante debería poder responder:

1. ¿Qué representa cada coordenada del vector $X = (T, H)$?
2. ¿Cuál es la diferencia entre π_k y γ_{ik} ?
3. ¿Qué significado climático puede tener μ_k ?
4. ¿Qué información aporta Σ_k ?
5. ¿Por qué $N_k = \sum_i \gamma_{ik}$ puede no ser entero?
6. ¿Qué significa una responsabilidad cercana a 0.5?
7. ¿Por qué el paso M utiliza promedios ponderados?
8. ¿Qué propiedad de la log-verosimilitud se espera durante EM?
9. ¿Por qué la clasificación MAP pierde información?
10. ¿Qué es el *label switching*?
11. ¿Por qué un mapa de responsabilidades no equivale a un modelo espacial?
12. ¿Qué cambiaría al permitir covarianzas no diagonales?

23. Ejercicios sugeridos

Ejercicio 1. Segunda iteración de EM.

Utilice los parámetros actualizados y vuelva a calcular el paso E y el paso M. Verifique que la log-verosimilitud no disminuye.

Ejercicio 2. Sensibilidad a los pesos iniciales.

Repita la primera iteración con

$$\pi_1 = 0.7, \quad \pi_2 = 0.3.$$

Analice especialmente los puntos

$$(24, 0.70) \quad \text{y} \quad (25, 0.65).$$

Ejercicio 3. Medias más cercanas.

Proponga medias iniciales con menor separación y describa cómo cambia la incertidumbre en las responsabilidades.

Ejercicio 4. Covarianzas completas.

Utilice `Mclust` y compare modelos como `EEE` y `VVV`. Analice BIC y la orientación de las nubes de puntos.

Ejercicio 5. Datos sintéticos.

Genere alrededor de 150 observaciones de dos Gaussianas bidimensionales. Controle el grado de solapamiento mediante las medias y covarianzas.

Ejercicio 6. Curva de log-verosimilitud.

Implemente EM completo y grafique

$$t \mapsto \ell(\Theta^{(t)}).$$

Ejercicio 7. ARI y solapamiento.

Para diferentes niveles de solapamiento entre las dos Gaussianas, compare el ARI obtenido.

Ejercicio 8. Mapa espacial.

Asigne coordenadas a un conjunto sintético de sensores y represente

$$\gamma_{i1}$$

sobre el espacio.

Ejercicio 9. Incorporación de posición.

Ajuste un GMM a

$$(T, H, \lambda x, \lambda y)$$

para varios valores de λ . Compare la clasificación resultante.

Ejercicio 10. Interpretación aplicada.

Discuta qué variables adicionales podrían ser necesarias para caracterizar mejor un microclima: radiación, precipitación, velocidad del viento, altitud u otras disponibles en una red de sensores.

24. Actividad integradora

Como actividad final, construya un conjunto sintético mayor que permita controlar explícitamente el solapamiento entre dos microclimas.

Una propuesta es utilizar

$$X \mid Z = 1 \sim \mathcal{N}(\mu_1, \Sigma_1), \quad X \mid Z = 2 \sim \mathcal{N}(\mu_2, \Sigma_2).$$

Mantenga inicialmente fijas las covarianzas y acerque progresivamente las medias.

Para cada configuración:

1. genere los datos;
2. ajuste modelos con distintos valores de G ;
3. compare BIC;
4. calcule ARI;
5. grafique las responsabilidades;
6. represente la frontera MAP;
7. discuta cómo cambia la incertidumbre al aumentar el solapamiento.

Conexión con aprendizaje máquina

Esta actividad permite relacionar tres ideas importantes: dificultad geométrica del problema, incertidumbre probabilística y desempeño de una clasificación derivada del modelo.

25. Ideas esenciales para recordar

- Un GMM modela una distribución como combinación de Gaussianas.
- Cada componente puede representar un régimen ambiental distinto.
- Los pesos π_k describen proporciones globales.
- Las responsabilidades γ_{ik} son probabilidades posteriores específicas de cada observación.
- EM alterna estimación probabilística de pertenencia y actualización de parámetros.
- La log-verosimilitud debe no disminuir durante las iteraciones estándar de EM.
- Una clasificación dura se obtiene a partir de responsabilidades, pero pierde información sobre incertidumbre.
- Un GMM sobre temperatura y humedad no es automáticamente un modelo espacial.
- Las coordenadas de sensores pueden visualizar resultados o incorporarse explícitamente si el objetivo lo justifica.

26. Bibliografía recomendada

Referencias

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [2] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2a ed., Springer, 2009.
- [3] G. McLachlan y D. Peel, *Finite Mixture Models*, Wiley, 2000.
- [4] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- [5] L. Scrucca, M. Fop, T. B. Murphy y A. E. Raftery, “mclust 5: Clustering, Classification and Density Estimation Using Gaussian Finite Mixture Models”, *The R Journal*, 8(1), 2016.