

Modelos de Mezcla Gaussiana para tráfico urbano

Velocidad media, regímenes de circulación y algoritmo EM

FCFM–UNACH

Licenciatura en Matemáticas Aplicadas

Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. Motivación: dos regímenes de circulación	3
3. Modelo probabilístico	4
3.1. Interpretación de las medias	4
3.2. Interpretación de las varianzas	4
3.3. Interpretación de los pesos	4
4. Variable latente	5
5. Algoritmo Expectation–Maximization	5
5.1. Paso E: responsabilidades	5
5.2. Paso M: actualización	6
6. Un caso especial: frontera inicial aproximada	6
7. Datos del ejemplo	7
8. Inicialización	7
9. Primera iteración: paso E	8
10. Lectura de las responsabilidades	8
11. Primera iteración: paso M	9
12. Interpretación del paso M	11
13. Verificación con la log-verosimilitud	11
14. Por qué EM mejora la verosimilitud	12
15. Visualización de la mezcla	12
15.1. Cómo leer la gráfica	14
16. Clasificación MAP	14
17. Umbral de decisión	15

18.Ajuste automático con mclust	15
18.1. Selección mediante BIC	15
19.Posteriores de mclust	16
20.Interpretación en tráfico urbano	16
21.Limitación del modelo unidimensional	16
22.Extensión a dos dimensiones	17
23.Otras variables útiles	17
24.Preguntas de autoevaluación	18
25.Ejercicios sugeridos	18
26.Actividad integradora	19
27.Ideas esenciales para recordar	20
28.Bibliografía recomendada	20

1. Propósito de esta guía

En estudios de movilidad urbana es frecuente resumir el comportamiento de un tramo vial mediante una velocidad media. Sin embargo, un único promedio puede ser poco representativo cuando el tránsito cambia entre distintos regímenes de operación.

Por ejemplo, en un mismo tramo pueden alternarse periodos de **hora pico**, caracterizados por velocidades bajas y frecuentes detenciones, y periodos de **flujo libre**, con velocidades mayores y una dinámica distinta.

En esta guía se utilizará un **Modelo de Mezcla Gaussiana** (*Gaussian Mixture Model*, GMM) para describir esos dos regímenes de forma probabilística. El ejemplo se mantiene deliberadamente pequeño para que sea posible seguir, verificar e interpretar una iteración completa del algoritmo *Expectation–Maximization* (EM) antes de automatizar el ajuste con `mclust`.

Objetivos de aprendizaje

Al finalizar el estudio de este material, el estudiante deberá ser capaz de:

1. Formular un GMM unidimensional con dos componentes.
2. Interpretar los parámetros π_k , μ_k y σ_k^2 en un problema de tráfico urbano.
3. Explicar el papel de la variable latente que identifica el régimen generador.
4. Calcular las responsabilidades del paso E.
5. Actualizar pesos, medias y varianzas en el paso M.
6. Verificar el incremento de la log-verosimilitud después de una iteración de EM.
7. Interpretar velocidades intermedias como observaciones con pertenencia incierta.
8. Comparar una iteración manual con el ajuste automático obtenido mediante `mclust`.

2. Motivación: dos regímenes de circulación

Supongamos que el área de movilidad de una ciudad desea caracterizar la velocidad media, medida en km/h, en un tramo conflictivo. La evidencia operativa sugiere que la distribución observada no es homogénea, sino que puede responder a dos situaciones:

- **Hora pico**: velocidades relativamente bajas, asociadas con congestión, semáforos, detenciones y alta interacción entre vehículos.
- **Flujo libre**: velocidades relativamente altas, asociadas con menor densidad vehicular y menos interrupciones.

Si se utiliza una sola distribución normal, el modelo intentaría resumir ambos comportamientos mediante una única media y una única varianza. Esto podría ocultar la coexistencia de dos patrones diferenciados.

Un GMM permite representar la densidad total como combinación de varias densidades simples.

Interpretación

El objetivo no es sólo dividir las observaciones en dos grupos. El GMM intenta explicar la distribución de las velocidades mediante dos mecanismos probabilísticos superpuestos. Por eso una velocidad intermedia puede recibir probabilidad significativa bajo ambos componentes.

3. Modelo probabilístico

Sea X la velocidad media observada en un intervalo de tiempo. Consideraremos un modelo con dos componentes:

$$p(x \mid \Theta) = \sum_{k=1}^2 \pi_k \mathcal{N}(x \mid \mu_k, \sigma_k^2), \quad (1)$$

donde

$$\pi_k > 0, \quad \pi_1 + \pi_2 = 1.$$

El conjunto de parámetros es

$$\Theta = \{\pi_1, \pi_2, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2\}.$$

3.1. Interpretación de las medias

Cada parámetro

$$\mu_k$$

representa la velocidad media característica del componente k .

En este ejemplo, una media menor se asociará con el régimen de hora pico y una media mayor con flujo libre.

3.2. Interpretación de las varianzas

Cada

$$\sigma_k^2$$

describe la dispersión de las velocidades dentro del régimen correspondiente.

Una varianza grande indica que, aun dentro del mismo régimen, las velocidades presentan mayor variabilidad.

3.3. Interpretación de los pesos

Los pesos

$$\pi_k$$

describen la importancia relativa de cada componente en la mezcla.

Por ejemplo,

$$\pi_1 = 0.45, \quad \pi_2 = 0.55$$

puede interpretarse como que, bajo el modelo ajustado, aproximadamente el 45 % de las observaciones proviene del primer régimen y el 55 % del segundo.

Punto de atención

El peso π_k es una proporción global del componente en la mezcla. No debe confundirse con la probabilidad posterior de que una observación específica pertenezca al componente.

4. Variable latente

Para cada observación x_i , introducimos una variable no observada

$$Z_i \in \{1, 2\}.$$

La interpretación es

$$Z_i = k \iff x_i \text{ fue generado por el régimen } k.$$

Si conociéramos todos los valores de Z_i , el problema sería sencillo: bastaría separar las velocidades por régimen y estimar una normal en cada grupo.

Sin embargo, en una aplicación no supervisada observamos las velocidades, pero no sabemos qué régimen generó cada una. Esta incertidumbre es la razón para utilizar EM.

Conexión con aprendizaje máquina

El GMM es un modelo de variables latentes. El algoritmo EM alterna entre estimar probabilísticamente esas variables ocultas y actualizar los parámetros del modelo.

5. Algoritmo Expectation–Maximization

EM alterna dos pasos fundamentales.

5.1. Paso E: responsabilidades

Para cada observación x_i y componente k , definimos

$$\gamma_{ik} = P(Z_i = k \mid x_i, \Theta).$$

Por el teorema de Bayes,

$$\gamma_{ik} = \frac{\pi_k \phi(x_i; \mu_k, \sigma_k^2)}{\sum_{j=1}^2 \pi_j \phi(x_i; \mu_j, \sigma_j^2)}. \quad (2)$$

Para cada observación,

$$\gamma_{i1} + \gamma_{i2} = 1.$$

Estas cantidades se denominan **responsabilidades** porque cuantifican cuánto “explica” cada componente una observación.

5.2. Paso M: actualización

Definimos

$$N_k = \sum_{i=1}^N \gamma_{ik}. \quad (3)$$

Luego actualizamos

$$\pi_k^{\text{new}} = \frac{N_k}{N}, \quad (4)$$

$$\mu_k^{\text{new}} = \frac{\sum_i \gamma_{ik} x_i}{N_k}, \quad (5)$$

y

$$(\sigma_k^2)^{\text{new}} = \frac{\sum_i \gamma_{ik} (x_i - \mu_k^{\text{new}})^2}{N_k}. \quad (6)$$

Interpretación

El paso M se parece al cálculo usual de medias y varianzas, pero las observaciones no cuentan todas por igual. Una velocidad con $\gamma_{i1} = 0.95$ influye mucho en el componente 1; una con $\gamma_{i1} = 0.10$ influye poco.

6. Un caso especial: frontera inicial aproximada

Supongamos momentáneamente que

$$\pi_1 = \pi_2$$

y que

$$\sigma_1^2 = \sigma_2^2.$$

En este caso, la igualdad

$$\gamma_{i1} = \gamma_{i2}$$

ocurre cerca del punto medio entre las medias:

$$x^* \approx \frac{\mu_1 + \mu_2}{2}.$$

Esto proporciona una intuición geométrica útil para la primera iteración.

Punto de atención

Este resultado depende de la igualdad de pesos y varianzas. Si $\pi_1 \neq \pi_2$ o $\sigma_1^2 \neq \sigma_2^2$, la frontera se desplaza.

7. Datos del ejemplo

Tomaremos seis velocidades:

28, 32, 37, 41, 46, 50

km/h.

En R:

```
1 X <- c(  
2   28, 32, 37,  
3   41, 46, 50  
4 )  
5  
6 data.frame(  
7   i = 1:length(X),  
8   x_i = X  
9 )
```

La pequeña muestra permite realizar todos los cálculos de manera transparente.

8. Inicialización

Comenzaremos con

$$\pi_1 = \pi_2 = 0.5,$$

$$\mu_1 = 30, \quad \mu_2 = 45,$$

y

$$\sigma_1 = \sigma_2 = 6.$$

Por tanto,

$$\sigma_1^2 = \sigma_2^2 = 36.$$

En R:

```
1 pi1 <- 0.5  
2 pi2 <- 0.5  
3  
4 mu1 <- 30  
5 mu2 <- 45  
6  
7 sd1 <- 6  
8 sd2 <- 6
```

Con esta elección, el punto medio inicial es

$$\frac{30 + 45}{2} = 37.5.$$

Podemos anticipar que velocidades cercanas a 37–38 km/h estarán en una región de mayor incertidumbre.

9. Primera iteración: paso E

Para cada velocidad x_i , calculamos primero

$$a_{i1} = \pi_1 \phi(x_i; \mu_1, \sigma_1^2),$$

$$a_{i2} = \pi_2 \phi(x_i; \mu_2, \sigma_2^2).$$

Después normalizamos:

$$\gamma_{i1} = \frac{a_{i1}}{a_{i1} + a_{i2}}, \quad \gamma_{i2} = 1 - \gamma_{i1}.$$

En R:

```
1 num1 <- pi1 *
2   dnorm(
3     X,
4     mean = mu1,
5     sd = sd1
6   )
7
8 num2 <- pi2 *
9   dnorm(
10    X,
11    mean = mu2,
12    sd = sd2
13  )
14
15 den <- num1 + num2
16
17 gamma1 <- num1 / den
18 gamma2 <- 1 - gamma1
19
20 E_table <- data.frame(
21   x_i = X,
22   gamma_i1 = round(gamma1, 3),
23   gamma_i2 = round(gamma2, 3)
24 )
25
26 E_table
```

Como valores de referencia,

$$\gamma_{i1} \approx (0.981, 0.908, 0.552, 0.189, 0.028, 0.005).$$

10. Lectura de las responsabilidades

La observación

$$x = 28$$

tiene

$$\gamma_{1,1} \approx 0.981.$$

El primer componente explica casi completamente esta velocidad.
En cambio, para

$$x = 50$$

se obtiene aproximadamente

$$\gamma_{6,1} \approx 0.005,$$

por lo que el segundo componente domina claramente.
El caso

$$x = 37$$

es especialmente importante:

$$\gamma_{3,1} \approx 0.552, \quad \gamma_{3,2} \approx 0.448.$$

La observación se encuentra cerca de la frontera probabilística de los dos componentes.

Interpretación

Una responsabilidad cercana a 0.5 no significa necesariamente que el tránsito esté físicamente “50 % en hora pico y 50 % en flujo libre”. Significa que, dadas las variables observadas y los parámetros actuales, ambos componentes ofrecen explicaciones similares para esa velocidad.

Actividad para el estudiante

Calcule manualmente las densidades normales correspondientes a $x = 37$:

$$\phi(37; 30, 6^2), \quad \phi(37; 45, 6^2).$$

Multiplique ambas por 0.5, normalice y verifique el valor aproximado de $\gamma_{3,1}$.

11. Primera iteración: paso M

Ahora calculamos los tamaños efectivos:

$$N_1 = \sum_i \gamma_{i1}, \quad N_2 = \sum_i \gamma_{i2}.$$

En R:

```
1 N1 <- sum(gamma1)
2 N2 <- sum(gamma2)
3
4 pi1_new <- N1 / length(X)
5 pi2_new <- N2 / length(X)
```

Las medias actualizadas son

```
1 mu1_new <-
2   sum(gamma1 * X) / N1
3
4 mu2_new <-
5   sum(gamma2 * X) / N2
```

Las varianzas se actualizan mediante

```

1 var1_new <-
2   sum(
3     gamma1 *
4     (X - mu1_new)^2
5   ) / N1
6
7 var2_new <-
8   sum(
9     gamma2 *
10    (X - mu2_new)^2
11  ) / N2
12
13 sd1_new <- sqrt(var1_new)
14 sd2_new <- sqrt(var2_new)

```

Los resultados pueden organizarse así:

```

1 M_table <- data.frame(
2   componente = c(
3     "1 (pico)",
4     "2 (libre)"
5   ),
6   N_k = c(N1, N2),
7   pi_k = c(
8     pi1_new,
9     pi2_new
10  ),
11  mu_k = c(
12    mu1_new,
13    mu2_new
14  ),
15  sigma_k = c(
16    sd1_new,
17    sd2_new
18  )
19 )
20
21 nums <- sapply(
22   M_table,
23   is.numeric
24 )
25
26 M_table_round <- M_table
27
28 M_table_round[, nums] <-
29   lapply(
30     M_table_round[, nums],
31     round,
32     3
33   )
34
35 M_table_round

```

Como referencia,

$$N_1 \approx 2.664, \quad \pi_1^{\text{new}} \approx 0.444,$$

$$N_2 \approx 3.336, \quad \pi_2^{\text{new}} \approx 0.556,$$

$$\mu_1^{\text{new}} \approx 32.385, \quad \sigma_1^{\text{new}} \approx 4.404,$$

$$\mu_2^{\text{new}} \approx 44.281, \quad \sigma_2^{\text{new}} \approx 5.098.$$

12. Interpretación del paso M

Después de una sola iteración, el primer componente queda centrado alrededor de 32–33 km/h y el segundo alrededor de 44–45 km/h.

Los pesos dejan de ser exactamente iguales:

$$\pi_1^{\text{new}} \approx 0.444, \quad \pi_2^{\text{new}} \approx 0.556.$$

Esto significa que el modelo comienza a asignar una proporción efectiva ligeramente mayor al régimen de flujo libre.

Interpretación

Los valores de N_k no son enteros porque no contamos observaciones de forma rígida. Cada velocidad participa parcialmente en ambos componentes de acuerdo con sus responsabilidades.

13. Verificación con la log-verosimilitud

Para observaciones independientes,

$$L(\Theta) = \prod_{i=1}^N p(x_i | \Theta).$$

En la práctica trabajamos con

$$\ell(\Theta) = \sum_{i=1}^N \log \left[\pi_1 \phi(x_i; \mu_1, \sigma_1^2) + \pi_2 \phi(x_i; \mu_2, \sigma_2^2) \right]. \quad (7)$$

En R:

```

1 loglik <- function(
2   x,
3   p1, m1, s1,
4   p2, m2, s2
5 ){
6   sum(
7     log(
8       p1 * dnorm(x, m1, s1) +
9       p2 * dnorm(x, m2, s2)
10    )
11  )
12 }
13
14 ll0 <- loglik(
15   X,
16   pi1, mu1, sd1,
17   pi2, mu2, sd2
18 )
19
```

```

20 l11 <- loglik(
21   X,
22   pi1_new, mu1_new, sd1_new,
23   pi2_new, mu2_new, sd2_new
24 )
25
26 c(
27   l1_inicial = l10,
28   l1_despues_EM = l11
29 )

```

Debe observarse un incremento aproximado de

$$-20.845$$

a

$$-20.237.$$

Como

$$-20.237 > -20.845,$$

la log-verosimilitud aumentó.

Punto de atención

Que la log-verosimilitud sea negativa no implica un mal ajuste. Lo importante aquí es comparar iteraciones.

14. Por qué EM mejora la verosimilitud

Una característica central del algoritmo EM es que construye cada iteración de forma que

$$\ell(\Theta^{(t+1)}) \geq \ell(\Theta^{(t)}).$$

Esto no significa necesariamente que llegue al máximo global de la verosimilitud. En mezclas Gaussianas pueden existir varios máximos locales.

Por ello, en problemas reales se suelen utilizar varias inicializaciones o métodos auxiliares para obtener buenos puntos de partida.

Conexión con aprendizaje máquina

Esta distinción es importante en aprendizaje máquina: EM ofrece una estrategia de optimización iterativa, pero la calidad final puede depender de la inicialización.

15. Visualización de la mezcla

Una gráfica útil combina:

- el histograma de velocidades;
- la densidad total de la mezcla;
- las contribuciones de cada componente.

En R:

```
1 library(ggplot2)
2
3 df <- data.frame(
4   x = X
5 )
6
7 gridx <- seq(
8   min(X) - 3,
9   max(X) + 3,
10  by = 0.1
11 )
12
13 dens_df <- data.frame(
14   x = gridx,
15   mix =
16     pi1_new *
17     dnorm(
18       gridx,
19       mu1_new,
20       sd1_new
21     ) +
22     pi2_new *
23     dnorm(
24       gridx,
25       mu2_new,
26       sd2_new
27     ),
28   comp1 =
29     pi1_new *
30     dnorm(
31       gridx,
32       mu1_new,
33       sd1_new
34     ),
35   comp2 =
36     pi2_new *
37     dnorm(
38       gridx,
39       mu2_new,
40       sd2_new
41     )
42 )
43
44 ggplot(
45   df,
46   aes(x = x)
47 ) +
48   geom_histogram(
49     aes(
50       y = after_stat(density)
51     ),
52     bins = 6,
53     fill = "grey85",
54     color = "grey40"
55 ) +
56   geom_line(
57     data = dens_df,
```

```

58     aes(
59       x = x,
60       y = mix
61     ),
62     linewidth = 1,
63     inherit.aes = FALSE
64   ) +
65   geom_line(
66     data = dens_df,
67     aes(
68       x = x,
69       y = comp1
70     ),
71     linetype = "dashed",
72     inherit.aes = FALSE
73   ) +
74   geom_line(
75     data = dens_df,
76     aes(
77       x = x,
78       y = comp2
79     ),
80     linetype = "dashed",
81     inherit.aes = FALSE
82   ) +
83   labs(
84     title =
85       "Histograma y densidad de la mezcla",
86     subtitle =
87       "Linea solida: mezcla; lineas punteadas: componentes",
88     x = "Velocidad (km/h)",
89     y = "Densidad"
90   ) +
91   theme_minimal()

```

15.1. Cómo leer la gráfica

Las líneas punteadas muestran las contribuciones ponderadas

$$\pi_1 \phi_1(x) \quad \text{y} \quad \pi_2 \phi_2(x),$$

mientras que la línea sólida representa su suma.

En la región donde ambas contribuciones son similares, la clasificación es más incierta.

16. Clasificación MAP

Aunque el GMM produce probabilidades, puede asignarse una etiqueta única mediante

$$\hat{z}_i = \arg \max_{k \in \{1,2\}} \gamma_{ik}.$$

Con dos componentes esto equivale a usar

$$\hat{z}_i = \begin{cases} 1, & \gamma_{i1} > 0.5, \\ 2, & \gamma_{i1} < 0.5. \end{cases}$$

Esta regla se denomina clasificación por máxima probabilidad posterior o clasificación MAP.

Interpretación

La clasificación MAP resume cada vector de probabilidades en una única etiqueta. Esto facilita decisiones operativas, pero descarta información sobre incertidumbre.

17. Umbral de decisión

La frontera entre los dos componentes está dada por los valores x que satisfacen

$$\pi_1 \phi(x; \mu_1, \sigma_1^2) = \pi_2 \phi(x; \mu_2, \sigma_2^2).$$

Con pesos y varianzas iguales, el umbral es exactamente el punto medio:

$$x^* = \frac{\mu_1 + \mu_2}{2}.$$

Después del paso M, como pesos y varianzas ya no son iguales, la frontera no tiene por qué coincidir con el punto medio de las medias actualizadas.

Actividad para el estudiante

Utilice los parámetros actualizados y resuelva numéricamente

$$\pi_1^{\text{new}} \phi(x; \mu_1^{\text{new}}, (\sigma_1^{\text{new}})^2) = \pi_2^{\text{new}} \phi(x; \mu_2^{\text{new}}, (\sigma_2^{\text{new}})^2).$$

Compare el resultado con

$$\frac{\mu_1^{\text{new}} + \mu_2^{\text{new}}}{2}.$$

18. Ajuste automático con `mclust`

Hasta ahora realizamos una sola iteración. En la práctica, EM se ejecuta hasta que los cambios sean suficientemente pequeños.

El paquete `mclust` permite automatizar el procedimiento:

```
1 # install.packages("mclust")
2 library(mclust)
3
4 fit <- Mclust(
5   matrix(X, ncol = 1),
6   G = 1:3
7 )
8
9 summary(fit)
```

La opción

```
1 G = 1:3
```

indica que se consideren modelos con uno, dos o tres componentes.

18.1. Selección mediante BIC

`mclust` utiliza BIC para comparar modelos con diferente número de componentes y distintas parametrizaciones.

Por ello, el ajuste automático no tiene por qué elegir exactamente dos componentes.

Punto de atención

En una muestra de sólo seis observaciones, cualquier criterio de selección de modelos debe interpretarse con cautela. El ejemplo tiene finalidad didáctica, no pretende representar una calibración robusta de un sistema de tráfico real.

19. Posteriores de `mclust`

Las probabilidades posteriores pueden consultarse mediante

```
1 post <- data.frame(  
2   x_i = X,  
3   tau_k1 =  
4     round(  
5       fit$z[,1],  
6       3  
7     )  
8 )  
9  
10 post
```

Estas probabilidades no deben coincidir exactamente con las obtenidas en la primera iteración manual.

La razón es que `mclust` ejecuta varias iteraciones hasta alcanzar convergencia y puede además seleccionar otro número de componentes.

20. Interpretación en tráfico urbano

Después de la primera iteración, el modelo sugiere aproximadamente:

- **Componente 1, hora pico:** media alrededor de 32–33 km/h, dispersión de aproximadamente 4–5 km/h y peso cercano al 40–45 %.
- **Componente 2, flujo libre:** media alrededor de 44–45 km/h, dispersión alrededor de 5 km/h y peso cercano al 55–60 %.

Las velocidades alrededor de 37–41 km/h se sitúan en una región de mayor solapamiento.

Interpretación

Las etiquetas “pico” y “libre” se asignan a partir del significado de las medias estimadas. El GMM por sí mismo sólo identifica componentes numéricos.

21. Limitación del modelo unidimensional

Una sola variable, la velocidad media, puede ser insuficiente para describir completamente el estado del tránsito.

Dos intervalos con la misma velocidad media pueden tener comportamientos distintos:

- uno puede presentar circulación estable;
- otro puede alternar detenciones y aceleraciones;
- uno puede tener alto flujo vehicular;

- otro puede tener pocos vehículos.

Por ello, una extensión natural consiste en incorporar más variables.

22. Extensión a dos dimensiones

Una propuesta sencilla es utilizar

$$X_i = \begin{pmatrix} \text{velocidad media} \\ \text{desviación estándar de la velocidad} \end{pmatrix}.$$

La segunda coordenada puede resumir la irregularidad del tránsito dentro de una subventana temporal.

Un régimen de hora pico podría presentar velocidad media baja y variabilidad relativamente alta debido a paradas y arranques.

El modelo pasaría a ser

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad x \in \mathbb{R}^2.$$

Conexión con aprendizaje máquina

Al pasar de una a varias variables, un régimen de tráfico deja de definirse únicamente por una velocidad típica y pasa a describirse mediante un patrón multivariado.

23. Otras variables útiles

Dependiendo del problema, podrían incorporarse:

- flujo vehicular;
- densidad de vehículos;
- ocupación de carril;
- tiempo medio entre vehículos;
- frecuencia de detenciones;
- longitud de cola;
- hora del día;
- día de la semana;
- condiciones meteorológicas.

La elección de variables debe responder al objetivo analítico y a la disponibilidad de sensores.

24. Preguntas de autoevaluación

Antes de continuar con conjuntos de datos más grandes, el estudiante debería poder responder:

1. ¿Por qué una única media puede ocultar la existencia de dos regímenes?
2. ¿Cuál es la diferencia entre π_k y γ_{ik} ?
3. ¿Qué representa N_k ?
4. ¿Por qué N_k puede no ser entero?
5. ¿Qué significa que una responsabilidad sea cercana a 0.5?
6. ¿Qué cambia en la frontera de decisión si $\pi_1 \neq \pi_2$?
7. ¿Qué cambia si $\sigma_1^2 \neq \sigma_2^2$?
8. ¿Por qué EM puede depender de la inicialización?
9. ¿Qué propiedad de la log-verosimilitud se espera entre iteraciones?
10. ¿Por qué `mclust` no tiene que coincidir exactamente con una sola iteración manual?
11. ¿Qué información pierde una clasificación MAP?
12. ¿Qué limitaciones tiene modelar tráfico utilizando sólo velocidad media?

25. Ejercicios sugeridos

Ejercicio 1. Segunda iteración de EM.

Utilice

$$\pi_k^{\text{new}}, \quad \mu_k^{\text{new}}, \quad \sigma_k^{\text{new}}$$

como nueva inicialización y repita los pasos E y M. Verifique que la log-verosimilitud vuelve a aumentar.

Ejercicio 2. Clasificación MAP.

Clasifique cada velocidad mediante

$$\arg \max_k \gamma_{ik}$$

Compare las etiquetas con la interpretación “pico” y “libre”.

Ejercicio 3. Cambio de pesos iniciales.

Repita el paso E con

$$\pi_1 = 0.7, \quad \pi_2 = 0.3.$$

Analice especialmente las velocidades de 37 y 41 km/h.

Ejercicio 4. Cambio de dispersión.

Mantenga las medias iniciales, pero utilice

$$\sigma_1 = 8, \quad \sigma_2 = 4.$$

Explique cómo cambia el solapamiento.

Ejercicio 5. Umbral posterior.

Calcule numéricamente el valor x^* que satisface

$$\gamma_1(x^*) = \gamma_2(x^*) = 0.5$$

usando los parámetros actualizados.

Ejercicio 6. Datos sintéticos.

Genere 100 velocidades de un componente con media 30 y 100 de otro con media 45. Modifique las desviaciones estándar para controlar el solapamiento.

Ejercicio 7. Curva de log-verosimilitud.

Implemente EM completo y grafique

$$t \mapsto \ell(\Theta^{(t)}).$$

Ejercicio 8. Comparación con mclust.

Ajuste modelos con

$$G = 1, 2, 3.$$

Compare BIC y las probabilidades posteriores.

Ejercicio 9. Extensión bidimensional.

Genere datos sintéticos con velocidad media y desviación estándar. Ajuste un GMM bidimensional e interprete sus componentes.

Ejercicio 10. Discusión aplicada.

Explique qué información adicional necesitaría para afirmar que los componentes obtenidos representan realmente “hora pico” y “flujo libre” y no simplemente dos grupos estadísticos de velocidades.

26. Actividad integradora

Como actividad final, construya un experimento sintético en el que la separación entre dos regímenes pueda controlarse.

Utilice, por ejemplo,

$$X \mid Z = 1 \sim \mathcal{N}(30, \sigma_1^2),$$

$$X \mid Z = 2 \sim \mathcal{N}(45, \sigma_2^2).$$

Repita el ajuste para diferentes valores de

$$\sigma_1 = \sigma_2 = \sigma.$$

Considere, por ejemplo,

$$\sigma = 2, \quad 4, \quad 6, \quad 8.$$

Para cada caso:

1. genere una muestra;
2. ajuste un GMM;
3. grafique las densidades;

4. calcule las responsabilidades;
5. localice la región donde las probabilidades son próximas a 0.5;
6. compare el número de errores de clasificación si conoce las etiquetas generadoras.

Conexión con aprendizaje máquina

Este ejercicio muestra directamente cómo el solapamiento entre distribuciones afecta la incertidumbre del clasificador probabilístico.

27. Ideas esenciales para recordar

- Un GMM representa una distribución como combinación de componentes Gaussianos.
- En tráfico urbano, cada componente puede interpretarse como un régimen de circulación si esa interpretación es consistente con los parámetros estimados y con el contexto.
- Los pesos π_k son proporciones globales.
- Las responsabilidades γ_{ik} son probabilidades posteriores específicas de cada observación.
- EM alterna entre estimar responsabilidades y actualizar parámetros.
- La log-verosimilitud no debe disminuir en las iteraciones estándar de EM.
- Las velocidades en la zona de solapamiento presentan mayor incertidumbre.
- Una clasificación MAP simplifica el resultado, pero descarta información probabilística.
- La velocidad media por sí sola puede ser insuficiente para caracterizar el estado del tránsito.

28. Bibliografía recomendada

Referencias

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [2] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2a ed., Springer, 2009.
- [3] G. McLachlan y D. Peel, *Finite Mixture Models*, Wiley, 2000.
- [4] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.
- [5] L. Scrucca, M. Fop, T. B. Murphy y A. E. Raftery, “mclust 5: Clustering, Classification and Density Estimation Using Gaussian Finite Mixture Models”, *The R Journal*, 8(1), 2016.