

Motivación

Modelo (1D) y algoritmo EM

Datos (tabla para cuentas a mano)

Una vuelta de EM **manual** (con números)

Visualización rápida

Confirmación con `mclust` (automatizado)

Interpretación (tráfico)

Ejercicios sugeridos

Tránsito urbano como mezcla Gaussiana (GMM): un ejemplo mínimo con EM

FCFM-UNACH | Matemáticas Aplicadas

2025-08-26

Motivación

El área de movilidad de una ciudad quiere **caracterizar la velocidad media** (km/h) en un **tramo conflictivo**. Sospechan que **coexisten dos regímenes**:

- **Hora pico** (velocidades bajas, más dispersión por detenciones).
- **Flujo libre** (velocidades altas, menos variabilidad).

En vez de forzar un único promedio, usamos un **Modelo de Mezcla Gaussiana (GMM)** con 2 componentes, y ajustamos sus parámetros con **Expectation-Maximization (EM)**. Veremos un caso **mínimo**, numérico y verificable “a mano”, antes de automatizar con `mclust`.

Modelo (1D) y algoritmo EM

Sea X la velocidad. Modelamos

$$p(x|\Theta) = \sum_{k=1}^2 \pi_k \mathcal{N}(x | \mu_k, \sigma_k^2), \quad \pi_k > 0, \pi_1 + \pi_2 = 1.$$

- μ_k : media del régimen k ,
- σ_k^2 : varianza del régimen k ,
- π_k : peso (proporción del tiempo en el régimen k).

Variables latentes: $Z_i \in \{1, 2\}$ indica el régimen que generó x_i . En el **E-step**, calculamos **responsabilidades**:

$$\gamma_{ik} = \mathbb{P}(Z_i = k | x_i, \Theta) = \frac{\pi_k \phi(x_i | \mu_k, \sigma_k^2)}{\sum_{j=1}^2 \pi_j \phi(x_i | \mu_j, \sigma_j^2)}.$$

En el **M-step**, actualizamos:

$$N_k = \sum_i \gamma_{ik}, \quad \pi_k^{\text{new}} = \frac{N_k}{N}, \quad \mu_k^{\text{new}} = \frac{\sum_i \gamma_{ik} x_i}{N_k}, \quad \sigma_k^{2\text{new}} = \frac{\sum_i \gamma_{ik} (x_i - \mu_k^{\text{new}})^2}{N_k}.$$

Nota didáctica: si $\pi_1 = \pi_2$ y $\sigma_1^2 = \sigma_2^2$, el **umbral** de decisión inicial está cerca del **punto medio** $(\mu_1 + \mu_2)/2$: alrededor de ese valor, $\gamma_{i1} \approx \gamma_{i2} \approx 0.5$.

Datos (tabla para cuentas a mano)

Tomamos **N = 6** velocidades (km/h):

```
# datos
X <- c(28, 32, 37, 41, 46, 50)
data.frame(i = 1:length(X), x_i = X)
```

Inicialización (intuitiva):

$$\pi_1 = \pi_2 = 0.5, \quad \mu_1 = 30, \mu_2 = 45, \quad \sigma_1 = \sigma_2 = 6.$$

Una vuelta de EM **manual** (con números)

E-step: responsabilidades γ_{ik}

```
# Estep
pi1 <- 0.5; pi2 <- 0.5
mu1 <- 30; mu2 <- 45
sd1 <- 6; sd2 <- 6

num1 <- pi1 * dnorm(X, mean = mu1, sd = sd1)
num2 <- pi2 * dnorm(X, mean = mu2, sd = sd2)
den <- num1 + num2

gamma1 <- num1 / den
gamma2 <- 1 - gamma1
```

```
E_table <- data.frame(
  x_i = X,
  gamma_i1 = round(gamma1, 3),
  gamma_i2 = round(gamma2, 3)
)
E_table
```

Valores de referencia (esperados, $\approx$): $(x=)$ 28, 32, 37, 41, 46, 50 $\rightarrow \gamma_{i1} \approx$ 0.981, 0.908, 0.552, 0.189, 0.028, 0.005.

M-step: actualización de (π, μ, σ^2)

```
N1 <- sum(gamma1); N2 <- sum(gamma2)
pi1_new <- N1/length(X); pi2_new <- N2/length(X)

mu1_new <- sum(gamma1 * X) / N1
mu2_new <- sum(gamma2 * X) / N2

var1_new <- sum(gamma1 * (X - mu1_new)^2) / N1
var2_new <- sum(gamma2 * (X - mu2_new)^2) / N2
sd1_new <- sqrt(var1_new); sd2_new <- sqrt(var2_new)

M_table <- data.frame(
  componente = c("1 (pico)", "2 (libre)"),
  N_k = c(N1, N2),
  pi_k = c(pi1_new, pi2_new),
  mu_k = c(mu1_new, mu2_new),
  sigma_k = c(sd1_new, sd2_new)
)
nums <- sapply(M_table, is.numeric)
M_table_round <- M_table
M_table_round[, nums] <- lapply(M_table_round[, nums], round, 3)
M_table_round
```

Referencia numérica: $(N_1 \approx 2.664, \pi_1^{\text{new}} \approx 0.444; \text{quad } N_2 \approx 3.336, \pi_2^{\text{new}} \approx 0.556) \setminus$
 $(\mu_1^{\text{new}} \approx 32.385, \sigma_1^{\text{new}} \approx 4.404; \text{quad } \mu_2^{\text{new}} \approx 44.281, \sigma_2^{\text{new}} \approx 5.098)$.

Verificación: mejora de la log-verosimilitud

```
loglik <- function(x, p1, m1, s1, p2, m2, s2){
  sum(log(p1*dnorm(x, m1, s1) + p2*dnorm(x, m2, s2)))
}

ll0 <- loglik(X, pi1, mu1, sd1, pi2, mu2, sd2)
ll1 <- loglik(X, pi1_new, mu1_new, sd1_new, pi2_new, mu2_new, sd2_new)
c(ll_inicial = ll0, ll_despues_EM = ll1)
```

```
##      ll_inicial ll_despues_EM
##      -20.84530      -20.23745
```

Deberías observar un aumento (por ejemplo, de ≈ -20.845 a ≈ -20.237).


Visualización rápida

```
# plot-mixtura, fig.height=3.6
library(ggplot2)

df <- data.frame(x = X)
gridx <- seq(min(X) - 3, max(X) + 3, by = 0.1)

dens_df <- data.frame(
  x      = gridx,
  mix    = pi1_new * dnorm(gridx, mu1_new, sd1_new) +
           pi2_new * dnorm(gridx, mu2_new, sd2_new),
  comp1  = pi1_new * dnorm(gridx, mu1_new, sd1_new),
  comp2  = pi2_new * dnorm(gridx, mu2_new, sd2_new)
)

ggplot(df, aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)),
    bins = 6, fill = "grey85", color = "grey40") +
  geom_line(data = dens_df, aes(x = x, y = mix),
    linewidth = 1, inherit.aes = FALSE) +
  geom_line(data = dens_df, aes(x = x, y = comp1),
    linetype = "dashed", inherit.aes = FALSE) +
  geom_line(data = dens_df, aes(x = x, y = comp2),
    linetype = "dashed", inherit.aes = FALSE) +
  labs(title = "Histograma + densidad de la mezcla (línea sólida)\ncomponentes G1 y G2 (líneas punteadas)",
    x = "Velocidad (km/h)", y = "Densidad") +
  theme_minimal()
```



Confirmación con mclust (automatizado)

```
# install.packages("mclust") # descomenta si no lo tienes
library(mclust)

fit <- Mclust(matrix(X, ncol = 1), G = 1:3) # deja que BIC escoja G
summary(fit)
```

```
## -----
## Gaussian finite mixture model fitted by EM algorithm
## -----
##
## Mclust X (univariate normal) model with 1 component:
##
## log-likelihood n df      BIC      ICL
## -20.69496 6 2 -44.97344 -44.97344
##
## Clustering table:
## 1
## 6
```

```
# Posteriores (responsabilidades) y comparación con nuestra 1ª vuelta manual:
post <- data.frame(x_i = X, tau_k1 = round(fit$z[,1], 3))
post
```

Mclust hará **múltiples** iteraciones EM hasta converger y puede elegir el número de componentes por **BIC**. No esperes que coincida exactamente con **una sola** vuelta manual; úsalo para contrastar y entender el proceso.

Interpretación (tráfico)

- **Componente 1 (pico):** centrado $\approx 32\text{--}33$ km/h, dispersión $\approx 4\text{--}5$ km/h, peso $\approx 40\text{--}45\%$.
- **Componente 2 (libre):** centrado $\approx 44\text{--}45$ km/h, dispersión ≈ 5 km/h, peso $\approx 55\text{--}60\%$.
- Velocidades intermedias 37–41 km/h quedan “**en frontera**” y se reparten probabilísticamente entre ambos regímenes.

Ejercicios sugeridos

1. Repite **E-step** con $((\pi^{\text{new}}, \mu^{\text{new}}, \sigma^{\text{new}}))$ y verifica que la log-verosimilitud vuelve a subir.
2. Clasifica cada x_i por **máxima posterior** $\arg\max_k \gamma_{ik}$ y marca un **umbral** aproximado.
3. Cambia iniciales a $(\pi_1=0.7, \pi_2=0.3)$ y comenta el efecto en la frontera.
4. Extiende a 2D incorporando, por ejemplo, la **desviación estándar** de la velocidad por subventanas; repite el flujo con Mclust .