

Descenso de Gradiente Estocástico y PINNs

Guía de estudio: minibatches, ruido de gradiente y entrenamiento de redes para EDO

FCFM–UNACH
Licenciatura en Matemáticas Aplicadas
Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de la guía	3
2. Entrenamiento de una red neuronal como problema de optimización	3
2.1. Significado de los símbolos	4
3. ¿Por qué se considera un problema sin restricciones explícitas?	4
4. Ejemplos de funciones de pérdida	4
4.1. Regresión	4
4.2. Clasificación binaria	5
4.3. Clasificación multiclase	5
4.4. Regularización L^2	5
5. Gradiente completo	5
6. Minibatches	5
7. Esquemas de muestreo	6
7.1. Muestreo con reemplazo	6
7.2. Muestreo sin reemplazo	6
7.3. Random reshuffling	6
8. ¿Por qué g_t es aleatorio?	7
9. Imparcialidad del gradiente estocástico	7
9.1. Prueba sin reemplazo	7
9.2. Prueba con reemplazo	7
10. Ruido estocástico	8
11. Covarianza del gradiente estocástico	8
11.1. Con reemplazo	8
11.2. Sin reemplazo	8
12. Efecto del tamaño del minibatch	9
13. ¿El ruido es gaussiano?	9
14. Interpretación de Monte Carlo	9
15. Ejemplo numérico unidimensional	10

16.Minibatch de tamaño $m = 1$	11
17.Minibatch de tamaño $m = 2$	11
18.Verificación mediante corrección por población finita	11
19.GD frente a SGD	12
20.Conexión continua: flujo gradiente	12
21.Conexión estocástica	12
22.¿Cuándo se utiliza SGD?	13
23.¿Cuándo es útil el gradiente completo?	13
24.Puente hacia PINNs	13
25.Ejemplo PINN: EDO de primer orden	14
26.Gradient completo en una PINN	14
27.Mini-batch de puntos de colocación	15
28.Ruido de gradiente en una PINN	15
29.Muestreo aleatorio de puntos de colocación	16
29.1. Conjunto fijo	16
29.2. Remuestreo del dominio	16
30.SGD en PINNs: interpretación práctica	16
31.Balance entre términos de la pérdida PINN	16
32.Diferenciación automática y SGD en una PINN	17
33.GD, SGD y Adam en PINNs	17
34.Preguntas de autoevaluación	17
35.Ejercicios propuestos	18
36.Actividad integradora	19
37.Ideas esenciales para recordar	19
38.Bibliografía recomendada	20

1. Propósito de la guía

El entrenamiento de una red neuronal puede formularse como un problema de optimización respecto de sus pesos y sesgos. En redes pequeñas, puede ser razonable evaluar la función de pérdida utilizando todos los datos disponibles. Sin embargo, cuando el número de observaciones o de puntos de evaluación es grande, resulta más eficiente construir estimaciones del gradiente usando sólo una parte de ellos.

Esta idea conduce al **descenso de gradiente estocástico** (SGD) y, en la práctica, al uso de **minibatches**.

En el contexto de las *Physics-Informed Neural Networks* (PINNs), esta misma idea aparece de manera natural: la pérdida suele evaluarse sobre un conjunto numeroso de puntos de colocación del dominio de una ecuación diferencial. En cada iteración, puede utilizarse sólo un subconjunto aleatorio de esos puntos para construir una aproximación del gradiente.

La secuencia de esta guía es:

pérdida $\longrightarrow$ gradiente completo $\longrightarrow$ minibatch $\longrightarrow$ gradiente estocástico $\longrightarrow$ ruido $\longrightarrow$ actualización SGD $\longrightarrow$

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Formular el entrenamiento de una RNA como un problema de optimización.
2. Diferenciar entre gradiente completo, SGD y mini-batch SGD.
3. Explicar por qué el gradiente de minibatch es una variable aleatoria.
4. Probar la imparcialidad del estimador del gradiente bajo esquemas estándar de muestreo.
5. Calcular la varianza del gradiente estocástico en ejemplos pequeños.
6. Interpretar el ruido
$$\xi_t = g_t - \nabla \mathcal{L}(W_t).$$
7. Comprender el efecto del tamaño del minibatch sobre la dispersión del gradiente.
8. Relacionar SGD con una dinámica determinista perturbada por ruido.
9. Aplicar estas ideas al entrenamiento de PINNs para ecuaciones diferenciales ordinarias.

2. Entrenamiento de una red neuronal como problema de optimización

Sea un conjunto de entrenamiento

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n.$$

Una red neuronal con parámetros

$$W \in \mathbb{R}^d$$

define una función

$$f_W : \mathbb{R}^p \longrightarrow \mathcal{Y}.$$

El entrenamiento consiste en minimizar la pérdida promedio

$$\min_{W \in \mathbb{R}^d} \mathcal{L}(W) = \frac{1}{n} \sum_{i=1}^n \ell(f_W(x_i), y_i) \quad (1)$$

donde ℓ mide el error de una observación individual.

2.1. Significado de los símbolos

Símbolo	Significado matemático	Interpretación en una RNA
$W \in \mathbb{R}^d$	vector de parámetros	pesos y sesgos de todas las capas
$x_i \in \mathbb{R}^p$	vector de entrada	observación o ejemplo
$y_i \in \mathcal{Y}$	salida deseada	etiqueta, valor o distribución objetivo
f_W	función parametrizada	red neuronal completa
ℓ	pérdida individual	discrepancia entre predicción y objetivo
n	tamaño de muestra	número total de ejemplos

3. ¿Por qué se considera un problema sin restricciones explícitas?

En la formulación básica no aparecen condiciones del tipo

$$g(W) = 0$$

o

$$h(W) \leq 0.$$

El objetivo es minimizar $\mathcal{L}(W)$ sobre el espacio de parámetros.

Sin embargo, la arquitectura impone estructura:

- las dimensiones de cada matriz de pesos están determinadas por las capas;
- las funciones de activación introducen no linealidad;
- regularizaciones como L^2 pueden incorporarse al funcional;
- compartir parámetros, como en convoluciones, reduce grados de libertad efectivos.

Por ello, el problema suele ser de alta dimensión y no convexo, aunque no tenga restricciones explícitas.

4. Ejemplos de funciones de pérdida

4.1. Regresión

Una elección frecuente es

$$\ell(f_W(x_i), y_i) = \frac{1}{2} |f_W(x_i) - y_i|^2.$$

Se utiliza para predecir variables continuas.

4.2. Clasificación binaria

Con salida probabilística,

$$\ell(f_W(x_i), y_i) = -[y_i \log f_W(x_i) + (1 - y_i) \log (1 - f_W(x_i))].$$

4.3. Clasificación multiclase

Con K clases,

$$\ell(f_W(x_i), y_i) = - \sum_{k=1}^K y_{ik} \log (f_W(x_i)_k).$$

4.4. Regularización L^2

Puede añadirse

$$\mathcal{L}_{\text{reg}}(W) = \frac{1}{n} \sum_{i=1}^n \ell(f_W(x_i), y_i) + \lambda \sum_{\ell} \|W^{(\ell)}\|_2^2.$$

Interpretación

La función de pérdida determina qué significa “mejorar” durante el entrenamiento. SGD no cambia el objetivo; cambia la forma en que aproximamos su gradiente.

5. Gradiente completo

Definamos el gradiente individual

$$g_i(W) := \nabla_W \ell(f_W(x_i), y_i).$$

Entonces

$$\nabla \mathcal{L}(W) = \frac{1}{n} \sum_{i=1}^n g_i(W). \quad (2)$$

El descenso de gradiente determinista utiliza

$$W_{t+1} = W_t - \eta_t \nabla \mathcal{L}(W_t), \quad (3)$$

donde $\eta_t > 0$ es la tasa de aprendizaje.

El costo de una actualización depende de evaluar todos los n términos del gradiente.

6. Minibatches

Para reducir el costo por iteración se selecciona un subconjunto aleatorio

$$B_t \subset \{1, \dots, n\}$$

de tamaño

$$|B_t| = m, \quad m \ll n.$$

Se define el gradiente de minibatch

$$g_t = \frac{1}{m} \sum_{i \in B_t} g_i(W_t) \quad (4)$$

y se actualiza

$$W_{t+1} = W_t - \eta_t g_t. \quad (5)$$

7. Esquemas de muestreo

Existen dos esquemas básicos.

7.1. Muestreo con reemplazo

Se eligen índices

$$I_1, \dots, I_m$$

independientes y uniformes:

$$P(I_j = i) = \frac{1}{n}.$$

El gradiente es

$$g_t = \frac{1}{m} \sum_{j=1}^m g_{I_j}(W_t).$$

Puede haber índices repetidos.

7.2. Muestreo sin reemplazo

Se selecciona uniformemente un subconjunto

$$B_t$$

entre todas las combinaciones de tamaño m .

No hay repeticiones dentro del minibatch.

7.3. Random reshuffling

En la práctica es frecuente generar una permutación aleatoria de

$$\{1, \dots, n\}$$

al inicio de cada época y dividirla en bloques.

Nota de precisión matemática

Para muestras independientes con reemplazo, la imparcialidad condicional del gradiente es directa. Para muestreo simple sin reemplazo también lo es si el minibatch se selecciona uniformemente de la población completa. En *random reshuffling*, los minibatches sucesivos dentro de una época son dependientes; por ello las afirmaciones condicionales deben formularse con cuidado.

8. ¿Por qué g_t es aleatorio?

El vector

$$g_t$$

es aleatorio porque depende de los índices seleccionados en B_t .

Aunque

$$W_t$$

sea fijo, distintos minibatches producen valores diferentes del gradiente estimado.

Esta es la fuente principal del carácter estocástico del método.

9. Imparcialidad del gradiente estocástico

Bajo muestreo uniforme estándar,

$$\mathbb{E}[g_t \mid W_t] = \nabla \mathcal{L}(W_t). \quad (6)$$

Es decir, el gradiente de minibatch es un estimador imparcial del gradiente completo.

9.1. Prueba sin reemplazo

Por simetría,

$$P(i \in B_t) = \frac{m}{n}.$$

Entonces

$$\mathbb{E} \left[\frac{1}{m} \sum_{i \in B_t} g_i(W_t) \middle| W_t \right] = \frac{1}{m} \sum_{i=1}^n P(i \in B_t) g_i(W_t).$$

Sustituyendo,

$$= \frac{1}{m} \frac{m}{n} \sum_{i=1}^n g_i(W_t) = \nabla \mathcal{L}(W_t).$$

9.2. Prueba con reemplazo

Como

$$\mathbb{E}[g_{I_j}(W_t) \mid W_t] = \frac{1}{n} \sum_{i=1}^n g_i(W_t),$$

se sigue que

$$\mathbb{E}[g_t \mid W_t] = \nabla \mathcal{L}(W_t).$$

Interpretación

“Imparcial” no significa que cada minibatch produzca el gradiente verdadero. Significa que, al promediar sobre muchas selecciones aleatorias, el error de muestreo se cancela.

10. Ruido estocástico

Definimos

$$\xi_t = g_t - \nabla \mathcal{L}(W_t). \quad (7)$$

Entonces,

$$\mathbb{E}[\xi_t \mid W_t] = 0.$$

La actualización puede escribirse como

$$\boxed{W_{t+1} = W_t - \eta_t (\nabla \mathcal{L}(W_t) + \xi_t)} \quad (8)$$

Esta forma separa dos efectos:

- el término determinista

$$-\eta_t \nabla \mathcal{L}(W_t);$$

- la perturbación aleatoria

$$-\eta_t \xi_t.$$

11. Covarianza del gradiente estocástico

11.1. Con reemplazo

Definamos

$$\Sigma(W_t) = \text{Cov}_{i \sim \text{Unif}[n]}(g_i(W_t)).$$

Entonces

$$\text{Cov}(g_t \mid W_t) = \frac{1}{m} \Sigma(W_t). \quad (9)$$

Por tanto, al aumentar m , la dispersión disminuye aproximadamente como $1/m$.

11.2. Sin reemplazo

Para una muestra simple,

$$\text{Cov}(g_t \mid W_t) = \frac{1}{m} \left(1 - \frac{m}{n}\right) \tilde{\Sigma}(W_t), \quad (10)$$

donde

$$\tilde{\Sigma}(W) = \frac{1}{n-1} \sum_{i=1}^n (g_i(W) - \nabla \mathcal{L}(W)) (g_i(W) - \nabla \mathcal{L}(W))^\top.$$

El factor

$$1 - \frac{m}{n}$$

es la corrección por población finita.

12. Efecto del tamaño del minibatch

La teoría anterior permite distinguir tres casos.

- Si

$$m = n,$$

se utiliza todo el conjunto y desaparece el ruido de muestreo.

- Si

$$m = 1,$$

cada actualización utiliza un solo ejemplo y la variabilidad es máxima.

- Si

$$1 < m < n,$$

se obtiene el régimen práctico de mini-batch SGD.

Interpretación

El tamaño del minibatch controla un compromiso: minibatches pequeños abaratan cada actualización pero introducen mayor variabilidad; minibatches grandes producen gradientes más estables, pero requieren más trabajo por iteración.

13. ¿El ruido es gaussiano?

En general,

$$\xi_t$$

no tiene distribución normal.

Para minibatches pequeños, el gradiente puede tomar sólo un número finito de valores determinados por las combinaciones posibles de observaciones.

Sin embargo, si se muestrea con reemplazo y m es moderado o grande, entonces g_t es un promedio de vectores i.i.d.

Bajo condiciones estándar del Teorema Central del Límite,

$$\sqrt{m}(g_t - \nabla \mathcal{L}(W_t)) \xrightarrow{d} \mathcal{N}(0, \Sigma(W_t)). \quad (11)$$

Para muestreo sin reemplazo existen resultados análogos con corrección por población finita.

Punto de atención

La aproximación normal es asintótica. No debe suponerse automáticamente para minibatches pequeños.

14. Interpretación de Monte Carlo

Cuando los datos pueden verse como realizaciones de una distribución,

$$\nabla \mathcal{L}(W)$$

puede interpretarse como una esperanza.

Entonces

$$g_t$$

es una estimación Monte Carlo basada en un subconjunto aleatorio.
De manera esquemática,

$$g_t \approx \mathbb{E}_X [\nabla_W \ell(f_W(X), Y)] .$$

Esta interpretación es especialmente útil para conectar SGD con métodos numéricos y probabilísticos.

15. Ejemplo numérico unidimensional

Consideremos el modelo lineal

$$\hat{y} = wx$$

y la pérdida individual

$$\ell_i(w) = \frac{1}{2}(wx_i - y_i)^2.$$

Entonces

$$g_i(w) = \frac{\partial \ell_i}{\partial w} = x_i(wx_i - y_i).$$

Tomemos

$$(x_1, y_1) = (1, 2),$$

$$(x_2, y_2) = (2, 4),$$

$$(x_3, y_3) = (3, 6),$$

y evaluemos en

$$w = 1.1.$$

Se obtiene

$$g_1 = -0.9, \quad g_2 = -3.6, \quad g_3 = -8.1.$$

El gradiente completo es

$$\nabla \mathcal{L}(w) = \frac{1}{3}(-0.9 - 3.6 - 8.1) = -4.2.$$

16. Minibatch de tamaño $m = 1$

Con reemplazo,

$$g_t \in \{-0.9, -3.6, -8.1\}$$

con probabilidad $1/3$ para cada valor.

La esperanza es

$$\mathbb{E}[g_t] = -4.2.$$

La varianza es

$$\text{Var}(g_t) = 8.82.$$

El estimador es correcto en promedio, pero muy variable.

17. Minibatch de tamaño $m = 2$

Sin reemplazo, los posibles promedios son

$$\frac{g_1 + g_2}{2} = -2.25,$$

$$\frac{g_1 + g_3}{2} = -4.50,$$

$$\frac{g_2 + g_3}{2} = -5.85.$$

Cada uno tiene probabilidad $1/3$.

Por tanto,

$$\mathbb{E}[g_t] = -4.2$$

y

$$\text{Var}(g_t) = 2.205.$$

La variabilidad disminuyó notablemente respecto del caso $m = 1$.

18. Verificación mediante corrección por población finita

La varianza muestral de los gradientes individuales es

$$\tilde{\Sigma} = \frac{1}{n-1} \sum_{i=1}^n (g_i - \bar{g})^2.$$

Aquí,

$$\bar{g} = -4.2$$

y

$$\tilde{\Sigma} = 13.23.$$

Entonces

$$\text{Var}(g_t) = \frac{1}{m} \left(1 - \frac{m}{n}\right) \tilde{\Sigma}.$$

Con $n = 3$ y $m = 2$,

$$\text{Var}(g_t) = \frac{1}{2} \left(1 - \frac{2}{3}\right) 13.23 = 2.205.$$

Coincide con el cálculo directo.

Actividad para el estudiante

Verifique manualmente la varianza 8.82 del caso $m = 1$ y compare la reducción relativa al pasar a $m = 2$.

19. GD frente a SGD

Propiedad	GD	SGD / mini-batch SGD
Gradiente	exacto	aproximado
Datos por iteración	todos	subconjunto
Costo por iteración	alto	menor
Trayectoria	más suave	más ruidosa
Ruido de muestreo	no	sí
Adecuado para	datos pequeños / análisis	datos grandes / redes profundas

20. Conexión continua: flujo gradiente

El descenso de gradiente determinista

$$W_{t+1} = W_t - \eta_t \nabla \mathcal{L}(W_t)$$

puede interpretarse, bajo un escalamiento adecuado, como una discretización de la ecuación diferencial

$$\frac{dW}{dt} = -\nabla \mathcal{L}(W). \quad (12)$$

Esta dinámica se denomina *gradient flow*.

21. Conexión estocástica

Con SGD,

$$W_{t+1} = W_t - \eta_t (\nabla \mathcal{L}(W_t) + \xi_t).$$

En ciertos regímenes de escalamiento, esta dinámica puede aproximarse mediante una EDE de tipo Langevin,

$$dW_t = -\nabla \mathcal{L}(W_t) dt + G(W_t) dB_t, \quad (13)$$

donde $G(W_t)$ representa la estructura de covarianza efectiva del ruido.

La forma exacta de la difusión depende del esquema de muestreo, del tamaño del paso y de la covarianza del gradiente. Por ello, escribir simplemente $\sqrt{2D} dB_t$ debe entenderse como una representación idealizada, no como una identidad universal para cualquier SGD.

22. ¿Cuándo se utiliza SGD?

SGD o mini-batch SGD son especialmente útiles cuando:

- el conjunto de datos es grande;
- el cálculo del gradiente completo es costoso;
- se entrenan redes profundas;
- los datos llegan de forma continua;
- interesa aprovechar aceleradores como GPU mediante lotes.

El ruido del gradiente también modifica la trayectoria de optimización y puede favorecer la exploración de regiones diferentes de la superficie de pérdida.

Punto de atención

No debe interpretarse que el ruido garantiza automáticamente una mejor generalización o que siempre permite escapar de cualquier mínimo local. Su efecto depende de la geometría de la pérdida, del tamaño del minibatch, de la tasa de aprendizaje y del optimizador.

23. ¿Cuándo es útil el gradiente completo?

GD puede ser conveniente cuando:

- el conjunto de datos es pequeño;
- el costo del gradiente completo es manejable;
- se requiere una trayectoria determinista;
- se realiza análisis teórico o validación numérica;
- la función objetivo es relativamente simple.

24. Puente hacia PINNs

Hasta aquí el desarrollo corresponde al entrenamiento general de redes neuronales.

En una PINN para una EDO, el conjunto sobre el que se evalúa la pérdida no está formado necesariamente por pares etiquetados (x_i, y_i) .

En su lugar, se seleccionan puntos de colocación

$$x_1, \dots, x_N$$

en el dominio de la ecuación.

Para una EDO

$$\mathcal{F}(x, u, u', \dots) = 0,$$

una red $u_\theta(x)$ induce el residuo

$$r_\theta(x) = \mathcal{F}(x, u_\theta, u'_\theta, \dots).$$

La pérdida física puede ser

$$\mathcal{L}_{\text{phys}}(\theta) = \frac{1}{N} \sum_{i=1}^N r_\theta(x_i)^2. \quad (14)$$

Conexión con PINNs

En una PINN, los puntos de colocación desempeñan un papel análogo al de las observaciones en una función de pérdida promedio. Esto permite aplicar directamente la lógica de minibatches y SGD.

25. Ejemplo PINN: EDO de primer orden

Considere

$$u'(x) + u(x) = 0, \quad x \in [0, 1],$$

con

$$u(0) = 1.$$

Sea

$$u_\theta(x)$$

la aproximación neuronal.

El residuo es

$$r_\theta(x) = u'_\theta(x) + u_\theta(x).$$

Una pérdida suave puede escribirse como

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N r_\theta(x_i)^2 + \lambda (u_\theta(0) - 1)^2. \quad (15)$$

26. Gradiente completo en una PINN

Definamos

$$\ell_i^{\text{phys}}(\theta) = r_\theta(x_i)^2.$$

Entonces

$$\nabla_\theta \mathcal{L}_{\text{phys}}(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_\theta \ell_i^{\text{phys}}(\theta).$$

Para el término de condición inicial,

$$\nabla_\theta [\lambda (u_\theta(0) - 1)^2] = 2\lambda (u_\theta(0) - 1) \nabla_\theta u_\theta(0).$$

Por tanto,

$$\nabla_{\theta} \mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} r_{\theta}(x_i)^2 + 2\lambda (u_{\theta}(0) - 1) \nabla_{\theta} u_{\theta}(0). \quad (16)$$

27. Mini-batch de puntos de colocación

Si N es grande, elegimos

$$B_t \subset \{1, \dots, N\}$$

con

$$|B_t| = m.$$

Entonces aproximamos el gradiente físico mediante

$$g_t^{\text{phys}} = \frac{1}{m} \sum_{i \in B_t} \nabla_{\theta} r_{\theta}(x_i)^2. \quad (17)$$

La actualización puede usar

$$g_t = g_t^{\text{phys}} + 2\lambda (u_{\theta}(0) - 1) \nabla_{\theta} u_{\theta}(0). \quad (18)$$

Después,

$$\theta_{t+1} = \theta_t - \eta_t g_t.$$

Interpretación

En este esquema, el término de condición inicial puede evaluarse en cada iteración porque suele contener pocos puntos, mientras que el residuo interior se aproxima mediante un minibatch de puntos de colocación.

28. Ruido de gradiente en una PINN

Definimos

$$\xi_t^{\text{phys}} = g_t^{\text{phys}} - \nabla_{\theta} \mathcal{L}_{\text{phys}}(\theta_t).$$

Bajo muestreo uniforme,

$$\mathbb{E} [\xi_t^{\text{phys}} \mid \theta_t] = 0.$$

La actualización PINN se puede interpretar como

$$\theta_{t+1} = \theta_t - \eta_t [\nabla_{\theta} \mathcal{L}(\theta_t) + \xi_t^{\text{phys}}].$$

Conexión con PINNs

El origen del ruido ya no es únicamente “qué datos etiquetados entraron al lote”, sino “qué puntos del dominio de la EDO se utilizaron en esta iteración para medir el residuo físico”.

29. Muestreo aleatorio de puntos de colocación

En una PINN se pueden utilizar dos estrategias conceptuales.

29.1. Conjunto fijo

Se genera una malla o un conjunto fijo

$$\{x_i\}_{i=1}^N$$

y en cada iteración se seleccionan minibatches de ese conjunto.

29.2. Remuestreo del dominio

En cada iteración o época se generan nuevos puntos

$$X_j^{(t)} \sim \mu$$

sobre el dominio.

En este caso, la pérdida física se aproxima como una esperanza

$$\mathcal{L}_{\text{phys}}(\theta) = \mathbb{E}_{X \sim \mu} \left[r_{\theta}(X)^2 \right],$$

y el minibatch produce la estimación Monte Carlo

$$\hat{\mathcal{L}}_{\text{phys}} = \frac{1}{m} \sum_{j=1}^m r_{\theta} \left(X_j^{(t)} \right)^2.$$

30. SGD en PINNs: interpretación práctica

El uso de minibatches de puntos de colocación puede ser útil cuando:

- el dominio contiene muchos puntos;
- la red es grande;
- calcular derivadas físicas en todos los puntos es costoso;
- se quiere remuestrear el dominio durante el entrenamiento;
- se desea concentrar puntos en regiones difíciles.

Sin embargo, un minibatch demasiado pequeño puede producir estimaciones ruidosas del residuo y del gradiente.

31. Balance entre términos de la pérdida PINN

Una PINN suele contener varios términos:

$$\mathcal{L} = \lambda_{\text{phys}} \mathcal{L}_{\text{phys}} + \lambda_{\text{IC}} \mathcal{L}_{\text{IC}} + \lambda_{\text{BC}} \mathcal{L}_{\text{BC}} + \lambda_{\text{data}} \mathcal{L}_{\text{data}}.$$

Cada término puede tener escalas y tamaños de muestra diferentes.

Por ello, el comportamiento del gradiente depende no sólo del tamaño del minibatch, sino también de los pesos

$$\lambda_{\text{phys}}, \lambda_{\text{IC}}, \lambda_{\text{BC}}, \lambda_{\text{data}}.$$

Punto de atención

Un gradiente estocástico imparcial de cada término por separado no garantiza que el entrenamiento sea numéricamente bien balanceado. Si un término domina en magnitud, puede controlar la actualización.

32. Diferenciación automática y SGD en una PINN

En una implementación moderna ocurren dos procesos distintos:

1. **diferenciación automática:** calcula

$$u'_\theta(x), \quad u''_\theta(x), \quad \nabla_\theta \mathcal{L};$$

2. **optimizador estocástico:** selecciona cómo utilizar ese gradiente para actualizar

$$\theta.$$

Por tanto, *autodiff* y SGD no son lo mismo.

33. GD, SGD y Adam en PINNs

En la práctica pueden emplearse distintos optimizadores:

- GD o variantes deterministas, si la pérdida completa es manejable;
- SGD, si se usan minibatches;
- Adam, que adapta escalas de actualización utilizando momentos del gradiente;
- métodos de segundo orden o cuasi-Newton en etapas posteriores.

Interpretación

El principio fundamental sigue siendo el mismo: construir un gradiente de la pérdida PINN y utilizarlo para modificar los parámetros de la red.

34. Preguntas de autoevaluación

1. ¿Qué diferencia existe entre $\nabla \mathcal{L}(W)$ y g_t ?
2. ¿Por qué g_t es una variable aleatoria?
3. ¿Qué significa que g_t sea imparcial?
4. ¿Cómo cambia la covarianza al aumentar m ?
5. ¿Por qué el ruido no tiene que ser normal?
6. ¿Qué papel desempeña el TCL cuando m es grande?
7. ¿Qué diferencia existe entre muestreo con y sin reemplazo?
8. ¿Qué significa la corrección $1 - m/n$?

9. ¿Cómo se escribe SGD como gradiente exacto más ruido?
10. ¿Qué representa un punto de colocación en una PINN?
11. ¿Qué constituye un minibatch en una PINN?
12. ¿Cuál es el origen del ruido de gradiente en una PINN?
13. ¿Por qué una PINN puede remuestrear puntos del dominio?
14. ¿Qué diferencia existe entre autodiff y SGD?

35. Ejercicios propuestos

Ejercicio 1. Imparcialidad.

Demuestre (6) para muestreo con reemplazo.

Ejercicio 2. Muestreo sin reemplazo.

Reproduzca la demostración de imparcialidad usando

$$P(i \in B_t) = \frac{m}{n}.$$

Ejercicio 3. Varianza para $m = 1$.

Con

$$g_1 = -0.9, \quad g_2 = -3.6, \quad g_3 = -8.1,$$

verifique

$$\text{Var}(g_t) = 8.82.$$

Ejercicio 4. Varianza para $m = 2$.

Calcule directamente la varianza de

$$-2.25, \quad -4.50, \quad -5.85.$$

Ejercicio 5. Efecto de m .

Explique qué ocurre con la covarianza cuando

$$m \rightarrow n.$$

Ejercicio 6. Actualización estocástica.

Para una tasa

$$\eta = 0.05$$

y $w = 1.1$, calcule las tres posibles actualizaciones cuando $m = 1$.

Ejercicio 7. PINN con tres puntos.

Para

$$u' + u = 0, \quad u(0) = 1,$$

suponga que existen tres puntos de colocación. Escriba la pérdida física y los posibles minibatches de tamaño 2.

Ejercicio 8. Estimador PINN.

Pruebe que el gradiente de minibatch de (17) es imparcial si los puntos se seleccionan uniformemente de un conjunto fijo.

Ejercicio 9. Remuestreo continuo.

Suponga

$$X_j \sim \text{Unif}(0, 1).$$

Escriba la estimación Monte Carlo de

$$\mathbb{E}[r_\theta(X)^2].$$

Ejercicio 10. Balance de pérdidas.

Analice qué puede ocurrir si

$$\lambda_{\text{IC}} \gg \lambda_{\text{phys}}.$$

36. Actividad integradora

Considere la EDO

$$u'(x) + u(x) = 0, \quad u(0) = 1.$$

Sea $u_\theta(x)$ una red neuronal y seleccione un conjunto de $N = 20$ puntos de colocación en $[0, 1]$. Compare conceptualmente tres esquemas:

$$m = 1, \quad m = 5, \quad m = 20.$$

Para cada caso, describa:

1. costo aproximado por actualización;
2. variabilidad esperada del gradiente;
3. diferencia entre pérdida de minibatch y pérdida completa;
4. número de actualizaciones que podrían realizarse por época;
5. ventajas y desventajas para el entrenamiento PINN.

Después explique cómo cambiaría la interpretación si los puntos de colocación no fueran fijos, sino que se remuestrearan uniformemente en cada iteración.

37. Ideas esenciales para recordar

- El gradiente completo es un promedio de gradientes individuales.
- SGD sustituye ese promedio por una estimación basada en un subconjunto aleatorio.
- Bajo muestreo uniforme estándar, el estimador puede ser imparcial.
- El ruido de gradiente tiene esperanza condicional cero, pero covarianza no nula.
- La varianza disminuye al aumentar el tamaño del minibatch.
- Para minibatches grandes puede aparecer una aproximación gaussiana por TCL.
- GD puede interpretarse mediante un flujo gradiente; SGD admite aproximaciones estocásticas continuas bajo hipótesis adicionales.
- En una PINN, los puntos de colocación cumplen el papel de observaciones para la parte física de la pérdida.

- Un minibatch PINN puede consistir en un subconjunto aleatorio de puntos del dominio.
- Autodiff calcula derivadas; SGD decide cómo usar gradientes aproximados para actualizar parámetros.

38. Bibliografía recomendada

Referencias

- [1] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.
- [2] L. Bottou, F. E. Curtis y J. Nocedal, “Optimization Methods for Large-Scale Machine Learning”, *SIAM Review*, 60(2), 2018.
- [3] S. Mandt, M. D. Hoffman y D. M. Blei, “Stochastic Gradient Descent as Approximate Bayesian Inference”, *Journal of Machine Learning Research*, 18, 2017.
- [4] M. Raissi, P. Perdikaris y G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”, *Journal of Computational Physics*, 378, 2019.
- [5] I. E. Lagaris, A. Likas y D. I. Fotiadis, “Artificial neural networks for solving ordinary and partial differential equations”, *IEEE Transactions on Neural Networks*, 9(5), 1998.