

Métodos general: Redes Bayesianas para degradación por temperatura

YofreH

2025-10-15

Introducción

Este documento describe, en forma **conceptual**, los **métodos** implementados en el cuaderno de redes bayesianas para analizar el efecto de la **temperatura de almacenamiento** sobre la **degradación** de vacunas. El objetivo es que un lector comprenda **qué hace** cada bloque del script y **por qué** se hace, sin necesidad de entrar a detalles de implementación.

El hilo conductor es un **DAG causal natural**:

$[A, SZN, P, R, T, M, H, B] \rightarrow S \rightarrow D, \perp V, L \rightarrow D, \perp$

donde: - A = temperatura ambiente, SZN = estacionalidad (mes), - P = cortes de energía, R = aperturas, T = traslado, - M = estado del equipo, H = manejo, B = calibración, - S = temperatura de almacenamiento (o su resumen), - D = degradación, - V/L = tipo de vacuna/lote.

La lógica física: **las condiciones ambientales/operativas influyen S , y S determina el daño térmico D** , modulado por la susceptibilidad del producto (V, L)).

Generación de datos sintéticos

Estacionalidad y ambiente

Se modela la **temperatura ambiente** como una variable continua con **patrón estacional**:

$A_{\text{num}} \sim \mathcal{N}(\text{Big}(22 + 5\sin(2\pi \frac{\text{mes}}{12}\text{Big}), 3^2\text{Big}), \perp$

donde la media oscila entre $\approx 17^\circ\text{C}$ y 27°C y la desviación típica 3°C captura variabilidad diaria o intrames.

Intuición: la estacionalidad (SZN) impulsa el ambiente (A), y A es un impulsor principal de la temperatura interna (S).

Discretización del ambiente

Para facilitar **inferencia exacta** en **redes discretas**, se discretiza A_{num} en $A \in \{\text{baja, media, alta}\}$ usando umbrales (p. ej., 20 y 25 °C). Esto: - simplifica las **tablas de probabilidad**, - vuelve más transparente la interpretación (ambiente frío/templado/cálido), - es consistente con decisiones operativas (umbrales).

Nota: si se necesita mayor fidelidad física, se puede mantener A continuo en un modelo **CLG (Conditional Linear Gaussian)**.

Variables operativas y de producto

Se simulan como variables categóricas: - Operación: P (cortes), R (aperturas), T (traslado), M (equipo), H (manejo), B (calibración). - Producto: V (tipo de vacuna) y L (lote).

Estas variables están motivadas por mecanismos plausibles que **afectan la estabilidad térmica (S)** y/o **modulan la degradación (D)**.

Construcción del estado térmico (S)

Score logístico para “fuera de rango”

Se construye un **puntaje lineal** que resume condiciones adversas:

$\text{linS} = \alpha + \beta_1 A_{\text{alta}} + \beta_2 A_{\text{media}} + \beta_3 P_{\text{sí}} + \dots$

que se transforma a una **probabilidad** mediante la función logística:

$\Pr(S = \text{fuera_rango}) = \text{logit}^{-1}(\text{linS})$

Finalmente, S se simula como binaria $(\text{en_rango}, \text{fuera_rango})$.

Idea clave: a mayor carga operativa/ambiental, **mayor** probabilidad de **excursiones térmicas** (fuera de rango).

Modelo de degradación $\backslash(D\backslash)$

Probabilidad de degradación condicionada

La degradación $\backslash(D\backslash)$ (binaria) se genera a partir de un segundo **puntaje logístico**:

$$\backslash[\text{linD} = \gamma_0 + \gamma_1 \backslash\mathbb{I}\{S=\text{fuera_rango}\} + \gamma_V(V) + \gamma_M \backslash\mathbb{I}\{M=\text{viejo}\} + \gamma_H \backslash\mathbb{I}\{H=\text{malo}\} + \gamma_B \backslash\mathbb{I}\{B=\text{descal}\}, \backslash]$$

$$\backslash[\Pr(D=\text{sí}) = \text{logit}^{-1}(\text{linD})]. \backslash]$$

- El término $\backslash\mathbb{I}\{S=\text{fuera_rango}\}$ captura el **efecto térmico**.
- $\backslash\gamma_V(V)$ permite que **tipos de vacuna** tengan **sensibilidades distintas**.
- $\backslash(M, H, B)$ suman efectos operativos de **riesgo residual**.

Fundamento físico (opcional): la tasa de daño puede vincularse a **Arrhenius**,

$$\backslash[\lambda(S) = k_0 \exp\left(-\frac{E_a}{R(S+273.15)}\right), \quad D^{\text{last}} = 1 - \exp\big(-\textstyle\int \lambda(S_t) dt\big), \backslash]$$

y mapear $\backslash(D^{\text{last}})$ a probabilidad de descarte. En el script adoptamos una **aproximación logística** práctica.

Redes Bayesianas: estructura y parámetros

Estructura (DAG) informada por dominio

Se emplean **listas blanca/negra**: - **Whitelist**: arcos plausibles por física/operación (p. ej., $\backslash(A, P, R, T, M, H, B, SZN \rightarrow S)$ y $\backslash(S, V, L \rightarrow D)$). - **Blacklist**: prohibiciones de **retrocausas** (p. ej., $\backslash(D \rightarrow S)$) o arcos inconsistentes.

Con estas restricciones, se aplica un **buscador** (p. ej., *Hill-Climbing*, score **BIC**): - El **BIC** penaliza la complejidad y favorece modelos parsimoniosos, - El resultado es un DAG *compatible* con el conocimiento experto pero **ajustado a los datos**.

Aprendizaje de parámetros

- En BNs **discretas**, cada nodo aprende sus tablas $\backslash(P(\text{hijo} \mid \text{padres}))$, típicamente con suavizado bayesiano (Dirichlet).
- En BNs **mixtas** (CLG), los nodos continuos usan **regresiones gaussianas condicionadas**.

Inferencia y preguntas “what-if”

gRain y evidencia

Para BNs discretas, se compila el modelo con `gRain` y se hacen consultas como:

- **Riesgo con temperatura en rango**: $\backslash(P(D=\text{sí} \mid S=\text{en_rango}))$.
- **Riesgo con temperatura fuera de rango**: $\backslash(P(D=\text{sí} \mid S=\text{fuera_rango}))$.

La **diferencia absoluta de riesgo** (puntos porcentuales) es:

$$\backslash[\Delta_{\text{pp}} = 100 \times \Big| P(D=\text{sí} \mid S=\text{fuera_rango}) - P(D=\text{sí} \mid S=\text{en_rango}) \Big|, \backslash]$$

que sirve como métrica **operativa** para la toma de decisiones.

Nota causal: fijar evidencia en $\backslash(S)$ **aproxima** un $\backslash(\text{do}(S=\cdot))$. Si se requiere el formalismo estricto, se “**mutila**” el grafo cortando arcos entrantes a $\backslash(S)$ (o se usa **g-computation**).

Interpretación causal (resumen)

- **Back-door**: si un conjunto $\backslash(Z)$ (p. ej., $\backslash\{H, M, SZN, B, V, L\}$) bloquea rutas espurias entre $\backslash(S)$ y $\backslash(D)$, entonces:

$$\backslash[P(D \mid \text{do}(S)) = \sum_z P(D \mid S, Z=z), P(Z=z). \backslash]$$

- **Efecto promedio (ATE)**:

$$\backslash[\text{ATE} = \mathbb{E}[D \mid \text{do}(S=s_1)] - \mathbb{E}[D \mid \text{do}(S=s_0)]. \backslash]$$

En la práctica, se estima promediando las probabilidades de $\backslash(D)$ bajo escenarios de **intervención** en $\backslash(S)$.

Supuestos, validación y robustez

Supuestos clave

1. **DAG correcto (o razonable):** direcciones causales alineadas con la **física** y la **operación**.
2. **No confusión no medida crítica:** las variables de ajuste capturan los **confusores** principales de $S \rightarrow D$.
3. **Estabilidad de mecanismos:** intervenir en S no cambia las leyes de los otros nodos (modularidad).

Validación

- **Causal:** verificación de **d-separación** y **conjuntos de ajuste** (p. ej., con dagitty).
- **Predictiva:** *cross-validation* para scoring (log-verosimilitud, Brier, AUC si D es binaria).
- **Estabilidad:** *bootstrap* de estructura y parámetros; obtener bandas para Δ_{pp} .
- **Física:** coherencia con ensayos térmicos/curvas de estabilidad del fabricante.

Extensiones

- **Grafo mutilado (do estricto):** para aproximar $do(S=s)$, eliminar arcos entrantes a S y recomputar $P(D)$.
- **DBN (dinámico):** replicar el DAG por tiempos $t, t+1$ con $S_t \rightarrow S_{t+1}$, y simular **políticas** (alarma a 7°C , límite de aperturas, cambio de set-point) comparando $E[D_T]$.
- **Mixto continuo (CLG):** mantener S continua y usar nodos gaussianos condicionados; integrar **Arrhenius** como nodo determinista o resumir S con **TAR/MKT**.

Script

El script implementa un **pipeline causal** coherente con el fenómeno físico-operativo: **genera datos sintéticos** realistas, **aprende** una **red bayesiana** restringida por el dominio y **contesta** preguntas *what-if* sobre el **impacto** de mantener la temperatura **en rango**. La métrica central, la **diferencia absoluta de riesgo** en puntos porcentuales, traduce el modelo en **decisiones**: cuánto se reduce la degradación si controlo S .

Este enfoque combina **claridad gráfica** (DAG), **probabilidad** (BN) y **practicidad** (consultas operativas), y es extensible a escenarios dinámicos y modelos físico-estadísticos más ricos.