

Introducción a PINN

YofreH

2025-10-08

¿Qué es una PINN?

Una **Physics-Informed Neural Network (PINN)** aproxima la solución $u(x)$ de una ecuación diferencial imponiendo en la **función de pérdida**: (i) que el **residuo** de la ecuación sea pequeño en puntos interiores ("collocation"), y (ii) que las **condiciones de contorno**/iniciales se satisfagan.

Ejemplo base (EDO 1D)

Considérese en $x \in [0, 1]$: $u'(x) + u(x) = 0, \quad u(0) = 1$. La solución exacta es $u(x) = e^{-x}$. La usaremos sólo como referencia.

Aproximación mediante una Red Neuronal Artificial

Usa una red muy simple (una sola neurona oculta, para poder derivar a mano): $u_{\theta}(x) = v \tanh(wx + b) + c, \quad \theta = (v, w, b, c)$.

Detalles de la arquitectura de la PINN

Esta es una **red neuronal mínima** (una sola neurona "oculta") que recibe una entrada escalar (x) y produce una salida escalar $u_{\theta}(x)$.

Se puede descomponer en tres etapas:

- Capa oculta:** calcula una combinación lineal del input $s = wx + b$. Aquí:
 - w es el **peso** (weight) que controla la pendiente de la activación;
 - b es el **bias** (sesgo) que desplaza el punto donde se activa la neurona.
- Función de activación:** aplica la no linealidad $a = \tanh(s) = \tanh(wx + b)$.
- Capa de salida:** combina la activación con un nuevo peso (v) y un nuevo bias (c) $u_{\theta}(x) = v a + c = v \tanh(wx + b) + c$.
 - v es el **peso de salida** (output weight) que escala la salida de la neurona oculta;
 - c es el **bias de salida**, que ajusta el nivel base de la función aproximada.

Resumen de significados

Símbolo	Nombre	Tipo	Rol en la red	Efecto geométrico
(w)	Peso interno (input → neurona)	Escalar	Controla la pendiente de la transición de la tanh	Estira o comprime la curva
(b)	Bias interno	Escalar	Desplaza la tanh horizontalmente	Mueve el centro de activación
(v)	Peso de salida (neurona → salida final)	Escalar	Escala la amplitud de la respuesta	Cambia la altura o signo de la curva
(c)	Bias de salida	Escalar	Desplaza verticalmente la salida	Mueve la curva arriba o abajo

Derivada: $u'_{\theta}(x) = v w \operatorname{sech}^2(wx + b)$.

Residuo de la EDO (lo que debería ser 0): $r_{\theta}(x) = u'_{\theta}(x) + u_{\theta}(x) - 0 = v w \operatorname{sech}^2(s) + v \tanh(s) + c, \quad s = wx + b$.

Función de Pérdida (PINN "suave" con penalización)

Con N puntos interiores $\{x_k\}$ y una penalización $\lambda > 0$ para la condición inicial: $\mathcal{L}(\theta) = \frac{1}{N} \sum_{k=1}^N r_{\theta}(x_k)^2 + \lambda (u_{\theta}(0) - 1)^2, \quad u_{\theta}(0) = v \tanh(b) + c$.

cálculo analítico de los gradientes en una (PINN)**

Aproxima la solución de una ecuación diferencial ordinaria (EDO) de primer orden.

Se muestra cómo se derivan las expresiones de cada parámetro, qué significan y cuál es su propósito dentro del entrenamiento de la red.

Definiciones básicas

Considera la ecuación diferencial:

$$[u'(x)+u(x)=0,\quad u(0)=1,\quad x\in[0,1].]$$

La solución exacta es $u(x)=e^{-x}$ (solo para referencia).

Se propone aproximar $u(x)$ mediante una red neuronal con una sola neurona oculta:

$$[u_{\theta}(x)=v,\tanh(wx+b)+c,\quad \theta=(v,w,b,c).]$$

Su derivada es:

$$[u_{\theta}'(x)=v,w,\operatorname{sech}^2(wx+b).]$$

El **residuo de la EDO** es:

$$[r_{\theta}(x)=u_{\theta}'(x)+u_{\theta}(x)-v\,w,\operatorname{sech}^2(s)+v,\tanh(s)+c,\quad s=wx+b.]$$

La **función de pérdida** (PINN con penalización suave) se define como:

$$[\mathcal{L}(\theta)=\frac{1}{N}\sum_{k=1}^N r_{\theta}(x_k)^2 +\lambda(v-1)^2.]$$

Propósito del cálculo de gradientes

La red busca minimizar $\mathcal{L}(\theta)$.

Para lograrlo, necesitamos saber **en qué dirección ajustar los parámetros $\theta=(v,w,b,c)$** .

Esa dirección viene dada por el **gradiente**:

$$[\nabla_{\theta} \mathcal{L} = \left(\frac{\partial \mathcal{L}}{\partial v}, \frac{\partial \mathcal{L}}{\partial w}, \frac{\partial \mathcal{L}}{\partial b}, \frac{\partial \mathcal{L}}{\partial c} \right).]$$

El algoritmo de aprendizaje actualiza los parámetros según:

$$[\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t),]$$

donde $\eta>0$ es la tasa de aprendizaje.

Cada derivada mide **cuánto cambia la pérdida** si se varía uno de los parámetros.

derivadas parciales del residuo

Notación:

- $s=wx+b$
- $t=\tanh(s)$
- $q=\operatorname{sech}^2(s)=1-t^2$
- $\frac{d}{ds}\tanh(s)=q$
- $\frac{d}{ds}q=-2qt$

Entonces:

$$[r_{\theta}(x)=v,w,q+v,t+c.]$$

(a) Derivada respecto a v

$$[\frac{\partial r}{\partial v} = wq + t.]$$

(b) Derivada respecto a w

Por regla de producto y cadena:

$$[\begin{aligned} \frac{\partial r}{\partial w} &= \frac{\partial}{\partial w}(v\,w\,q + v\,t) = v\,q + v\,w\frac{\partial q}{\partial w} + v\,x\,q. \end{aligned}]$$

Como $\frac{\partial q}{\partial w}=(-2qt)x$, se obtiene:

$$[\boxed{ \frac{\partial r}{\partial w} = v\,q - 2vwx\,q\,t + v\,x\,q = v\,q(1+x-2vwx\,q\,t). }]$$

(c) Derivada respecto a b

$$[\frac{\partial r}{\partial b} = -2vw\,q\,t + v\,q.]$$

(d) Derivada respecto a c

$$\frac{\partial r}{\partial c}=1.$$

Derivadas de la condición inicial

Dado que $u_\theta(0)=v,\tanh(b)+c$, se tiene:

$$\boxed{\frac{\partial u(0)}{\partial v}=\tanh(b),\quad \frac{\partial u(0)}{\partial w}=0,\quad \frac{\partial u(0)}{\partial b}=v,\operatorname{sech}^2(b),\quad \frac{\partial u(0)}{\partial c}=1.}$$

Regla de la cadena para la pérdida

Cada punto interior x_k contribuye con:

$$\frac{\partial}{\partial \theta}\big[r_\theta(x_k)^2\big]=2r_\theta(x_k)\frac{\partial r_\theta(x_k)}{\partial \theta}.$$

Y la condición inicial aporta:

$$2\lambda(u_\theta(0)-1)\frac{\partial u_\theta(0)}{\partial \theta}.$$

Por tanto:

$$\boxed{\frac{\partial \mathcal{L}}{\partial \theta}=\frac{2}{N}\sum_{k=1}^N r_\theta(x_k)\frac{\partial r_\theta(x_k)}{\partial \theta}+2\lambda(u_\theta(0)-1)\frac{\partial u_\theta(0)}{\partial \theta}.}$$

Interpretación del gradiente

- Cada derivada mide **cómo cambiaría el error físico (residuo)** si se ajusta un parámetro.
- Los términos $r_\theta(x_k)\frac{\partial r_\theta(x_k)}{\partial \theta}$ representan **correcciones locales** en los puntos de entrenamiento.
- Su suma ponderada es la **dirección global de corrección física**: hace que la red respete mejor la ecuación diferencial.

Propósito teórico dentro de una PINN

Variacional:

Minimizar $\mathcal{L}(\theta)$ es equivalente a minimizar el funcional: $J[u]=\int_0^1 (u'(x)+u(x))^2dx$, con $u(0)=1$. La PINN sustituye u por u_θ y busca el mínimo variacional en el espacio paramétrico.

Gradiente como derivada funcional:

$\frac{d\mathcal{L}}{d\theta}=\left\langle \frac{\delta J}{\delta u},\frac{\partial u_\theta}{\partial \theta}\right\rangle$ Es la versión paramétrica de la derivada funcional clásica.

Interpretación física:

El gradiente indica **cómo modificar los parámetros** para reducir la violación de la ecuación diferencial en cada punto.

Mini-cálculo numérico en un punto (todo a mano)

Toma parámetros “plausibles” que ya muestran decaimiento: $v=-1,\quad w=1,\quad b=0,\quad c=1.$ En $(x=0.5)$: $(s=0.5),\quad (t=\tanh(0.5)\approx 0.462117),\quad (q=\operatorname{sech}^2(0.5)\approx 0.786447).$

- **Aproximación y derivada:** $u_\theta(0.5)=v,t+c=-0.462117+1=0.537883,\quad u_\theta'(0.5)=v\ w\ q=-0.786447.$
- **Residuo:** $r_\theta(0.5)=u'(0.5)+u(0.5)=-0.786447+0.537883=-0.248564.$
- **Gradientes del residuo** en $(x=0.5)$:
$$\begin{aligned}\frac{\partial r}{\partial v}&=wq+t=0.786447+0.462117=1.248564,\\ \frac{\partial r}{\partial w}&=v,q(1+x)-2vw\,q,t=-0.786447(1.5)+(1)\cdot 0.786447\cdot 0.5\cdot 0.462117\\ &=-1.179671+0.363000\approx -0.816671,\\ \frac{\partial r}{\partial b}&=v,q-2vw\,q,t=-0.786447+0.726000=-0.060447,\\ \frac{\partial r}{\partial c}&=1.\end{aligned}$$
- **Condición inicial:** $u_\theta(0)=\tanh(0)+c=1\Rightarrow$ el término de contorno **no aporta** a $(\nabla \mathcal{L})$ (su residuo es 0).

Si (sólo para ilustrar) usas este **único** punto interior ($N=1$, λ arbitraria), los gradientes de $\mathcal{L}$ quedan:

$$\frac{\partial \mathcal{L}}{\partial v}=2r\frac{\partial r}{\partial v}\approx 2(-0.248564)(1.248564)=-0.620,\quad \frac{\partial \mathcal{L}}{\partial w}\approx 2(-0.248564)(-0.816671)=+0.406,$$

$$\frac{\partial \mathcal{L}}{\partial b}\approx 2(-0.248564)(-0.060447)=+0.030,\quad \frac{\partial \mathcal{L}}{\partial c}=2(-0.248564)\cdot 1=-0.497.$$

Una **pasada de descenso** $(\theta\leftarrow \theta-\eta \nabla \mathcal{L})$ movería w y b **hacia arriba** (signos $(+)$), y (v,c) **hacia arriba** también (porque restas un gradiente negativo), todo con el fin de **reducir el residuo** en el punto.

Variante con restricción dura (condición inicial exacta)

Otra táctica frecuente en PINNs: construir un ansatz que **satisfaga la condición** por construcción. Aquí, se puede imponer $u(0)=1$ mediante $\widehat{u}^*(\theta(x))=1+xN^*\theta(x)$ con N_θ una red cualquiera. Entonces $\widehat{u}^*(\theta(0))=1$ **siempre**. El residuo es $\big(N_\theta(x)+x, N_\theta'(x)\big)+\big(1+x, N_\theta(x)\big)$ y la pérdida **ya no necesita** término de contorno:

$$\mathcal{L}(\theta)=\frac{1}{N}\sum_{k=1}^N \widehat{r}^*(\theta(x_k))^2.$$

(De nuevo, $N^*\theta$ se obtiene por regla de la cadena —*autodiff* en práctica—, pero aquí ves la **forma exacta** de las derivadas que se minimizan.)

Conclusión

- Una **PINN** minimiza el **residuo** de la EDO en puntos interiores y, además, **impone** las **condiciones** (suaves o duras).
- El ejemplo muestra, con **fórmulas explícitas**, cómo se computan r_θ , $\mathcal{L}(\theta)$ y sus **gradientes**.
- Con suficientes puntos y una red un poco más rica, el mínimo de $\mathcal{L}$ aproxima la solución $u(x)=e^{-x}$ en $[0,1]$.

“Tipos de condiciones de frontera en DeepXDE”

Ecuación base: calor 1D

Consideremos la ecuación de calor unidimensional:

$$\frac{\partial u}{\partial t} = \alpha \frac{\partial^2 u}{\partial x^2}, \quad x \in [0,L], \quad t > 0,$$

donde

- $u(x,t)$ representa la temperatura,
- $\alpha > 0$ es la difusividad térmica.

1. Condición de Dirichlet

Se fija la temperatura en los extremos:

$$\begin{cases} u(0,t) = T_0, \\ u(L,t) = T_L. \end{cases}$$

Interpretación: las paredes se mantienen a temperatura constante (por ejemplo, $T_0=100^\circ\text{C}$, $T_L=0^\circ\text{C}$).

Solución estacionaria: gradiente lineal.

2. Condición de Neumann

Se fija el flujo térmico en la frontera, es decir, la derivada espacial:

$$\begin{cases} \frac{\partial u}{\partial x}(0,t) = q_0, \\ \frac{\partial u}{\partial x}(L,t) = q_L. \end{cases}$$

Interpretación: el flujo de calor (entrada o salida) está controlado.

Ejemplo físico: pared aislada $\rightarrow q_0 = q_L = 0$.

Efecto: no hay pérdida ni ganancia de calor en los bordes.

3. Condición de Robin (mixta)

Combinación lineal de Dirichlet y Neumann:

$$\alpha_1 u(0,t) + \beta_1 \frac{\partial u}{\partial x}(0,t) = g_1(t), \quad \alpha_2 u(L,t) + \beta_2 \frac{\partial u}{\partial x}(L,t) = g_2(t).$$

Interpretación: paredes que intercambian calor con el ambiente (convección).

Ejemplo: $-\kappa \frac{\partial u}{\partial x}(0,t) = h(u(0,t) - T_\infty)$. Es una forma física de la **ley de enfriamiento de Newton**.

4. Condición de operador general

Permite imponer combinaciones o derivadas de orden superior o relaciones no lineales:

$$\mathcal{B}[u](x,t) = g(x,t)$$

por ejemplo:

$$\frac{\partial^2 u}{\partial x^2}(0,t) - \frac{\partial u}{\partial t}(0,t) = 0.$$

Interpretación: condición dinámica en la frontera, donde el flujo depende también de la evolución temporal.

Ejemplo: una pared con **capacidad térmica** (se calienta y enfría con el tiempo).

5. Condición periódica

El dominio “se cierra sobre sí mismo”:

$$u(0,t) = u(L,t), \quad \frac{\partial u}{\partial x}(0,t) = \frac{\partial u}{\partial x}(L,t).$$

Interpretación: barra circular, sin borde real.

Ejemplo: difusión en un anillo metálico.

Efecto: el calor “circula” sin discontinuidades.

6. Condición inicial

Impone el estado inicial de temperatura ($t = 0$):

$$u(x,0) = f(x).$$

Interpretación: distribución de temperatura inicial en toda la barra.

Ejemplo: $u(x,0) = 100e^{-(x-0.5)^2}$. **Efecto:** define el punto de partida de la evolución temporal.

7. Condición interior (constraint interna)

Impone una relación en un punto o región **dentro del dominio**, no en la frontera:

$$u(x_0,t) = c_0, \quad x_0 \in (0,L).$$

o más generalmente:

$$\frac{\partial u}{\partial x}(x_0,t) = 0.$$

Interpretación: un punto interno con temperatura controlada (sensor o nodo refrigerado).

Ejemplo físico: una sonda térmica que mantiene su temperatura constante.

8. Condiciones multifrontera

En dominios más complejos (2D o 3D), se definen condiciones distintas en cada parte del borde:

$$\begin{cases} u = 0 & \text{en } x=0, \\ \frac{\partial u}{\partial n} = 0 & \text{en } y=0, \\ \alpha u + \beta \frac{\partial u}{\partial n} = g(x,y) & \text{en } x=L, \\ u(x,y,t) = h(x,y) & \text{en } y=H. \end{cases}$$

Interpretación: distintas paredes tienen condiciones físicas diferentes

(ej. aislamiento lateral, contacto con un fluido, pared fija, etc.).

Resumen de tipos de condición

Tipo de condición	Ecuación simbólica	Ejemplo físico	Lugar
Dirichlet	$u = g$	Temperatura fija	Frontera
Neumann	$\frac{\partial u}{\partial n} = g$	Flujo impuesto o aislado	Frontera
Robin	$\alpha u + \beta \frac{\partial u}{\partial n} = g$	Intercambio con ambiente	Frontera
Operador general	$\mathcal{B}[u] = g$	Pared con dinámica o reacción	Frontera
Periódica	$u(a)=u(b), u_n(a)=u_n(b)$	Barra circular	Frontera doble
Inicial	$u(x,0)=f(x)$	Estado inicial	Interior ($t=0$)
Interior	$u(x_0,t)=c_0$ o $u_x(x_0,t)=0$	Sensor o punto de control	Interior del dominio
Multi-frontera	$\mathcal{B}_i[u]=g_i$	Diferentes materiales o condiciones	Varias fronteras

“Formulación en Diferencias Finitas (FDM) para la Ecuación de Onda 1D”

1. Ecuación de partida

La ecuación de onda unidimensional es:

$$\frac{\partial^2 u}{\partial t^2} = c^2 \frac{\partial^2 u}{\partial x^2}, \quad x \in [0, L], \quad t > 0,$$

con condiciones de frontera **Dirichlet homogéneas**:

$$u(0, t) = 0, \quad u(L, t) = 0,$$

y condiciones iniciales:

$$u(x, 0) = f(x), \quad \frac{\partial u}{\partial t}(x, 0) = 0.$$

2. Discretización del dominio

Dividimos el dominio en una malla uniforme:

$$x_i = i \Delta x, \quad i = 0, 1, \dots, N, \quad \Delta x = \frac{L}{N},$$

$$t_n = n \Delta t, \quad n = 0, 1, \dots, M, \quad \Delta t = \frac{T}{M}.$$

Aproximamos la solución continua por valores discretos:

$$u_i^n \approx u(x_i, t_n).$$

3. Aproximaciones en diferencias finitas

Derivada temporal segunda

$$\frac{\partial^2 u}{\partial t^2}(x_i, t_n) \approx \frac{u_i^{n+1} - 2u_i^n + u_i^{n-1}}{(\Delta t)^2}.$$

Derivada espacial segunda

$$\frac{\partial^2 u}{\partial x^2}(x_i, t_n) \approx \frac{u_{i+1}^n - 2u_i^n + u_{i-1}^n}{(\Delta x)^2}.$$

4. Esquema explícito de actualización

Sustituyendo las aproximaciones en la ecuación de onda se obtiene:

$$\frac{u_i^{n+1} - 2u_i^n + u_i^{n-1}}{(\Delta t)^2} = c^2 \frac{u_{i+1}^n - 2u_i^n + u_{i-1}^n}{(\Delta x)^2}.$$

Reordenando los términos:

$$\boxed{u_i^{n+1} = 2u_i^n - u_i^{n-1} + r^2(u_{i+1}^n - 2u_i^n + u_{i-1}^n)},$$

donde $r = \frac{c \Delta t}{\Delta x}$ es el número de Courant.

5. Paso inicial $(n = 0 \text{ to } 1)$

Como se conocen u_i^0 y $u_t(x_i, 0) = 0$, se utiliza una expansión de Taylor:

$$u(x_i, \Delta t) = u(x_i, 0) + \Delta t u_t(x_i, 0) + \frac{(\Delta t)^2}{2} u_{tt}(x_i, 0) + \mathcal{O}(\Delta t^3).$$

Sustituyendo $u_{tt} = c^2 u_{xx}$:

$$u_i^1 = u_i^0 + \frac{r^2}{2} (u_{i+1}^0 - 2u_i^0 + u_{i-1}^0).$$

Este es el **primer paso del método** que inicia la propagación temporal.

6. Condiciones de frontera

Para **Dirichlet homogéneas**:

$$u_0^n = 0, \quad u_N^n = 0, \quad \forall n.$$

Estos valores se fijan en cada iteración y no se actualizan.

7. Esquema completo

1. Inicialización:

$$u_i^0 = f(x_i), \quad u_i^1 = u_i^0 + \frac{r^2}{2} (u_{i+1}^0 - 2u_i^0 + u_{i-1}^0),$$

con $u_0^n = u_N^n = 0$.

2. Iteración temporal:

$$u_i^{n+1} = 2u_i^n - u_{i-1}^n + r^2(u_{i+1}^n - 2u_i^n + u_{i-1}^n),$$

para $i=1,\dots,N-1, n \geq 1.$

3. Condiciones de frontera:

$$u_0^{n+1}=u_N^{n+1}=0.$$

8. Condición de estabilidad (CFL)

El método es condicionalmente estable si se cumple la condición CFL:

$$r = \frac{c \Delta t}{\Delta x} \leq 1.$$

Si $r > 1$, aparecen oscilaciones numéricas crecientes y el método se vuelve inestable.

9. Interpretación geométrica

Cada nuevo punto u_i^{n+1} depende de los tres puntos previos $(u_{i-1}^n, u_i^n, u_{i+1}^n)$, representando la propagación de la onda hacia adelante en el tiempo y en ambos sentidos en el espacio.

10. Resumen

Concepto	Fórmula	Interpretación
Ecuación de onda	$u_{tt} = c^2 u_{xx}$	Propagación de ondas 1D
Diferencia temporal	$\frac{u_i^{n+1} - 2u_i^n + u_{i-1}^n}{(\Delta t)^2}$	Aceleración temporal
Diferencia espacial	$\frac{u_{i+1}^n - 2u_i^n + u_{i-1}^n}{(\Delta x)^2}$	Curvatura espacial
Esquema explícito	$u_i^{n+1} = 2u_i^n - u_{i-1}^n - 1 + r^2(u_{i+1}^n - 2u_i^n + u_{i-1}^n)$	Actualización en el tiempo
Primer paso	$u_i^1 = u_i^0 + \frac{r^2}{2}(u_{i+1}^0 - 2u_i^0 + u_{i-1}^0)$	Construcción inicial
Condición Dirichlet	$u_0^n = u_N^n = 0$	Bordes fijos
Estabilidad CFL	$r \leq 1$	Criterio de estabilidad