

Modelos No Lineales y Núcleo

YofreH

2025-08-29

1. Clasificación no lineal en espacios de alta dimensión (kernel trick con RBF vs. polinomial)

- **Motivación:** mostrar cómo los kernels permiten separar clases no linealmente separables en $\mathbb{R}^2$ o $\mathbb{R}^3$.
- **Ejemplo práctico en Python:** generar datos en forma de “círculo concéntrico” (similar al dataset *moons* o *circles*) y aplicar SVM con kernel lineal, polinomial y RBF para comparar fronteras de decisión.
- **Enfoque matemático:** repasar el teorema del kernel de Mercer y el papel del espacio de Hilbert reproducing (RKHS).

2. SVM para problemas de regresión (SVR) en series temporales

- **Motivación:** estudiar cómo los SVM se extienden a regresión con una función de pérdida ϵ -insensible.
- **Ejemplo práctico en Python:** generar una serie temporal (p. ej. onda sinusoidal con ruido gaussiano) y ajustar un **SVR** con distintos kernels para comparar predicción y suavización.
- **Enfoque matemático:** deducción de la formulación primal y dual del SVR, interpretación geométrica del margen ϵ .

3. Clasificación en datos reales de texto (SVM con kernel lineal en NLP)

- **Motivación:** mostrar que los SVM con kernel lineal funcionan muy bien en espacios de dimensión enorme, como en **bolsa de palabras** o **TF-IDF**.
- **Ejemplo práctico en Python:** descargar un dataset pequeño de clasificación de correos spam/no spam (o noticias por categoría), aplicar vectorización de texto, entrenar SVM lineal y evaluar precisión.
- **Enfoque matemático:** justificar por qué en espacios de gran dimensión, la separación lineal es más factible (teorema de Cover).

4. SVM en problemas de clasificación multiclase (One-vs-One, One-vs-Rest)

- **Motivación:** ampliar el enfoque binario de SVM a clasificación multiclase.
- **Ejemplo práctico en Python:** usar el dataset *Iris* o *Digits* de `scikit-learn` para entrenar un SVM multiclase y visualizar resultados.
- **Enfoque matemático:** explicar estrategias de extensión binaria, discutir complejidad computacional y estructura de las soluciones duales.

Máquinas de vectores soporte (SVM) y kernels

Motivación aplicada

En muchos problemas de **agricultura y clima** nos interesa clasificar datos a partir de múltiples variables.

Algunos ejemplos:

- **Agricultura:** Determinar si un cultivo de maíz presenta riesgo de plaga a partir de temperatura, humedad del suelo, nivel de fertilización y reflectancia espectral.
- **Clima:** Clasificar días en categorías como “lluvioso” o “seco” a partir de variables meteorológicas: presión atmosférica, temperatura máxima, humedad relativa y velocidad del viento.

En ambos casos, los datos de entrada $X = (x_1, \dots, x_p)$ no siempre son separables linealmente. Por ejemplo, condiciones de clima seco y húmedo pueden agruparse en regiones no convexas del espacio de variables. **Aquí es donde las SVM con kernels se vuelven esenciales:** permiten separar clases complejas al proyectar los datos a espacios de características de mayor dimensión sin necesidad de calcular explícitamente la transformación.

Fundamentos matemáticos

1. SVM lineal

Dado un conjunto de datos etiquetados $\{(x_i, y_i)\}_{i=1}^n$, con $x_i \in \mathbb{R}^p$, $y_i \in \{-1, +1\}$, una SVM lineal busca el hiperplano

$$f(x) = w^\top x + b$$

que maximiza el **margen** entre las clases, resolviendo el problema:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i (w^\top x_i + b) \geq 1, \quad i=1, \dots, n.$$

La solución se formula de manera dual en términos de productos internos $\langle x_i, x_j \rangle$.

2. El truco del kernel

Cuando los datos no son separables linealmente, se introduce una transformación $\phi: \mathbb{R}^p \rightarrow \mathcal{H}$ (un espacio de características de alta dimensión), de modo que el clasificador es:

$$f(x) = \sum_{i=1}^n \alpha_i y_i \langle \phi(x), \phi(x_i) \rangle + b.$$

En lugar de calcular $\langle \phi(x), \phi(x_i) \rangle$ explícitamente, se define una función **kernel**:

$$k(x, x') = \langle \phi(x), \phi(x') \rangle,$$

lo que permite computar el producto interno en $\mathcal{H}$ de manera implícita.

3. Teorema de Mercer

El **teorema de Mercer** garantiza que una función $k: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ puede actuar como kernel válido si es **simétrica y definida positiva**. Es decir, para cualquier conjunto finito $\{x_1, \dots, x_n\}$:

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j k(x_i, x_j) \geq 0 \quad \text{para todo vector } (c_1, \dots, c_n) \in \mathbb{R}^n.$$

Esto garantiza la existencia de un espacio de Hilbert de funciones (RKHS) y una transformación ϕ tal que:

$$k(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}.$$

4. Espacios de Hilbert con núcleo reproducing (RKHS)

Un **RKHS** es un espacio de Hilbert de funciones sobre $\mathcal{X}$, asociado a un kernel k , con la propiedad de **reproducción**:

$$f(x) = \langle f, k(\cdot, x) \rangle_{\mathcal{H}}, \quad \text{for all } f \in \mathcal{H}.$$

Esto formaliza la idea de que los kernels actúan como “átomos” que generan funciones en $\mathcal{H}$. Las SVM se interpretan entonces como la búsqueda de una función $f \in \mathcal{H}$ que maximiza el margen bajo regularización en norma de $\mathcal{H}$.

Teoremas clave (sin demostración)

- **Teorema (Existencia de SVM lineal):**
Si los datos son linealmente separables, existe un hiperplano que maximiza el margen y es único en términos de $(w^*/|w^*|)$.
- **Teorema de Mercer:**
Una función simétrica $k(x, x')$ es un kernel válido si y solo si la matriz de Gram $[k(x_i, x_j)]$ es semidefinida positiva para cualquier conjunto finito de puntos.
- **Propiedad de Reproducción (RKHS):**
En un RKHS asociado a k , se cumple la identidad de reproducción $f(x) = \langle f, k(\cdot, x) \rangle$, lo cual conecta funciones evaluadas en puntos con productos internos en el espacio.

SVM con kernels: interpretación paso a paso en $\mathbb{R}^3$ (agro-clima)

Planteamiento (contexto aplicado)

Objetivo: clasificar parcelas como **alto riesgo de plaga** ($Y=+1$) o **bajo riesgo** ($Y=-1$) usando tres predictores medidos el mismo día: $x=(M, T, V) \in \mathbb{R}^3$, donde M =humedad del suelo, T =temperatura del aire, V =NDVI (índice de vegetación).

Paso 1. Preparación de datos (qué se hace y por qué)

- **Estandarización:** transformar cada variable a media 0 y varianza 1.
Interpretación: evita que la escala de T domine a M o V , y en kernels como RBF controla qué significa “parecido”.
- **Partición:** entrenamiento/validación/ prueba (p. ej., 60/20/20) o validación cruzada estratificada.
Interpretación: estima el rendimiento fuera de muestra y evita sobreajuste.
- **Desbalanceo:** si hay pocos casos de plaga, usar pesos de clase o ajustar C por clase.
Interpretación: penaliza más los **falsos negativos** (no detectar plaga).

Paso 2. Intento lineal (línea base)

- Ajustar una **SVM lineal** $f(x)=w^{\top} x+b$.
Interpretación geométrica: si falla (baja sensibilidad o muchas violaciones), sugiere que las clases no son separables por un hiperplano en $\mathbb{R}^3$.

Paso 3. Kernelización (qué cambia conceptualmente)

- Elegir un **kernel** $k(x, x')=\langle \phi(x), \phi(x') \rangle$ (p. ej., **RBF** $k(x, x')=\exp(-\gamma ||x-x'||^2)$).
Interpretación: comparamos **similitud** entre parcelas; la decisión se construye como combinación de “prototipos” (vectores de

soporte) ponderados por esa similitud.

- El clasificador toma la forma $f(x) = \sum_{i \in SV} \alpha_i y_i k(x, x_i) + b$ donde (SV) son los **vectores de soporte** y $(\alpha_i \geq 0)$ sus pesos.

¿Qué es un kernel?

En el contexto de las Máquinas de Vectores de Soporte (SVM) y otros métodos de aprendizaje estadístico, un **kernel** es una función de similitud que permite trabajar en un **espacio de características implícito** sin necesidad de calcular la transformación de forma explícita.

Formalmente, un kernel es una función $k(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}$ donde $\phi: \mathcal{X} \rightarrow \mathcal{H}$ es una transformación (posiblemente no lineal) de los datos de entrada a un espacio de Hilbert con núcleo reproducing (RKHS).

Esto significa que **comparar directamente x y x' en el espacio original** equivale a **compararlos mediante producto interno en un espacio de mayor dimensión** donde puede existir una frontera lineal separadora.

Un ejemplo clásico es el kernel gaussiano o **RBF (Radial Basis Function)**: $k(x, x') = \exp(-\gamma \|x - x'\|^2)$, donde $(\gamma > 0)$ controla el radio de influencia de cada muestra.

Variantes comunes de kernels tipo RBF

Aunque el kernel gaussiano es el más usado, existen otras funciones de base radial que se pueden emplear como kernels. Todas cumplen la condición de **positividad definida** (Teorema de Mercer).

1. Kernel Gaussiano (o RBF estándar)

$$k(x, x') = \exp(-\gamma \|x - x'\|^2)$$

- Ventajas:**
 - Muy flexible, capaz de modelar fronteras altamente no lineales.
 - Solo requiere ajustar dos hiperparámetros: (C) y (γ) .
- Desventajas:**
 - Sensible a la elección de (γ) : muy grande $\rightarrow$ sobreajuste, muy pequeño $\rightarrow$ infraajuste.
 - Menos interpretable en términos geométricos.

2. Kernel Laplaciano

$$k(x, x') = \exp(-\gamma \|x - x'\|)$$

- Ventajas:**
 - Similar al gaussiano, pero con **decadencia más lenta**.
 - Puede ser más robusto frente a outliers.
- Desventajas:**
 - Fronteras menos suaves; puede generar modelos más irregulares.

3. Kernel Multicuadrático inverso

$$k(x, x') = \frac{1}{\sqrt{1 + \|x - x'\|^2 + c^2}}, \quad c > 0$$

- Ventajas:**
 - Útil cuando la similitud debe decrecer lentamente con la distancia.
 - Tiene aplicaciones en interpolación y geostatística.
- Desventajas:**
 - Menos usado en la práctica de SVM, menos paquetes lo implementan.
 - Necesita un parámetro extra (c) .

4. Kernel Multicuadrático

$$k(x, x') = \sqrt{1 + \|x - x'\|^2 + c^2}, \quad c > 0$$

- Ventajas:**
 - Buena capacidad para capturar relaciones de largo alcance en los datos.
- Desventajas:**
 - No siempre garantiza una matriz de Gram bien condicionada.
 - Menor popularidad y menos soporte en librerías estándar.

5. Kernel de Bessel modificado

$$k(x, x') = K_\nu(\gamma \|x - x'\|),$$
 donde (K_ν) es la función de Bessel modificada de segundo tipo.

- Ventajas:**
 - Tiene fundamentos teóricos sólidos en análisis armónico y series de Fourier.
 - Útil en contextos físicos (ondas, difusión).

- **Desventajas:**
 - Complejo de implementar y de interpretar.
 - Requiere elegir orden ν y parámetro γ .

Paso 4. Selección de hiperparámetros (C, γ)

- **(C)** controla la penalización por errores: (C) alto $\rightarrow$ menos sesgo, más varianza (frontera muy ajustada); (C) bajo $\rightarrow$ más suavidad.
- **(γ)** (en RBF) controla el radio de influencia: (γ) alto $\rightarrow$ influencia muy local (riesgo de sobreajuste); (γ) bajo $\rightarrow$ frontera demasiado suave (infraajuste).
Interpretación práctica: elegir (C, γ) por validación cruzada optimizando una métrica sensible al objetivo (p. ej., **recall** de plaga o **AUC**).

Paso 5. Salida del optimizador (qué mirar en la práctica)

- **Vectores de soporte:** muestras cercanas a la frontera (o mal clasificadas) con $\alpha_i > 0$.
Interpretación: son **prototipos** que “definen” la frontera; inspeccionarlos revela **situaciones límite** (p. ej., humedad alta pero NDVI también alto).
- **Sesgo (b) :** se obtiene de las condiciones KKT con un SV “blando” ($0 < \alpha_i < C$).
Interpretación: ajusta el nivel de decisión global tras ponderar las similitudes.

Paso 6. Decisión y margen (qué significa “distancia” a la frontera)

- La **clasificación** es $\text{sign}(f(x))$; $|f(x)|$ mide **confianza/margen**: valores grandes $\Rightarrow$ lejos de la frontera.
Interpretación agronómica: parcelas con $|f(x)| \gg 0$ son perfiles **muy similares** a prototipos de **alto riesgo**; con $|f(x)| \approx 0$, a prototipos **bajo riesgo**.

Paso 7. Sensibilidad local (cómo leer efectos de variables)

- Para kernel RBF, el **gradiente** del score en (x) es $\nabla_x f(x) = 2\gamma \sum_{i \in \text{SV}} \alpha_i y_i k(x, x_i) (x - x_i)$.
Interpretación: la dirección de mayor aumento del riesgo es una media ponderada de vectores que apuntan hacia **soportes de plaga** cercanos; si la componente en temperatura es positiva, **aumentar (T)** eleva el score (más riesgo) en ese entorno local.

Paso 8. Diagnóstico de rendimiento (más allá de la accuracy)

- **Matriz de confusión** (con umbral 0.5 o el que se elija operativamente).
- **ROC/AUC** para evaluar discriminación **independiente del umbral**.
- **Curva precisión-recall** cuando la clase positiva (plaga) es rara.
Interpretación: escoger el **umbral** que prioriza **recall** (evitar perder brotes) manteniendo una **precisión** manejable (coste de falsas alarmas).

Paso 9. Robustez y validez (qué comprobar)

- **Generalización temporal/espacial:** validación por temporadas o por zonas (bloques) para detectar **shift** de distribución.
- **Outliers** y ruido de sensores: (C) y (γ) regulan la sensibilidad; considerar **pre-filtrado** o **robust scaling**.
- **Importancia de variables:** la SVM no es aditiva; usar **sensibilidades locales**, pruebas de **ablation** (retirar una variable) o técnicas post-hoc (p. ej., SHAP) para interpretar.

Paso 10. Traducción a decisiones (cómo usar la salida en campo)

- Establecer **umbrales de acción** (p. ej., aplicar control si $f(x) > \tau$) o si $P(Y=+1 | x) > \tau$ tras calibración.
- Mapear el score a **zonas de manejo** (alto/medio/bajo) y **protocolos** (monitoreo adicional, muestreo, intervención).
- Documentar **incertidumbre**: reportar márgenes/intervalos y **calibrar** probabilidades si se usan como insumo de riesgo.

Checklist de cálculos para el ejemplo numérico en $(\mathbb{R}^3)$

1. Estandarizar (M, T, V) y separar un conjunto pequeño de entrenamiento (p. ej., 6–10 puntos por clase).
2. Elegir kernel (RBF) y fijar (γ) inicial; **calcular la matriz de Gram** $K_{ij} = k(x_i, x_j)$.
3. Plantear el **dual** y resolver (con QP o paquete); obtener (α_i) .
4. Identificar **vectores de soporte** y calcular (b) con un SV que cumpla $0 < \alpha_i < C$: $b = y_i - \sum_j \alpha_j y_j k(x_i, x_j)$.
5. Construir $f(x)$ y clasificar los puntos de prueba; calcular márgenes $|f(x)|$.
6. Evaluar (confusión, ROC/AUC) y ajustar (C, γ) si es necesario.
7. Interpretar **sensibilidades** con $\nabla_x f(x)$ en puntos representativos para explicar el efecto local de (M, T, V) .

Esta guía te dice **qué computar** y **cómo leer** cada salida del modelo SVM con kernel en un problema agro-climático. En la siguiente sección, realizaremos el **ejemplo numérico en $(\mathbb{R}^3)$** con un conjunto sintético pequeño, mostrando **cada cálculo** (matriz de Gram, (α) , (b) , márgenes y diagnóstico) paso a paso.

Ejemplo SVM con kernel RBF en $\mathbb{R}^3$ (4 puntos por clase)

Datos y notación

Construimos un conjunto agro-climático sintético: $x=(M,T,V)$ (humedad, temperatura, NDVI).

Dos clases: $y=+1$ = **alto riesgo** (puntos “internos”), $y=-1$ = **bajo riesgo** (puntos “externos”).

El patrón es **esférico** (no separable por hiperplano), ideal para mostrar el efecto del kernel RBF $k(x,x')=\exp\{-\gamma|x-x'|^2\}$.

SVM con kernel RBF en $\mathbb{R}^3$: cálculo numérico paso a paso (4 puntos por clase)

Datos. Usaremos 8 observaciones $x_i=(M,T,V)$ con etiquetas $y_i \in \{+1,-1\}$:

- $y=+1$ (alto riesgo):
 $x_1=(0.2, 0.1, 0.9)$, $x_2=(0.0, -0.6, 0.6)$, $x_3=(-0.7, 0.3, 0.6)$, $x_4=(0.4, 0.5, -0.5)$.
- $y=-1$ (bajo riesgo):
 $x_5=(2.0, 0.2, 0.8)$, $x_6=(-1.8, -1.0, -0.8)$, $x_7=(0.5, 2.1, -1.2)$, $x_8=(-2.2, 0.4, 0.7)$.

Kernel RBF. $k(x,x')=\exp\{-\gamma|x-x'|^2\}$ con $\gamma=1$.

1) Matriz de Gram $K=[k(x_i, x_j)]$

(Valores aproximados, 4 decimales. Filas/columnas en el orden $x_1, \dots, x_8$.)

```
\[ K \approx \begin{pmatrix} 1.0000 & 0.5379 & 0.3906 & 0.1153 & 0.0384 & 0.0003 & 0.0002 & 0.0028 \\ 0.5379 & 1.0000 & 0.2725 & 0.0758 & 0.0093 & 0.0047 & 0.0000 & 0.0029 \\ 0.3906 & 0.2725 & 1.0000 & 0.0854 & 0.0006 & 0.0078 & 0.0004 & 0.1033 \\ 0.1153 & 0.0758 & 0.0854 & 1.0000 & 0.0130 & 0.0008 & 0.0469 & 0.0003 \\ 0.0384 & 0.0093 & 0.0006 & 0.0130 & 1.0000 & 0.0000 & 0.0001 & 0.0000 \\ 0.0003 & 0.0047 & 0.0000 & 0.0001 & 0.0000 & 1.0000 & 0.0000 & 0.0028 \\ 0.0002 & 0.0029 & 0.0004 & 0.0000 & 0.0000 & 0.0028 & 1.0000 & 0.0000 \\ 0.0028 & 0.0029 & 0.1033 & 0.0003 & 0.0000 & 0.0127 & 0.0000 & 1.0000 \end{pmatrix} \]
```

Para calcular la **entrada (1,2)** de la matriz de Gram K , es decir

$$K_{12}=k(x_1, x_2)=\exp\{-\gamma|x_1-x_2|^2\} \quad \text{con } \gamma=1.$$

Con los puntos que definimos

- $x_1=(0.2, 0.1, 0.9)$
- $x_2=(0.0, -0.6, 0.6)$

hacemos:

- Diferencia componente a componente

$$x_1-x_2=(0.2-0.0, 0.1-(-0.6), 0.9-0.6)=(0.2, 0.7, 0.3).$$

- Norma al cuadrado

$$|x_1-x_2|^2=(0.2)^2+(0.7)^2+(0.3)^2=0.04+0.49+0.09=0.62.$$

- Kernel RBF (con $\gamma=1$)

$$K_{12}=\exp(-0.62) \approx 0.5379.$$

(Usando $\exp(-0.62)=\exp(-0.60)\times\exp(-0.02)\approx 0.5488\times 0.9802\approx 0.5379$.)

- Diagonal $K_{ii}=1$.
- Entre clases opuestas (p. ej., x_1 vs x_5) los valores son pequeños ($\rightarrow$) **baja similitud**.

2) Problema dual y solución α

qué significa el problema dual en un contexto aplicado (como el ejemplo agro-climático de 3 variables: humedad M , temperatura T , vegetación V).

la **lógica del dual** y cómo leer los α :

2.1. ¿Por qué trabajamos en el dual?

En el problema primal de la SVM queremos encontrar w y b que definan la frontera. Pero:

- Con **kernel**, no existe w explícito en el espacio original.
- La frontera depende solo de **productos internos** entre datos (K_{ij}).
- Así, la optimización se formula en términos de los **coeficientes duales** α_i .

2.2. El problema dual (recordemos la fórmula)

$$\left[\max_{\alpha \in [0, C]^n} \left(\sum_{i=1}^n \alpha_i \left(-\frac{1}{2} \sum_{j=1}^n \alpha_j y_i y_j K_{ij} \right) \right), \text{s.t. } \sum_{i=1}^n y_i \alpha_i = 0 \right]$$

- $K_{ij} = k(x_i, x_j)$ es la similitud entre dos parcelas según el **kernel RBF**.
- α_i mide **cuánto peso** tiene la observación (i) como **vector de soporte**.
- Restricción $(\sum y_i \alpha_i = 0)$: equilibra la contribución entre las clases positivas y negativas.

2.3. Interpretación en el problema agrícola

- Cada $(x_i = (M_i, T_i, V_i))$ es una **parcela agrícola** descrita por humedad, temperatura y NDVI.
- Cada (y_i) indica la **etiqueta**: $(+1) =$ alto riesgo de plaga, $(-1) =$ bajo riesgo.
- La matriz (K) contiene las **similitudes radiales** entre parcelas.
 - Si dos parcelas tienen condiciones agro-climáticas parecidas, (K_{ij}) es cercano a 1.
 - Si son muy diferentes, (K_{ij}) es cercano a 0.

Al resolver el dual:

- Se asigna un $(\alpha_i > 0)$ a aquellas parcelas que **están en la frontera de decisión** o que **son difíciles de clasificar**.
- Esas parcelas se convierten en **vectores de soporte**: puntos críticos que **sostienen el hiperplano en el espacio de características**.

2.4. Rol del parámetro (C)

- $(C=10)$ fija un máximo para cada (α_i) .
- Si $(\alpha_i < C)$, significa que el punto puede clasificarse correctamente **sobre el margen**.
- Si $(\alpha_i = C)$, significa que el punto está **mal clasificado** o **dentro del margen**, y por tanto “choca” con la frontera.
- En nuestro ejemplo, como todos quedaron con $(0 < \alpha_i < C)$, todos los puntos terminan siendo soporte (por el tamaño pequeño del dataset).

2.5. Ejemplo interpretado

En el resultado numérico teníamos algo así:

$$[\alpha \approx (0.43, 0.71, 0.89, 1.12, 0.78, 0.74, 0.80, 0.83)]$$

- Cada (α_i) corresponde a una parcela.
- Todos son **positivos** $(\rightarrow)$ todas las parcelas ayudan a definir la frontera.
- Por ejemplo, $(x_4 = (0.4, 0.5, -0.5))$ con $(\alpha_4 = 1.12)$: esta parcela tiene un peso fuerte en definir el margen, porque su posición está cerca de la zona de separación entre “alto riesgo” y “bajo riesgo”.
- Parcelas más alejadas (como $(x_6 = (-1.8, -1.0, -0.8))$) también aparecen con $(\alpha > 0.7)$, lo que significa que el modelo las necesita para “cerrar” la frontera en ese lado del espacio.

2.6. Conclusión interpretativa

- En el dual, **cada (α_i) representa la importancia de una parcela como prototipo de su clase** en la construcción de la frontera.
- Los (α_i) multiplicados por (y_i) forman los “pesos efectivos” de cada vector en la función de decisión:

$$f(x) = \sum_{i=1}^n \alpha_i y_i k(x, x_i) + b$$

- Así, en el contexto agro-climático:
 - Las parcelas con $(\alpha_i > 0)$ son **referencias críticas**: si desaparecieran del dataset, la frontera cambiaría.
 - El resto (si hubiera con $(\alpha_i = 0)$) serían **redundantes** (no influyen en la frontera).

cálculos del Dual (SVM (C) -svc):

$$\left[\max_{\alpha \in [0, C]^n} \sum_{i=1}^n \alpha_i \left(-\frac{1}{2} \sum_{j=1}^n \alpha_j y_i y_j K_{ij} \right), \text{s.t. } \sum_{i=1}^n y_i \alpha_i = 0 \right]$$

Con $(C=10)$, la solución numérica (todas **positivas**, por lo que **todos** son vectores de soporte) es:

$$[\alpha \approx \text{big}(0.4291, 0.7103, 0.8905, 1.1249, 0.7824, 0.7448, 0.7973, 0.8302\text{big})]$$

- Restricción $(\sum y_i \alpha_i \approx 0)$ (se cumple por redondeo a (10^{-15})).
- Como $(0 < \alpha_i < C)$ para todos, **valen las KKT suaves** en cada soporte.

3) Cálculo del sesgo (b)

Para cualquier SV con $(0 < \alpha_i < C)$, $[b = -\sum_{j=1}^n \alpha_j y_j, K_{ij}]$. Usando cualquiera de los 8 SV se obtiene consistentemente: $[b \approx -0.25584]$

4) Función de decisión y márgenes en los 8 puntos

$$f(x_i) = \sum_{j=1}^n \alpha_j y_j \cdot K_{ij} + b, \quad \widehat{y}_i = \operatorname{sign}(\big(f(x_i)\big)), \quad \text{margen} = y_i f(x_i).$$

Valores numéricos (redondeo a (10^{-6})):

- $f(x_1) \approx 1.000187$, $f(x_2) \approx 1.000007$, $f(x_3) \approx 0.999597$, $f(x_4) \approx 1.000045$.
- $f(x_5) \approx -0.999945$, $f(x_6) \approx -0.999959$, $f(x_7) \approx -0.999993$, $f(x_8) \approx -0.999940$.

Márgenes: $y_i f(x_i) \approx 1$ para todos i , lo que indica que **todos** los puntos están **exactamente sobre el margen** (dentro de la tolerancia numérica) y, por tanto, son vectores de soporte.

5) Diagnóstico

- # de SV:** 8 (todos).
- Exactitud en entrenamiento:** (100%) (las predicciones coinciden con (y)).
- La situación $f(x_i) = \pm 1$ en todos los (i) es característica de soluciones donde todos los ejemplos **soportan** la frontera con kernel RBF y este (C) .

6) Lectura e implicaciones

- La **Gram** (K) separa **similitud intraclase** (valores medios/altos) e **interclase** (valores muy bajos).
- Los **pesos duales** (α_i) determinan cuánto contribuye cada soporte; su signo efectivo en la suma viene dado por $(y_i \alpha_i)$.
- El **sesgo** (b) ajusta el nivel de decisión tras ponderar todas las similitudes.
- En problemas **esféricos** (alto riesgo “dentro”, bajo riesgo “fuera”), el **RBF** captura la curvatura; una SVM lineal no podría separar satisfactoriamente.

Nota sobre hiperparámetros. Con otros (C, γ) , cambiará el número de SV y la “anchura” de la frontera. En práctica, se seleccionan por validación cruzada, idealmente con métricas acordes al objetivo (p. ej., **recall** si importa más detectar “alto riesgo”).

con uno de los puntos concretos, cómo se usa su (α_i) en la suma para calcular $(f(x))$ y verificar que cae en el margen correcto (± 1)

1) Recordatorios del ejemplo

- Función de decisión:**

$$f(x_i) = \sum_{j=1}^n \alpha_j y_j \cdot K_{ij} + b, \quad K_{ij} = \exp(-\gamma |x_i - x_j|^2).$$

- Etiquetas:** $(y_1, \dots, y_4 = +1)$ (alto riesgo), $(y_5, \dots, y_8 = -1)$ (bajo riesgo).

- Solución dual (coeficientes):**

$$\alpha \approx (0.4291, 0.7103, 0.8905, 1.1249, 0.7824, 0.7448, 0.7973, 0.8302).$$

- Sesgo:** $b \approx -0.25584$.

2) Cálculo de $(f(x_1))$

Usamos la **fila 1** de (K) (similitudes de (x_1) con todos):

$$K_{1\bullet} \approx (1.0000, 0.5379, 0.3906, 0.1153, 0.0384, 0.0003, 0.0002, 0.0028).$$

Ahora multiplicamos término a término $(\alpha_j y_j K_{1j})$ y sumamos:

$$\begin{aligned} \alpha_1 y_1 K_{11} &= 0.4291 \cdot (+1) \cdot 1.0000 = 0.4291 \\ \alpha_2 y_2 K_{12} &= 0.7103 \cdot (+1) \cdot 0.5379 \approx 0.38207037 \\ \alpha_3 y_3 K_{13} &= 0.8905 \cdot (+1) \cdot 0.3906 \approx 0.34782930 \\ \alpha_4 y_4 K_{14} &= 1.1249 \cdot (+1) \cdot 0.1153 \approx 0.12970097 \\ \alpha_5 y_5 K_{15} &= 0.7824 \cdot (-1) \cdot 0.0384 \approx -0.03004416 \\ \alpha_6 y_6 K_{16} &= 0.7448 \cdot (-1) \cdot 0.0003 \approx -0.00022344 \\ \alpha_7 y_7 K_{17} &= 0.7973 \cdot (-1) \cdot 0.0002 \approx -0.00015946 \\ \alpha_8 y_8 K_{18} &= 0.8302 \cdot (-1) \cdot 0.0028 \approx -0.00232456 \\ \hline \text{suma } \sum_j \alpha_j y_j K_{1j} &\approx 1.25594902 \end{aligned}$$

Añadimos el sesgo (b) :

$$f(x_1) = 1.25594902 + (-0.25584) \approx 1.00010902.$$

- Predicción:** $(\widehat{y}_1 = \operatorname{sign}(f(x_1)) = +1)$.
- Margen:** $(y_1 f(x_1) \approx 1.0001)$ (está esencialmente **sobre el margen** $(+1)$).

3) (Opcional) Verificación con un punto de la clase (-1) : (x_5)

Fila 5 de (K) :

$[K_{5\bullet}\approx(0.0384,0.0093,0.0006,0.0130,1.0000,0,0.0001,0).]$

Contribuciones $(\alpha_j y_j K_{5j})$ (sumario):

- Suma de productos $(\sum_j \alpha_j y_j K_{5j})\approx -0.74423850$.
 - Más el sesgo: $(f(x_5)\approx -0.74423850-0.25584=-1.00007850)$.
 - **Predicción:** $(\widehat{y}_5=\mathrm{sign}(f(x_5))=-1)$.
 - **Margen:** $(y_5 f(x_5)=(-1)\cdot(-1.00008)\approx 1.00008)$ (también **sobre el margen**).
-

¿Qué nos dice esto?

- Los (α_j) ponderan cuánto “tira” cada parcela (como **prototipo** de su clase) sobre el punto evaluado, a través de la **similitud** (K_{ij}) .
 - Los puntos de la **misma clase** (con (y_j) del mismo signo) empujan $(f(x_i))$ en la **misma dirección**; los de **clase opuesta** empujan en **sentido contrario**.
 - El **sesgo** (b) ajusta globalmente la frontera para que los puntos de soporte queden en el margen (± 1) .
-