

Physics-Informed Neural Networks para EDO

Guía de estudio: residuo, función de pérdida, gradientes y condiciones iniciales

FCFM-UNACH

Licenciatura en Matemáticas Aplicadas

Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. ¿Qué es una PINN?	3
3. Problema base: una EDO de primer orden	4
3.1. Lectura matemática del problema	4
4. Aproximador neuronal	4
4.1. Interpretación de los parámetros	5
5. Derivada de la red	5
6. Residuo de la EDO	5
7. Puntos de colocación	6
8. Imposición suave de la condición inicial	6
9. Interpretación del parámetro λ	7
10. Preparación para calcular gradientes	7
11. Derivadas parciales del residuo	7
12. Derivadas de la condición inicial	8
13. Gradiente de la pérdida total	8
14. Mini-cálculo numérico en un punto	9
14.1. Aproximación neuronal	9
14.2. Derivada	9
14.3. Residuo	9
15. Gradientes del residuo en $x = 0.5$	10
16. La condición inicial en este ejemplo	10
17. Gradiente de la pérdida con un solo punto	11
18. Una actualización por descenso de gradiente	11

19.¿Qué ocurre con varios puntos de colocación?	12
20.Imposición suave frente a imposición dura	12
21.Restricción dura para $u(0) = 1$	12
22.Residuo con condición inicial dura	12
23.Comparación: condición suave y condición dura	13
24.PINN frente a aprendizaje supervisado clásico	13
25.Papel de la diferenciación automática	14
26.Extensión natural a una EDO de segundo orden	14
27.Preguntas de autoevaluación	14
28.Ejercicios propuestos	15
29.Actividad integradora	16
30.Ideas esenciales para recordar	17
31.Bibliografía recomendada	17

1. Propósito de esta guía

Las *Physics-Informed Neural Networks* (PINNs) constituyen una forma de utilizar redes neuronales para aproximar soluciones de ecuaciones diferenciales. Su característica distintiva es que la ecuación diferencial no se emplea únicamente para generar datos, sino que se incorpora directamente en la función de pérdida.

Esta guía desarrolla un ejemplo elemental de una ecuación diferencial ordinaria de primer orden. El objetivo es que el estudiante pueda seguir todo el procedimiento con lápiz y papel antes de utilizar herramientas de diferenciación automática o software especializado.

La secuencia conceptual será:

EDO $\longrightarrow$ red neuronal $\longrightarrow$ residuo $\longrightarrow$ función de pérdida $\longrightarrow$ gradientes $\longrightarrow$ optimización.

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Explicar qué distingue una PINN de una red neuronal supervisada estándar.
2. Construir un aproximador neuronal para una EDO escalar.
3. Derivar el residuo de la ecuación diferencial.
4. Formular una función de pérdida que combine residuo interior y condición inicial.
5. Calcular derivadas parciales del residuo respecto de los parámetros de la red.
6. Aplicar la regla de la cadena para obtener el gradiente de la pérdida.
7. Interpretar una actualización por descenso de gradiente.
8. Distinguir entre imposición suave y dura de condiciones iniciales.
9. Relacionar el procedimiento manual con la diferenciación automática.

2. ¿Qué es una PINN?

Una PINN aproxima la solución de una ecuación diferencial mediante una red neuronal parametrizada. La ecuación física o matemática se incorpora como parte del criterio de entrenamiento.

En un problema de EDO, la red produce una aproximación

$$u_{\theta}(x),$$

donde θ denota los parámetros de la red. A partir de esta aproximación se calcula el residuo de la ecuación diferencial.

Si la ecuación tiene la forma

$$\mathcal{F}(x, u, u', u'', \dots) = 0,$$

la PINN construye

$$r_{\theta}(x) = \mathcal{F}(x, u_{\theta}, u'_{\theta}, u''_{\theta}, \dots).$$

La idea es entrenar la red de manera que

$$r_{\theta}(x) \approx 0$$

en un conjunto de puntos interiores.
Además, deben imponerse las condiciones iniciales o de contorno.

Interpretación

Una PINN no necesita conocer la solución exacta en todos los puntos. Aprende buscando una función neuronal que satisfaga aproximadamente la ecuación diferencial y las condiciones del problema.

3. Problema base: una EDO de primer orden

Consideremos

$$u'(x) + u(x) = 0, \quad x \in [0, 1], \quad (1)$$

con condición inicial

$$u(0) = 1. \quad (2)$$

La solución exacta es

$$u(x) = e^{-x}.$$

En esta guía la solución exacta se utilizará solamente como referencia. La PINN se construirá utilizando la EDO y la condición inicial.

3.1. Lectura matemática del problema

La ecuación puede escribirse como

$$u'(x) = -u(x).$$

Por tanto, la rapidez de cambio de u es proporcional a su valor actual y tiene signo opuesto. Esto produce un comportamiento de decaimiento.

Conexión con aprendizaje máquina

Desde el punto de vista de aprendizaje máquina, la solución exacta no se presenta como etiqueta de entrenamiento. La información disponible es estructural: la función buscada debe obedecer (1) y (2).

4. Aproximador neuronal

Para que todas las derivadas puedan calcularse a mano, utilizaremos una red muy pequeña:

$$u_{\theta}(x) = v \tanh(wx + b) + c, \quad (3)$$

con parámetros

$$\theta = (v, w, b, c).$$

Esta red contiene una sola neurona oculta con activación hiperbólica tangente.

4.1. Interpretación de los parámetros

El argumento interno es

$$s = wx + b.$$

Después,

$$\tanh(s)$$

introduce la no linealidad.

El parámetro v escala la salida de la neurona y c introduce un desplazamiento final.

5. Derivada de la red

Como

$$\frac{d}{ds} \tanh(s) = \operatorname{sech}^2(s),$$

y

$$s = wx + b, \quad \frac{ds}{dx} = w,$$

por la regla de la cadena obtenemos

$$u'_\theta(x) = vw \operatorname{sech}^2(wx + b). \quad (4)$$

Actividad para el estudiante

Derive paso a paso (4) escribiendo explícitamente:

$$\frac{du_\theta}{dx} = \frac{du_\theta}{ds} \frac{ds}{dx}.$$

6. Residuo de la EDO

La ecuación exige

$$u'(x) + u(x) = 0.$$

Por ello definimos el residuo neuronal

$$r_\theta(x) = u'_\theta(x) + u_\theta(x). \quad (5)$$

Sustituyendo (3) y (4),

$$r_\theta(x) = vw \operatorname{sech}^2(s) + v \tanh(s) + c, \quad s = wx + b. \quad (6)$$

Si la red representara exactamente una solución de la EDO,

$$r_\theta(x) = 0$$

para todo $x \in [0, 1]$.

Interpretación

El residuo mide el grado de incumplimiento de la ecuación diferencial. En una PINN, los puntos interiores no necesitan etiquetas $u(x)$; basta exigir que el residuo sea pequeño.

7. Puntos de colocación

Elegimos puntos interiores

$$x_1, \dots, x_N \in (0, 1),$$

llamados puntos de colocación o *collocation points*.

La red se evalúa en esos puntos y se penalizan los valores

$$r_\theta(x_k)^2.$$

El término promedio será

$$\mathcal{L}_{\text{EDO}}(\theta) = \frac{1}{N} \sum_{k=1}^N r_\theta(x_k)^2. \quad (7)$$

Punto de atención

Que el residuo sea pequeño en los puntos de colocación no implica automáticamente que sea pequeño en todo el intervalo. Por eso la distribución y el número de puntos de colocación son decisiones importantes.

8. Imposición suave de la condición inicial

La condición inicial exige

$$u_\theta(0) \approx 1.$$

De (3),

$$u_\theta(0) = v \tanh(b) + c.$$

Definimos entonces

$$\mathcal{L}_{\text{CI}}(\theta) = (u_\theta(0) - 1)^2. \quad (8)$$

La pérdida total es

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{k=1}^N r_\theta(x_k)^2 + \lambda (u_\theta(0) - 1)^2 \quad (9)$$

con

$$\lambda > 0.$$

9. Interpretación del parámetro λ

El parámetro λ regula la importancia relativa de la condición inicial.

Si λ es muy pequeño, el entrenamiento puede concentrarse en reducir el residuo interior y tolerar una violación apreciable de la condición inicial.

Si λ es grande, la red recibe una penalización fuerte cuando

$$u_\theta(0) \neq 1.$$

Interpretación

La pérdida PINN es una función compuesta. No se minimiza únicamente el residuo de la EDO: se intenta equilibrar el cumplimiento de la ecuación y de las condiciones auxiliares.

10. Preparación para calcular gradientes

Para simplificar la notación, definimos

$$t = \tanh(s), \quad q = \operatorname{sech}^2(s) = 1 - t^2.$$

Entonces

$$r = vwq + vt + c.$$

El objetivo ahora es calcular

$$\frac{\partial r}{\partial v}, \quad \frac{\partial r}{\partial w}, \quad \frac{\partial r}{\partial b}, \quad \frac{\partial r}{\partial c}.$$

11. Derivadas parciales del residuo

Para v ,

$$\frac{\partial r}{\partial v} = wq + t. \quad (10)$$

Para c ,

$$\frac{\partial r}{\partial c} = 1. \quad (11)$$

Para derivar respecto de w y b , utilizamos

$$\frac{dt}{ds} = q$$

y

$$\frac{dq}{ds} = -2qt.$$

Como

$$\frac{\partial s}{\partial w} = x, \quad \frac{\partial s}{\partial b} = 1,$$

se obtiene

$$\frac{\partial r}{\partial w} = vq - 2vwxtq + vxq, \quad (12)$$

que también puede escribirse como

$$\frac{\partial r}{\partial w} = vq(1+x) - 2vwxt.$$

Análogamente,

$$\frac{\partial r}{\partial b} = -2vwqt + vq. \quad (13)$$

Actividad para el estudiante

Compruebe (12) partiendo de

$$r = vwq + vt + c$$

y aplicando la regla del producto a vwq .

12. Derivadas de la condición inicial

Como

$$u_\theta(0) = v \tanh(b) + c,$$

tenemos

$$\frac{\partial u(0)}{\partial v} = \tanh(b),$$

$$\frac{\partial u(0)}{\partial w} = 0,$$

$$\frac{\partial u(0)}{\partial b} = v \operatorname{sech}^2(b),$$

y

$$\frac{\partial u(0)}{\partial c} = 1.$$

Interpretación

La derivada respecto de w es cero porque, en $x = 0$,

$$wx + b = b.$$

Por tanto, w no afecta el valor de la red exactamente en el punto inicial.

13. Gradiente de la pérdida total

Aplicando la regla de la cadena a (9),

$$\frac{\partial \mathcal{L}}{\partial \theta} = \frac{2}{N} \sum_{k=1}^N r_\theta(x_k) \frac{\partial r_\theta(x_k)}{\partial \theta} + 2\lambda (u_\theta(0) - 1) \frac{\partial u_\theta(0)}{\partial \theta}. \quad (14)$$

Esta expresión resume la mecánica del entrenamiento.

El primer término empuja los parámetros para reducir el residuo interior.

El segundo los empuja para reducir la violación de la condición inicial.

Conexión con aprendizaje máquina

En implementaciones modernas, estas derivadas se calculan mediante *automatic differentiation*. Sin embargo, la estructura matemática sigue siendo exactamente la mostrada en (14).

14. Mini-cálculo numérico en un punto

Consideremos los parámetros

$$v = -1, \quad w = 1, \quad b = 0, \quad c = 1.$$

Evaluemos en

$$x = 0.5.$$

Entonces

$$s = 0.5,$$

$$t = \tanh(0.5) \approx 0.462117,$$

y

$$q = \operatorname{sech}^2(0.5) \approx 0.786447.$$

14.1. Aproximación neuronal

$$u_\theta(0.5) = v t + c = -0.462117 + 1 = 0.537883.$$

14.2. Derivada

$$u'_\theta(0.5) = v w q = -0.786447.$$

14.3. Residuo

$$r_\theta(0.5) = u'_\theta(0.5) + u_\theta(0.5).$$

Por tanto,

$$r_\theta(0.5) = -0.786447 + 0.537883 = -0.248564.$$

Interpretación

El residuo no es cero, por lo que estos parámetros todavía no representan una solución exacta de la EDO en $x = 0.5$.

15. Gradientes del residuo en $x = 0.5$

Para v ,

$$\frac{\partial r}{\partial v} = wq + t = 0.786447 + 0.462117 = 1.248564.$$

Para w ,

$$\frac{\partial r}{\partial w} = vq(1 + x) - 2vwxt.$$

Sustituyendo,

$$\frac{\partial r}{\partial w} \approx -1.179671 + 0.363000 = -0.816671.$$

Para b ,

$$\frac{\partial r}{\partial b} = vq - 2vwxt$$

y por tanto

$$\frac{\partial r}{\partial b} \approx -0.786447 + 0.726000 = -0.060447.$$

Finalmente,

$$\frac{\partial r}{\partial c} = 1.$$

16. La condición inicial en este ejemplo

Con

$$v = -1, \quad b = 0, \quad c = 1,$$

se obtiene

$$u_\theta(0) = v \tanh(0) + c = 1.$$

Por tanto,

$$u_\theta(0) - 1 = 0.$$

El término de condición inicial no contribuye al gradiente en este punto de parámetros.

Punto de atención

Esto no significa que la condición inicial nunca influya en el entrenamiento. Significa únicamente que, para esta elección concreta de parámetros, ya se satisface exactamente.

17. Gradiente de la pérdida con un solo punto

Para ilustrar el mecanismo, tomemos

$$N = 1.$$

Como el residuo de la condición inicial es cero,

$$\frac{\partial \mathcal{L}}{\partial \theta} = 2r \frac{\partial r}{\partial \theta}.$$

Entonces,

$$\frac{\partial \mathcal{L}}{\partial v} \approx 2(-0.248564)(1.248564) \approx -0.620,$$

$$\frac{\partial \mathcal{L}}{\partial w} \approx 2(-0.248564)(-0.816671) \approx 0.406,$$

$$\frac{\partial \mathcal{L}}{\partial b} \approx 2(-0.248564)(-0.060447) \approx 0.030,$$

y

$$\frac{\partial \mathcal{L}}{\partial c} \approx 2(-0.248564) \approx -0.497.$$

18. Una actualización por descenso de gradiente

Una actualización elemental tiene la forma

$$\theta^{\text{new}} = \theta - \eta \nabla_{\theta} \mathcal{L}, \quad (15)$$

donde $\eta > 0$ es la tasa de aprendizaje.

Por componentes,

$$v^{\text{new}} = v - \eta \frac{\partial \mathcal{L}}{\partial v},$$

y análogamente para w, b, c .

Con los signos anteriores:

$$\frac{\partial \mathcal{L}}{\partial v} < 0, \quad \frac{\partial \mathcal{L}}{\partial c} < 0,$$

por lo que v y c aumentan después de restar el gradiente.

En cambio,

$$\frac{\partial \mathcal{L}}{\partial w} > 0, \quad \frac{\partial \mathcal{L}}{\partial b} > 0,$$

por lo que w y b disminuyen después de una actualización estándar de descenso.

Interpretación

El signo del gradiente indica cómo cambiar cada parámetro para reducir localmente la pérdida. Lo importante es recordar la regla

$$\theta \leftarrow \theta - \eta \nabla \mathcal{L}.$$

19. ¿Qué ocurre con varios puntos de colocación?

Con varios puntos,

$$x_1, \dots, x_N,$$

cada uno aporta un término al gradiente:

$$r_\theta(x_k) \frac{\partial r_\theta(x_k)}{\partial \theta}.$$

La actualización final combina información de todo el conjunto.

Esto obliga a la red a buscar parámetros que reduzcan simultáneamente el residuo en diferentes zonas del intervalo.

Actividad para el estudiante

Elija tres puntos:

$$x_1 = 0.25, \quad x_2 = 0.50, \quad x_3 = 0.75.$$

Con los mismos parámetros iniciales, calcule los tres residuos y compare sus signos.

20. Imposición suave frente a imposición dura

Hasta ahora utilizamos una condición inicial suave:

$$\lambda (u_\theta(0) - 1)^2.$$

Otra estrategia es construir una forma funcional que satisfaga la condición inicial automáticamente.

21. Restricción dura para $u(0) = 1$

Definimos

$$\hat{u}_\theta(x) = 1 + xN_\theta(x), \tag{16}$$

donde $N_\theta(x)$ es una red neuronal cualquiera.

Entonces

$$\hat{u}_\theta(0) = 1$$

para cualquier valor de θ .

La condición inicial queda satisfecha por construcción.

22. Residuo con condición inicial dura

Derivamos:

$$\hat{u}'_\theta(x) = N_\theta(x) + xN'_\theta(x).$$

Por tanto,

$$\hat{r}_\theta(x) = \hat{u}'_\theta(x) + \hat{u}_\theta(x).$$

Sustituyendo,

$$\hat{r}_\theta(x) = N_\theta(x) + xN'_\theta(x) + 1 + xN_\theta(x). \quad (17)$$

La pérdida puede reducirse a

$$\hat{\mathcal{L}}(\theta) = \frac{1}{N} \sum_{k=1}^N \hat{r}_\theta(x_k)^2. \quad (18)$$

Ya no es necesario añadir una penalización para $u(0) = 1$.

23. Comparación: condición suave y condición dura

Aspecto	Condición suave	Condición dura
Imposición	mediante penalización	por construcción
Parámetro extra	requiere λ	no requiere λ para esa condición
Cumplimiento exacto	no necesariamente	sí
Flexibilidad de formulación	alta	depende de encontrar un ansatz adecuado

Interpretación

Las condiciones duras son atractivas cuando puede construirse fácilmente una forma que las satisfaga. Las condiciones suaves son más flexibles y se extienden de manera natural a problemas complejos.

24. PINN frente a aprendizaje supervisado clásico

En aprendizaje supervisado convencional se dispone de pares

$$(x_i, y_i)$$

y la pérdida compara

$$f_\theta(x_i)$$

con

$$y_i.$$

En una PINN, gran parte del entrenamiento puede realizarse sin conocer valores exactos de $u(x)$. La señal de aprendizaje proviene de la propia ecuación:

$$r_\theta(x_k) = 0.$$

Conexión con aprendizaje máquina

Esto convierte a la ecuación diferencial en una fuente de información para el entrenamiento. La física o la matemática del problema actúa como regularizador estructural de la red.

25. Papel de la diferenciación automática

En este ejemplo derivamos manualmente

$$u'_\theta(x), \quad \frac{\partial r}{\partial \theta}, \quad \nabla_\theta \mathcal{L}.$$

En una implementación real, un sistema de diferenciación automática construye estas derivadas a partir del grafo computacional.

En problemas de segundo orden, por ejemplo,

$$u''(x) + u(x) = 0,$$

la PINN necesita calcular

$$u''_\theta(x).$$

La diferenciación automática permite obtener estas derivadas sin construir fórmulas manuales para cada arquitectura.

26. Extensión natural a una EDO de segundo orden

Un problema típico es

$$u''(x) + u(x) = 0,$$

con condiciones

$$u(0) = 0, \quad u'(0) = 1.$$

El residuo sería

$$r_\theta(x) = u''_\theta(x) + u_\theta(x).$$

Una pérdida suave podría tomar la forma

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{k=1}^N r_\theta(x_k)^2 + \lambda_1 u_\theta(0)^2 + \lambda_2 (u'_\theta(0) - 1)^2.$$

Interpretación

La lógica no cambia al aumentar el orden de la EDO. Lo que cambia es el número de derivadas que deben calcularse y el número de condiciones auxiliares que deben imponerse.

27. Preguntas de autoevaluación

1. ¿Qué información utiliza una PINN para aprender una solución?
2. ¿Qué representa el residuo $r_\theta(x)$?
3. ¿Por qué se utilizan puntos de colocación?
4. ¿Qué papel desempeña λ en una condición suave?
5. ¿Cuál es la diferencia entre $u'_\theta(x)$ y $\partial r / \partial w$?
6. ¿Por qué la regla de la cadena aparece repetidamente en una PINN?

7. ¿Qué significa que $u_\theta(0) - 1 = 0$?
8. ¿Qué indica el signo de una componente del gradiente?
9. ¿Qué diferencia existe entre condición suave y condición dura?
10. ¿Por qué una condición dura elimina un término de la pérdida?
11. ¿Qué ventaja ofrece autodiff?
12. ¿Cómo cambia el residuo cuando la EDO es de segundo orden?

28. Ejercicios propuestos

Ejercicio 1. Derivada de la red.

Derive

$$u'_\theta(x)$$

a partir de

$$u_\theta(x) = v \tanh(wx + b) + c.$$

Ejercicio 2. Residuo.

Sustituya explícitamente u_θ y u'_θ en

$$u' + u = 0.$$

Ejercicio 3. Gradiente respecto de v .

Compruebe que

$$\frac{\partial r}{\partial v} = wq + t.$$

Ejercicio 4. Gradiente respecto de w .

Derive completamente

$$\frac{\partial r}{\partial w}.$$

Ejercicio 5. Nuevo punto.

Con

$$v = -1, \quad w = 1, \quad b = 0, \quad c = 1,$$

calcule el residuo en

$$x = 0.25.$$

Ejercicio 6. Tres puntos de colocación.

Use

$$x = 0.25, 0.50, 0.75$$

y calcule

$$\mathcal{L}_{\text{EDO}}.$$

Ejercicio 7. Condición inicial violada.

Cambie $c = 0.8$ y calcule

$$u_\theta(0) - 1.$$

Determine cómo aparece ahora el término de condición inicial en el gradiente.

Ejercicio 8. Efecto de λ .

Compare conceptualmente

$$\lambda = 0.1, \quad 1, \quad 100.$$

Ejercicio 9. Condición dura.

Verifique que

$$\hat{u}_\theta(x) = 1 + xN_\theta(x)$$

satisface la condición inicial para cualquier N_θ .

Ejercicio 10. EDO de segundo orden.

Proponga la pérdida PINN para

$$u'' + u = 0, \quad u(0) = 0, \quad u'(0) = 1.$$

29. Actividad integradora

Considere nuevamente

$$u'(x) + u(x) = 0, \quad u(0) = 1.$$

Realice un pequeño entrenamiento manual con tres puntos de colocación:

$$x_1 = 0.25, \quad x_2 = 0.50, \quad x_3 = 0.75.$$

Utilice

$$v = -1, \quad w = 1, \quad b = 0, \quad c = 1.$$

La actividad consiste en:

1. calcular $u_\theta(x_k)$;
2. calcular $u'_\theta(x_k)$;
3. calcular $r_\theta(x_k)$;
4. obtener $\mathcal{L}_{\text{EDO}}$;
5. calcular las cuatro componentes del gradiente;
6. elegir una tasa η pequeña;
7. realizar una actualización;
8. volver a evaluar la pérdida;
9. comparar los valores de la red con

$$e^{-x_k}.$$

Conexión con aprendizaje máquina

Esta actividad reproduce, a escala manual, el ciclo completo que realiza un entrenamiento PINN automático.

30. Ideas esenciales para recordar

- Una PINN aproxima una solución mediante una red neuronal parametrizada.
- La ecuación diferencial aparece dentro de la función de pérdida mediante un residuo.
- Los puntos de colocación permiten exigir el cumplimiento de la EDO en el dominio.
- Las condiciones iniciales o de contorno pueden imponerse de forma suave o dura.
- El entrenamiento sigue siendo un problema de optimización respecto de los parámetros de la red.
- Las derivadas necesarias pueden calcularse manualmente en ejemplos pequeños o mediante autodiff en aplicaciones reales.
- El gradiente combina información del residuo interior y de las condiciones auxiliares.
- La misma lógica se extiende a EDO de orden mayor y, posteriormente, a EDP.

31. Bibliografía recomendada

Referencias

- [1] M. Raissi, P. Perdikaris y G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”, *Journal of Computational Physics*, 378, 2019.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.
- [3] I. E. Lagaris, A. Likas y D. I. Fotiadis, “Artificial neural networks for solving ordinary and partial differential equations”, *IEEE Transactions on Neural Networks*, 9(5), 1998.