

Encoder Transformer

Guía de estudio para series temporales climáticas

FCFM–UNACH

Licenciatura en Matemáticas Aplicadas

Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. 1. Contexto general	3
3. 2. Arquitectura global: Encoder y Decoder	4
4. 3. Flujo dentro del Encoder	4
5. 4. Proyección o Embedding	5
6. 5. El problema del orden temporal	5
7. 6. Positional Encoding	5
8. 7. Positional Encoding sinusoidal	6
9. 8. Interpretación multiescala del PE	6
10.9. Relación relativa entre posiciones	7
11.10. Self-Attention	7
12.11. Atención escalada por producto punto	7
13.12. Lectura climática de la atención	8
14.13. Por qué se divide entre $\sqrt{d_k}$	8
15.14. Atención global y dependencias largas	8
16.15. Feed-Forward por posición	9
17.16. Conexiones residuales y LayerNorm	9
18.17. Secuencia completa del Encoder	9
19.18. Resumen climático del Encoder	10
20.19. Glosario de siglas	10
21.20. Preguntas de autoevaluación	10

22.21. Ejercicios propuestos	11
23.22. Actividad integradora	12
24.23. Ideas esenciales para recordar	12
25.24. Bibliografía recomendada	12

1. Propósito de esta guía

El Transformer, introducido por Vaswani et al. (2017), es un modelo para secuencias que evita la recurrencia y permite procesar en paralelo los elementos de una ventana temporal.

En esta guía se estudia específicamente el **encoder Transformer**, utilizando como ejemplo una serie climática multivariada

$$X_t = (T_t, H_t, P_t),$$

donde:

- T_t : temperatura;
- H_t : humedad;
- P_t : precipitación.

El objetivo es comprender cómo una secuencia de observaciones se transforma en una secuencia de representaciones internas contextualizadas.

La ruta conceptual será:

entrada $\longrightarrow$ embedding $\longrightarrow$ posición $\longrightarrow$ self-attention $\longrightarrow$ feed-forward $\longrightarrow$ salida codificada.

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Explicar la diferencia entre encoder y decoder.
2. Describir el flujo interno de un encoder Transformer.
3. Interpretar el papel de la proyección de entrada.
4. Explicar por qué se necesita información posicional.
5. Identificar la función de Q , K y V .
6. Interpretar la atención escalada por producto punto.
7. Explicar qué significa atención global.
8. Relacionar el positional encoding con escalas temporales distintas.
9. Reconocer las siglas básicas de la arquitectura.

2. 1. Contexto general

Un Transformer trabaja con secuencias, pero a diferencia de una RNN, LSTM o GRU no procesa cada observación de forma estrictamente secuencial.

Esto permite que muchas operaciones se ejecuten en paralelo.

En el ejemplo climático, se desea predecir

$$T_{t+h}$$

utilizando la historia de

$$X_t = (T_t, H_t, P_t).$$

La ventaja clave es que el mecanismo de atención puede aprender qué partes del pasado son relevantes para cada posición sin depender de una actualización recurrente paso a paso.

Interpretación

En una RNN, la información del pasado se transporta mediante un estado oculto. En un Transformer, cada posición puede consultar directamente otras posiciones de la ventana.

3. 2. Arquitectura global: Encoder y Decoder

La arquitectura Transformer original contiene dos grandes módulos:

Módulo	Propósito	Ejemplo climático
Encoder	Comprende la secuencia de entrada y produce una representación interna	Analiza relaciones entre T , H y P en el pasado
Decoder	Genera una salida usando lo codificado	Útil en traducción; en pronóstico univariado puede no ser necesario

Para muchas tareas de pronóstico numérico puede bastar con el encoder.

Conexión entre bloques

En esta guía nos concentraremos en cómo el encoder transforma una ventana temporal en una representación útil para un predictor posterior.

4. 3. Flujo dentro del Encoder

Sea una secuencia de longitud L :

$$(X_1, \dots, X_L), \quad X_t \in \mathbb{R}^3.$$

El flujo básico es:

1. Proyección o embedding.
2. Positional Encoding.
3. Self-Attention.
4. Feed-Forward por posición.
5. Residual + LayerNorm.

Al final se obtiene una secuencia de representaciones enriquecidas:

$$(Z_1, \dots, Z_L).$$

5. 4. Proyección o Embedding

La entrada original tiene dimensión tres:

$$X_t = (T_t, H_t, P_t) \in \mathbb{R}^3.$$

Antes de aplicar atención, se proyecta a un espacio interno de dimensión

$$d_{\text{model}}.$$

La transformación es

$$E_t = W_{\text{in}}X_t + b_{\text{in}}, \quad (1)$$

con

$$E_t \in \mathbb{R}^{d_{\text{model}}}.$$

Interpretación

El embedding no debe entenderse únicamente como un cambio de dimensión. Construye una representación interna en la que la red aprenderá combinaciones útiles de temperatura, humedad y precipitación.

6. 5. El problema del orden temporal

El Transformer procesa los vectores

$$E_1, \dots, E_L$$

en paralelo.

Por sí sola, esta operación no incorpora automáticamente la noción de que

$$X_1$$

es anterior a

$$X_L.$$

Por ello se añade una representación de posición.

Punto de atención

El contenido de una observación y su posición temporal son dos tipos de información diferentes. El Transformer necesita recibir ambas.

7. 6. Positional Encoding

La representación posicional se suma al embedding:

$$Z_t = E_t + \text{PE}_t. \quad (2)$$

El resultado contiene simultáneamente información del contenido y de la posición.

8. 7. Positional Encoding sinusoidal

Para

$$t \in \{1, \dots, L\},$$

y

$$i = 0, \dots, \left\lfloor \frac{d_{\text{model}}}{2} \right\rfloor - 1,$$

se define

$$\text{PE}(t, 2i) = \sin \left(\frac{t}{10000^{2i/d_{\text{model}}}} \right), \quad (3)$$

y

$$\text{PE}(t, 2i + 1) = \cos \left(\frac{t}{10000^{2i/d_{\text{model}}}} \right). \quad (4)$$

La idea es utilizar múltiples funciones seno y coseno a distintas escalas.

9. 8. Interpretación multiescala del PE

Las componentes del PE pueden verse como una colección de relojes.

Algunas cambian rápidamente y otras lentamente.

Esto permite distinguir:

- variaciones locales;
- posiciones intermedias;
- posiciones muy separadas dentro de la secuencia.

En el contexto climático, el material relaciona conceptualmente:

Fenómeno	Componente	Lectura conceptual
Estacionalidad anual	frecuencias bajas	variaciones lentas y repetitivas
Ciclos semanales o intramensuales	frecuencias medias	pulsos de lluvia y humedad
Eventos locales	frecuencias altas + atención	dependencias cercanas y puntuales

Interpretación

La lectura climática es una interpretación conceptual del uso de distintas escalas posicionales. El PE proporciona posición; el modelo debe aprender después qué escalas son útiles para la tarea.

10. 9. Relación relativa entre posiciones

Una propiedad interesante del PE sinusoidal es que

$$t + \Delta$$

puede relacionarse algebraicamente con

$$t$$

mediante identidades trigonométricas.

Por ejemplo,

$$\sin(t + \Delta) = \sin t \cos \Delta + \cos t \sin \Delta.$$

Esto facilita representar desplazamientos relativos entre posiciones.

Conexión entre bloques

La información posicional no sólo permite distinguir posiciones absolutas. También proporciona una estructura matemática que puede ayudar a aprender distancias relativas.

11. 10. Self-Attention

Una vez construida la secuencia

$$Z_1, \dots, Z_L,$$

cada posición se transforma en tres representaciones:

$$Q_t = \text{Query},$$

$$K_t = \text{Key},$$

$$V_t = \text{Value}.$$

Conceptualmente:

- Q_t : qué busca la posición t ;
- K_k : qué características ofrece la posición k ;
- V_k : qué información aporta la posición k .

12. 11. Atención escalada por producto punto

La operación básica es

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V. \quad (5)$$

Aquí

$$Q, K \in \mathbb{R}^{d_k}, \quad V \in \mathbb{R}^{d_v}.$$

La matriz

$$QK^\top$$

mide similitudes entre consultas y claves.

13. 12. Lectura climática de la atención

Para un día t , la atención asigna pesos a otros días k .

Si un día pasado contiene información relevante para explicar la posición actual, su peso puede aumentar.

El material fuente utiliza como ejemplos:

$$t - 1, \quad t - 30, \quad t - 120, \quad t - 365.$$

Esto permite que el modelo conecte directamente posiciones cercanas y lejanas.

Interpretación

La atención global significa que una posición no está limitada a interactuar únicamente con sus vecinos inmediatos.

14. 13. Por qué se divide entre $\sqrt{d_k}$

Los productos punto pueden crecer en magnitud cuando aumenta d_k .

Por ello se utiliza el escalamiento

$$\frac{QK^\top}{\sqrt{d_k}}.$$

Después se aplica softmax para obtener pesos normalizados.

Actividad para el estudiante

Suponga que un vector de scores es

$$(2, 1, 0).$$

Explique qué efecto cualitativo tendrá softmax: ¿qué posición recibirá mayor peso?

15. 14. Atención global y dependencias largas

Una de las ventajas conceptuales del Transformer es que una posición puede interactuar directamente con otra muy distante.

Esto es útil cuando aparecen:

- estacionalidad;
- rezagos prolongados;
- efectos retardados;
- relaciones no locales.

Por ejemplo, el material propone que una observación de precipitación en

$$t - 120$$

podría resultar relevante para explicar una temperatura posterior.

16. 15. Feed-Forward por posición

Después de la atención, cada posición pasa por una red densa.
De forma esquemática,

$$\text{FFN}(z) = W_2 \sigma(W_1 z + b_1) + b_2.$$

Esta red se aplica de manera independiente a cada posición.

Interpretación

La atención mezcla información entre posiciones. La FFN transforma no linealmente la representación de cada posición una vez incorporado el contexto.

17. 16. Conexiones residuales y LayerNorm

El encoder incluye conexiones residuales.
Esquemáticamente,

$$z_{\text{out}} = \text{LN}(z_{\text{in}} + \text{bloque}(z_{\text{in}})).$$

El material atribuye a este mecanismo un papel de estabilización y aceleración del entrenamiento.

Interpretación

La conexión residual permite conservar información de la representación anterior mientras se añade una corrección aprendida.

18. 17. Secuencia completa del Encoder

El flujo puede resumirse como:

$$X_t$$

↓

$$E_t = W_{\text{in}} X_t + b_{\text{in}}$$

↓

$$Z_t = E_t + \text{PE}_t$$

↓

Self-Attention

↓

Residual + LayerNorm



Feed-Forward



Residual + LayerNorm



representación codificada.

19. 18. Resumen climático del Encoder

Elemento	Símbolo	Rol
Entrada	$X_t = (T_t, H_t, P_t)$	observaciones diarias
Embedding	$E_t = WX_t + b$	proyección a d_{model}
Posición	PE_t	orden y distancia temporal
Suma	$Z_t = E_t + PE_t$	contenido más posición
Atención	$\text{softmax}(QK^\top / \sqrt{d_k})V$	conecta posiciones cercanas y lejanas
FFN	FFN	refinamiento no lineal por posición
Salida	$(Z_1, \dots, Z_L)$	secuencia contextualizada

20. 19. Glosario de siglas

- **PE**: Positional Encoding.
- **MHA**: Multi-Head Attention.
- **FFN**: Feed-Forward Network.
- **LN**: Layer Normalization.
- d_{model} : dimensión del espacio latente.
- d_k : dimensión de Query/Key.
- d_v : dimensión de Value.

21. 20. Preguntas de autoevaluación

1. ¿Qué función cumple el encoder?
2. ¿Por qué un problema de pronóstico puede utilizar sólo encoder?
3. ¿Qué transforma la proyección de entrada?
4. ¿Por qué se necesita PE?

5. ¿Qué diferencia conceptual existe entre E_t y Z_t ?
6. ¿Qué representan Query, Key y Value?
7. ¿Qué papel cumple softmax?
8. ¿Por qué se divide entre $\sqrt{d_k}$?
9. ¿Qué significa que la atención sea global?
10. ¿Qué hace la FFN?
11. ¿Qué función tienen las conexiones residuales?
12. ¿Qué significa d_{model} ?

22. 21. Ejercicios propuestos

Ejercicio 1. Dimensiones.

Si

$$X_t \in \mathbb{R}^3$$

y

$$d_{\text{model}} = 8,$$

indique la dimensión de W_{in} .

Ejercicio 2. Embedding.

Escriba la expresión completa de

$$E_t = W_{\text{in}}X_t + b_{\text{in}}.$$

Ejercicio 3. Posición.

Explique qué información contiene

$$Z_t = E_t + \text{PE}_t$$

que no está en E_t .

Ejercicio 4. PE sinusoidal.

Calcule las primeras dos componentes de $\text{PE}(1)$ cuando el denominador es 10000^0 .

Ejercicio 5. Atención.

Explique por qué dos posiciones con productos punto más altos reciben mayor peso después de softmax.

Ejercicio 6. Globalidad.

Compare conceptualmente una dependencia entre t y $t - 1$ con otra entre t y $t - 365$.

Ejercicio 7. FFN.

Explique por qué la FFN no mezcla posiciones directamente.

Ejercicio 8. Residual.

Interprete

$$z + \text{bloque}(z).$$

Ejercicio 9. Comparación.

Explique por qué una RNN no necesita PE en el mismo sentido que un Transformer.

Ejercicio 10. Diseño.

Proponga qué variables adicionales añadiría a X_t si los datos fueran horarios.

23. 22. Actividad integradora

Considere una ventana climática de longitud

$$L = 7.$$

Diseñe conceptualmente un encoder Transformer que utilice:

$$X_t = (T_t, H_t, P_t).$$

Debe especificar:

1. dimensión de entrada;
2. valor de d_{model} ;
3. forma de la proyección;
4. tipo de PE;
5. dimensiones de Q , K y V ;
6. cómo se calcula la atención;
7. qué ocurre después de la atención;
8. cómo utilizaría la secuencia codificada para predecir

$$T_{t+1}.$$

24. 23. Ideas esenciales para recordar

- El encoder transforma una secuencia en representaciones contextualizadas.
- La proyección de entrada lleva los datos a un espacio latente común.
- El PE introduce posición y distancia temporal.
- Self-attention relaciona posiciones mediante Query, Key y Value.
- La atención escalada usa

$$\text{softmax}(QK^T / \sqrt{d_k})V.$$

- La atención global permite conectar posiciones lejanas.
- La FFN añade transformación no lineal por posición.
- Residual y LayerNorm estabilizan el flujo de información y entrenamiento.
- En pronóstico numérico puede ser suficiente utilizar sólo el encoder.

25. 24. Bibliografía recomendada

Referencias

- [1] A. Vaswani et al., “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, 2017.
- [2] J. Alammari, *The Illustrated Transformer*, 2018.
- [3] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.