

2_encoder_transformer

YofreH

2025-10-22

Contexto general

Transformer (Vaswani et al., 2017) es un modelo para **secuencias** que evita la recurrencia y procesa en **paralelo**.
Ejemplo didáctico: predecir $\text{predicir}(T_{t+h})$ usando la historia de $X_t = (T_t, H_t, P_t)$ con $t=1, \dots, N$.

Ventaja clave: el mecanismo de **atención** aprende *qué partes* del pasado son relevantes para cada instante, sin depender de una iteración paso a paso como en RNN/LSTM/GRU.

Arquitectura global: Encoder y Decoder

Módulo	Propósito	Ejemplo climático
Encoder	Comprende la secuencia de entrada y produce una representación interna	Analiza relaciones entre $(T), (H), (P)$ en el pasado
Decoder	Genera una salida usando lo codificado	Útil en traducción; en pronóstico univariado suele no usarse

En pronóstico de series temporales numéricas (como T_{t+h}), a menudo **basta el Encoder**.

Flujo dentro del Encoder

Entrada: secuencia $(X_1, \dots, X_L)$ con $X_t \in \mathbb{R}^3$ (temperatura, humedad, precipitación).

- Proyección / Embedding:**
 $E_t = W_{\text{in}} X_t + b_{\text{in}}$, con $E_t \in \mathbb{R}^{d_{\text{model}}}$.
- Positional Encoding (PE):**
Añade información de la **posición temporal** t .
- Self-Attention** (autoatención):
Cada paso “mira” a todos los demás para ponderar relevancia.
- Feed-Forward por posición:**
Refinamiento local no lineal.
- Residual + LayerNorm:**
Estabiliza y acelera el entrenamiento.

Salida: representaciones $(Z_1, \dots, Z_L)$ enriquecidas y contextualizadas.

Self-Attention: conceptos y siglas

Para cada posición t se calculan tres proyecciones:

- $Q_t = \text{Query}$ (consulta): “¿qué busco?”
- $K_t = \text{Key}$ (clave): “¿qué tengo?”
- $V_t = \text{Value}$ (valor): “¿qué contenido aportó?”

Dimensiones típicas: $(Q, K \in \mathbb{R}^{d_k}), (V \in \mathbb{R}^{d_v})$.

Atención escalada por producto punto: $\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^{\text{top}}}{\sqrt{d_k}}) V$

Lectura climática: el día t asigna pesos a días k (pasados) según similitud $Q_t \cdot K_k$, combinando sus V_k ponderados.

¿Por qué atención “global”?

- No hay restricción de *vecindad*: el día t puede conectar con $t-1, t-30, t-120$ o $t-365$.
- Útil para **estacionalidad** y **rezagos largos** (p. ej., precipitación antecedente que influye en temperatura).

El problema del orden temporal

El Transformer **no es recurrente**: procesa todos los (E_t) en paralelo.

Sin una pista explícita, **no sabría** si (X_{t-1}) es más antiguo que (X_L) .

Solución: añadir **Positional Encoding (PE)** para inyectar noción de orden y distancia temporal.

Positional Encoding sinusoidal (definición)

Para $(t \in \{1, \dots, L\})$ y $(i=0, \dots, \lfloor d_{\text{model}}/2 \rfloor - 1)$:

$$\text{PE}(t, 2i) = \sin\left(\frac{t^{10000^{2i/d_{\text{model}}}}}{d_{\text{model}}}\right), \quad \text{PE}(t, 2i+1) = \cos\left(\frac{t^{10000^{2i/d_{\text{model}}}}}{d_{\text{model}}}\right)$$

Se suman a los embeddings:

$$Z_t = E_t + \text{PE}_t$$

Idea: múltiples *relojes* (senos/cosenos) a distintas **frecuencias** codifican la posición (t) .

Propiedades del PE sinusoidal

- Continuo en (t) :** posiciones cercanas tienen PE similares.
- Multiescala:** frecuencias bajas (tendencias estacionales), medias y altas (variaciones locales).
- Relación relativa:** $(t+\Delta)$ puede expresarse como combinación lineal de (t) gracias a identidades trigonométricas (facilita aprender “distancias” temporales).

Ejemplo climático: $(X_t=(T_t, H_t, P_t))$

- Proyección** a (d_{model}) :
 $(E_t = W_{\text{in}} X_t + b_{\text{in}})$.
- Añadir PE:**
 $(Z_t = E_t + \text{PE}_t)$.
- Atención:**
Cada (Z_t) puede asignar peso alto a días con **fase estacional** similar (p. ej., (t) y $(t-365)$) o a rezagos concretos (p. ej., $(t-120)$) si precipitación antecedente (P_{t-120}) ayuda a explicar (T_t) .

Correspondencia con fenómenos climáticos

Fenómeno	Componente en el modelo	Interpretación
Estacionalidad anual (~365 días)	Frecuencias bajas en PE	Captura variaciones lentas y repetitivas
Ciclos intra-mensuales / semanales	Frecuencias medias en PE	Relaciona pulsos de lluvia y humedad
Eventos locales (tormentas)	Frecuencias altas + atención	Enfatiza dependencias cercanas y puntuales

Visualización conceptual (sin código)

Si graficamos $(\text{PE}(t))$ en dos componentes: - $(\text{PE}_1(t) = \sin\left(\frac{t^{10000^{0/d_{\text{model}}}}}{d_{\text{model}}}\right))$ (muy suave),
- $(\text{PE}_2(t) = \cos\left(\frac{t^{10000^{0/d_{\text{model}}}}}{d_{\text{model}}}\right))$,

y luego componentes de índice mayor (frecuencia alta), veríamos una **familia de ondas**.

Cada día (t) se representa como un **vector de fases** que posiciona el día en el “calendario geométrico” del modelo.

Resumen del Encoder (climático)

Elemento	Símbolo	Rol
Entrada	$(X_t=(T_t, H_t, P_t))$	Observaciones diarias
Embedding	$(E_t=W X_t + b)$	Proyección a (d_{model})
Posición	(PE_t)	Inyecta orden y distancia temporal

Suma	$\sum (Z_t = E_t + \text{PE}_t)$	Representación con calendario
Atención	$\text{softmax}(\frac{QK^{\text{top}}}{\sqrt{d_k}})$	Conecta días cercanos y lejanos
Salida	$(Z_1, \dots, Z_L)$	Secuencia codificada para el predictor

Glosario rápido de siglas

- **PE**: *Positional Encoding* (codificación posicional)
- **MHA**: *Multi-Head Attention* (atención multi-cabeza)
- **FFN**: *Feed-Forward Network* (red densa por posición)
- **LN**: *Layer Normalization* (normalización por capa)
- d_{model} : dimensión del espacio latente del encoder
- (d_k, d_v) : dimensiones de (Q/K) y (V) , respectivamente

Preguntas para discusión

1. ¿Por qué el Transformer necesita **PE** y una RNN no?
2. ¿Qué ventajas teóricas tiene un **PE sinusoidal** frente a uno totalmente aprendido?
3. Si el ciclo anual es de 365 días, ¿cómo esperas que las **frecuencias bajas** del PE ayuden al modelo?
4. ¿Cómo combinarías PE con información de **hora del día** o **día de la semana** si los datos fueran horarios?
5. ¿Qué tipo de dependencia (local vs. lejana) esperas que destaque más el **Self-Attention** en (X_t) ?

Referencias breves

- Vaswani, A., et al. (2017). *Attention Is All You Need*.
- Alammr, J. (2018). *The Illustrated Transformer*.
- Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.