

2_taller_mini-experimentos

YofreH

2025-10-22

Instrucciones generales

El propósito de este taller es **comprender experimentalmente**, usando el caso de las variables climáticas $(X_t = (T_t, H_t, P_t))$ (temperatura, humedad y precipitación), por qué:

A diferencia de las RNN, el Transformer no conoce el orden temporal de las observaciones, porque todas las entradas se procesan en paralelo.

Cada mini-experimento debe desarrollarse como una **celda corta en Google Colab**, que:

1. Explica la **idea y procedimiento** con comentarios.
2. Ejecuta un bloque mínimo de código con las variables climáticas simuladas.
3. Calcula una **métrica cuantitativa** que respalde el resultado.
4. Visualiza o imprime una salida que permita **interpretar fácilmente** la diferencia entre modelos con y sin *Positional Encoding* (PE).

Mini-Experimento 1: Invariancia a permutaciones sin PE

Idea:

Un Transformer **sin Positional Encoding (PE)** procesa todas las entradas en paralelo, por lo que su salida es *invariante a permutaciones* del orden temporal.

Procedimiento: - Usa una ventana $(X_{t-L+1:t})$ de las tres variables.

- Aplica una permutación aleatoria (π) a los índices del tiempo.

- Compara la salida del encoder con y sin PE.

Métrica: $ISP = \frac{1}{M} \sum_{m=1}^M |\widehat{T}_{t+h}(\pi_m) - \widehat{T}_{t+h}|$

Esperado:

Sin PE $\rightarrow ISP \approx 0$;

Con PE $\rightarrow ISP$ mayor (el orden importa).

Visualización sugerida:

Gráfica de barras con valores de ISP para *sin PE* y *con PE*.

Mini-Experimento 2: Degradación por *shuffle* con / sin PE

Idea:

Si el modelo no conoce el orden, barajar la secuencia no debería cambiar su predicción. Con PE, el error debe aumentar.

Procedimiento:

- Evalúa MSE sobre secuencias ordenadas y barajadas internamente.

- Compara los resultados para ambos modelos.

Métrica: $\Delta MSE = MSE_{\text{shuffle}} - MSE_{\text{orden}}$

Esperado:

Sin PE $\rightarrow \Delta MSE$ pequeño;

Con PE $\rightarrow \Delta MSE$ grande.

Visualización sugerida:

Barplot con MSE_{orden} y MSE_{shuffle} para ambos casos.

Guía de prompt:

> "Genera una celda que calcule el MSE en secuencias originales y en secuencias barajadas, y muestre ambas en un gráfico de barras."

Mini-Experimento 3: Prueba de *time-shift*

Idea:

El PE sinusoidal codifica posiciones absolutas; al desplazar la ventana temporal, cambia la representación posicional.

Procedimiento:

- Desplaza la ventana k días: $X_{t-L+1:t}$ to $X_{t-L+1+k:t+k}$.
- Calcula la predicción para distintos k .

Métrica: $|\Delta_k| = |\widehat{T}_{t+h}^{(k)} - \widehat{T}_{t+h}^{(0)}|$

Esperado:

Con PE absoluto $\rightarrow |\Delta_k|$ crece con $|k|$;
Con PE relativo $\rightarrow$ menor sensibilidad.

Visualización sugerida:

Curva $|\Delta_k|$ vs. k mostrando cómo aumenta la discrepancia con el desplazamiento.

Mini-Experimento 4: Atención vs distancia temporal

Idea:

Sin PE, la atención no distingue posiciones; con PE, surgen patrones de atención relacionados con los lags climáticos.

Procedimiento:

- Extrae la matriz de atención promedio $\bar{A} \in \mathbb{R}^{L \times L}$.
- Promedia las atenciones por lag d :
 $w(d) = \frac{1}{L-d} \sum_{t>d} \bar{A}_{t,t-d}$.

Métrica:

El perfil de atención $w(d)$.

Esperado:

Sin PE $\rightarrow w(d)$ plano.
Con PE $\rightarrow$ picos en lags estacionales (30, 90, 180, 365).

Visualización sugerida:

Gráfico de línea de $w(d)$ vs. d .

Guía de prompt:

> "Grafica el perfil medio de atención por lag d y compara el patrón con PE y sin PE."

Mini-Experimento 5: AUC de orden correcto

Idea:

¿El modelo puede distinguir entre secuencias con orden correcto y permutadas?
Sin PE $\rightarrow$ no; con PE $\rightarrow$ sí.

Procedimiento:

- Construye pares (original, permutada).
- Asigna una puntuación de coherencia (por ejemplo, $-\text{MSE}$).
- Clasifica cuál es la secuencia real.

Métrica:

Área bajo la curva ROC: $\text{AUC} = \mathbb{P}(s_{\text{original}} > s_{\text{permutada}})$

Esperado:

Sin PE $\rightarrow \text{AUC} \approx 0.5$;
Con PE $\rightarrow \text{AUC} \gg 0.5$.

Visualización sugerida:

Gráfico ROC comparando ambos modelos.

Mini-Experimento 6: Mitad ordenada / mitad barajada

Idea:

Si solo se altera parte de la secuencia, el modelo con PE debe detectar el desorden y aumentar su error localmente.

Procedimiento:

- Divide la ventana en dos mitades.
- Baraja solo una mitad.
- Evalúa el error total.

Métrica:

$|\Delta \text{MSE}_{\text{local}}| = \text{MSE}_{\text{barajada}} - \text{MSE}_{\text{ordenada}}$

Esperado:

El incremento $|\Delta \text{MSE}_{\text{local}}|$ es mayor cuando el bloque barajado corresponde a rezagos relevantes (p. ej. $d \approx 120$).

Visualización sugerida:
Mapa de calor con el bloque barajado resaltado y valores de ΔMSE .

Guía de prompt:
> “Muestra visualmente qué parte de la ventana (barajada) provoca mayor incremento en el error.”

Mini-Experimento 7: Comparación con LSTM (control positivo)

Idea:
Una LSTM sí incorpora orden temporal, por lo que cualquier permutación debería degradar su desempeño.

Procedimiento:
- Repite el experimento 2 con una LSTM.
- Compara ΔMSE con y sin PE en el Transformer.

Métrica:
 $\Delta \text{MSE}_{\text{LSTM}} \quad \text{vs.} \quad \Delta \text{MSE}_{\text{Transformer}}$

Esperado:
LSTM → alta sensibilidad (ΔMSE grande);
Transformer sin PE → insensible;
Transformer con PE → sensible.

Visualización sugerida:
Gráfico de barras comparando las tres condiciones.

Mini-Experimento 8: IAE vs ISP (Atención y Orden)

Idea:
Relacionar la *atención a lags lejanos* (IAE) con la *sensibilidad al orden* (ISP).

Procedimiento:
- Calcula el indicador de atención efectiva:
 $\text{IAE} = \frac{1}{L} \sum_{t=1}^L \sum_{k=1}^L a_{t,k}, k$ - Calcula el índice de sensibilidad a permutación (ISP) del experimento 1.

Métrica conjunta:
Comparación IAE vs. ISP .

Esperado:
Sin PE → IAE moderado, ISP bajo.
Con PE → IAE alto, ISP alto.

Visualización sugerida:
Diagrama de dispersión (IAE, ISP) mostrando agrupaciones para los dos modos del modelo.

Conclusión general

Estos ocho mini-experimentos permiten **verificar empíricamente** que:

- Sin *Positional Encoding*, un Transformer **no distingue el orden** temporal.
- Con *Positional Encoding*, **recupera** sensibilidad al orden, reproduciendo el efecto que las RNN capturan de forma secuencial.

Recomendaciones para el aula

- Limitar cada ejecución a unas pocas secuencias para mantener tiempos breves.
- Mostrar los resultados con gráficos simples (`plt.bar`, `plt.plot`, `plt.imshow`).
- Pedir al alumnado **explicar cada curva o barra**: *¿por qué varía así?*
- Relacionar las observaciones con la hipótesis:
> “¿El modelo distingue el orden temporal o no?”

Referencias

- Vaswani, A. et al. (2017). *Attention Is All You Need*.
- Alammar, J. (2018). *The Illustrated Transformer*.
- Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.