

Transformers para series temporales: mini-experimentos

Guía de estudio sobre orden temporal, positional encoding y atención

FCFM-UNACH
Licenciatura en Matemáticas Aplicadas
Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de la guía	3
2. 1. Idea central: un Transformer no recibe el orden “gratis”	3
3. 2. Equivarianza e invariancia a permutaciones	4
4. 3. Positional Encoding	4
5. 4. Diseño general de los mini-experimentos	5
6. 5. Mini-experimento 1: sensibilidad a permutaciones	5
6.1. 5.1 Idea	5
6.2. 5.2 Procedimiento	5
6.3. 5.3 Métrica ISP	5
6.4. 5.4 Interpretación esperada	6
6.5. 5.5 Visualización	6
7. 6. Mini-experimento 2: degradación por shuffle	6
7.1. 6.1 Idea	6
7.2. 6.2 Métrica	6
7.3. 6.3 Lectura	6
7.4. 6.4 Visualización	6
8. 7. Mini-experimento 3: prueba de time-shift	7
8.1. 7.1 Idea original	7
8.2. 7.2 Dos formas distintas de interpretar el desplazamiento	7
8.3. 7.3 Experimento recomendado	7
8.4. 7.4 Interpretación	7
9. 8. Mini-experimento 4: atención vs. distancia temporal	8
9.1. 8.1 Idea	8
9.2. 8.2 Qué representa $w(d)$	8
9.3. 8.3 Lags de interés	8
10.9. Mini-experimento 5: AUC de orden correcto	8
10.1. 9.1 Idea	8
10.2. 9.2 Métrica	9
10.3. 9.3 Interpretación	9

11.10. Mini-experimento 6: mitad ordenada y mitad barajada	9
11.1. 10.1 Idea	9
11.2. 10.2 Métrica	9
11.3. 10.3 Extensión recomendada	9
11.4. 10.4 Interpretación	9
12.11. Mini-experimento 7: comparación con LSTM	10
12.1. 11.1 Idea	10
12.2. 11.2 Métrica	10
12.3. 11.3 Patrón esperado	10
13.12. Mini-experimento 8: IAE vs. ISP	10
13.1. 12.1 Idea	10
13.2. 12.2 Ajuste interpretativo	10
13.3. 12.3 Comparación conjunta	11
14.13. Control experimental	11
15.14. Repetición y variabilidad	11
16.15. Qué significa “evidencia” en estos experimentos	12
17.16. Recomendaciones para Google Colab	12
18.17. Preguntas de autoevaluación	13
19.18. Ejercicios propuestos	13
20.19. Actividad integradora	14
21.20. Conclusiones	15
22.21. Bibliografía recomendada	15

1. Propósito de la guía

Los Transformers procesan simultáneamente los elementos de una secuencia mediante mecanismos de atención. Esta característica los diferencia de modelos recurrentes como las RNN y LSTM, en los que el orden temporal queda incorporado de manera natural por la actualización secuencial del estado oculto.

Para utilizar Transformers en series de tiempo es necesario introducir alguna representación de posición u orden. En esta guía se estudia experimentalmente esta idea mediante ocho mini-experimentos contruidos sobre variables climáticas:

$$X_t = (T_t, H_t, P_t),$$

donde:

- T_t : temperatura;
- H_t : humedad;
- P_t : precipitación.

El objetivo no es desarrollar un Transformer completo desde cero, sino utilizar experimentos pequeños para aislar y observar qué cambia cuando el modelo dispone, o no, de información posicional.

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Explicar por qué la autoatención, por sí sola, no codifica orden temporal.
2. Diferenciar entre equivarianza e invariancia a permutaciones.
3. Interpretar el papel del *Positional Encoding* (PE).
4. Diseñar experimentos de permutación, *shuffle* y desplazamiento temporal.
5. Medir sensibilidad al orden mediante métricas como ISP y Δ MSE.
6. Analizar perfiles de atención por lag.
7. Comparar un Transformer con una LSTM como control positivo.
8. Relacionar atención a rezagos lejanos con sensibilidad al orden.
9. Interpretar resultados experimentales y no limitarse a ejecutar código.

2. 1. Idea central: un Transformer no recibe el orden “gratis”

En una RNN, el estado oculto se actualiza de forma secuencial:

$$h_t = f(h_{t-1}, x_t).$$

La observación x_t es procesada después de x_{t-1} , por lo que la posición temporal participa directamente en la dinámica.

En un Transformer, en cambio, las entradas de una ventana

$$X_{t-L+1:t} = (x_{t-L+1}, \dots, x_t)$$

se procesan en paralelo mediante autoatención.

Para una matriz de entradas X , la atención básica tiene la forma

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V,$$

y

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V.$$

En esta expresión no aparece, por sí misma, la posición temporal absoluta o relativa.

3. 2. Equivarianza e invariancia a permutaciones

Sea P una matriz de permutación que reordena los elementos de una secuencia.

Sin PE, un bloque estándar de autoatención satisface, idealmente,

$$\text{Att}(PX) = P \text{Att}(X).$$

Esto se denomina **equivarianza a permutaciones**.

Nota de precisión conceptual

Equivarianza no significa que todas las salidas sean idénticas después de permutar. Significa que, si se permutan las entradas, las representaciones de salida se permutan de la misma manera.

La salida final sólo será **invariante** a la permutación si el mecanismo de lectura final también lo es, por ejemplo mediante promedio global o suma simétrica:

$$\rho(PZ) = \rho(Z).$$

Si, en cambio, se utiliza “el último token” como salida, permutar la secuencia puede cambiar qué elemento ocupa esa posición.

Esta distinción es fundamental para interpretar correctamente los experimentos.

4. 3. Positional Encoding

Una estrategia clásica consiste en modificar cada vector de entrada:

$$z_t = x_t + \text{PE}(t).$$

El PE sinusoidal de Vaswani et al. se define mediante funciones seno y coseno con distintas frecuencias. Su objetivo es proporcionar al modelo información sobre la posición.

Con PE, dos secuencias con los mismos valores pero distinto orden ya no generan exactamente las mismas representaciones posicionales.

Interpretación

El Transformer aprende relaciones entre contenidos; el PE introduce información acerca de *dónde* aparece cada contenido dentro de la secuencia.

5. 4. Diseño general de los mini-experimentos

Cada mini-experimento debe desarrollarse como una celda breve en Google Colab que contenga cuatro elementos:

1. explicación de la hipótesis;
2. modificación controlada de la secuencia;
3. métrica cuantitativa;
4. salida gráfica o tabular que permita interpretar el resultado.

No se busca únicamente obtener una figura. El estudiante debe responder:

¿Qué propiedad del modelo está siendo puesta a prueba y qué evidencia cuantitativa respalda la conclusión?

6. 5. Mini-experimento 1: sensibilidad a permutaciones

6.1. 5.1 Idea

Se desea comprobar qué ocurre cuando la misma ventana climática se presenta en distinto orden.

Sea una permutación

$$\pi : \{1, \dots, L\} \rightarrow \{1, \dots, L\}.$$

La secuencia permutada es

$$X^{(\pi)} = (x_{\pi(1)}, \dots, x_{\pi(L)}).$$

6.2. 5.2 Procedimiento

1. Seleccionar una ventana de longitud L .
2. Calcular una predicción base $\hat{T}_{t+h}$.
3. Generar M permutaciones aleatorias.
4. Evaluar cada secuencia permutada.
5. Repetir para un modelo sin PE y otro con PE.

6.3. 5.3 Métrica ISP

Definimos

$$\text{ISP} = \frac{1}{M} \sum_{m=1}^M \left| \hat{T}_{t+h}^{(\pi_m)} - \hat{T}_{t+h} \right|. \quad (1)$$

6.4. 5.4 Interpretación esperada

Si la arquitectura completa utiliza una lectura invariante y no incorpora PE,

$$\text{ISP} \approx 0.$$

Con PE, el reordenamiento modifica la relación entre contenido y posición y se espera una mayor sensibilidad.

Nota de precisión conceptual

El valor $\text{ISP} \approx 0$ sin PE requiere controlar también el mecanismo de salida. Para evitar ambigüedad en el experimento, conviene usar *global average pooling* o una lectura simétrica sobre los tokens.

6.5. 5.5 Visualización

Una gráfica de barras con:

ISP sin PE y ISP con PE.

Actividad para el estudiante

Explique por qué este experimento sería menos limpio si la predicción se toma directamente del último token.

7. 6. Mini-experimento 2: degradación por shuffle

7.1. 6.1 Idea

Se compara el desempeño predictivo sobre secuencias ordenadas y secuencias cuya estructura temporal interna ha sido destruida mediante *shuffle*.

7.2. 6.2 Métrica

$$\Delta \text{MSE} = \text{MSE}_{\text{shuffle}} - \text{MSE}_{\text{orden}}.$$

7.3. 6.3 Lectura

Un valor

$$\Delta \text{MSE} > 0$$

indica que el modelo pierde precisión cuando se altera el orden.

Para un Transformer sin PE y con lectura invariante se espera una diferencia pequeña.

Para un Transformer con PE se espera una degradación mayor si el modelo realmente aprendió relaciones temporales dependientes de posición.

7.4. 6.4 Visualización

Mostrar cuatro barras:

$$\begin{aligned} & \text{MSE}_{\text{orden, sin PE}}, \\ & \text{MSE}_{\text{shuffle, sin PE}}, \\ & \text{MSE}_{\text{orden, con PE}}, \\ & \text{MSE}_{\text{shuffle, con PE}}. \end{aligned}$$

Interpretación

La comparación relevante no es sólo qué modelo tiene menor MSE absoluto, sino cuánto empeora cada uno cuando se destruye la estructura temporal.

8. 7. Mini-experimento 3: prueba de time-shift

8.1. 7.1 Idea original

Se desplaza temporalmente una ventana:

$$X_{t-L+1:t} \longrightarrow X_{t-L+1+k:t+k}.$$

Se define

$$\Delta_k = \left| \hat{T}_{t+h}^{(k)} - \hat{T}_{t+h}^{(0)} \right|.$$

8.2. 7.2 Dos formas distintas de interpretar el desplazamiento

Nota de precisión conceptual

Hay que distinguir dos diseños.

Diseño A: cada ventana se vuelve a indexar internamente como

$$1, \dots, L.$$

En ese caso, un PE absoluto local usa las mismas posiciones para todas las ventanas. El cambio en la predicción se debe principalmente al contenido climático, no al desplazamiento del índice global.

Diseño B: el PE recibe posiciones globales del calendario o índices absolutos diferentes. Entonces el desplazamiento k también modifica explícitamente la codificación posicional.

8.3. 7.3 Experimento recomendado

Para aislar el efecto posicional, mantener constante el contenido de la ventana y modificar únicamente los índices posicionales suministrados al PE.

Así se compara:

$$(X, \text{PE}(1:L))$$

con

$$(X, \text{PE}(1+k:L+k)).$$

8.4. 7.4 Interpretación

Con PE absoluto global puede observarse sensibilidad al desplazamiento.

Con PE relativo, el modelo depende principalmente de las distancias entre posiciones, por lo que una traslación global puede afectar menos.

9. 8. Mini-experimento 4: atención vs. distancia temporal

9.1. 8.1 Idea

Se busca resumir cuánto peso de atención se asigna a observaciones separadas por un lag d . Sea

$$\overline{A} \in \mathbb{R}^{L \times L}$$

una matriz de atención promedio.

Podemos definir

$$w(d) = \frac{1}{L-d} \sum_{t=d+1}^L \overline{A}_{t,t-d}. \quad (2)$$

9.2. 8.2 Qué representa $w(d)$

El valor $w(d)$ resume cuánto peso promedio reciben claves ubicadas d pasos atrás respecto de la consulta.

Si aparecen picos en ciertos rezagos, puede investigarse si corresponden a periodicidades climáticas.

Nota de precisión conceptual

Sin PE no debe esperarse necesariamente un perfil plano. La atención puede variar con el *contenido* de temperatura, humedad y precipitación.

Lo correcto es afirmar que, sin PE, el modelo no dispone de la etiqueta explícita “este valor está a d días”. Un perfil $w(d)$ sistemático sólo puede surgir indirectamente por patrones de contenido o por otros componentes de la arquitectura.

9.3. 8.3 Lags de interés

Según la resolución temporal y el problema, pueden inspeccionarse rezagos como

$$30, \quad 90, \quad 180, \quad 365.$$

No deben interpretarse automáticamente como estacionalidades reales: la evidencia debe aparecer en los datos o en el patrón aprendido.

10. 9. Mini-experimento 5: AUC de orden correcto

10.1. 9.1 Idea

Construir pares formados por:

secuencia original vs. secuencia permutada.

Cada secuencia recibe una puntuación de coherencia.

Una opción es usar

$$s = -\text{error}.$$

Así, una secuencia con menor error recibe mayor puntuación.

10.2. 9.2 Métrica

$$\text{AUC} = \mathbb{P}(s_{\text{original}} > s_{\text{permutada}}).$$

En la práctica se calcula mediante una curva ROC o por comparación de pares.

10.3. 9.3 Interpretación

$$\text{AUC} \approx 0.5$$

indica que el sistema no distingue ambas condiciones mejor que al azar.

Valores sustancialmente mayores que 0.5 indican que el modelo asigna puntuaciones superiores a secuencias con orden correcto.

Punto de atención

La definición de la puntuación debe fijarse antes de evaluar el experimento. Si se utiliza MSE, se necesita un objetivo conocido para cada secuencia.

11. 10. Mini-experimento 6: mitad ordenada y mitad barajada

11.1. 10.1 Idea

En vez de permutar toda la ventana, se altera sólo una región.

Sea una ventana dividida en bloques:

$$X = (X^{(1)}, X^{(2)}).$$

Se baraja uno de los bloques y se deja el otro intacto.

11.2. 10.2 Métrica

$$\Delta \text{MSE}_{\text{local}} = \text{MSE}_{\text{barajada}} - \text{MSE}_{\text{ordenada}}.$$

11.3. 10.3 Extensión recomendada

En lugar de usar sólo dos mitades, dividir la ventana en varios bloques y permutar uno a la vez.

Esto permite construir un mapa:

$$j \mapsto \Delta \text{MSE}_j.$$

11.4. 10.4 Interpretación

Los bloques con mayor incremento de error pueden corresponder a regiones temporales que el modelo utiliza más intensamente.

Nota de precisión conceptual

No debe concluirse causalidad a partir de esta sensibilidad. El experimento indica dependencia predictiva del bloque perturbado, no un efecto causal del lag.

12. 11. Mini-experimento 7: comparación con LSTM

12.1. 11.1 Idea

La LSTM sirve como control positivo porque incorpora orden mediante recurrencia. Se repite el experimento de *shuffle* para tres condiciones:

Transformer sin PE,

Transformer con PE,

LSTM.

12.2. 11.2 Métrica

$$\Delta \text{MSE}_{\text{LSTM}} \quad \text{vs.} \quad \Delta \text{MSE}_{\text{Transformer}} .$$

12.3. 11.3 Patrón esperado

Se espera que la LSTM y el Transformer con PE sean más sensibles a permutaciones que un Transformer sin PE con lectura simétrica.

Interpretación

El objetivo no es demostrar que una arquitectura sea “mejor” en general. El experimento usa la LSTM como referencia de un modelo en el que el orden forma parte explícita del mecanismo de procesamiento.

13. 12. Mini-experimento 8: IAE vs. ISP

13.1. 12.1 Idea

El experimento busca relacionar dos aspectos:

- qué tan lejos en el pasado atiende el modelo;
- qué tan sensible es al orden.

El material base propone

$$\text{IAE} = \frac{1}{L} \sum_{t=1}^L \sum_{k=1}^L a_{t,k} k. \quad (3)$$

13.2. 12.2 Ajuste interpretativo

La expresión anterior pondera directamente el índice k , no la distancia temporal respecto de t .

Si el objetivo es medir atención a rezagos lejanos, resulta más interpretable definir

$$\text{IAE}_{\text{lag}} = \frac{1}{L} \sum_{t=1}^L \sum_{k=1}^L a_{t,k} |t - k|. \quad (4)$$

o, en un modelo causal donde sólo se atiende al pasado,

$$\text{IAE}_{\text{lag}} = \frac{1}{L} \sum_{t=1}^L \sum_{k \leq t} a_{t,k}(t-k).$$

Nota de precisión conceptual

Se conserva la definición original (3) como parte del material base, pero para hablar específicamente de “lags lejanos” es preferible (4).

13.3. 12.3 Comparación conjunta

Cada modelo puede representarse como un punto

(IAE, ISP).

La gráfica permite comparar:

- sensibilidad a permutaciones;
- distribución de atención a distintas distancias.

14. 13. Control experimental

Para que las comparaciones sean interpretables, ambos Transformers deben compartir, en lo posible:

- misma arquitectura;
- mismo número de parámetros;
- mismo conjunto de entrenamiento;
- misma inicialización o varias semillas;
- mismo optimizador;
- mismo número de épocas;
- misma estrategia de lectura final.

La única diferencia principal debería ser la presencia o ausencia de PE.

Interpretación

Un mini-experimento es útil cuando cambia una propiedad a la vez. Si se modifican simultáneamente arquitectura, entrenamiento y PE, la comparación deja de aislar el efecto del orden.

15. 14. Repetición y variabilidad

Una única permutación o una única semilla puede producir un resultado accidental. Por ello conviene repetir:

$$m = 1, \dots, M$$

y resumir mediante:

media, desviación estándar, intervalos o barras de error.

Para ISP ya aparece naturalmente el promedio sobre permutaciones.
Puede extenderse la misma idea a Δ MSE, AUC y perfiles de atención.

16. 15. Qué significa “evidencia” en estos experimentos

Un resultado convincente combina tres niveles:

1. **métrica:** muestra una diferencia cuantitativa;
2. **visualización:** permite inspeccionar el patrón;
3. **interpretación:** conecta el patrón con la propiedad teórica del modelo.

Por ejemplo:

$$\text{ISP}_{\text{sin PE}} \approx 0$$

por sí solo no basta si la salida final es invariante por construcción. El alumno debe explicar por qué esa arquitectura produce el resultado y qué cambiaría con otra lectura.

17. 16. Recomendaciones para Google Colab

Cada celda debe ser deliberadamente pequeña.

Una estructura recomendable es:

1. fijar semilla;
2. seleccionar pocas secuencias;
3. crear una perturbación;
4. evaluar ambos modelos;
5. calcular una métrica;
6. mostrar una figura simple.

Visualizaciones suficientes:

- `plt.bar`;
- `plt.plot`;
- `plt.imshow`;
- curva ROC;
- diagrama de dispersión.

18. 17. Preguntas de autoevaluación

1. ¿Por qué la autoatención sin PE no conoce el orden por sí sola?
2. ¿Cuál es la diferencia entre equivarianza e invariancia?
3. ¿Qué condición debe cumplir la lectura final para obtener invariancia global?
4. ¿Qué mide ISP?
5. ¿Qué mide Δ MSE?
6. ¿Por qué un *shuffle* es una perturbación útil?
7. ¿Qué problema conceptual aparece en un experimento de *time-shift* si el PE se reinicia siempre en $1, \dots, L$?
8. ¿Qué representa $w(d)$?
9. ¿Por qué $w(d)$ no tiene que ser plano sin PE?
10. ¿Qué significa una AUC cercana a 0.5?
11. ¿Por qué la LSTM es un control positivo?
12. ¿Qué diferencia existe entre índice de posición y distancia temporal en la definición de IAE?
13. ¿Por qué deben repetirse los experimentos con varias permutaciones?

19. 18. Ejercicios propuestos

Ejercicio 1. Equivarianza.

Sea P una matriz de permutación. Explique conceptualmente por qué

$$\text{Att}(PX) = P \text{Att}(X)$$

en ausencia de PE.

Ejercicio 2. Lectura simétrica.

Demuestre que

$$\frac{1}{L} \sum_{t=1}^L z_t$$

no cambia si los z_t se permutan.

Ejercicio 3. ISP.

Proponga $M = 20$ permutaciones y describa cómo calcular la media y desviación estándar de las diferencias.

Ejercicio 4. Shuffle parcial.

Divida una ventana en cuatro bloques y diseñe un experimento que permute cada bloque por separado.

Ejercicio 5. Time-shift.

Diseñe dos versiones: PE local reiniciado y PE absoluto global. Indique qué comparación sería más informativa.

Ejercicio 6. Atención por lag.

A partir de una matriz $A \in \mathbb{R}^{L \times L}$, calcule $w(1), w(2), w(3)$.

Ejercicio 7. AUC.

Explique cómo construir etiquetas y puntuaciones para distinguir secuencias originales de permutadas.

Ejercicio 8. LSTM.

Prediga cualitativamente qué ocurrirá con ΔMSE al barajar una secuencia entrenada para pronóstico.

Ejercicio 9. IAE.

Compare

$$\sum a_{t,k}k$$

con

$$\sum a_{t,k}|t-k|.$$

¿Cuál representa mejor “atención a lags lejanos”?

Ejercicio 10. Diseño experimental.

Enumere al menos cinco variables de entrenamiento que deben mantenerse constantes al comparar modelos con y sin PE.

20. 19. Actividad integradora

Diseñe una práctica breve con un conjunto climático simulado y tres modelos:

Transformer sin PE,

Transformer con PE,

LSTM.

La práctica debe incluir:

1. una tarea de pronóstico de temperatura;
2. una ventana L ;
3. una perturbación por permutación;
4. una perturbación local;
5. ISP;
6. ΔMSE ;
7. al menos una visualización de atención;
8. una comparación con LSTM;
9. una conclusión escrita de máximo cinco líneas.

La conclusión debe responder:

¿Qué evidencia muestra que el modelo utiliza, o no utiliza, información de orden temporal?

21. 20. Conclusiones

Los ocho mini-experimentos permiten estudiar empíricamente una propiedad central de los Transformers:

- la autoatención por sí sola no contiene información explícita de posición;
- un PE introduce información de orden o distancia;
- las permutaciones constituyen una herramienta útil para probar sensibilidad temporal;
- una LSTM ofrece una referencia natural de un modelo secuencial;
- las matrices de atención pueden analizarse por lag, pero deben interpretarse con cuidado;
- la arquitectura de lectura final influye en que la salida sea invariante o simplemente equivariante;
- las métricas experimentales deben acompañarse de un diseño que aisle la propiedad estudiada.

Interpretación

La finalidad del taller no es sólo comprobar que “PE ayuda”, sino aprender a diseñar pequeñas pruebas controladas que conecten una propiedad matemática de la arquitectura con una evidencia cuantitativa observable.

22. 21. Bibliografía recomendada

Referencias

- [1] A. Vaswani et al., “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, 2017.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.
- [3] J. Alammari, *The Illustrated Transformer*, 2018.