

Bloque 1 — Proyección de entrada en el Encoder Transformer

Curso de Aprendizaje Automático — Matemáticas Aplicadas
2025

- 1 Objetivo
- 2 Dimensiones mínimas
- 3 Interpretación conceptual
- 4  Ejemplo numérico
- 5 Cálculo paso a paso
- 6  Resultado esperado
- 7 Interpretación del aprendizaje
- 8  Qué se obtiene al entrenar
- 9 Conclusión del bloque
- 10  Nota práctica
- 11 “Bloque 2 — Incorporación de la posición temporal (Positional Encoding)”
- 12 Objetivo
- 13  Dimensiones mínimas
- 14 Definición matemática
- 15 Ejemplo numérico
 - 15.1 Paso 1. Cálculo de las frecuencias
 - 15.2 Paso 2. Evaluación de las funciones seno y coseno
 - 15.3 Paso 3. Suma con el vector proyectado
- 16  Interpretación
- 17  Resultados esperados
- 18 Aprendizaje
- 19  Resumen del bloque 2
- 20 Qué observar al implementarlo
- 21 Conclusión del bloque
- 22  Nota práctica
- 23 “Bloque 3 — Mecanismo de Atención (Self-Attention)”
- 24 Objetivo
- 25  Dimensiones mínimas
- 26 Descripción general del proceso
- 27 Datos iniciales
- 28 Transformaciones lineales aprendibles
- 29  Cálculo paso a paso para el día 1
 - 29.1 1. Vectores “consulta”, “describir” y “contenido”
 - 29.2 2. Cálculo de similitudes y escala
 - 29.3 3. Ponderaciones (softmax)
 - 29.4 4. Mezcla de contenidos
 - 29.5 5. Proyección de vuelta a 4 dimensiones y suma residual
 - 29.6 6. Normalización por capa
- 30 Interpretación del aprendizaje
- 31  Actividades sugeridas
- 32  Interpretación en el contexto climático
- 33  Resultados esperados para comprobar en clase
- 34 Conclusión del bloque
- 35  Resumen conceptual
- 36  Verificación y reflexión
- 37 “Bloque 4 — Red densa por posición y salida del Encoder Transformer”
- 38 Objetivo
- 39  Dimensiones mínimas
- 40 Datos de entrada
- 41 Primera capa ($4 \rightarrow 3$)
- 42 Segunda capa ($3 \rightarrow 4$)
- 43 Suma residual y normalización
- 44  Salida del Encoder y cabeza final
 - 44.1 1. Agregación temporal
 - 44.2 2. Capa lineal final (ejemplo ilustrativo)
- 45 Interpretación del aprendizaje
- 46 Actividades de verificación
- 47  Resultados esperados (día 1)
- 48 Conclusión
- 49  Resumen conceptual del Bloque 4
- 50  Reflexión final

1 Objetivo

Transformar cada observación climática $X_t = (T_t, H_t, P_t) \in \mathbb{R}^3$ a un **espacio interno o latente** de mayor dimensión donde el modelo pueda representar relaciones complejas.

Este paso cumple el papel de una **capa lineal** de una red neuronal (multiplicación de matriz por vector más un desplazamiento).

2 Dimensiones mínimas

Concepto	Símbolo	Dimensión
Entrada diaria (temperatura, humedad, precipitación)	X_t	$\mathbb{R}^3$
Dimensión interna (características internas del modelo)	—	$d = 4$
Matriz de pesos	W_{in}	4×3
Vector de sesgo	b_{in}	4×1
Salida proyectada	E_t	$\mathbb{R}^4$

3 Interpretación conceptual

El modelo **aprende una combinación lineal** de las variables (T_t, H_t, P_t) para producir **cuatro características internas** $(e_{t,1}, e_{t,2}, e_{t,3}, e_{t,4})$.

Matemáticamente:

$$E_t = W_{\text{in}} X_t + b_{\text{in}}$$

4 Ejemplo numérico

Supongamos que el día $t = 1$:

$$X_1 = (T_1, H_1, P_1) = (25, 0.7, 3)$$

y que el modelo inicializa sus pesos de manera aleatoria (antes del aprendizaje):

$$W_{\text{in}} = \begin{pmatrix} 0.2 & 0.5 & -0.1 \\ 0.4 & -0.3 & 0.2 \\ -0.2 & 0.6 & 0.3 \\ 0.1 & 0.2 & 0.4 \end{pmatrix}, \quad b_{\text{in}} = \begin{pmatrix} 0.1 \\ 0.0 \\ -0.1 \\ 0.05 \end{pmatrix}$$

Entonces el cálculo es:

$$E_1 = \begin{pmatrix} 0.2 & 0.5 & -0.1 \\ 0.4 & -0.3 & 0.2 \\ -0.2 & 0.6 & 0.3 \\ 0.1 & 0.2 & 0.4 \end{pmatrix} \begin{pmatrix} 25 \\ 0.7 \\ 3 \end{pmatrix} + \begin{pmatrix} 0.1 \\ 0.0 \\ -0.1 \\ 0.05 \end{pmatrix}$$

5 Cálculo paso a paso

1. **Primera componente:**
- $$0.2(25) + 0.5(0.7) - 0.1(3) + 0.1 = 5 + 0.35 - 0.3 + 0.1 = 5.15$$
2. **Segunda componente:**
- $$0.4(25) - 0.3(0.7) + 0.2(3) + 0 = 10 - 0.21 + 0.6 = 10.39$$
3. **Tercera componente:**
- $$-0.2(25) + 0.6(0.7) + 0.3(3) - 0.1 = -5 + 0.42 + 0.9 - 0.1 = -3.78$$
4. **Cuarta componente:**
- $$0.1(25) + 0.2(0.7) + 0.4(3) + 0.05 = 2.5 + 0.14 + 1.2 + 0.05 = 3.89$$
- Por lo tanto:
- $$E_1 = (5.15, 10.39, -3.78, 3.89)$$

6 Resultado esperado

Cada día (X_t) se transforma en un vector $(E_t \in \mathbb{R}^4)$.
Si consideramos una ventana de $(L = 5)$ días, la entrada al modelo se convierte en una **matriz**:
 $E = \begin{pmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \\ E_5 \end{pmatrix} \in \mathbb{R}^{5 \times 4}$.
Cada fila contiene una representación interna de un día.

7 Interpretación del aprendizaje

Durante el entrenamiento, los valores de (W_{in}) y (b_{in}) **se ajustan** para que las combinaciones lineales aprendan **relaciones relevantes entre variables**.

Por ejemplo:

- Si el modelo descubre que **temperatura alta con baja humedad** predice bien la siguiente temperatura, los pesos en (W_{in}) aumentarán en la dirección de $((T_t, -H_t))$.
- Si la **precipitación** no aporta información, sus pesos tenderán a 0 en algunas filas de (W_{in}) .

8 Qué se obtiene al entrenar

Al final del entrenamiento, cada fila de (W_{in}) se comporta como un “filtro” o **combinador lineal** que extrae una *característica climática interna*:

Filtro	Posible significado aprendido
Filtro 1	Temperatura suavizada
Filtro 2	Contraste entre temperatura y humedad
Filtro 3	Variación de precipitación
Filtro 4	Tendencia combinada temperatura-humedad

9 Conclusión del bloque

- Este bloque transforma datos originales $((T,H,P))$ en un **espacio interno** donde se representan interacciones más complejas.
- Matemáticamente, es una multiplicación matricial más un desplazamiento.
- El modelo aprende los pesos (W_{in}) para que el espacio resultante sea útil para la predicción.
- Su salida (E_t) alimenta al **bloque siguiente**, donde se añadirá la **información posicional**.

10 Nota práctica

Si los cálculos se realizan mediante software (por ejemplo, R o Python):

- El resultado numérico para el ejemplo anterior debe ser $(E_1 = (5.15, 10.39, -3.78, 3.89))$.
- Este vector corresponde al **espacio interno** que representará el día 1.
- reproducir este cálculo paso a paso** para visualizar cómo los datos climáticos se convierten en representaciones internas.

11 “Bloque 2 — Incorporación de la posición temporal (Positional Encoding)”

12 Objetivo

El bloque de proyección del paso anterior transforma los datos climáticos $(X_t = (T_t, H_t, P_t))$ en vectores internos $(E_t \in \mathbb{R}^4)$.
Sin embargo, todos los días están representados solo por su contenido (temperatura, humedad y lluvia), **no por su lugar en la secuencia temporal**.

Como el Transformer procesa todos los vectores **en paralelo**, no “sabe” que el día 1 es anterior al día 2.
El propósito de este bloque es **inyectar información de orden y distancia temporal** para que el modelo pueda reconocer que ciertas observaciones son consecutivas o periódicas (por ejemplo, ciclos estacionales).

13 Dimensiones mínimas

Usaremos el mismo tamaño de representación interna:

Concepto	Símbolo	Dimensión
Vector proyectado del día t	$\mathbf{E}_t$	$\mathbb{R}^4$
Codificación de posición	PE_t	$\mathbb{R}^4$
Resultado de la suma	$\mathbf{Z}_t$	$\mathbb{R}^4$

La relación entre ellos es:

$$\mathbf{Z}_t = \mathbf{E}_t + \mathrm{PE}_t$$

14 Definición matemática

Para cada posición temporal t (día dentro de la ventana) y cada componente $i = 0, 1, \dots, \lfloor d/2 \rfloor - 1$, donde $d = 4$:

$$\mathrm{PE}_t(2i) = \sin\left(\frac{t}{10000^{2i/d}}\right), \quad \mathrm{PE}_t(2i+1) = \cos\left(\frac{t}{10000^{2i/d}}\right).$$

Con $d=4$, tendremos dos pares seno-coseno de diferentes frecuencias.

15 Ejemplo numérico

Supongamos una ventana de **5 días**, $t = 1, 2, 3, 4, 5$,
y que queremos generar los cuatro componentes de PE_t .

15.1 Paso 1. Cálculo de las frecuencias

$$10000^{2i/d} = \begin{cases} 10000^{0/4} = 1, & i=0 \\ 10000^{2/4} = 100, & i=1 \end{cases}$$

Por tanto:

- Los dos primeros componentes usan frecuencia (1) (alta),
- Los dos siguientes usan frecuencia (100) (más lenta).

15.2 Paso 2. Evaluación de las funciones seno y coseno

Día t	$\sin(t/1)$	$\cos(t/1)$	$\sin(t/100)$	$\cos(t/100)$
1	0.8415	0.5403	0.009999	0.99995
2	0.9093	−0.4161	0.019999	0.99980
3	0.1411	−0.9900	0.029998	0.99955
4	−0.7568	−0.6536	0.039989	0.99920
5	−0.9589	0.2837	0.049979	0.99875

(Aproximado a 5 decimales.)

Así, para $t=1$:

$$\mathrm{PE}_1 = (0.8415, 0.5403, 0.009999, 0.99995)$$

15.3 Paso 3. Suma con el vector proyectado

Tomando el vector $\mathbf{E}_1$ del bloque 1:

$$\mathbf{E}_1 = (5.15, 10.39, -3.78, 3.89)$$

sumamos componente a componente:

$$\mathbf{Z}_1 = \mathbf{E}_1 + \mathrm{PE}_1 = (5.15+0.8415, 10.39+0.5403, -3.78+0.009999, 3.89+0.99995)$$

Resultado:

$$\mathbf{Z}_1 \approx (5.99, 10.93, -3.77, 4.89)$$

16 Interpretación

- Cada vector $\mathbf{Z}_t$ contiene ahora tanto **información climática** (de $\mathbf{E}_t$) como **información temporal** (de PE_t).

- La primera pareja de seno/coseno cambia rápidamente → representa **días consecutivos**.
- La segunda pareja cambia lentamente → representa **tendencias largas o estacionales**.

Geométricamente, esto coloca cada día en un punto distinto de un “círculo de fases” en el espacio 4-dimensional.

17 Resultados esperados

1. Si graficas $\sin(t)$ y $\cos(t)$ para $t=1,\dots,365$, verás una trayectoria circular perfecta (periodicidad anual ideal).
2. Si graficas $\sin(t/100)$ y $\cos(t/100)$, obtendrás una oscilación lenta que codifica cambios de estación.
3. Al sumar $E_t + \mathrm{PE}_t$, los vectores resultantes Z_t se distribuyen de forma **ordenada en el espacio interno**, permitiendo que la siguiente etapa (atención) reconozca el orden temporal aun sin procesar secuencialmente.

18 Aprendizaje

Los valores de PE_t **no se aprenden**: son constantes deterministas.
Sin embargo, los pesos posteriores (en el bloque de atención) **aprenden a usar** esas posiciones para distinguir “quién mira a quién”.
Durante el entrenamiento, el modelo ajustará sus matrices internas de modo que, por ejemplo:

- Si el día t tiende a depender de $t-30$, los pesos aprenderán a asociar posiciones separadas por 30 unidades.
- Si las relaciones se repiten cada 365 días, el modelo reconocerá esa periodicidad por la similitud trigonométrica de las codificaciones.

19 Resumen del bloque 2

Eta ­ pa	Operación	Salida	Significado
1	Calcular seno y coseno para cada día t	PE_t	Representación temporal multiescala
2	Sumar $E_t + \mathrm{PE}_t$	Z_t	Vector enriquecido con posición
3	Usar Z_t como entrada del bloque siguiente	—	Permite distinguir orden y distancia temporal

20 Qué observar al implementarlo

Cuando los estudiantes reproduzcan los cálculos:

- **Verificar las amplitudes**: todas las componentes de PE_t están entre -1 y 1 .
- **Comprobar las escalas**: al sumarlas con E_t , los cambios son pequeños (no destruyen la información original).
- **Explorar la periodicidad**: al aumentar t hasta 365, las funciones seno/coseno deben repetir sus patrones.

21 Conclusión del bloque

Este bloque agrega al vector climático proyectado una codificación posicional que introduce **noción de orden temporal** sin necesidad de recurrencia.
De esta forma, el modelo puede captar dependencias como “días consecutivos” o “patrones estacionales” al operar en paralelo.
El resultado Z_t será la **entrada del siguiente bloque**, encargado de calcular cómo cada día “atiende” a los demás días (el bloque de atención).

22 Nota práctica

Si los cálculos se realizan mediante software (por ejemplo, R o Python):

- Los valores numéricos deben coincidir con la tabla de senos y cosenos presentada.
- El vector final para el día $t=1$ debe ser $Z_1 \approx (5.99, 10.93, -3.77, 4.89)$.
- Este vector ya contiene tanto la información climática como la posición temporal del día 1.
- **reproducir los cálculos con funciones trigonométricas básicas y verificar que los resultados sean consistentes con la tabla**

23 “Bloque 3 — Mecanismo de Atención (Self-Attention)”

24 Objetivo

Este bloque introduce el **mecanismo de atención** dentro del *Encoder Transformer*. Su propósito es permitir que **cada día** de la secuencia climática “mire” a los demás días y combine su información de forma **ponderada y dependiente del contexto**.

A diferencia de una red recurrente (RNN), que procesa secuencialmente, la atención calcula **en paralelo** todas las relaciones de influencia entre días.

25 ⚙️ Dimensiones mínimas

- **Ventana temporal:** 5 días.
- **Dimensión de representación interna:** 4.

Concepto	Símbolo	Dimensión
Entrada del bloque (día t)	Z_t	$\mathbb{R}^4$
Vector de consulta (qué busca el día t)	Q_t	$\mathbb{R}^2$
Vector de descripción (cómo se ofrece cada día)	K_t	$\mathbb{R}^2$
Vector de contenido (qué aporta cada día)	V_t	$\mathbb{R}^2$
Salida atencional (día t)	A_t	$\mathbb{R}^4$

26 Descripción general del proceso

- Cada día Z_t genera tres proyecciones lineales mediante matrices aprendibles:
 - Consulta ($Q_t = Z_t W^{\text{consulta}}$)
 - Descripción ($K_t = Z_t W^{\text{describir}}$)
 - Contenido ($V_t = Z_t W^{\text{contenido}}$)
- Se calculan **similitudes** $s_{tk} = Q_t \cdot K_k$ entre el día t y todos los días k .
- Se **normalizan** con función exponencial (*softmax*), generando ponderaciones a_{tk} .
- Se obtiene una **mezcla ponderada de los contenidos** V_k según a_{tk} .
- Finalmente se suma la entrada original Z_t (*residual*) y se normaliza (*LayerNorm*).

27 Datos iniciales

Para simplificar los cálculos, trabajamos con una mini-secuencia de cinco días con vectores de dimensión 4 (representaciones con posición temporal ya incorporada):

$$\begin{aligned} Z_1 &= (0.60, 1.10, -0.40, 0.50), \quad Z_2 = (0.50, 1.00, -0.50, 0.60), \quad Z_3 = (0.00, 0.90, -0.60, 0.70), \quad Z_4 = \\ &(-0.50, 0.60, -0.10, 0.80), \quad Z_5 = (-0.70, 0.40, 0.00, 0.90). \end{aligned}$$

(Estos valores se eligen solo para ilustrar el procedimiento.
El flujo es idéntico con los Z_t reales obtenidos en el Bloque 2.)

28 Transformaciones lineales aprendibles

Se aplican tres matrices lineales (simplificadas para este ejemplo):

$$W^{\text{consulta}} = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix}, \quad W^{\text{describir}} = W^{\text{consulta}}, \quad W^{\text{contenido}} = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix}.$$

Interpretación:

- **Consulta:** $Q_t = (z_{1t} + z_{3t}, z_{2t} + z_{4t})$
- **Descripción:** $K_t = (z_{1t} + z_{3t}, z_{2t} + z_{4t})$
- **Contenido:** $V_t = (z_{1t} + z_{2t}, z_{3t} + z_{4t})$

29 📐 Cálculo paso a paso para el día 1

29.1 1. Vectores “consulta”, “describir” y “contenido”

Para $Z_1 = (0.60, 1.10, -0.40, 0.50)$:

$$Q_1 = (0.60 + (-0.40), 1.10 + 0.50) = (0.20, 1.60)$$

Día k	$K_k^{(1)}$	$K_k^{(2)}$	$V_k^{(1)}$	$V_k^{(2)}$
1	0.20	1.60	1.70	0.10
2	0.00	1.60	1.50	0.10
3	-0.60	1.60	0.90	0.10
4	-0.60	1.40	0.10	0.70
5	-0.70	1.30	-0.30	0.90

29.2 2. Cálculo de similitudes y escala

El producto punto $s_k = Q_1 \cdot K_k$:

Día k	Cálculo	s_k
1	$0.2(0.2)+1.6(1.6)$	2.60
2	$0.2(0.0)+1.6(1.6)$	2.56
3	$0.2(-0.6)+1.6(1.6)$	2.44
4	$0.2(-0.6)+1.6(1.4)$	2.12
5	$0.2(-0.7)+1.6(1.3)$	1.94

Escalamos por $\sqrt{2} \approx 1.4142$:

$$(1.840, 1.810, 1.726, 1.499, 1.372)$$

29.3 3. Ponderaciones (softmax)

Exponenciales aproximadas:

$$(6.30, 6.11, 5.62, 4.48, 3.94)$$

Suma total ≈ 26.45

Normalización:

$$a_k = \frac{e^{s_k}}{\sum_k e^{s_k}}$$

Por tanto:

$$(a_{11}, a_{12}, a_{13}, a_{14}, a_{15}) \approx (0.238, 0.231, 0.212, 0.169, 0.149)$$

29.4 4. Mezcla de contenidos

Calculamos:

- Primera componente:** $0.238(1.70)+0.231(1.50)+0.212(0.90)+0.169(0.10)+0.149(-0.30)=0.914$
- Segunda componente:** $0.238(0.10)+0.231(0.10)+0.212(0.10)+0.169(0.70)+0.149(0.90)=0.321$

Resultado:

$$V_1 = (0.914, 0.321)$$

29.5 5. Proyección de vuelta a 4 dimensiones y suma residual

Proyección simple $\Pi(\alpha, \beta) = (\alpha, \beta, \alpha, \beta)$:

$$\Pi(V_1) = (0.914, 0.321, 0.914, 0.321)$$

Suma con la entrada original:

$$S_1 = Z_1 + \Pi(V_1) = (1.514, 1.421, 0.514, 0.821)$$

29.6 6. Normalización por capa

Promedio:

$$\mu = \frac{1.514+1.421+0.514+0.821}{4} = 1.0675$$

Desviaciones:

$\sigma = \sqrt{0.1729} = 0.4159$

Desviación estándar:

$\sigma = \sqrt{0.1729} = 0.4159$

Vector normalizado:

$Y_1 = \frac{S_1 - \mu}{\sigma} \approx (1.073, 0.850, -1.331, -0.592)$

Resultado comprobable: los estudiantes deben obtener aproximadamente este vector final.

30 Interpretación del aprendizaje

- Las tres matrices W^{consulta} , $W^{\text{describir}}$ y $W^{\text{contenido}}$ son **parámetros aprendibles**. Se ajustan durante el entrenamiento para que las **similitudes** entre días relevantes sean altas.
- Las **ponderaciones de atención** a_{tk} **no son parámetros**: se calculan **en función de la entrada actual**, por eso el modelo se adapta dinámicamente a cada secuencia climática.

31 Actividades sugeridas

- Repita el procedimiento completo para los días $t=2, \dots, 5$.
 - Calcula Q_t , los productos punto, los a_{tk} y las mezclas V'_t .
 - Compara con el patrón del día 1.
- Comprueba que las ponderaciones a_{tk} siempre suman 1.
- Observa cómo los días con características similares reciben ponderaciones más altas.
- Grafica los pesos a_{1k} (por día k) para visualizar a qué días “atiende” más el día 1.

32 Interpretación en el contexto climático

- Los productos punto altos indican **similitud entre patrones** (por ejemplo, humedad y temperatura parecidas).
- La normalización *softmax* concentra la atención en los días más relevantes.
- La salida Y_t combina información de varios días y conserva escala numérica controlada mediante normalización.
- Este bloque es el corazón del aprendizaje de dependencias **a largo plazo y en paralelo**.

33 Resultados esperados para comprobar en clase

Día t	Resultado aproximado V'_t	Resultado aproximado Y_t
1	$(0.914, 0.321)$	$(1.073, 0.850, -1.331, -0.592)$
2–5	— (se deja como ejercicio)	— (se calculará en Colab)

34 Conclusión del bloque

El **bloque de atención** permite que el modelo combine información de todo el contexto histórico sin procesar secuencialmente. Los pesos de atención se recalculan dinámicamente según las entradas, reflejando **qué días pasados son más informativos** para cada día actual.

El resultado Y_t se utiliza como entrada del **bloque siguiente**, que refina localmente la información mediante una red totalmente conectada (*feed-forward por posición*).

35 Resumen conceptual

Etap	Operación	Resultado	Significado
1	$Z_t \rightarrow (Q_t, K_t, V_t)$	Proyecciones lineales	Preparar la atención
2	$Q_t K_t^T$	Similitudes entre días	Relevancia mutua
3	Softmax	Ponderaciones a_{tk}	Pesos normalizados
4	$\sum_k a_{tk} V_k$	Mezcla de contenidos	Contexto integrado
5	Residual + Normalización	Y_t	Escala estable y salida del bloque

36 Verificación y reflexión

- **Resultado numérico clave para $t=1$:**
 $Y_1 \approx (1.073, 0.850, -1.331, -0.592)$
- **Verificación conceptual:** los pesos de atención varían según la entrada (dinámicos).
- **Reflexión:** este bloque reemplaza la necesidad de “memoria secuencial” de las RNN, utilizando geometría de vectores y proyecciones lineales.

37 “Bloque 4 — Red densa por posición y salida del Encoder Transformer”

38 Objetivo

Este bloque corresponde al **feed-forward por posición** dentro del Encoder del Transformer. Su función es **refinar localmente** la información integrada globalmente por la atención. Cada vector de un día se transforma mediante una pequeña red densa, sin interacción con los otros días. Finalmente se muestra cómo se obtiene la **salida total del Encoder**, lista para una capa final de predicción.

39 Dimensiones mínimas

- **Ventana temporal:** 5 días.
- **Dimensión interna (entrada/salida):** 4.
- **Capa oculta intermedia:** 3 unidades.
- **Activación:** ReLU.

Etap	Entrada	Salida	Operación
Capa 1	$\mathbb{R}^4$	$\mathbb{R}^3$	Lineal + ReLU
Capa 2	$\mathbb{R}^3$	$\mathbb{R}^4$	Lineal
Residual + Normalización	$\mathbb{R}^4$	$\mathbb{R}^4$	Estabilización

40 Datos de entrada

Usaremos como entrada el resultado del bloque de atención para el día 1:
 $Y_1 = (1.073, 0.850, -1.331, -0.592)$

41 Primera capa (4 → 3)

Matriz de pesos y sesgo:
 $W^{(1)} = \begin{pmatrix} 0.5 & -0.2 & 0.1 \\ 0.3 & 0.4 & -0.1 \\ -0.4 & 0.2 & 0.5 \\ 0.2 & -0.3 & 0.2 \end{pmatrix}, \quad b^{(1)} = \begin{pmatrix} 0.1 \\ 0.0 \\ -0.05 \end{pmatrix}$
Cálculo:
 $z^{(1)} = Y_1 W^{(1)} + b^{(1)} \rightarrow z^{(1)} \approx (1.3055, 0.0368, -0.8116)$
Aplicamos ReLU (máximo entre 0 y el valor):
 $a^{(1)} = \max(0, z^{(1)}) = (1.3055, 0.0368, 0.0)$

Resultado a comprobar: $a^{(1)} \approx (1.3055, 0.0368, 0.0)$

42 Segunda capa (3 → 4)

Matriz y sesgo:
 $W^{(2)} = \begin{pmatrix} 0.6 & -0.1 & 0.2 & 0.0 \\ -0.2 & 0.5 & 0.1 & 0.3 \\ 0.4 & 0.0 & -0.3 & 0.2 \end{pmatrix}, \quad b^{(2)} = \begin{pmatrix} 0.05 \\ 0.0 \\ 0.02 \\ -0.01 \end{pmatrix}$
Cálculo:
 $o^{(2)} = a^{(1)} W^{(2)} + b^{(2)} \rightarrow o^{(2)} \approx (0.82594, -0.11215, 0.28478, 0.00104)$

Resultado a comprobar: $\sigma^2 \approx (0.82594, -0.11215, 0.28478, 0.00104)$

43 Suma residual y normalización

Suma con la entrada original:

$$R_1 = Y_1 + o^2 = (1.89894, 0.73785, -1.04622, -0.59096)$$

Media y desviación estándar:

$$\mu = \frac{1.514 + 1.421 + 0.514 + 0.821}{4} = 0.24990, \quad \sigma = 1.15590$$

Normalizamos:

$$U_1 = \frac{R_1 - \mu}{\sigma} \approx (1.4266, 0.4221, -1.1213, -0.7275)$$

Resultado a comprobar:

$$R_1 \approx (1.89894, 0.73785, -1.04622, -0.59096)$$

$$\mu \approx 0.24990, \quad \sigma \approx 1.15590$$

$$U_1 \approx (1.4266, 0.4221, -1.1213, -0.7275)$$

44 Salida del Encoder y cabeza final

Después de aplicar el bloque a cada día $(t=1, \dots, 5)$, el encoder devuelve la secuencia $(U_1, \dots, U_5)$.

44.1 1. Agregación temporal

Promedio (pooling por media):

$$h_{\text{salida}} = \frac{1}{L} \sum_{t=1}^L U_t$$

(Los estudiantes pueden completar los cálculos para $(t=2)$ a $(t=5)$ y obtener el promedio.)

44.2 2. Capa lineal final (ejemplo ilustrativo)

Usamos pesos finales y sesgo:

$$w_{\text{fin}} = (0.7, -0.2, 0.4, 0.1), \quad b_{\text{fin}} = 0.05$$

Predicción escalar:

$$\widehat{y} = w_{\text{fin}} \cdot U_1 + b_{\text{fin}} \approx 0.443$$

Resultado a comprobar: $\widehat{y} \approx 0.443$

45 Interpretación del aprendizaje

- Este bloque **refina** la información ya integrada por la atención.
- Cada día se transforma de forma **independiente** por una red densa local.
- Las **matrices y sesgos** de las capas se **aprenden** para mejorar la capacidad de representación.
- La **suma residual** conserva información original si la red no aporta mejora inmediata.
- La **normalización** estabiliza el rango de valores.

46 Actividades de verificación

1. Repetir el procedimiento completo para los días $(t=2, \dots, 5)$.
2. Calcular el promedio temporal h_{salida} .
3. Obtener la predicción escalar $\widehat{y}$ con h_{salida} y comparar con el resultado usando solo U_1 .
4. Explorar cómo pequeños cambios en $W^{(1)}$ o $W^{(2)}$ modifican la salida U_1 .

47 Resultados esperados (día 1)

Cálculo	Resultado
$a^{(1)}$	$(1.3055, 0.0368, 0.0)$

σ^2	$(0.82594, -0.11215, 0.28478, 0.00104)$
U_1	$(1.4266, 0.4221, -1.1213, -0.7275)$
$\widehat{y}$	0.443

48 Conclusión

El **feed-forward por posición** actúa como una mini-red neuronal aplicada a cada día por separado. Combinado con la suma residual y la normalización, este bloque:

- Aumenta la capacidad no lineal del encoder.
- Estabiliza los gradientes y magnitudes.
- Produce representaciones internas U_t listas para tareas de predicción.

La salida final $\widehat{y}$ representa la estimación del modelo sobre la variable climática futura o el valor que se desee pronosticar.

49 Resumen conceptual del Bloque 4

Etap	Operación	Resultado (día 1)	Interpretación
1	$Y_1 W^1 + b^1$, ReLU	$(1.3055, 0.0368, 0.0)$	Transformación no lineal
2	$a^1 W^2 + b^2$	$(0.82594, -0.11215, 0.28478, 0.00104)$	Salida densa
3	Residual + Normalización	$(1.4266, 0.4221, -1.1213, -0.7275)$	Escala estabilizada
4	Capa final $w_{\text{fin}} \cdot U_1 + b_{\text{fin}}$	$\widehat{y} \approx 0.443$	Predicción ilustrativa

50 Reflexión final

El **Encoder Transformer mínimo** queda conformado por:

1. **Proyección de entrada:** transforma las variables originales.
2. **Codificación posicional:** añade información de orden temporal.
3. **Mecanismo de atención:** integra dependencias globales.
4. **Feed-forward por posición:** refina localmente la información.

Cada bloque contribuye a que el modelo aprenda dependencias de corto y largo alcance de las variables climáticas.