

Estructura de un Encoder Transformer

Guía de estudio paso a paso con una secuencia climática

FCFM–UNACH

Licenciatura en Matemáticas Aplicadas

Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de la guía	3
2. Mapa general del encoder	3
3. Bloque 1. Proyección de entrada	4
3.1. Objetivo del bloque	4
3.2. Dimensiones	4
3.3. Interpretación conceptual	4
3.4. Ejemplo numérico	5
3.5. Una ventana completa	5
4. Bloque 2. Codificación posicional	6
4.1. ¿Por qué hace falta posición?	6
4.2. Codificación sinusoidal	6
4.3. Valores para cinco posiciones	6
4.4. Interpretación	7
4.5. Parámetros aprendibles	7
5. Bloque 3. Self-Attention	7
5.1. Objetivo	7
5.2. Interpretación de Q , K y V	8
5.3. Datos simplificados	8
5.4. Consulta del día 1	9
5.5. Similitudes	9
5.6. ¿Por qué escalar?	10
5.7. Softmax	10
5.8. Mezcla de contenidos	10
5.9. Proyección de regreso	10
5.10. Conexión residual	11
5.11. Layer Normalization	11
5.12. Qué se aprende	11
6. Bloque 4. Feed-forward por posición	12
6.1. Objetivo	12
6.2. Arquitectura	12
6.3. Primera capa	12
6.4. Segunda capa	13
6.5. Segunda conexión residual	13
6.6. Interpretación	13

7. Salida completa del encoder	13
7.1. Pooling temporal	14
7.2. Cabeza de predicción	14
8. Resumen dimensional completo	14
9. Qué parámetros aprende el modelo	15
10. Qué observar durante el aprendizaje	15
10.1. Representaciones	16
10.2. Atención	16
10.3. Predicción	16
11. Preguntas de autoevaluación	16
12. Ejercicios propuestos	17
13. Actividad integradora	17
14. Ideas esenciales para recordar	18
15. Bibliografía recomendada	18

1. Propósito de la guía

El Transformer puede parecer una arquitectura complicada cuando se presenta de una sola vez. Una estrategia más útil para estudiantes de Matemáticas Aplicadas consiste en descomponerlo en bloques y seguir cuidadosamente qué transformación matemática realiza cada uno.

En esta guía se utiliza una secuencia climática sencilla,

$$X_t = (T_t, H_t, P_t) \in \mathbb{R}^3,$$

donde T_t representa temperatura, H_t humedad y P_t precipitación.

A partir de esa entrada se construirá, paso a paso, una versión mínima de un encoder Transformer:

$$X_t \longrightarrow E_t \longrightarrow Z_t \longrightarrow Y_t \longrightarrow U_t \longrightarrow \hat{y}$$

Cada flecha representa una transformación matemática distinta.

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Explicar la función de la proyección de entrada.
2. Calcular una codificación posicional sinusoidal.
3. Construir vectores Q , K y V .
4. Calcular productos punto, escalamiento y softmax.
5. Interpretar los pesos de atención.
6. Explicar la función de la conexión residual y LayerNorm.
7. Desarrollar una red feed-forward por posición.
8. Reconstruir el flujo completo de un encoder Transformer mínimo.
9. Distinguir entre parámetros aprendibles y cantidades calculadas dinámicamente.

2. Mapa general del encoder

Antes de realizar cálculos conviene visualizar la arquitectura completa.

Para cada día t :

$$X_t \in \mathbb{R}^3$$

se proyecta a

$$E_t \in \mathbb{R}^4.$$

Después se añade información temporal:

$$Z_t = E_t + \text{PE}_t.$$

Sobre la secuencia

$$(Z_1, \dots, Z_L)$$

se calcula self-attention, produciendo una nueva representación

$$Y_t \in \mathbb{R}^4.$$

Finalmente, una red densa por posición transforma

$$Y_t \longrightarrow U_t.$$

La secuencia

$$(U_1, \dots, U_L)$$

puede agregarse y pasar a una capa final de predicción.

Interpretación

El encoder no realiza una única transformación grande. Está construido como una composición de transformaciones pequeñas, cada una con un objetivo bien definido.

3. Bloque 1. Proyección de entrada

3.1. Objetivo del bloque

La observación climática original tiene dimensión tres:

$$X_t = (T_t, H_t, P_t) \in \mathbb{R}^3.$$

El Transformer trabaja internamente en una dimensión común d . En este ejemplo utilizaremos

$$d = 4.$$

Por ello se introduce una transformación afín:

$$E_t = W_{\text{in}} X_t + b_{\text{in}}, \tag{1}$$

con

$$W_{\text{in}} \in \mathbb{R}^{4 \times 3}, \quad b_{\text{in}} \in \mathbb{R}^4.$$

3.2. Dimensiones

Concepto	Símbolo	Dimensión
Entrada climática	X_t	$\mathbb{R}^3$
Matriz de pesos	W_{in}	4×3
Sesgo	b_{in}	$\mathbb{R}^4$
Representación interna	E_t	$\mathbb{R}^4$

3.3. Interpretación conceptual

Cada fila de W_{in} define una combinación lineal distinta de temperatura, humedad y precipitación.

Por ello,

$$E_t = (e_{t,1}, e_{t,2}, e_{t,3}, e_{t,4})$$

puede verse como un conjunto de cuatro características internas aprendidas.

Punto de atención

En una implementación real no debemos asignar de antemano un significado físico exacto a cada componente de E_t . Su interpretación puede explorarse después del entrenamiento, pero matemáticamente son combinaciones aprendidas.

3.4. Ejemplo numérico

Tomemos

$$X_1 = (25, 0.7, 3).$$

El material base utiliza

$$W_{\text{in}} = \begin{pmatrix} 0.2 & 0.5 & -0.1 \\ 0.4 & -0.3 & 0.2 \\ -0.2 & 0.6 & 0.3 \\ 0.1 & 0.2 & 0.4 \end{pmatrix}, \quad b_{\text{in}} = \begin{pmatrix} 0.1 \\ 0 \\ -0.1 \\ 0.05 \end{pmatrix}.$$

Entonces,

$$E_1 = W_{\text{in}}X_1 + b_{\text{in}}.$$

La primera componente es

$$0.2(25) + 0.5(0.7) - 0.1(3) + 0.1 = 5.15.$$

La segunda:

$$0.4(25) - 0.3(0.7) + 0.2(3) = 10.39.$$

La tercera:

$$-0.2(25) + 0.6(0.7) + 0.3(3) - 0.1 = -3.78.$$

La cuarta:

$$0.1(25) + 0.2(0.7) + 0.4(3) + 0.05 = 3.89.$$

Por tanto,

$$E_1 = (5.15, 10.39, -3.78, 3.89). \quad (2)$$

3.5. Una ventana completa

Para una ventana de cinco días,

$$L = 5,$$

se obtiene

$$E = \begin{pmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \\ E_5 \end{pmatrix} \in \mathbb{R}^{5 \times 4}.$$

Cada fila representa un día y cada columna una característica interna.

Conexión entre bloques

El Bloque 1 sólo transforma el *contenido*. Todavía no indica al modelo cuál fila corresponde al primer, segundo o quinto día. Esa información se introduce en el Bloque 2.

Actividad para el estudiante

Repita el cálculo de (2) cambiando únicamente la precipitación de 3 a 0. Identifique qué componentes de E_1 cambian más.

4. Bloque 2. Codificación posicional

4.1. ¿Por qué hace falta posición?

La autoatención procesa la secuencia en paralelo. Por ello es necesario introducir explícitamente información que permita distinguir posiciones.

La idea es construir

$$Z_t = E_t + \text{PE}_t, \quad (3)$$

donde

$$E_t \in \mathbb{R}^4, \quad \text{PE}_t \in \mathbb{R}^4.$$

La suma conserva la dimensión interna.

4.2. Codificación sinusoidal

Para una dimensión d , el material utiliza

$$\begin{aligned} \text{PE}(t, 2i) &= \sin\left(\frac{t}{10000^{2i/d}}\right), \\ \text{PE}(t, 2i+1) &= \cos\left(\frac{t}{10000^{2i/d}}\right). \end{aligned}$$

Con

$$d = 4,$$

tenemos dos escalas:

$$10000^0 = 1, \quad 10000^{1/2} = 100.$$

Por tanto,

$$\text{PE}_t = (\sin t, \cos t, \sin(t/100), \cos(t/100)).$$

4.3. Valores para cinco posiciones

t	$\sin t$	$\cos t$	$\sin(t/100)$	$\cos(t/100)$
1	0.8415	0.5403	0.009999	0.99995
2	0.9093	-0.4161	0.019999	0.99980
3	0.1411	-0.9900	0.029998	0.99955
4	-0.7568	-0.6536	0.039989	0.99920
5	-0.9589	0.2837	0.049979	0.99875

Para $t = 1$,

$$\text{PE}_1 = (0.8415, 0.5403, 0.009999, 0.999995).$$

Usando (2),

$$Z_1 = E_1 + \text{PE}_1,$$

y por tanto

$$Z_1 \approx (5.99, 10.93, -3.77, 4.89).$$

4.4. Interpretación

La representación Z_t contiene dos tipos de información:

$$\underbrace{E_t}_{\text{contenido}} + \underbrace{\text{PE}_t}_{\text{posición}}.$$

Las componentes sinusoidales cambian a distintas escalas y proporcionan señales posicionales multiescala.

Punto de atención

Las funciones seno y coseno codifican posición; no garantizan por sí mismas que exista una periodicidad climática concreta de 30, 90 o 365 días. El modelo aprende posteriormente qué relaciones posicionales son útiles para la tarea.

4.5. Parámetros aprendibles

En la codificación sinusoidal clásica,

$$\text{PE}_t$$

no se entrena.

Sin embargo, las matrices de atención posteriores sí se entrenan y pueden aprender a explotar esta información.

Conexión entre bloques

El Bloque 2 produce Z_t . Ahora cada día contiene contenido y posición. El Bloque 3 utilizará estos vectores para calcular relaciones entre todos los días de la ventana.

Actividad para el estudiante

Compruebe que todas las componentes de PE_t permanecen en $[-1, 1]$. Explique por qué la suma (3) no cambia la dimensión del vector.

5. Bloque 3. Self-Attention

5.1. Objetivo

La atención permite que cada día combine información de todos los demás días de la ventana. Partimos de

$$Z_t \in \mathbb{R}^4.$$

Para cada posición se construyen tres vectores:

$$Q_t, \quad K_t, \quad V_t.$$

En el ejemplo,

$$Q_t, K_t, V_t \in \mathbb{R}^2.$$

5.2. Interpretación de Q , K y V

Podemos usar la analogía:

- Q_t : qué información busca el día t ;
- K_k : cómo se describe el día k ;
- V_k : qué contenido aporta el día k .

Las proyecciones son lineales:

$$Q = ZW_Q, \quad K = ZW_K, \quad V = ZW_V.$$

Las matrices W_Q, W_K, W_V son parámetros aprendibles.

5.3. Datos simplificados

El material utiliza

$$\begin{aligned} Z_1 &= (0.60, 1.10, -0.40, 0.50), \\ Z_2 &= (0.50, 1.00, -0.50, 0.60), \\ Z_3 &= (0.00, 0.90, -0.60, 0.70), \\ Z_4 &= (-0.50, 0.60, -0.10, 0.80), \\ Z_5 &= (-0.70, 0.40, 0.00, 0.90). \end{aligned}$$

Para simplificar,

$$W_Q = W_K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix},$$

y

$$W_V = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Por tanto,

$$Q_t = (z_1 + z_3, z_2 + z_4),$$

$$K_t = (z_1 + z_3, z_2 + z_4),$$

$$V_t = (z_1 + z_4, z_2 + z_3)$$

si se sigue literalmente la multiplicación matricial anterior.

Punto de atención

En el material fuente se proporciona también una interpretación verbal específica de las componentes de V_t . Para el estudio autónomo conviene verificar siempre las proyecciones mediante multiplicación matricial y no sólo a partir de una descripción verbal.

5.4. Consulta del día 1

Para

$$Z_1 = (0.60, 1.10, -0.40, 0.50),$$

se obtiene

$$Q_1 = (0.20, 1.60).$$

El material base utiliza la siguiente tabla para K_k y V_k :

Día k	$K_k^{(1)}$	$K_k^{(2)}$	$V_k^{(1)}$	$V_k^{(2)}$
1	0.20	1.60	1.70	0.10
2	0.00	1.60	1.50	0.10
3	-0.60	1.60	0.90	0.10
4	-0.60	1.40	0.10	0.70
5	-0.70	1.30	-0.30	0.90

5.5. Similitudes

La similitud entre la consulta del día 1 y la clave del día k es

$$s_{1k} = Q_1 K_k^\top.$$

Los valores son

$$(2.60, 2.56, 2.44, 2.12, 1.94).$$

En scaled dot-product attention se divide entre

$$\sqrt{d_k}.$$

Como

$$d_k = 2,$$

obtenemos aproximadamente

$$(1.840, 1.810, 1.726, 1.499, 1.372).$$

5.6. ¿Por qué escalar?

El producto punto tiende a crecer con la dimensión de Q y K .
La división por

$$\sqrt{d_k}$$

ayuda a evitar valores demasiado grandes antes de aplicar softmax.

5.7. Softmax

Los pesos se calculan mediante

$$a_{1k} = \frac{\exp(s_{1k}/\sqrt{d_k})}{\sum_j \exp(s_{1j}/\sqrt{d_k})}. \quad (4)$$

El material obtiene aproximadamente

$$(a_{11}, a_{12}, a_{13}, a_{14}, a_{15}) = (0.238, 0.231, 0.212, 0.169, 0.149).$$

Debe verificarse que

$$\sum_{k=1}^5 a_{1k} \approx 1.$$

Interpretación

Los pesos de atención no son parámetros fijos. Se recalculan para cada secuencia a partir de Q y K .

5.8. Mezcla de contenidos

La salida de atención para el día 1 es

$$V'_1 = \sum_{k=1}^5 a_{1k} V_k. \quad (5)$$

El material base obtiene

$$V'_1 \approx (0.914, 0.321).$$

Este vector resume información de los cinco días, ponderada de acuerdo con la atención.

5.9. Proyección de regreso

Como la representación interna del encoder tiene dimensión cuatro, se introduce una proyección de salida.

En el ejemplo se utiliza

$$\Pi(\alpha, \beta) = (\alpha, \beta, \alpha, \beta).$$

Por tanto,

$$\Pi(V'_1) = (0.914, 0.321, 0.914, 0.321).$$

5.10. Conexión residual

La salida proyectada se suma a la entrada:

$$S_1 = Z_1 + \Pi(V'_1).$$

Se obtiene

$$S_1 = (1.514, 1.421, 0.514, 0.821).$$

La conexión residual permite que el bloque aprenda una corrección sobre la representación existente.

5.11. Layer Normalization

Se calcula la media de las componentes:

$$\mu = \frac{1}{4} \sum_{j=1}^4 S_{1j}.$$

El material base obtiene

$$\mu = 1.0675.$$

Después se normaliza:

$$Y_1 = \frac{S_1 - \mu}{\sigma}.$$

El resultado proporcionado es

$$Y_1 \approx (1.073, 0.850, -1.331, -0.592). \quad (6)$$

Punto de atención

En implementaciones reales, LayerNorm incluye típicamente parámetros aprendibles de escala y desplazamiento, además de un pequeño ε numérico.

5.12. Qué se aprende

Son aprendibles:

$$W_Q, \quad W_K, \quad W_V,$$

y, en un Transformer completo, también la proyección de salida.

En cambio, los pesos

$$a_{tk}$$

se calculan dinámicamente.

Conexión entre bloques

La atención ya mezcló información entre días. El siguiente bloque no volverá a mezclar posiciones: aplicará la misma red densa a cada día por separado.

Actividad para el estudiante

Repita el cálculo para $t = 2$: obtenga Q_2 , sus cinco similitudes y los pesos a_{2k} . Verifique que sumen uno.

6. Bloque 4. Feed-forward por posición

6.1. Objetivo

El bloque feed-forward introduce capacidad no lineal adicional.
Se aplica independientemente a cada posición:

$$Y_t \longrightarrow U_t.$$

No hay mezcla entre días dentro de esta subred.

6.2. Arquitectura

El ejemplo utiliza

$$\mathbb{R}^4 \longrightarrow \mathbb{R}^3 \longrightarrow \mathbb{R}^4.$$

La primera capa aplica una transformación lineal seguida de ReLU:

$$z^{(1)} = Y_t W^{(1)} + b^{(1)},$$

$$a^{(1)} = \text{ReLU}(z^{(1)}).$$

La segunda capa es lineal:

$$o^{(2)} = a^{(1)} W^{(2)} + b^{(2)}.$$

6.3. Primera capa

Para el día 1 se usa (6):

$$Y_1 = (1.073, 0.850, -1.331, -0.592).$$

El material proporciona

$$W^{(1)} = \begin{pmatrix} 0.5 & -0.2 & 0.1 \\ 0.3 & 0.4 & -0.1 \\ -0.4 & 0.2 & 0.5 \\ 0.2 & -0.3 & 0.2 \end{pmatrix},$$

$$b^{(1)} = (0.1, 0, -0.05).$$

Se obtiene

$$z^{(1)} \approx (1.3055, 0.0368, -0.8116).$$

Después,

$$a^{(1)} = \text{ReLU}(z^{(1)}) \approx (1.3055, 0.0368, 0).$$

6.4. Segunda capa

Se utiliza

$$W^{(2)} = \begin{pmatrix} 0.6 & -0.1 & 0.2 & 0 \\ -0.2 & 0.5 & 0.1 & 0.3 \\ 0.4 & 0 & -0.3 & 0.2 \end{pmatrix},$$

y

$$b^{(2)} = (0.05, 0, 0.02, -0.01).$$

Entonces

$$o^{(2)} \approx (0.82594, -0.11215, 0.28478, 0.00104).$$

6.5. Segunda conexión residual

Se suma la entrada Y_1 :

$$R_1 = Y_1 + o^{(2)}.$$

El material base obtiene

$$R_1 \approx (1.89894, 0.73785, -1.04622, -0.59096).$$

Después de normalización, se reporta

$$U_1 \approx (1.4266, 0.4221, -1.1213, -0.7275). \quad (7)$$

6.6. Interpretación

El bloque feed-forward:

- transforma cada posición por separado;
- introduce no linealidad mediante ReLU;
- conserva información mediante la conexión residual;
- estabiliza la escala mediante normalización.

Interpretación

La atención responde a “de qué posiciones debo tomar información”. El feed-forward responde a “cómo debo transformar la representación de cada posición después de haber integrado contexto”.

7. Salida completa del encoder

Después de procesar todos los días:

$$(U_1, U_2, U_3, U_4, U_5).$$

Esta secuencia constituye la salida del encoder.

Para una tarea de predicción escalar puede aplicarse una agregación.

7.1. Pooling temporal

Una opción es la media:

$$h_{\text{salida}} = \frac{1}{L} \sum_{t=1}^L U_t. \quad (8)$$

Esto transforma

$$\mathbb{R}^{L \times d}$$

en

$$\mathbb{R}^d.$$

7.2. Cabeza de predicción

Una salida escalar puede escribirse como

$$\hat{y} = w_{\text{fin}}^\top h_{\text{salida}} + b_{\text{fin}}.$$

El material presenta como ejemplo

$$w_{\text{fin}} = (0.7, -0.2, 0.4, 0.1), \quad b_{\text{fin}} = 0.05.$$

También se muestra una predicción ilustrativa usando U_1 :

$$\hat{y} = w_{\text{fin}}^\top U_1 + b_{\text{fin}} \approx 0.443.$$

Punto de atención

Usar sólo U_1 y usar el vector agregado h_{salida} son dos cabezas diferentes. Para una implementación debe decidirse explícitamente cuál será la estrategia de lectura.

8. Resumen dimensional completo

Para una ventana de

$$L = 5$$

y dimensión interna

$$d = 4,$$

el flujo es:

Etapa	Objeto	Dimensión
Datos originales	X	5×3
Proyección	E	5×4
Posición	Z	5×4
Consultas	Q	5×2
Claves	K	5×2
Valores	V	5×2
Matriz de atención	A	5×5
Salida atención	Y	5×4
Feed-forward	U	5×4
Pooling	h_{salida}	$\mathbb{R}^4$
Predicción	$\hat{y}$	$\mathbb{R}$

Interpretación

Seguir las dimensiones es una de las formas más efectivas de comprender un Transformer. Antes de realizar cualquier producto matricial, debe verificarse que las dimensiones sean compatibles.

9. Qué parámetros aprende el modelo

En este encoder mínimo, los parámetros aprendibles incluyen:

$$W_{\text{in}}, \quad b_{\text{in}},$$

$$W_Q, \quad W_K, \quad W_V,$$

$$W^{(1)}, \quad b^{(1)}, \quad W^{(2)}, \quad b^{(2)},$$

y la cabeza final

$$w_{\text{fin}}, \quad b_{\text{fin}}.$$

En una implementación completa se añaden además parámetros de proyección de salida y de LayerNorm.

No son parámetros entrenados:

$$a_{tk},$$

porque dependen de la entrada, ni

$$\text{PE}_t$$

cuando se usa codificación sinusoidal fija.

10. Qué observar durante el aprendizaje

Durante el entrenamiento es útil distinguir tres niveles.

10.1. Representaciones

Los vectores

$$E_t, \quad Z_t, \quad Y_t, \quad U_t$$

cambian a medida que cambian los parámetros.

10.2. Atención

La matriz

$$A = [a_{tk}]$$

cambia tanto con los parámetros como con cada secuencia.

10.3. Predicción

La cabeza final transforma las representaciones aprendidas en la variable objetivo.

Conexión entre bloques

El entrenamiento no aprende “la matriz de atención” directamente. Aprende proyecciones W_Q, W_K, W_V que determinan, junto con la entrada, las matrices de atención que aparecerán.

11. Preguntas de autoevaluación

1. ¿Por qué es necesaria una proyección de $\mathbb{R}^3$ a $\mathbb{R}^4$?
2. ¿Qué diferencia existe entre E_t y Z_t ?
3. ¿Qué información introduce PE_t ?
4. ¿Qué dimensiones tienen Q , K y V ?
5. ¿Qué representa el producto
$$Q_t K_k^\top?$$
6. ¿Por qué se divide entre $\sqrt{d_k}$?
7. ¿Qué propiedad garantiza softmax sobre los pesos?
8. ¿Por qué a_{tk} no es un parámetro fijo?
9. ¿Qué función cumple una conexión residual?
10. ¿Qué diferencia existe entre self-attention y feed-forward por posición?
11. ¿Qué objetos se transforman de forma independiente para cada día?
12. ¿Qué opciones existen para obtener una única predicción a partir de $U_1, \dots, U_L$?

12. Ejercicios propuestos

Ejercicio 1. Proyección.

Repita el Bloque 1 con

$$X = (28, 0.6, 0).$$

Ejercicio 2. Posición.

Calcule

$$\text{PE}_2, \quad \text{PE}_3$$

para $d = 4$.

Ejercicio 3. Suma contenido–posición.

Dados E_2 y PE_2 , obtenga Z_2 .

Ejercicio 4. Consulta.

Calcule Q_2 para los valores de Z_2 del Bloque 3.

Ejercicio 5. Softmax.

Verifique numéricamente que

$$\sum_{k=1}^5 a_{1k} \approx 1.$$

Ejercicio 6. Atención.

Obtenga manualmente V'_2 .

Ejercicio 7. Residual.

Explique por qué la suma residual requiere que la proyección de atención vuelva a dimensión cuatro.

Ejercicio 8. ReLU.

Compruebe que

$$\text{ReLU}(-0.8116) = 0.$$

Ejercicio 9. Feed-forward.

Calcule $z^{(1)}$ para otro vector Y_t .

Ejercicio 10. Dimensiones.

Construya una tabla de dimensiones si

$$L = 10, \quad d = 8, \quad d_k = 4.$$

13. Actividad integradora

Utilice una ventana de tres días y construya manualmente un encoder reducido.

Debe definir:

1. tres vectores

$$X_1, X_2, X_3 \in \mathbb{R}^3;$$

2. una matriz

$$W_{\text{in}};$$

3. la proyección

$$E_t;$$

4. una codificación posicional;
5. matrices W_Q, W_K, W_V ;
6. la matriz completa de atención

$$A \in \mathbb{R}^{3 \times 3};$$

7. una salida residual;
8. una red feed-forward simple;
9. una predicción escalar.

El objetivo es reconstruir todo el flujo:

$$X \rightarrow E \rightarrow Z \rightarrow (Q, K, V) \rightarrow A \rightarrow Y \rightarrow U \rightarrow \hat{y}.$$

14. Ideas esenciales para recordar

- La proyección de entrada lleva todas las variables a una dimensión interna común.
- La codificación posicional introduce información de orden.
- Q, K y V son proyecciones distintas de la misma representación.
- La atención se calcula dinámicamente a partir de similitudes.
- Softmax convierte similitudes en pesos normalizados.
- Las conexiones residuales preservan información de la representación anterior.
- LayerNorm estabiliza la escala de activaciones.
- El feed-forward actúa por posición y añade no linealidad.
- El encoder devuelve una representación por cada posición.
- La cabeza final decide cómo convertir esas representaciones en una predicción.

15. Bibliografía recomendada

Referencias

- [1] A. Vaswani et al., “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, 2017.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.
- [3] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.