

Arquitectura y ciclo de aprendizaje de un Transformer

Del forward pass a la retropropagación

FCFM–UNACH

Licenciatura en Matemáticas Aplicadas

Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. 1. Visión global del ciclo	3
3. 2. Entrada: datos climáticos	4
4. 3. Bloque 1: proyección de entrada	4
4.1. Qué hace este bloque	4
4.2. Qué se aprende	4
5. 4. Bloque 2: codificación posicional	5
6. 5. Bloque 3: mecanismo de atención	5
6.1. Interpretación	5
7. 6. Similitud entre posiciones	5
8. 7. Pesos de atención	6
9. 8. Combinación ponderada de contenidos	6
10.9. Proyección, residual y normalización	6
10.1. Conexión residual	7
10.2. Normalización	7
11.10. Resultado del bloque de atención	7
12.11. Bloque 4: Feed-Forward por posición	7
13.12. Segunda conexión residual	7
14.13. Qué aprende el Feed-Forward	8
15.14. Bloque 5: agregación temporal	8
16.15. Capa de salida	8
17.16. Función de pérdida	8
18.17. Resumen del Forward Pass	9

19.18. Retropropagación	10
20.19. Regla de la cadena	10
21.20. Actualización de pesos	11
22.21. Qué significa aprender	11
23.22. Parámetros aprendibles y cantidades dinámicas	11
24.23. Mapa dimensional recomendado	11
25.24. Preguntas de autoevaluación	12
26.25. Ejercicios propuestos	13
27.26. Actividad integradora	14
28.27. Ideas esenciales para recordar	14
29.28. Bibliografía recomendada	15

1. Propósito de esta guía

Comprender la arquitectura de un Transformer requiere distinguir dos procesos complementarios:

1. la **propagación hacia adelante** o *forward pass*, en la que los datos atraviesan los bloques de la red hasta producir una predicción;
2. la **retropropagación** o *backward pass*, en la que se calcula cómo cada parámetro contribuye al error y se actualizan los pesos.

Esta guía sigue el esquema del material base utilizando una secuencia climática

$$X_t = (T_t, H_t, P_t),$$

y desarrolla el flujo completo:

$$X_t \longrightarrow E_t \longrightarrow Z_t \longrightarrow \text{Atención} \longrightarrow Y_t \longrightarrow U_t \longrightarrow \hat{y} \longrightarrow \mathcal{L}.$$

Después se recorre el camino inverso:

$$\mathcal{L} \longrightarrow \nabla_W \mathcal{L} \longrightarrow \text{actualización de pesos}.$$

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Identificar los bloques principales del encoder Transformer.
2. Explicar qué entra y qué sale de cada bloque.
3. Distinguir parámetros aprendibles de cantidades calculadas dinámicamente.
4. Interpretar Query, Key y Value dentro de la atención.
5. Explicar la función de las conexiones residuales y la normalización.
6. Describir el papel del feed-forward por posición.
7. Formular una cabeza de salida para regresión.
8. Relacionar la función de pérdida con los gradientes de cada bloque.
9. Interpretar el descenso de gradiente como mecanismo de aprendizaje.

2. 1. Visión global del ciclo

Un Transformer entrenable puede entenderse como una función parametrizada

$$\hat{y} = f_W(X),$$

donde W representa todos los pesos y sesgos de la arquitectura.

El aprendizaje consiste en encontrar valores de W que reduzcan una pérdida

$$\mathcal{L}(W).$$

Por tanto, el proceso completo se divide en:

Forward pass $\longrightarrow$ Pérdida $\longrightarrow$ Backward pass $\longrightarrow$ Actualización

Interpretación

La arquitectura describe cómo se calcula la predicción. El algoritmo de entrenamiento describe cómo se modifican sus parámetros.

3. 2. Entrada: datos climáticos

Cada observación diaria se representa como

$$X_t = (T_t, H_t, P_t).$$

Para una ventana de longitud L ,

$$X = (X_1, \dots, X_L).$$

Cada X_t pertenece a

$$\mathbb{R}^3.$$

El encoder no trabaja directamente en esta dimensión física, sino que transforma cada observación a una representación interna.

4. 3. Bloque 1: proyección de entrada

La primera transformación es

$$E_t = X_t W_{\text{in}} + b_{\text{in}}. \quad (1)$$

Si la dimensión interna es d ,

$$W_{\text{in}} \in \mathbb{R}^{3 \times d}, \quad b_{\text{in}} \in \mathbb{R}^d,$$

y

$$E_t \in \mathbb{R}^d.$$

4.1. Qué hace este bloque

Transforma las variables físicas en una representación interna común.

Cada componente de E_t es una combinación lineal aprendida de temperatura, humedad y precipitación.

4.2. Qué se aprende

Son parámetros aprendibles:

$$W_{\text{in}}, \quad b_{\text{in}}.$$

Conexión entre bloques

Después de esta transformación, la red ya dispone de una representación del contenido, pero todavía no conoce la posición temporal de cada observación.

5. 4. Bloque 2: codificación posicional

Se añade información de orden mediante

$$Z_t = E_t + \text{PE}_t. \quad (2)$$

En el material base se utiliza un positional encoding sinusoidal.

En ese caso,

$$\text{PE}_t$$

no contiene pesos aprendibles.

Interpretación

E_t describe qué contiene la observación; PE_t indica dónde aparece dentro de la secuencia.

6. 5. Bloque 3: mecanismo de atención

A partir de cada Z_t se construyen tres proyecciones:

$$Q_t = Z_t W_{\text{consulta}}, \quad (3)$$

$$K_t = Z_t W_{\text{describir}}, \quad (4)$$

$$V_t = Z_t W_{\text{contenido}}. \quad (5)$$

Estas matrices corresponden a Query, Key y Value.

6.1. Interpretación

- Q_t : qué información busca la posición t ;
- K_k : cómo se describe la posición k ;
- V_k : qué contenido aporta la posición k .

Los pesos

$$W_{\text{consulta}}, \quad W_{\text{describir}}, \quad W_{\text{contenido}}$$

son parámetros aprendibles.

7. 6. Similitud entre posiciones

Para comparar la posición t con la posición k , se utiliza

$$s_{tk} = \frac{Q_t K_k^\top}{\sqrt{d_k}}. \quad (6)$$

El numerador mide similitud mediante producto punto.

El denominador

$$\sqrt{d_k}$$

controla la escala numérica de los scores.

Interpretación

Un score alto indica que, en la representación aprendida, la posición k parece relevante para la consulta generada desde t .

8. 7. Pesos de atención

Los scores se convierten en pesos mediante softmax:

$$a_{tk} = \frac{\exp(s_{tk})}{\sum_j \exp(s_{tj})}. \quad (7)$$

Para cada t ,

$$\sum_k a_{tk} = 1.$$

Esto permite interpretar

$$a_{tk}$$

como un peso relativo de la posición k para construir la representación de t .

Punto de atención

Los valores a_{tk} no son parámetros fijos. Se calculan dinámicamente a partir de la secuencia y de las matrices aprendidas W_Q y W_K .

9. 8. Combinación ponderada de contenidos

La salida del mecanismo de atención es

$$V'_t = \sum_k a_{tk} V_k. \quad (8)$$

Cada posición recibe una mezcla de contenidos procedentes de otras posiciones.

Interpretación

La atención no copia una única observación. Construye una combinación ponderada de varias representaciones.

10. 9. Proyección, residual y normalización

El material base resume este paso mediante

$$S_t = Z_t + V'_t.$$

En una implementación completa, si V'_t no tiene la misma dimensión que Z_t , debe existir una proyección previa para hacer compatibles las dimensiones.

Después se normaliza:

$$Y_t = \text{Norm}(S_t). \quad (9)$$

10.1. Conexión residual

La suma

$$Z_t + V'_t$$

preserva información de la entrada del bloque.

10.2. Normalización

La normalización controla la escala de las activaciones.

Punto de atención

El material fuente describe la normalización como “sin pesos”. Conceptualmente, la operación de normalización calcula media y varianza; en implementaciones estándar de LayerNorm suelen existir además parámetros aprendibles de escala y desplazamiento.

11. 10. Resultado del bloque de atención

Después de atención, residual y normalización, se obtiene

$$Y_t.$$

Esta representación ya incorpora contexto procedente de otras posiciones.

Conexión entre bloques

Hasta aquí, el modelo ha mezclado información entre días. El siguiente bloque transformará cada posición de forma independiente.

12. 11. Bloque 4: Feed-Forward por posición

La primera transformación es

$$Z_t^{(1)} = Y_t W^{(1)} + b^{(1)}. \quad (10)$$

Después se aplica ReLU:

$$A_t = \text{ReLU}(Z_t^{(1)}) = \max(0, Z_t^{(1)}). \quad (11)$$

La segunda transformación es

$$O_t = A_t W^{(2)} + b^{(2)}. \quad (12)$$

13. 12. Segunda conexión residual

Se combina la salida con la entrada del bloque:

$$U_t = \text{Norm}(Y_t + O_t). \quad (13)$$

Interpretación

La atención mezcla contexto entre posiciones. La FFN refina cada representación de forma no lineal y local.

14. 13. Qué aprende el Feed-Forward

Son aprendibles:

$$W^{(1)}, \quad b^{(1)}, \quad W^{(2)}, \quad b^{(2)}.$$

La activación ReLU no tiene parámetros.

15. 14. Bloque 5: agregación temporal

Después de procesar todas las posiciones se obtiene

$$U_1, \dots, U_L.$$

Para producir una única predicción escalar puede utilizarse un promedio:

$$h_{\text{enc}} = \frac{1}{L} \sum_{t=1}^L U_t. \quad (14)$$

También podrían utilizarse otras estrategias de lectura.

Interpretación

La agregación transforma una secuencia de vectores en una única representación del intervalo temporal completo.

16. 15. Capa de salida

La predicción final se obtiene mediante

$$\hat{y} = h_{\text{enc}} W_{\text{out}} + b_{\text{out}}. \quad (15)$$

Para un problema de regresión climática, $\hat{y}$ puede representar una temperatura futura. Los parámetros son

$$W_{\text{out}}, \quad b_{\text{out}}.$$

17. 16. Función de pérdida

El material base utiliza una pérdida cuadrática:

$$\mathcal{L} = (\hat{y} - y)^2. \quad (16)$$

En un conjunto de datos completo se utilizaría normalmente un promedio sobre varias observaciones.

Interpretación

La pérdida resume en un único número qué tan lejos está la predicción del valor objetivo.

18. 17. Resumen del Forward Pass

El forward pass completo puede escribirse como:

$$X_t$$

$$\downarrow$$

$$E_t = X_t W_{\text{in}} + b_{\text{in}}$$

$$\downarrow$$

$$Z_t = E_t + \text{PE}_t$$

$$\downarrow$$

$$Q_t, K_t, V_t$$

$$\downarrow$$

$$a_{tk}$$

$$\downarrow$$

$$V'_t$$

$$\downarrow$$

$$Y_t$$

$$\downarrow$$

$$U_t$$

$$\downarrow$$

$$h_{\text{enc}}$$

$$\downarrow$$

$$\hat{y}$$

$$\downarrow$$

$$\mathcal{L}.$$

19. 18. Retropropagación

Una vez calculada la pérdida, comienza el aprendizaje.
El objetivo es determinar cómo cambia

$$\mathcal{L}$$

cuando se modifica cada parámetro.
Por ejemplo:

$$\begin{aligned} & \frac{\partial \mathcal{L}}{\partial W_{\text{out}}}, \\ & \frac{\partial \mathcal{L}}{\partial W^{(2)}}, \quad \frac{\partial \mathcal{L}}{\partial W^{(1)}}, \\ & \frac{\partial \mathcal{L}}{\partial W_{\text{consulta}}}, \\ & \frac{\partial \mathcal{L}}{\partial W_{\text{describir}}}, \\ & \frac{\partial \mathcal{L}}{\partial W_{\text{contenido}}}, \\ & \frac{\partial \mathcal{L}}{\partial W_{\text{in}}}. \end{aligned}$$

20. 19. Regla de la cadena

Estas derivadas se obtienen aplicando repetidamente la regla de la cadena.
Por ejemplo,

$$W_{\text{in}}$$

influye en

$$E_t,$$

que influye en

$$Z_t,$$

que influye en la atención, después en Y_t , U_t , la salida y finalmente la pérdida.
De forma esquemática:

$$\frac{\partial \mathcal{L}}{\partial W_{\text{in}}} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial h_{\text{enc}}} \cdots \frac{\partial E_t}{\partial W_{\text{in}}}.$$

Interpretación

Backpropagation organiza eficientemente la aplicación repetida de la regla de la cadena.

21. 20. Actualización de pesos

El material base utiliza descenso de gradiente:

$$W \leftarrow W - \eta \frac{\partial \mathcal{L}}{\partial W}, \quad (17)$$

donde

$$\eta > 0$$

es la tasa de aprendizaje.

El signo negativo indica que se busca mover los parámetros en dirección opuesta al gradiente.

22. 21. Qué significa aprender

Después de muchas iteraciones:

- W_{in} aprende mejores combinaciones de variables;
- W_Q, W_K, W_V aprenden cómo comparar y combinar posiciones;
- $W^{(1)}, W^{(2)}$ aprenden transformaciones internas útiles;
- W_{out} aprende cómo convertir la representación final en una predicción.

Conexión entre bloques

El Transformer no aprende directamente “qué día mirar”. Aprende matrices que producen patrones de atención dependientes de los datos.

23. 22. Parámetros aprendibles y cantidades dinámicas

Objeto	¿Se aprende?	Comentario
$W_{\text{in}}, b_{\text{in}}$	sí	proyección inicial
PE_t sinusoidal	no	codificación fija
W_Q, W_K, W_V	sí	atención
a_{tk}	no directamente	se calcula dinámicamente
$W^{(1)}, b^{(1)}$	sí	FFN
$W^{(2)}, b^{(2)}$	sí	FFN
$W_{\text{out}}, b_{\text{out}}$	sí	salida
$\hat{y}$	no	resultado del forward pass
$\mathcal{L}$	no	función objetivo

24. 23. Mapa dimensional recomendado

Suponga:

$$X_t \in \mathbb{R}^3,$$

$$d_{\text{model}} = d,$$

$$d_k = r,$$

L = longitud de la ventana.

Entonces:

Objeto	Dimensión
X	$L \times 3$
E	$L \times d$
Z	$L \times d$
Q	$L \times r$
K	$L \times r$
$QK^\top$	$L \times L$
$A = [a_{tk}]$	$L \times L$
V	$L \times d_v$
U	$L \times d$
h_{enc}	$\mathbb{R}^d$
$\hat{y}$	escalar

Actividad para el estudiante

Verifique por qué

$$QK^\top$$

tiene dimensión

$$L \times L.$$

¿Qué representa cada fila de esta matriz?

25. 24. Preguntas de autoevaluación

1. ¿Qué diferencia existe entre forward pass y backward pass?
2. ¿Qué función cumple W_{in} ?
3. ¿Qué añade el positional encoding?
4. ¿Qué representan Query, Key y Value?
5. ¿Qué hace el softmax en la atención?
6. ¿Por qué a_{tk} no es un peso fijo aprendido directamente?
7. ¿Qué función cumple la conexión residual?
8. ¿Qué diferencia existe entre atención y feed-forward?
9. ¿Qué hace la agregación temporal?
10. ¿Qué mide la función de pérdida?
11. ¿Cómo interviene la regla de la cadena en backpropagation?
12. ¿Qué significa la tasa de aprendizaje η ?

26. 25. Ejercicios propuestos

Ejercicio 1. Dimensiones.

Si

$$X_t \in \mathbb{R}^3$$

y

$$d = 8,$$

determine la dimensión de W_{in} .

Ejercicio 2. Scores.

Si

$$Q_t, K_k \in \mathbb{R}^4,$$

explique por qué

$$Q_t K_k^\top$$

es escalar.

Ejercicio 3. Softmax.

Para scores

$$(2, 1, 0),$$

determine cualitativamente qué posición recibirá más atención.

Ejercicio 4. Residual.

Explique por qué se necesita que Z_t y V_t' tengan dimensiones compatibles.

Ejercicio 5. FFN.

Escriba la secuencia

$$Y_t \rightarrow Z_t^{(1)} \rightarrow A_t \rightarrow O_t.$$

Ejercicio 6. Pooling.

Si

$$L = 5,$$

escriba explícitamente

$$h_{\text{enc}}.$$

Ejercicio 7. Pérdida.

Si

$$\hat{y} = 24.5, \quad y = 25.2,$$

calcule

$$\mathcal{L}.$$

Ejercicio 8. Gradiente.

Explique qué significa

$$\frac{\partial \mathcal{L}}{\partial W_Q}.$$

Ejercicio 9. Actualización.

Si

$$W = 2, \quad \frac{\partial \mathcal{L}}{\partial W} = 0.4, \quad \eta = 0.1,$$

calcule el nuevo valor de W .

Ejercicio 10. Arquitectura.

Dibuje el flujo completo desde X_t hasta $\mathcal{L}$.

27. 26. Actividad integradora

Considere una ventana climática de siete días.

Diseñe conceptualmente un encoder para predecir la temperatura del día siguiente.

Debe especificar:

1. dimensión de entrada;
2. dimensión interna d ;
3. forma de W_{in} ;
4. positional encoding;
5. dimensiones de Q, K, V ;
6. matriz de atención;
7. FFN;
8. estrategia de agregación;
9. capa de salida;
10. función de pérdida;
11. parámetros que se actualizarán durante el entrenamiento.

Finalmente, explique en no más de cinco líneas cómo viaja la información en el forward pass y cómo viaja el error en el backward pass.

28. 27. Ideas esenciales para recordar

- El forward pass transforma datos en una predicción.
- La atención compara posiciones mediante Query y Key y combina contenidos mediante Value.
- Los pesos de atención se calculan dinámicamente.
- Las conexiones residuales preservan información entre bloques.
- La FFN transforma cada posición de manera no lineal.
- La capa de salida convierte la representación codificada en una predicción.
- La pérdida mide el error.
- Backpropagation calcula gradientes mediante la regla de la cadena.
- El descenso de gradiente actualiza los parámetros para reducir la pérdida.
- Aprender significa modificar las matrices internas para producir mejores representaciones y predicciones.

29. 28. Bibliografía recomendada

Referencias

- [1] A. Vaswani et al., “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, 2017.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.
- [3] J. Alammam, *The Illustrated Transformer*, 2018.