

Esquema_Arquitectura_transformer

YofreH

2025-10-27

Esquema ampliado del flujo del Encoder Transformer

1. Forward pass (propagación hacia adelante)

(Del vector climático X_t hasta el cálculo del error $\mathcal{L}$).

Entrada: datos climáticos

$X_t = (T_t, H_t, P_t)$

Cada observación diaria de temperatura, humedad y precipitación entra al encoder.

Bloque 1 — Proyección de entrada (transformación lineal)

$E_t = X_t W_{\text{in}} + b_{\text{in}}$

- Tipo de pesos:** W_{in}
- Acción:** transforma las variables físicas en una representación interna de dimensión d .
- Salida:** E_t , vector interno.

Bloque 2 — Codificación posicional

$Z_t = E_t + \text{PE}_t$

- No hay pesos aprendibles.**
- Añade la información del orden temporal mediante funciones seno-coseno.

Bloque 3 — Mecanismo de atención

Aquí aparecen los tres tipos de pesos principales del Transformer:

$Q_t = Z_t W_{\text{consulta}}, K_t = Z_t W_{\text{describir}}, V_t = Z_t W_{\text{contenido}}$

Estas tres proyecciones permiten comparar cada día con los demás y decidir "a quién mirar".

Luego:

- Similitud entre días:** $s_{tk} = \frac{Q_t K_k^{\text{top}}}{\sqrt{d_k}}$
- Ponderaciones (softmax):** $a_{tk} = \frac{\exp(s_{tk})}{\sum_j \exp(s_{tj})}$
- Combinación ponderada de contenidos:** $V'_t = \sum_k a_{tk} V_k$
- Proyección y suma residual:** $S_t = Z_t + V'_t$
- Normalización (sin pesos):** $Y_t = \text{Norm}(S_t)$

Hasta aquí, el modelo ha aprendido a integrar dependencias entre días y generar una representación contextual Y_t .

Bloque 4 — Feed-forward por posición

Dentro de cada día:

- Primera transformación lineal:** $Z^{(1)}_t = Y_t W^{(1)} + b^{(1)}$
- Activación no lineal (ReLU):** $A_t = \max(0, Z^{(1)}_t)$
- Segunda transformación lineal:** $O_t = A_t W^{(2)} + b^{(2)}$
- Suma residual y normalización:** $U_t = \text{Norm}(Y_t + O_t)$

💡 Este bloque refina localmente las representaciones, filtra ruido y estabiliza la escala numérica.

Bloque 5 — Capa de salida

- Agregación temporal (promedio o token especial):** $h_{\text{enc}} = \frac{1}{L} \sum_{t=1}^L U_t$

2. **Proyección final (lineal):** $\hat{y} = h_{\text{enc}} W_{\text{out}} + b_{\text{out}}$
 3. **Cálculo del error de predicción (pérdida):** $\mathcal{L} = (\hat{y} - y)^2 \quad \text{(para MSE)}$
-

2. Retropropagación (Backward pass)

Ahora comienza el aprendizaje: la minimización del error.

1. **Cálculo de gradientes:** $\frac{\partial \mathcal{L}}{\partial W_{\text{out}}}, \quad \frac{\partial \mathcal{L}}{\partial W^{(2)}}, \quad \frac{\partial \mathcal{L}}{\partial W^{(1)}}, \quad \frac{\partial \mathcal{L}}{\partial W_{\text{consulta}}}, \quad \frac{\partial \mathcal{L}}{\partial W_{\text{describir}}}, \quad \frac{\partial \mathcal{L}}{\partial W_{\text{contenido}}}, \quad \frac{\partial \mathcal{L}}{\partial W_{\text{in}}}$

Cada uno mide cómo influye cada peso en el error final.

2. **Actualización de pesos (descenso de gradiente):** $W \leftarrow W - \eta \frac{\partial \mathcal{L}}{\partial W}$ donde η es la tasa de aprendizaje.
 3. **Reinicio del ciclo:**
Se repite para todos los lotes de datos hasta que la pérdida converge o deja de mejorar.
-