

Introducción a Transformers

Dependencias largas en series climáticas y motivación del mecanismo de atención

FCFM–UNACH
Licenciatura en Matemáticas Aplicadas
Curso de Aprendizaje Máquina Estadístico

Índice

1. Propósito de esta guía	3
2. Caso de estudio: una serie climática multivariada	3
3. Paso 1. Motivación: dependencias largas	4
4. Autocorrelación y correlación cruzada	4
5. Qué significa una correlación persistente	5
6. Paso 2. RNN y memoria temporal	5
7. Vanishing y exploding gradients	5
8. LSTM y GRU	6
9. Indicador ilustrativo de memoria efectiva	6
10. Paso 3. Error según horizonte de predicción	6
11. Indicador de memoria de largo horizonte	7
12. Paso 4. Introducción conceptual al Transformer	7
13. Qué significa “atender”	8
14. Por qué ayuda con dependencias largas	8
15. Procesamiento paralelo	8
16. Ejemplo ilustrativo de mejora	8
17. Indicador de atención efectiva	9
18. Comparación conceptual	9
19. Qué no debe concluirse demasiado rápido	10
20. Interpretabilidad mediante mapas de atención	10
21. Ruta hacia los siguientes temas	10

22.Preguntas de autoevaluación	11
23.Ejercicios propuestos	11
24.Actividad integradora	12
25.Ideas esenciales para recordar	12
26.Bibliografía recomendada	13

1. Propósito de esta guía

Los modelos Transformer surgieron como una alternativa a las arquitecturas recurrentes para trabajar con secuencias largas. Su idea central consiste en reemplazar la recurrencia por mecanismos de atención capaces de relacionar directamente posiciones distantes dentro de una secuencia.

En esta guía se utiliza un caso climático multivariado como hilo conductor. Consideramos

$$X_t = (T_t, H_t, P_t),$$

donde:

- T_t : temperatura media diaria;
- H_t : humedad relativa;
- P_t : precipitación acumulada.

El objetivo es predecir una temperatura futura

$$T_{t+h}$$

a partir de la historia pasada.

La secuencia conceptual será:

dependencias largas $\longrightarrow$ limitaciones recurrentes $\longrightarrow$ atención $\longrightarrow$ Transformer.

Objetivos de aprendizaje

Al finalizar esta guía, el estudiante deberá ser capaz de:

1. Explicar por qué las series climáticas pueden presentar dependencias de largo alcance.
2. Relacionar el problema de vanishing/exploding gradients con el entrenamiento de RNN.
3. Interpretar autocorrelaciones y correlaciones cruzadas a distintos rezagos.
4. Comprender el papel del horizonte h en el error de predicción.
5. Interpretar un indicador de memoria efectiva como medida comparativa.
6. Explicar conceptualmente la atención escalada.
7. Comparar el procesamiento recurrente con el procesamiento paralelo de un Transformer.
8. Formular preguntas experimentales para evaluar memoria y atención.

2. Caso de estudio: una serie climática multivariada

Supongamos que observamos diariamente

$$X_t = (T_t, H_t, P_t).$$

Queremos construir un modelo que utilice una ventana histórica

$$(X_{t-L+1}, \dots, X_t)$$

para predecir

$$T_{t+h}.$$

El reto principal es que la información relevante puede encontrarse muy lejos en el pasado.

Por ejemplo, una condición observada hoy puede depender de patrones estacionales o de procesos que comenzaron semanas o meses antes.

Interpretación

La dificultad no consiste únicamente en tener muchas observaciones. Consiste en que la señal útil puede encontrarse a gran distancia temporal respecto de la predicción.

3. Paso 1. Motivación: dependencias largas

En climatología pueden aparecer fenómenos con escalas temporales muy diferentes.

Entre ellos:

- ciclos estacionales de aproximadamente un año;
- persistencia térmica de varios días o semanas;
- efectos retardados de precipitación y humedad;
- fenómenos oceánico-atmosféricos con escalas de meses.

Esto motiva el estudio de correlaciones a grandes rezagos.

4. Autocorrelación y correlación cruzada

Para dos variables climáticas T_t y P_t , puede definirse una correlación cruzada a rezago k como

$$\rho_{T,P}(k) = \frac{\text{Cov}(T_t, P_{t-k})}{\sigma_T \sigma_P}. \quad (1)$$

Si

$$\rho_{T,P}(k)$$

permanece apreciablemente distinto de cero para valores grandes de k , existe evidencia de dependencia estadística a largo plazo entre ambas series.

El material fuente utiliza como ejemplo ilustrativo:

$$\rho_{T,P}(30) = 0.42,$$

$$\rho_{T,P}(100) = 0.35,$$

$$\rho_{T,P}(200) = 0.28.$$

Nota de precisión

Estos valores deben entenderse como números ilustrativos del caso de estudio, no como valores universales para datos climáticos. En una aplicación real deben estimarse a partir del conjunto de datos disponible.

5. Qué significa una correlación persistente

Una correlación que decrece lentamente con k sugiere que la dependencia no desaparece rápidamente.

Esto puede indicar:

- estacionalidad;
- tendencias compartidas;
- persistencia física;
- dependencia real de largo alcance.

Punto de atención

Correlación a gran rezago no implica automáticamente causalidad. Puede surgir por estacionalidad común, tendencias o variables omitidas.

6. Paso 2. RNN y memoria temporal

Una RNN elemental puede escribirse como

$$h_t = f(W_x X_t + W_h h_{t-1}), \quad (2)$$

donde

$$h_t$$

resume información de la historia.

En principio, h_t depende de todos los estados anteriores. Sin embargo, el entrenamiento exige propagar gradientes a través de muchos pasos temporales.

7. Vanishing y exploding gradients

De forma esquemática,

$$\frac{\partial h_t}{\partial h_{t-k}},$$

contiene productos repetidos de matrices Jacobianas.

Una representación simplificada es

$$\frac{\partial h_t}{\partial h_{t-k}} \approx \prod_{i=1}^k W_h^\top f'(a_{t-i}). \quad (3)$$

Cuando k crece, este producto puede:

- tender a cero: *vanishing gradient*;

- crecer excesivamente: *exploding gradient*.

Interpretación

El problema no es que la RNN “olvide” de manera literal, sino que el proceso de optimización puede tener dificultades para asignar correctamente crédito a eventos muy lejanos.

8. LSTM y GRU

Las arquitecturas LSTM y GRU introducen compuertas que mejoran el flujo de información y de gradientes.

Esto permite capturar dependencias más largas que una RNN simple.

Sin embargo, la información sigue propagándose de forma secuencial a través del tiempo.

Por ello, secuencias muy largas pueden seguir siendo difíciles de modelar y costosas de entrenar.

9. Indicador ilustrativo de memoria efectiva

El material fuente propone una idea de longitud efectiva de memoria:

$$L_{\text{ef}} \approx \text{número de pasos hasta que } \left\| \frac{\partial h_t}{\partial h_{t-k}} \right\| < 10^{-3}.$$

También utiliza como ejemplo un rango

$$L_{\text{ef}} \in [30, 60]$$

para LSTM/GRU en un caso climático ilustrativo.

Nota de precisión

Este rango no debe interpretarse como una constante arquitectónica. La memoria efectiva depende de datos, arquitectura, inicialización, entrenamiento, escalamiento y tarea.

10. Paso 3. Error según horizonte de predicción

Una forma práctica de estudiar la memoria de un modelo consiste en observar cómo cambia el error con el horizonte h .

Definimos

$$\text{MSE}(h) = \frac{1}{N-h} \sum_{t=1}^{N-h} \left(T_{t+h} - \hat{T}_{t+h} \right)^2. \quad (4)$$

El material fuente presenta el siguiente ejemplo ilustrativo:

Horizonte	RNN	LSTM	GRU
1	0.35	0.32	0.33
7	0.61	0.55	0.54
30	1.20	0.95	0.90
90	3.10	2.40	2.35

La tendencia del ejemplo muestra que el error aumenta al crecer el horizonte.

Interpretación

Una degradación rápida del error con h puede indicar que el modelo pierde capacidad predictiva cuando necesita utilizar información cada vez más lejana.

11. Indicador de memoria de largo horizonte

El material propone

$$\text{IML} = \frac{\text{MSE}(h_{\text{largo}}) - \text{MSE}(h_{\text{corto}})}{\text{MSE}(h_{\text{corto}})}. \quad (5)$$

Por ejemplo, para RNN:

$$\text{IML} = \frac{3.10 - 0.61}{0.61} \approx 4.08.$$

Para LSTM:

$$\text{IML} = \frac{2.40 - 0.55}{0.55} \approx 3.36.$$

Para GRU:

$$\text{IML} = \frac{2.35 - 0.54}{0.54} \approx 3.35.$$

Interpretación

Un valor mayor indica un crecimiento relativo más fuerte del error entre el horizonte corto y el largo.

Punto de atención

Este IML es un indicador pedagógico propuesto en el material. No es una métrica estándar universal en literatura de series temporales.

12. Paso 4. Introducción conceptual al Transformer

El Transformer reemplaza la recurrencia por mecanismos de atención.

La operación central es

$$Z = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V. \quad (6)$$

Los objetos

$$Q, \quad K, \quad V$$

son proyecciones aprendidas de las representaciones de entrada.

13. Qué significa “atender”

Para una posición t , el modelo calcula similitudes con otras posiciones k .
Después aplica softmax y obtiene pesos

$$a_{t,k}.$$

La salida de la posición t se construye como

$$z_t = \sum_k a_{t,k} v_k.$$

Así, una observación puede combinar información de posiciones cercanas o lejanas.

Interpretación

La atención no “recuerda” de la misma forma que una RNN. Calcula directamente qué posiciones son relevantes para construir la representación actual.

14. Por qué ayuda con dependencias largas

En una arquitectura recurrente, la información debe atravesar una cadena de estados:

$$h_{t-k} \rightarrow h_{t-k+1} \rightarrow \cdots \rightarrow h_t.$$

En self-attention existe una interacción directa entre posiciones:

$$t \longleftrightarrow t - k.$$

Esto acorta el camino computacional entre posiciones distantes.

Conexión con aprendizaje máquina

Ésta es una de las razones por las que los Transformers son atractivos para secuencias largas: la relación entre dos posiciones no necesita atravesar todos los estados intermedios.

15. Procesamiento paralelo

Otra diferencia importante es computacional.

Las RNN procesan una secuencia de manera esencialmente secuencial:

$$x_1 \rightarrow x_2 \rightarrow \cdots \rightarrow x_T.$$

En self-attention, muchas operaciones entre posiciones pueden calcularse simultáneamente mediante álgebra matricial.

Esto favorece el uso eficiente de GPU y otros aceleradores.

16. Ejemplo ilustrativo de mejora

El material fuente presenta el siguiente ejemplo:

Horizonte	MSE Transformer	Reducción vs. LSTM
1	0.33	—
7	0.46	16 %
30	0.72	24 %
90	1.35	44 %

La idea pedagógica es que el error del Transformer crece más lentamente con el horizonte.

Nota de precisión

Estos números son ilustrativos del material original. No implican que un Transformer siempre supere a una LSTM ni que la mejora sea del mismo orden en cualquier conjunto de datos.

17. Indicador de atención efectiva

El material introduce

$$\text{IAE} = \sum_{k=1}^T a_{t,k} k. \quad (7)$$

donde $a_{t,k}$ representa pesos de atención.

La intención es resumir hasta qué posiciones distribuye el modelo su atención.

Nota de precisión

La expresión (7) pondera índices de posición. Si se desea medir específicamente distancia temporal respecto de t , una alternativa más directa sería

$$\sum_k a_{t,k} |t - k|.$$

Esto será útil más adelante cuando se estudien mini-experimentos de atención por lag.

18. Comparación conceptual

Propiedad	RNN/LSTM/GRU	Transformer
Procesamiento temporal	secuencial	paralelo
Dependencias largas	indirectas	atención directa
Camino entre posiciones	crece con distancia	puede ser corto
Estado oculto recurrente	sí	no
Mapa explícito de atención	no	sí
Información de posición	implícita en recurrencia	debe incorporarse

19. Qué no debe concluirse demasiado rápido

Punto de atención

Un Transformer no es automáticamente mejor que una RNN, LSTM o GRU. El desempeño depende de:

- tamaño y calidad del conjunto de datos;
- longitud de las secuencias;
- arquitectura;
- regularización;
- estrategia de entrenamiento;
- tipo de positional encoding;
- horizonte de predicción.

La comparación debe realizarse mediante experimentos controlados.

20. Interpretabilidad mediante mapas de atención

La matriz de atención

$$A = [a_{t,k}]$$

puede visualizarse como un mapa.

Esto permite observar qué posiciones reciben mayor peso.

Sin embargo, los pesos de atención deben interpretarse con cautela.

Nota de precisión

Un mapa de atención ofrece información sobre el mecanismo interno de una capa, pero no constituye por sí solo una explicación causal ni una medida completa de importancia.

21. Ruta hacia los siguientes temas

Esta introducción prepara tres bloques posteriores:

1. **componentes del Transformer:** proyecciones, Q , K , V , residual y feed-forward;
2. **mini-experimentos:** permutaciones, positional encoding y sensibilidad al orden;
3. **implementación:** construcción de modelos en Colab.

Conexión con aprendizaje máquina

Primero se comprende por qué podría ser útil la atención; después se estudia cómo está construida.

22. Preguntas de autoevaluación

1. ¿Qué significa una dependencia de largo alcance?
2. ¿Qué mide $\rho_{T,P}(k)$?
3. ¿Por qué una correlación grande para $k = 200$ puede ser relevante?
4. ¿Qué relación existe entre backpropagation through time y vanishing gradients?
5. ¿Qué mejora introducen LSTM y GRU respecto de una RNN simple?
6. ¿Qué mide $\text{MSE}(h)$?
7. ¿Cómo se interpreta el IML?
8. ¿Qué hacen Q , K y V de forma conceptual?
9. ¿Qué ventaja aporta un camino directo de atención entre posiciones distantes?
10. ¿Por qué el procesamiento paralelo puede ser computacionalmente ventajoso?
11. ¿Qué limitación interpretativa tienen los mapas de atención?
12. ¿Por qué los valores numéricos presentados deben tratarse como ejemplos y no como constantes universales?

23. Ejercicios propuestos

Ejercicio 1. Correlación cruzada.

Explique la diferencia entre

$$\rho_{T,P}(0)$$

y

$$\rho_{T,P}(30).$$

Ejercicio 2. Horizonte.

Para una tabla hipotética de errores, calcule $\text{MSE}(7)$ y $\text{MSE}(90)$.

Ejercicio 3. IML.

Si

$$\text{MSE}(7) = 0.50, \quad \text{MSE}(90) = 1.75,$$

calcule IML.

Ejercicio 4. Gradientes.

Explique por qué un producto repetido de matrices con norma menor que uno puede conducir a vanishing gradients.

Ejercicio 5. Atención.

Dados pesos

$$(0.1, 0.2, 0.5, 0.2),$$

compruebe que suman uno e interprete la posición de mayor atención.

Ejercicio 6. Camino computacional.

Compare el número de pasos que separa x_1 de h_T en una RNN con la interacción directa entre dos tokens en self-attention.

Ejercicio 7. IAE.

Compare

$$\sum_k a_{t,k} k$$

con

$$\sum_k a_{t,k} |t - k|.$$

Ejercicio 8. Discusión.

Proponga dos razones por las que una LSTM podría superar a un Transformer en un conjunto de datos pequeño.

24. Actividad integradora

Suponga que dispone de una serie climática diaria de tres años.
Diseñe un experimento comparando:

LSTM vs. Transformer.

Debe especificar:

1. variables de entrada;
2. longitud de ventana L ;
3. horizontes de predicción;
4. métrica principal;
5. cálculo de IML;
6. al menos una medida de dependencia temporal de los datos;
7. una visualización de atención para el Transformer;
8. una conclusión basada en evidencia y no sólo en una gráfica.

25. Ideas esenciales para recordar

- Las series climáticas pueden contener dependencias a múltiples escalas.
- Las RNN modelan secuencias mediante recurrencia.
- LSTM y GRU mejoran la memoria, pero siguen siendo secuenciales.
- La atención permite relacionar directamente posiciones distantes.
- Los Transformers facilitan procesamiento paralelo.
- El horizonte de predicción es una forma práctica de evaluar memoria.
- Los mapas de atención ofrecen información útil, pero no deben interpretarse como causalidad.
- Toda comparación entre arquitecturas debe realizarse mediante un experimento controlado.

26. Bibliografía recomendada

Referencias

- [1] A. Vaswani et al., “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, 2017.
- [2] J. Alammam, *The Illustrated Transformer*, 2018.
- [3] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.
- [4] F. Chollet, *Deep Learning with Python*, Manning, 2021.
- [5] J. Grus, *Data Science from Scratch*, O’Reilly Media, 2019.