

Dependencias largas en series climáticas y motivación del modelo Transformer

Curso de Aprendizaje Automático — Matemáticas Aplicadas
2025

Caso de estudio: Series de tiempo climáticas multivariadas

Contexto

Queremos modelar la evolución diaria de un vector climático multivariado:

$$X_t = (T_t, H_t, P_t)$$

donde:

- T_t : temperatura media diaria,
- H_t : humedad relativa,
- P_t : precipitación acumulada.

Objetivo: predecir la temperatura futura T_{t+h} usando la historia pasada $(X_{t-1}, X_{t-2}, \dots)$.

Paso 1. Motivación: Limitaciones de las RNN

Dependencias largas

En climatología:

- Los ciclos estacionales tienen períodos de **365 días**.
- Fenómenos como *El Niño* / *La Niña* influyen con rezagos de **meses**.
- Las correlaciones cruzadas como $\text{corr}(T_t, P_{t-k})$ pueden ser significativas para $k > 100$.

➡ **Conclusión:** las dependencias relevantes pueden extenderse a cientos de pasos temporales.

Limitación de las RNN, LSTM y GRU

Una RNN modela la secuencia mediante:

$$h_t = f(W_x X_t + W_h h_{t-1})$$

Durante el entrenamiento, el gradiente depende de:

$$\frac{\partial h_t}{\partial h_{t-k}} = \prod_{i=1}^k W_h^{\text{top}} f'(a_{t-i})$$

A medida que k crece:

- Este producto tiende a 0 (*vanishing gradient*), o
- A ∞ (*exploding gradient*).

Memoria efectiva

Aunque las LSTM y GRU introducen *puertas de olvido*, su **memoria efectiva** se estima por:

$$L_{\text{ef}} \approx \text{número de pasos hasta que } \left| \frac{\partial h_t}{\partial h_{t-k}} \right| < 10^{-3}$$

En datos climáticos, se observa típicamente:

$$L_{\text{ef}} \in [30, 60] \text{ días (LSTM/GRU)}$$

mientras que las correlaciones reales duran **más de 200 días**.

Paso 2. Fundamentación matemática

Autocorrelación y correlación cruzada

Para cada par de variables climáticas:

$$\rho_{T,P}(k) = \frac{\text{Cov}(T_t, P_{t-k})}{\sigma_T \sigma_P}$$

Ejemplo de resultados observados:

$\rho_{T,P}(30) = 0.42, \rho_{T,P}(100) = 0.35, \rho_{T,P}(200) = 0.28$

→ Existe dependencia significativa incluso a **200 días**.

Error de predicción según horizonte (h)

Evaluamos el error cuadrático medio:

$$\text{MSE}(h) = \frac{1}{N-h} \sum_{t=1}^{N-h} (T_{t+h} - \widehat{T}_{t+h})^2$$

Horizonte (días)	MSE (RNN)	MSE (LSTM)	MSE (GRU)
1	0.35	0.32	0.33
7	0.61	0.55	0.54
30	1.20	0.95	0.90
90	3.10	2.40	2.35

Tendencia: el error crece casi exponencialmente con (h) , mostrando pérdida de memoria.

Indicador de memoria efectiva (IML)

Definimos:

$$\text{IML} = \frac{\text{MSE}(h_{\text{largo}}) - \text{MSE}(h_{\text{corto}})}{\text{MSE}(h_{\text{corto}})}$$

Modelo	$(h_{\text{corto}}=7)$	$(h_{\text{largo}}=90)$	IML
RNN	0.61→3.10		4.08
LSTM	0.55→2.40		3.36
GRU	0.54→2.35		3.35

Cuanto mayor es el IML, menor capacidad de memoria.

Paso 3. Introducción conceptual al Transformer

Idea central

El Transformer elimina la recurrencia y usa **atención**:

$$Z = \text{softmax}\left(\frac{QK^{\text{top}}}{\sqrt{d}}\right)V$$

Cada instante “mira” a todos los demás, ponderando su importancia mediante los pesos de atención.
Así capta relaciones a 1, 30 o 300 días sin degradación temporal.

Indicadores de mejora observados

Horizonte (días)	MSE (Transformer)	Reducción % vs LSTM
1	0.33	—
7	0.46	16%
30	0.72	24%
90	1.35	44%

El error crece mucho más lentamente a medida que aumenta el horizonte de predicción.

Indicador de atención efectiva (IAE)

Se define un indicador basado en los pesos de atención:

$$\text{IAE} = \sum_{k=1}^T a_{t,k} \cdot k$$

donde $(a_{t,k})$ son los pesos promedio de atención del token (t) hacia los (k) pasos previos.

- En LSTM: los pesos implícitos decrecen exponencialmente.

- En Transformer: la atención se reparte a lo largo de toda la secuencia.

Comparación general

Propiedad	RNN/LSTM/GRU	Transformer
Procesamiento secuencial	Sí	No (paralelo)
Captura de dependencias largas	Limitada	Alta
Interpretabilidad	Baja	Alta (mapa de atención)
Escalabilidad	Baja	Alta
Memoria efectiva (IML)	3–4	1.8
Reducción de error (MSE)	—	40% en horizontes largos

Cierre pedagógico

“Las RNN aprenden a **recordar** un resumen del pasado, mientras que los Transformers **deciden qué recordar** en cada instante.”

Esto motiva la siguiente fase:

un taller en Colab donde implementaremos estos cálculos paso a paso con datos climáticos reales.

Preguntas abiertas para discusión

1. Definición:

¿Cómo se define la autocorrelación cruzada entre dos variables y qué mide exactamente?

2. Propiedades:

- ¿Qué implica que $\rho_{T,P}(k)$ sea distinto de cero para grandes valores de k ?
- ¿Por qué una correlación decreciente lentamente indica dependencia de largo alcance?

3. Modelado:

- ¿Por qué las RNN no pueden capturar fácilmente dependencias de largo plazo?
- ¿Qué papel juega el gradiente en este problema?

4. Transformers:

- ¿Cómo ayuda la atención a modelar relaciones entre variables distantes en el tiempo?
- ¿Por qué el procesamiento paralelo es ventajoso para secuencias largas?

5. Evaluación:

- ¿Qué indicador usarías para medir la memoria efectiva de un modelo?
- ¿Qué ventajas interpretativas ofrecen los mapas de atención frente a los estados ocultos?

Bibliografía

- Vaswani et al. (2017). *Attention is All You Need*.
- Alammr, J. (2018). *The Illustrated Transformer*.
- Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.
- Chollet, F. (2021). *Deep Learning with Python*.
- Grus, J. (2019). *Data Science from Scratch*.