

Modelo Estocástico con Retraso para la Dinámica Fenológica de la Vegetación

Carlos Eduardo Chacón Rodríguez

Licenciatura en Matemáticas Aplicadas
Facultad de Ciencias en Física y Matemáticas
Benemérita Universidad Autónoma de Chiapas
Asesor: Dr. Yofre Hernán García Gómez

Reunión Anual MexSIAM 2026
20 de Agosto

- 1 Introducción
- 2 Planteamiento del problema
- 3 Objetivos
- 4 Datos
- 5 Modelo Matemático
- 6 Discretización Numérica
- 7 Simulación Monte Carlo
- 8 Resultados y conclusiones

Problema

Comprender la dinámica temporal de la vegetación es fundamental para

- agricultura,
- conservación ambiental,
- manejo forestal,
- estimación de productividad,
- monitoreo del cambio climático.

Dificultad


La respuesta de la vegetación depende tanto de

- condiciones ambientales actuales,
- memoria fisiológica,
- procesos aleatorios del ambiente.

¿Qué es la fenología?

La fenología estudia los eventos periódicos del desarrollo vegetal:

- brotación,
- crecimiento,
- floración,
- senescencia,
- caída de hojas.



Problema de investigación

Las variables climáticas explican parte del crecimiento vegetal.

Sin embargo,

- la vegetación posee memoria,
- existe incertidumbre ambiental,
- las respuestas no son instantáneas.

Surge entonces la siguiente pregunta:

Pregunta

¿Cómo incorporar simultáneamente

- memoria,
- ruido estocástico,
- variables climáticas

en un modelo matemático?

Objetivo General


Desarrollar un modelo basado en ecuaciones diferenciales estocásticas con retraso que describa la dinámica temporal del índice de verdor de la vegetación utilizando información climática.



- Formular el modelo SDDE.
- Incorporar memoria mediante un retraso temporal.
- Incorporar variables climáticas y variabilidad estocástica.
- Obtener una aproximación mediante Euler–Maruyama.
- Estimar los parámetros mediante mínimos cuadrados ordinarios.
- Evaluar la sensibilidad respecto al retraso.
- Comparar el modelo SDDE con un modelo $AR(\tau)$.

Datos: cuatro periodos disponibles

El conjunto de datos disponible se divide en cuatro periodos temporales.



Cada periodo representa una ventana temporal disponible para el análisis de la dinámica del GCC.

La variable de respuesta es

$$X(t) = \text{GCC}(t).$$

Las variables explicativas consideradas son:

Variable	Interpretación
$X(t)$	GCC actual
$X(t - \tau)$	GCC retrasado
$Rad(t)$	Radiación solar
$Temp(t)$	Temperatura
$Prec(t)$	Precipitación

El objetivo es determinar cómo estas variables contribuyen a explicar la dinámica temporal del índice GCC.

Datos utilizados

Se utilizaron observaciones provenientes de:

- PhenoCam
- Radiación solar
- Temperatura
- Precipitación



¿Por qué utilizar una SDDE?

Idea principal

El crecimiento de la vegetación depende simultáneamente de

- su estado actual,
- su estado pasado (memoria biológica),
- variables climáticas,
- perturbaciones ambientales aleatorias.

Vegetación $\longrightarrow$ Memoria + Ruido + Clima


El modelo propuesto es una ecuación diferencial estocástica con retraso

$$dX(t) = [\alpha + \beta X(t) + \gamma X(t - \tau) + \delta^T C(t)] dt + \sigma X(t) dW(t)$$

donde

- $X(t)$ representa el índice GCC.
- τ es el retraso biológico.
- $C(t)$ contiene las variables climáticas.
- $W(t)$ es un proceso de Wiener.

Esquema conceptual



Parámetro	Interpretación
α	crecimiento basal
β	efecto del estado actual
γ	memoria biológica
δ	efecto climático
σ	intensidad del ruido
τ	tiempo de retraso

El término

$$\sigma X(t)dW(t)$$

representa perturbaciones aleatorias.

Por ejemplo

- nubosidad,
- viento,
- humedad,
- errores de medición,
- variabilidad natural.


Este término convierte al modelo determinista en un modelo estocástico.

¿Qué representa el retraso?

El retraso modela la memoria fisiológica. Los cambios observados hoy pueden depender del estado de la planta hace varios días.

Ejemplos:

- acumulación de biomasa,
- almacenamiento de fotoasimilados,
- adaptación al clima.



¿Cómo determinar el retraso temporal?

El retraso τ es un parámetro fundamental del modelo.

En lugar de fijarlo arbitrariamente, se realizó un análisis de sensibilidad para los valores

$$\tau \in \{3, 4, \dots, 23\}$$


en cada uno de los cuatro periodos disponibles.

Para cada valor de τ se estimó el coeficiente asociado al término retrasado:

$$\gamma X(t - \tau).$$

La finalidad fue identificar el comportamiento de γ frente a diferentes escalas de retraso y establecer un valor de trabajo para el modelo.

Sensibilidad del retraso temporal



Magnitud estimada del coeficiente γ para $\tau \in [3, 23]$ en los cuatro periodos.

El análisis de sensibilidad permite estudiar cómo cambia la magnitud y el comportamiento del coeficiente de retraso

$$\gamma$$

cuando se modifica τ .

A partir de este análisis se adopta como valor de trabajo

$$\tau = 15$$

para las etapas posteriores del estudio.

Esquema de Euler–Maruyama

Sea

$$t_n = n\Delta t.$$

El esquema numérico queda

$$X_{n+1} = X_n + \mu(t_n, X_n, X_{n-k})\Delta t + \sigma X_n \Delta W_n.$$

donde

$$k = \frac{\tau}{\Delta t}.$$

y

$$\Delta W_n \sim \mathcal{N}(0, \Delta t).$$

Del modelo continuo a la regresión

Una vez discretizado, el modelo puede escribirse como

$$\Delta X_n = \alpha + \beta X_n + \gamma X_{n-k} + \delta_1 Rad_n + \delta_2 Temp_n + \delta_3 Prec_n + \varepsilon_n.$$

Esta formulación permite estimar los parámetros mediante técnicas de regresión lineal.

Estimación mediante mínimos cuadrados ordinarios

Los parámetros del modelo SDDE se estiman mediante

$$\hat{\theta} = \arg \min_{\theta} \|Y - X\theta\|^2.$$

La solución de mínimos cuadrados es

$$\hat{\theta} = (X^T X)^{-1} X^T Y$$

El modelo ajustado proporciona:

$$\hat{\alpha}, \quad \hat{\beta}, \quad \hat{\gamma}, \quad \hat{\delta}_1, \quad \hat{\delta}_2, \quad \hat{\delta}_3.$$

Estos parámetros permiten cuantificar la contribución de la dinámica actual, la memoria y las variables climáticas.

Comparación: SDDE vs AR(τ)

Para evaluar la contribución de la estructura propuesta se compara el modelo SDDE con un modelo autorregresivo tradicional.

Modelo SDDE

$$\Delta X_n = \alpha + \beta X_n + \gamma X_{n-\tau} + \delta^T C_n + \varepsilon_n.$$

Modelo AR(τ)

$$X_t = c + \sum_{i=1}^{\tau} \phi_i X_{t-i} + \varepsilon_t.$$

Validación del modelo entre periodos

Para evaluar la capacidad predictiva del modelo se realizó una validación utilizando los cuatro periodos disponibles.

Para cada periodo se calcularon:

- **RMSE**: mide el error cuadrático medio de las predicciones.
- **MAE**: mide el error absoluto medio.
- **Cobertura**: proporción de observaciones que se encuentran dentro del intervalo de confianza.
- **Ancho del intervalo**: mide la amplitud promedio de los intervalos de confianza.

De esta manera se evalúan simultáneamente la precisión predictiva y la incertidumbre.

Resultados de la validación

Periodo	RMSE	MAE	Cobertura	Ancho IC
P1	0.01245	0.01010	66.29 %	0.03121
P2	0.01050	0.00952	95.38 %	0.03126
P3	0.00750	0.00616	100.00 %	0.03447
P4	0.00392	0.00260	100.00 %	0.03568
Media	0.00859	0.00709	90.42 %	0.03316

Resultados promedio

$$RMSE = 0,00859 \quad MAE = 0,00709$$

$$Cobertura = 90,42 \% \quad \text{Ancho medio} = 0,03316$$

Interpretación de la validación

Los resultados muestran una disminución progresiva del error de predicción entre los cuatro periodos:

$$0,01245 > 0,01050 > 0,00750 > 0,00392.$$

De manera análoga, el MAE disminuye de

$$0,01010 \quad \text{a} \quad 0,00260.$$

La cobertura presenta un comportamiento diferente:

$$66,29 \%, \quad 95,38 \%, \quad 100 \%, \quad 100 \%.$$

Por tanto, el modelo presenta una precisión creciente en los periodos evaluados, mientras que la cobertura de los intervalos de confianza presenta variabilidad entre periodos.

Una vez estimados los parámetros del modelo SDDE, se realizan simulaciones de Monte Carlo para estudiar la variabilidad de las trayectorias generadas.

Para cada simulación:


$$X_0 \rightarrow X_1 \rightarrow \cdots \rightarrow X_N.$$

Se generan múltiples trayectorias utilizando el término estocástico

$$\sigma X_n \Delta W_n.$$

El conjunto de trayectorias permite construir una estimación de la trayectoria media y un intervalo de confianza.

Monte Carlo e intervalo de confianza



Trayectoria media simulada e intervalo de confianza obtenidos mediante Monte Carlo.

Principales resultados

1 Se analizaron cuatro periodos temporales de datos fenológicos.

2 Se realizó un barrido de

$$\tau \in [3, 23]$$

para estudiar la sensibilidad del coeficiente de retraso.

3 El análisis permitió establecer

$$\tau = 15$$

como valor de trabajo para las etapas posteriores.

4 Se incorporaron radiación, temperatura y precipitación como variables explicativas.

5 Se formuló el modelo discretizado como una regresión lineal y sus parámetros se estimaron mediante OLS.

6 Se comparó el modelo estructurado SDDE con un modelo AR(τ).

7 Se realizaron simulaciones de Monte Carlo para cuantificar la variabilidad de las trayectorias.

El modelo propuesto permite representar la dinámica fenológica del GCC incorporando simultáneamente el estado actual de la vegetación, su memoria temporal, las condiciones climáticas y la variabilidad estocástica.

El análisis de sensibilidad realizado sobre los cuatro periodos muestra la importancia de estudiar el retraso temporal antes de fijar su valor. El barrido

$$\tau \in [3, 23]$$

proporciona una base empírica para seleccionar

$$\boxed{\tau = 15}$$

como valor de trabajo en el análisis posterior.

La discretización mediante Euler–Maruyama permite transformar la SDDE en una formulación estadística que puede estimarse mediante mínimos cuadrados ordinarios.

La comparación con un modelo $AR(\tau)$ permite evaluar qué aporta la estructura explícita del modelo SDDE frente a una representación autorregresiva tradicional.

Además, la simulación de Monte Carlo permite pasar de una única trayectoria estimada a una distribución de trayectorias posibles, incorporando explícitamente la incertidumbre del modelo.

Esto proporciona un marco para estudiar procesos fenológicos en los que la dinámica presente depende tanto de las condiciones ambientales como de la historia reciente del sistema.

Las principales extensiones consideradas son:

- Comparar el modelo SDDE con modelos **ARIMA**.
- Estudiar diferentes valores de τ en la formulación final del modelo.
- Analizar si el retraso óptimo permanece estable entre los distintos periodos.

¡Muchas gracias!

