

Introducción Optimización Difusa

Marbin Rubely Cruz Bartolon

Licenciatura en Matemáticas Aplicadas.
Facultad de Ciencias en Física y Matemáticas.
Benemérita Universidad Autónoma de Chiapas.

Coautor: Dr. Yofre Hernán García Gómez.

20 de agosto de 2026

- Fundamentos de Conjuntos Difusos
- Principios de Optimización Difusa
- Formulación y Funciones de Pertenencia Exponenciales
- Caso de Estudio: Consumo Eléctrico en Tuxtla Gutiérrez
- Conclusión
- Referencia

Definición

Sea Ω un conjunto no vacío y $A \subseteq \Omega$, se dice que A es un conjunto difuso si existe una función

$$\mu_{(A)} : \Omega \rightarrow [0, 1]$$


Llamada **función de pertenencia** tal que si $x \in \Omega$ se tiene lo siguiente

- Si $\mu_{(A)}(x) = 1$, entonces $x \in A$
- Si $\mu_{(A)}(x) = 0$, entonces $x \notin A$
- Si $0 < \mu_{(A)}(x) < 1$, entonces $x \in A$, parcialmente

Ejemplo

Sea $a, m, b \in \mathbb{R}$ tal que $a < m < b$, definamos la siguiente **función de pertenencia**

$$\mu(x) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{m-a}, & x \in [a, m] \\ \frac{b-x}{b-m}, & x \in [m, b] \\ 0, & x \geq b \end{cases}$$



Definición

Sea A, B conjuntos difusos de Ω y sean μ_A, μ_B sus correspondientes funciones de pertenencias .

- El conjunto $A = \emptyset$, sí y sólo si $\mu_A(x) = 0, \forall x \in \Omega$
- $A = B$, sí y sólo si $\mu_A = \mu_B$
- $A \subset B$, sí y sólo si $\mu_A \leq \mu_B$
- A^c el complemento de A tendrá como función de pertenencia a $\mu_{A^c} = 1 - \mu_A$

Definición

Sea A, B conjuntos difusos con μ_A, μ_B , sus correspondientes funciones de pertenencia.

$$\mu_{A \cap B}(x) = \min[\mu_A(x), \mu_B(x)]$$

$$\mu_{A \cup B}(x) = \max[\mu_A(x), \mu_B(x)]$$

Note que la intersección clásica de conjuntos clásicos es un caso particular de lo anterior.

Demostración:

Sea $A, B \subset \Omega$ dos conjuntos. Consideremos la intersección común de conjuntos, $A \cap B = \{x \in \Omega \mid x \in A \text{ y } x \in B\}$, así podemos dar su función de pertenencia como lo siguiente.

$$\mu(x) = \begin{cases} 1, & x \in A \text{ y } x \in B \\ 0, & x \notin A \text{ o } x \notin B \end{cases}$$

Consideremos la función de pertenencia de la intersección difusa.

$$\mu_{A \cap B}(x) = \min[\mu_A(x), \mu_B(x)]$$

Veamos que dichas funciones son la misma.

Demostración:

Sea $x \in \Omega$ con lo cual tenemos dos casos $x \in A \cap B$ o $x \notin A \cap B$.

Supongamos que $x \in A \cap B$ así se tiene que $\mu(x) = 1$, por otro lado se tiene que

$$\mu_{A \cap B}(x) = \min[\mu_A(x), \mu_B(x)] = \min[1, 1] = 1$$

Ahora supongamos que $x \notin A \cap B$. S.P.G supongamos que $x \notin A$ así se tiene que $\mu(x) = 0$ por otro lado se tiene que.

$$\mu_{A \cap B}(x) = \min[0, \mu_B(x)] = 0$$

por lo tanto $\mu = \mu_{A \cap B}$



Función de pertenencia de $(A \cup B)^c$ (Leyes de De Morgan)

Demostración:

Sea A, B conjuntos difusos de Ω y sean μ_A, μ_B sus correspondientes funciones de pertenencias.

$$\mu_{(A \cup B)^c} = 1 - \max[\mu_A, \mu_B] = \min[1 - \mu_A, 1 - \mu_B]$$

Pues si $x \in \Omega$ tal que $\mu_A(x) \geq \mu_B(x)$ se tiene que $-\mu_A(x) \leq -\mu_B(x)$ así se tiene que $1 - \mu_A(x) \leq 1 - \mu_B(x)$.

Note que $\mu_{A^c \cap B^c} = \min[1 - \mu_A, 1 - \mu_B]$.

Por lo tanto $(A \cup B)^c = A^c \cap B^c$.



En la optimización clásica, el objetivo (lo que quieres lograr, como maximizar ganancias) y las restricciones (tus límites, como el presupuesto máximo) son cosas completamente separadas matemáticamente.

Bellman y Zadeh propusieron algo radical para la lógica difusa: Simetría. Argumentaron que, en la vida real, un objetivo y una restricción son básicamente lo mismo: ambos son condiciones que queremos satisfacer. Por lo tanto, ambos pueden representarse como Conjuntos Difusos.

Simetría entre Objetivos y Restricciones

En la optimización difusa, los objetivos y las restricciones se tratan de manera simétrica. Ambos se modelan como **conjuntos difusos** en el espacio de decisiones.

- Sea G el conjunto difuso de la **Meta** (Goal), con función $\mu_G(x)$.
- Sea C el conjunto difuso de la **Restricción** (Constraint), con función $\mu_C(x)$.

Definición

La **Decisión Difusa** D se define como la intersección de las metas y las restricciones:

$$D = G \cap C$$

Cuya función de pertenencia está dada por:

$$\mu_D(x) = \min[\mu_G(x), \mu_C(x)]$$

El Principio

El objetivo de la optimización difusa es encontrar la alternativa x^* que maximice la función de pertenencia de la Decisión Difusa D .

Matemáticamente, esto equivale a **maximizar el mínimo**:

$$x^* = \arg \max_x (\min[\mu_G(x), \mu_C(x)])$$

Nota: Este principio asegura que la solución óptima sea aquella que proporciona el mejor nivel de satisfacción en el “peor” de los criterios (ya sea objetivo o restricción).

Ejemplo: Decisión Difusa (Bellman-Zadeh)

Planteamiento del Problema

Supongamos que deseamos comprar un coche y tenemos dos condiciones que trataremos como conjuntos difusos:

- **Meta (G):** Queremos que el coche sea “muy rápido”.
- **Restricción (C):** Queremos que el coche sea “barato”.

Evaluación de Opciones

Evaluamos dos vehículos diferentes (x_1 y x_2):

- **Coche Deportivo (x_1):** Muy rápido pero muy caro.

$$\mu_G(x_1) = 0,9, \quad \mu_C(x_1) = 0,2$$

- **Coche Intermedio (x_2):** Medianamente rápido y asequible.

$$\mu_G(x_2) = 0,6, \quad \mu_C(x_2) = 0,7$$

Ejemplo: Decisión Óptima

Calculando la Decisión Difusa (D)

Usando el operador mínimo ($\mu_D = \min[\mu_G, \mu_C]$), evaluamos el grado de satisfacción global para cada coche:

- Para el Deportivo (x_1): $\mu_D(x_1) = \min[0,9, 0,2] = 0,2$
- Para el Intermedio (x_2): $\mu_D(x_2) = \min[0,6, 0,7] = 0,6$

Aplicando el Principio de Maximización

Buscamos la opción que maximice nuestra decisión difusa:

$$x^* = \max\{\mu_D(x_1), \mu_D(x_2)\} = \max\{0,2, 0,6\} = 0,6$$

Conclusión: El modelo elige el Coche Intermedio (x_2). El principio de Bellman-Zadeh penaliza severamente el “eslabón más débil” (en el deportivo, el precio era inaceptable), logrando así la decisión más equilibrada.

El Problema Clásico (Crisp)

Un problema general de programación no lineal se formula como:

Minimizar $f(x)$

Sujeto a: $g_i(x) \leq 0, \quad i = 1, 2, \dots, m$

Aquí, las restricciones son rígidas. Cualquier violación, por mínima que sea, hace que la solución sea infactible.

El Problema Difuso ($\tilde{M}P$)

En un entorno difuso, permitimos cierta flexibilidad estableciendo un **nivel de aspiración** z_0 para el objetivo y **tolerancias** para las restricciones:

$$\begin{aligned} \text{Encontrar } x \text{ tal que: } & f(x) \lesssim z_0 \\ & g_i(x) \lesssim 0, \quad i = 1, 2, \dots, m \end{aligned}$$

Donde el símbolo $\lesssim$ denota “esencialmente menor o igual que”.

$$f(x) \lesssim z_0$$

De esto se obtiene la siguiente función de pertenencia, con tolerancia p_0

$$\mu_f(x) = \begin{cases} 1, & \text{si } f(x) \leq z_0 \\ (0, 1), & \text{si } z_0 < f(x) < z_0 + p_0 \\ 0, & \text{si } f(x) \geq z_0 + p_0 \end{cases}$$

Definición de Tolerancias

Para resolver ($\tilde{M}P$), definimos márgenes de error aceptables:

- p_0 : Violación máxima permitida para la función objetivo.
- p_i : Violación máxima permitida para la i -ésima restricción.

Modelado de la Satisfacción

La satisfacción del tomador de decisiones se modela mediante funciones de pertenencia. En este enfoque, utilizaremos **funciones de pertenencia exponenciales**, las cuales penalizan de manera no lineal las desviaciones de las metas.

Funciones de Pertenencia Exponenciales

Para la Función Objetivo

$$\mu_0(x) = \begin{cases} 1, & \text{si } f(x) - z_0 \leq 0 \\ \frac{e^{-F} - e^{-\alpha}}{1 - e^{-\alpha}}, & \text{si } 0 < f(x) - z_0 < p_0 \\ 0, & \text{si } f(x) - z_0 \geq p_0 \end{cases}$$

Donde $F = \alpha \left(\frac{f(x) - z_0}{p_0} \right)$ y $\alpha > 0$ es un parámetro de forma.

Para las Restricciones ($i = 1, \dots, m$)

$$\mu_i(x) = \begin{cases} 1, & \text{si } g_i(x) \leq 0 \\ \frac{e^{-G_i} - e^{-\alpha_i}}{1 - e^{-\alpha_i}}, & \text{si } 0 < g_i(x) < p_i \\ 0, & \text{si } g_i(x) \geq p_i \end{cases}$$

Donde $G_i = \alpha_i \left(\frac{g_i(x)}{p_i} \right)$ y $\alpha_i > 0$.

Caso de Estudio: Consumo Eléctrico en Tuxtla Gutiérrez

Contexto del Problema

En un hogar de 4 personas en Tuxtla Gutiérrez, se busca optimizar el consumo eléctrico bimestral. Debido al clima cálido, el uso de ventiladores y aire acondicionado eleva la demanda. La CFE penaliza los altos consumos con tarifas escalonadas, por lo que buscamos un equilibrio justo entre los habitantes.

Variables de Decisión

Sean x_1, x_2, x_3, x_4 el consumo eléctrico bimestral (en kWh) de cada uno de los 4 habitantes.

Función Objetivo No Lineal

Para modelar el aumento acelerado del costo de la tarifa de luz, definimos una función objetivo cuadrática (estrictamente convexa):

$$f(x) = x_1^2 + x_2^2 + x_3^2 + x_4^2$$

Queremos minimizar $f(x)$ buscando un nivel de aspiración ideal $z_0 = 80,000$, permitiendo una desviación máxima $p_0 = 20,000$.

Restricciones Difusas

- **Límite del Subsidio CFE:** El hogar debe intentar mantenerse por debajo del límite de alto consumo (aprox. 800 kWh bimestrales), con una tolerancia $p_{CFE} = 150$ kWh.

$$g_1(x) = x_1 + x_2 + x_3 + x_4 - 800 \lesssim 0$$

- **Necesidad Básica Mínima:** Cada persona requiere un mínimo indispensable de energía (ej. 100 kWh para celular, luces, refri compartido), con una tolerancia $p_i = 20$ kWh.

$$g_{i+1}(x) = 100 - x_i \lesssim 0, \quad \text{para } i = 1, 2, 3, 4$$

Restricciones Difusas

$$\text{Minimizar } f(x) = x_1^2 + x_2^2 + x_3^2 + x_4^2 - 80000 \lesssim 0$$

$$\text{Sujeto a: } g_1(x) = x_1 + x_2 + x_3 + x_4 - 800 \lesssim 0,$$

$$g_{i+1} = 100 - x_i \lesssim 0 \quad i = 1, 2, 3, 4$$

$$p_0 = 20000, p_1 = 150, p_i = 20 \quad i = 2, 3, 4$$

Modelando la Incertidumbre (Gupta et al.)

Utilizando los parámetros de forma α para el objetivo y α_j para las restricciones, definimos la satisfacción:

Para la función de costo (Objetivo):

$$\mu_0(x) = \frac{e^{-F} - e^{-\alpha}}{1 - e^{-\alpha}}, \quad \text{donde } F = \alpha \left(\frac{f(x) - 80000}{20000} \right)$$

Para la restricción global de CFE (g_1):

$$\mu_1(x) = \frac{e^{-G_1} - e^{-\alpha_1}}{1 - e^{-\alpha_1}}, \quad \text{donde } G_1 = \alpha_1 \left(\frac{x_1 + x_2 + x_3 + x_4 - 800}{150} \right)$$

$$\mu_i(x) = \frac{e^{-G_i} - e^{-\alpha_i}}{1 - e^{-\alpha_i}}, \quad \text{donde } G_i = \alpha_i \left(\frac{100 - x_i}{20} \right)$$

Tomando

$$\xi = \min\{\mu_1(x), \dots, \mu_m(x)\}$$

$$\xi \leq \mu_i, \quad i = 1, 2, \dots, m$$

El Problema (PP-1)

Aplicando el Principio de Maximización de Bellman-Zadeh y la transformación logarítmica, convertimos el modelo difuso en un problema de optimización convexo determinista:

Maximizar ξ

$$\text{Sujeto a: } 20000 \log(\xi + e^{-\alpha}(1 - \xi)) \leq \alpha(80000 - (x_1^2 + x_2^2 + x_3^2 + x_4^2))$$

$$150 \log(\xi + e^{-\alpha_1}(1 - \xi)) \leq -\alpha_1(x_1 + x_2 + x_3 + x_4 - 800)$$

$$20 \log(\xi + e^{-\alpha_j}(1 - \xi)) \leq -\alpha_j(100 - x_{j-1}), \quad j = 2, 3, 4, 5$$

$$0 \leq \xi \leq 1$$

$$x_i \geq 0, \quad i = 1, 2, 3, 4$$

Transformación a un Problema Convexo Nítido

Se realizó una implementación en python utilizando la librería `scipy.optimize` (utilizando el método SLSQP)

```
1 import numpy as np
2 from scipy.optimize import minimize
3
4 # =====
5 # 1. DEFINICIÓN DE HIPERPARÁMETROS (Alfas)
6 # =====
7 # Se inicializan en 1.0 para una primera prueba (análisis de sensibilidad)
8 alpha = 3 # Parámetro para la meta de costo
9 alpha_1 = 1 # Parámetro para el límite global de CFE
10 alpha_j = 0.5 # Parámetro para las necesidades básicas individuales
11
12 # =====
13 # 2. FUNCIÓN OBJETIVO
14 # =====
15 # El vector de decisión 'v' contiene: [x1, x2, x3, x4, xi]
16
17 # Maximizar xi es matemáticamente idéntico a minimizar -xi.
18 def objetivo(v):
19     return -v[4]
20
21 # =====
22 # 3. RESTRICCIONES (Sujeto a:)
23 # =====
24 # Scipy requiere que la restricción se exprese como "función >= 0".
25
26 def restriccion_costo(v):
27     x1, x2, x3, x4, xi = v
```

Transformación a un Problema Convexo Nítido

```
27 x1, x2, x3, x4, xi = v
28 izq = 20000 * np.log(x1 + np.exp(-alpha) * (1 - xi))
29 der = alpha * (80000 - (x1**2 + x2**2 + x3**2 + x4**2))
30 return der - izq
31
32 def restriccion_cfe(v):
33     x1, x2, x3, x4, xi = v
34     izq = 150 * np.log(xi + np.exp(-alpha_1) * (1 - xi))
35     der = -alpha_1 * (x1 + x2 + x3 + x4 - 800)
36     return der - izq
37
38 # Función genérica para los 4 habitantes (j = 2, 3, 4, 5)
39 def restriccion_necesidad(v, indice_x):
40     x_j = v[indice_x]
41     xi = v[4]
42     izq = 20 * np.log(xi + np.exp(-alpha_j) * (1 - xi))
43     der = -alpha_j * (100 - x_j)
44     return der - izq
45
46 # Diccionario de restricciones para el algoritmo
47 restricciones = [
48     {'type': 'ineq', 'fun': restriccion_costo},
49     {'type': 'ineq', 'fun': restriccion_cfe},
50     {'type': 'ineq', 'fun': lambda v: restriccion_necesidad(v, 0)}, # Para x1
51     {'type': 'ineq', 'fun': lambda v: restriccion_necesidad(v, 1)}, # Para x2
52     {'type': 'ineq', 'fun': lambda v: restriccion_necesidad(v, 2)}, # Para x3
53     {'type': 'ineq', 'fun': lambda v: restriccion_necesidad(v, 3)} # Para x4
54 ]
55
56 # =====
57 # 4. LÍMITES Y CONDICIONES INICIALES
58 # =====
59 # Límites: xi entre 0 y 1. Consumos x_i >= 0.
60 limites = [(0, None), (0, None), (0, None), (0, None), (0, 1)]
61
```

Transformación a un Problema Convexo Nítido

```
57 # 4. LÍMITES Y CONDICIONES INICIALES
58 # =====
59 # Límites:  $x_i$  entre 0 y 1. Consumos  $x_i \geq 0$ .
60 limites = [(0, None), (0, None), (0, None), (0, None), (0, 1)]
61
62 # Punto de partida (guess inicial)
63 # Empezamos asumiendo que cada quien consume sus 100 kwh básicos y un nivel de satisfacción medio (0.5)
64 v_inicial = [100.0, 100.0, 100.0, 100.0, 0.5]
65
66 # =====
67 # 5. EJECUCIÓN DEL ALGORITMO
68 # =====
69 resultado = minimize(objetivo, v_inicial, method='SLSQP', bounds=limites, constraints=restricciones)
70
71 # =====
72 # 6. RESULTADOS
73 # =====
74 print("--- RESULTADOS DEL MODELO EN TUXTLA GUTIÉRREZ ---")
75 print(f"Estado del Solver: {resultado.message}")
76 print(f"Nivel Máximo de Satisfacción ( $x_i$ ): {resultado.x[4]:.4f}")
77 print("-" * 45)
78 print(f"Consumo Habitante 1 ( $x_1$ ): {resultado.x[0]:.2f} kWh")
79 print(f"Consumo Habitante 2 ( $x_2$ ): {resultado.x[1]:.2f} kWh")
80 print(f"Consumo Habitante 3 ( $x_3$ ): {resultado.x[2]:.2f} kWh")
81 print(f"Consumo Habitante 4 ( $x_4$ ): {resultado.x[3]:.2f} kWh")
82 print("-" * 45)
83 print(f"Consumo Total CFE: {sum(resultado.x[0:4]):.2f} kWh")

... --- RESULTADOS DEL MODELO EN TUXTLA GUTIÉRREZ ---
Estado del Solver: Optimization terminated successfully
Nivel Máximo de Satisfacción ( $x_i$ ): 1.0000
-----
Consumo Habitante 1 ( $x_1$ ): 100.01 kWh
Consumo Habitante 2 ( $x_2$ ): 100.01 kWh
Consumo Habitante 3 ( $x_3$ ): 100.01 kWh
Consumo Habitante 4 ( $x_4$ ): 100.01 kWh
```

Interpretación de la Solución Óptima

Si aumentamos el requerimiento energético en $160kWh$ por persona se tiene el siguiente resultado

```
--- RESULTADOS: OLA DE CALOR EN TUXTLA GUTIÉRREZ ---  
Estado del Solver: Optimization terminated successfully  
Nivel Máximo de Satisfacción ( $\xi$ ): 0.3165  
-----  
Consumo Habitante 1: 147.47 kWh  
Consumo Habitante 2: 147.47 kWh  
Consumo Habitante 3: 147.47 kWh  
Consumo Habitante 4: 147.47 kWh  
-----  
Consumo Total CFE: 589.88 kWh  
Costo Cuadrático Total: 86989.01
```

- **Flexibilidad:** La optimización difusa permitió gestionar la incertidumbre del clima de Tuxtla y los hábitos de 4 personas diferentes.
- **Convexidad:** Al usar funciones cuadráticas (objetivo) y lineales (restricciones), aseguramos la existencia de una solución óptima única y global, cumpliendo con la teoría de Gupta et al.
- **Toma de decisiones:** La optimización no solo "hace cálculos", sino que nos ayuda a decidir cómo distribuir un recurso limitado (electricidad) de manera justa y económica.

Líneas de Investigación y Extensión

- **Modelado Estacional Dinámico:** Incorporar variaciones de temperatura mensuales en Tuxtla Gutiérrez mediante parámetros difusos de tipo intervalo o trapezoidales.
- **Optimización Multiobjetivo Difusa:** Modelar de forma independiente el conflicto entre el confort térmico (uso de aire acondicionado) y la minimización del costo de facturación CFE.
- **Análisis de Precios Sombra (Dualidad):** Implementar el problema dual (DP-1) para calcular el costo marginal o la valoración económica de flexibilizar las tolerancias p_0 y p_i [cite: 1].

-  Zadeh, L. A. (1965). *Fuzzy Sets*. Information and Control, 8(3), 338–353. doi:10.1016/S0019-9958(65)90241-X
-  Gupta, P., et. al. (2014). *Fuzzy Portfolio Optimization: Theory and Methods*. Springer, Berlin, Heidelberg.
doi:10.1007/978-3-642-54652-5
-  *Duality in nonlinear programming problems under fuzzy environment with exponential membership functions*. Journal of Inequalities and Applications (2018).
DOI: 10.1186/s13660-018-1812-x

Gracias

