

Reconocimiento de Caracteres Manuscritos mediante Modelos Ocultos de Markov

Mariana Belén Cruz Rodríguez

Licenciatura en Matemáticas Aplicadas
Facultad de Ciencias en Física y Matemáticas
Benemérita Universidad Autónoma de Chiapas

Asesor: Dr. Yofre Hernán García Gómez
Reunión Anual MexSIAM 2026

20 de agosto de 2026

Índice

- 1 Introducción
- 2 Marco Teórico
- 3 Inferencia y Aprendizaje
- 4 Desarrollo y Aplicación
- 5 Resultados
- 6 Conclusiones

Motivación

La digitalización de documentos manuscritos presenta diversos desafíos:

- Variabilidad entre escritores.
- Diferencias en tamaño, inclinación y proporción.
- Distorsiones y ruido en las imágenes.
- Similitud entre algunos caracteres.
- Diferencias en la forma de realizar un mismo trazo.

Por esta razón, reconocer un carácter manuscrito no consiste únicamente en comparar dos imágenes.

Se necesita una representación que permita describir la información presente en la imagen y, al mismo tiempo, considerar la **incertidumbre** inherente al proceso de reconocimiento.

El problema del reconocimiento

Supongamos que recibimos una imagen correspondiente a una letra manuscrita.

El objetivo es determinar a cuál de las clases disponibles pertenece:

$$O \longrightarrow \{A, B, C, \dots, Z\}.$$

Sin embargo, dos imágenes correspondientes a la misma letra pueden ser considerablemente diferentes.

Por ejemplo, una misma letra puede presentar:

- diferentes grosores de trazo,
- diferentes inclinaciones,
- pequeñas deformaciones,
- ruido o información irrelevante.

Por lo tanto, se busca una decisión basada en la **probabilidad de que cada modelo explique la observación**.

Enfoque probabilístico

En el reconocimiento de caracteres rara vez existe una decisión completamente determinista.

Para una observación O , puede ocurrir que:

$$P(A \mid O) = 0.82, \quad P(H \mid O) = 0.14, \quad P(P \mid O) = 0.04.$$

En este caso, el modelo no afirma que la imagen sea inequívocamente una letra A.

Lo que hace es cuantificar qué tan compatible es la observación con cada una de las posibles clases.

Por tanto, el problema puede formularse como:

Inferir el carácter más probable dado un conjunto de observaciones.

Procesos estocásticos

Un **proceso estocástico** es, en esencia, una colección de variables aleatorias

$$\{X_t\}_{t \in T}$$

que modelan la evolución de un sistema sujeto a incertidumbre a lo largo del tiempo o del espacio.

De manera particular una imagen puede ser recorrida espacialmente y transformada en una secuencia de observaciones.

De esta manera, podemos estudiar la información de la imagen como:

$$O = (o_1, o_2, \dots, o_T).$$

Se busca entonces modelar probabilísticamente la dependencia entre estas observaciones.

Cadenas de Markov

Sea $\{X_t\}_{t \geq 0}$ un proceso estocástico definido sobre un espacio de probabilidad $(\Omega, \mathcal{F}, P)$, que toma valores en un espacio de estados discreto S .

Propiedad de Markov

Se dice que este proceso es una **Cadena de Markov** si:

$$P(X_{t+1} = j \mid X_t = i, X_{t-1}, \dots, X_0) = P(X_{t+1} = j \mid X_t = i).$$

La idea fundamental es que el futuro depende del **estado actual**, pero no directamente de toda la historia anterior.

Esto puede interpretarse como una especie de **pérdida de memoria**.


Ejemplo: Modelo del Clima

Consideremos un sistema con dos estados: $S = \{1, 2\}$,
donde 1 representa **Soleado** y 2 representa **Lluvioso**.

Las probabilidades de transición se organizan en una matriz:

$$A = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}.$$

Por ejemplo: $P(\text{Sol} \mid \text{Sol}) = 0.8$ y $P(\text{Lluvia} \mid \text{Sol}) = 0.2$.



De una Cadena de Markov a un HMM


En una Cadena de Markov suponemos que podemos observar directamente el estado del sistema.

Por ejemplo:

Soleado $\rightarrow$ Lluvioso $\rightarrow$ Lluvioso.

Pero existen muchos problemas donde el estado real **no puede observarse directamente**.

En el reconocimiento de caracteres ocurre algo similar:



No observamos directamente el estado que describe la estructura interna del carácter. Lo que observamos es una imagen y, posteriormente, una secuencia de características extraídas de ella.

Modelo Oculto de Markov

Un Modelo Oculto de Markov, o HMM, es un modelo estadístico donde el sistema se considera como un proceso de Markov cuyos estados **no son directamente observables**.

Formalmente, consta de dos procesos relacionados:

- 1 Un proceso de **estados ocultos**

$$Q = (q_1, q_2, \dots, q_T).$$

- 2 Un proceso de **observaciones**

$$O = (o_1, o_2, \dots, o_T).$$


Los estados ocultos siguen una dinámica de Markov:

$$P(q_{t+1} \mid q_t, q_{t-1}, \dots) = P(q_{t+1} \mid q_t).$$

Mientras que cada observación depende del estado oculto correspondiente.

Estructura de un HMM

La estructura básica puede representarse como:



Los estados q_t son ocultos, mientras que las observaciones o_t son las variables que podemos obtener de los datos.

Parámetros del Modelo (λ)

Un HMM queda caracterizado por el triplete: $\lambda = (A, B, \pi)$.

Matriz de transición:

$$a_{ij} = P(q_{t+1} = s_j \mid q_t = s_i).$$

Describe cómo evoluciona el sistema entre estados.

Matriz de emisión:

$$b_j(k) = P(o_t = v_k \mid q_t = s_j).$$

Relaciona los estados ocultos con las observaciones.

Distribución inicial:

$$\pi_i = P(q_1 = s_i).$$

Indica la probabilidad de comenzar en cada estado.

Interpretación de los parámetros

En el contexto del reconocimiento de caracteres podemos interpretar los parámetros de la siguiente manera:

A : transición

Describe cómo puede avanzar la estructura interna del modelo de una posición a otra.

B : emisión

Describe qué características son más probables de observar cuando el modelo se encuentra en determinado estado.

π : estado inicial

Determina qué estados tienen mayor probabilidad de aparecer al comienzo de la secuencia.

Por tanto, los parámetros no son únicamente matrices abstractas: representan diferentes aspectos del comportamiento estadístico del carácter.

Ejemplo intuitivo de un HMM

Imagina que trabajas en una oficina sin ventanas.

No puedes observar el clima, pero cada día observas qué trae puesto tu compañero.

Estados ocultos

$$S = \{\text{Sol}, \text{Lluvia}\}$$

Por ejemplo:

$$P(\text{Paraguas} \mid \text{Lluvia}) = 0.85$$

Observaciones

$$V = \{\text{Camiseta}, \text{Paraguas}\}$$

mientras que:

$$P(\text{Paraguas} \mid \text{Sol}) = 0.05.$$

Aunque no vemos directamente el clima, podemos inferirlo a partir de las observaciones.

Esta es precisamente la idea que posteriormente trasladamos al reconocimiento de caracteres.

Los tres problemas fundamentales

Para aplicar un HMM a un problema real es necesario resolver tres problemas fundamentales:

1 Evaluación

Dada una secuencia O y un modelo λ , calcular:

$$P(O \mid \lambda).$$

2 Decodificación

Encontrar la secuencia de estados ocultos más probable:

$$Q^* = \arg \max_Q P(Q, O \mid \lambda).$$

3 Aprendizaje

Ajustar los parámetros del modelo para explicar mejor los datos:

$$\lambda^* = \arg \max_{\lambda} P(O \mid \lambda).$$

Estos problemas se abordan mediante los algoritmos **Forward**, **Viterbi** y **Baum-Welch**.

Evaluación: Algoritmo Forward

El objetivo es calcular: $P(O \mid \lambda)$.

De forma directa es considerar todas las posibles trayectorias de estados, pero el número de trayectorias crece rápidamente con la longitud de la secuencia.

Para evitar este problema se define:

$$\alpha_t(i) = P(o_1, \dots, o_t, q_t = i \mid \lambda).$$

La recursión es:
$$\alpha_{t+1}(j) = \left(\sum_{i=1}^N \alpha_t(i) a_{ij} \right) b_j(o_{t+1}).$$

Finalmente:
$$P(O \mid \lambda) = \sum_{i=1}^N \alpha_T(i).$$

Forward en nuestro problema

Para una letra determinada, tenemos un modelo: λ_A .

Y una imagen que después del procesamiento se transforma en:

$$O = (o_1, o_2, \dots, o_T).$$

El algoritmo Forward nos permite calcular:

$$P(O \mid \lambda_A).$$

Este valor representa qué tan compatible es la secuencia observada con el modelo correspondiente a la letra A.

Si tenemos un modelo para cada letra:

$$\lambda_A, \lambda_B, \dots, \lambda_Z,$$

podemos comparar sus probabilidades, por lo tanto, Forward se convierte en una herramienta fundamental para la **clasificación**.

Decodificación: Algoritmo de Viterbi

Viterbi busca la secuencia de estados ocultos más probable:

$$Q^* = \arg \max_Q P(Q, O \mid \lambda).$$

Se define:

$$\delta_t(i) = \max_{q_1, \dots, q_{t-1}} P(q_1, \dots, q_t = i, o_1, \dots, o_t \mid \lambda).$$

La recursión es:

$$\delta_{t+1}(j) = \max_i [\delta_t(i) a_{ij}] b_j(o_{t+1}).$$

Posteriormente, mediante *backtracking*, se reconstruye la trayectoria completa.

Aporte de Viterbi

Mientras que Forward responde:

¿Qué tan probable es esta observación bajo el modelo?

Viterbi responde:

¿Cuál es la trayectoria de estados más probable que explica esta observación?

En el contexto de una imagen, esto permite interpretar cómo el modelo recorre espacialmente el carácter.

Es decir, no solamente tenemos una probabilidad final, sino también una posible explicación de cómo el modelo llegó a ella.

Aprendizaje: Algoritmo de Baum-Welch

El objetivo es entrenar el modelo.

Partimos de una estimación inicial de:

$$\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)}).$$

Baum-Welch es una aplicación del algoritmo **Expectation-Maximization (EM)**.

❶ **Paso E:**

Se calculan los valores esperados de las transiciones y emisiones utilizando los parámetros actuales.

❷ **Paso M:**

Se actualizan A , B y π utilizando los valores calculados.

El proceso se repite:

$$\lambda^{(0)} \rightarrow \lambda^{(1)} \rightarrow \lambda^{(2)} \rightarrow \dots \quad \text{hasta alcanzar un criterio de convergencia.}$$

Interpretación del aprendizaje

La idea de Baum-Welch puede entenderse de manera intuitiva como un proceso de ajuste.

Inicialmente, el modelo no conoce exactamente:

$$A, \quad B, \quad \pi.$$

A partir de las secuencias de entrenamiento, el algoritmo busca encontrar parámetros que hagan que las observaciones sean cada vez más probables bajo el modelo.

Por ello, después de varias iteraciones esperamos:

$$P(O \mid \lambda^{(k+1)}) \geq P(O \mid \lambda^{(k)}).$$

El resultado es un modelo entrenado específicamente para representar las características estadísticas de una determinada clase.

Aplicación al Reconocimiento de Caracteres

Una imagen bidimensional debe convertirse en una secuencia de observaciones para poder utilizar un HMM.

El proceso general es:





Imagen a secuencia

El principal reto consiste en pasar de una representación bidimensional a una representación secuencial.

Para ello, se utiliza una ventana vertical que recorre la imagen espacialmente.

Podemos representar el procedimiento de manera conceptual como:

Cada posición de la ventana proporciona información que puede transformarse en una observación o_t .



Cada columna de píxeles constituye una ventana vertical utilizada para construir la secuencia de observaciones (Matriz de Bakis).

Representación secuencial

Una vez realizado el recorrido, la imagen puede representarse como:

$$O = (o_1, o_2, o_3, \dots, o_T).$$

De esta manera:

Imagen bidimensional $\longrightarrow$ Secuencia unidimensional.

Cada observación contiene información asociada con una región de la imagen.


La ventaja de esta representación es que permite utilizar la estructura matemática de los HMM para modelar cómo cambia la información conforme avanzamos espacialmente sobre el carácter.

En otras palabras, en lugar de indexar en el tiempo, en este problema **indexamos en el espacio**.

Procesamiento de las imágenes

Antes de obtener las observaciones, las imágenes deben procesarse de manera consistente.

El objetivo del procesamiento es reducir información que no sea relevante para el reconocimiento y obtener una representación adecuada para el modelo.



Caso de estudio

Se emplea HMM en el reconocimiento de letras del **alfabeto latino**, utilizando imágenes de EMNIST.

El conjunto considera las 26 letras del alfabeto:

$$\{A, B, C, \dots, Z\}.$$

La idea central consiste en representar cada imagen como una secuencia de observaciones y entrenar un modelo independiente para cada carácter.

Así, el problema original:

$$\text{Imagen} \rightarrow \text{Letra}$$

se transforma en:

$$\text{Imagen} \rightarrow O \rightarrow \{\lambda_A, \lambda_B, \dots, \lambda_Z\} \rightarrow \text{Letra}.$$

Construcción del Sistema

Se construye un HMM para cada carácter.

Por lo tanto, se tienen:

$$\lambda_A, \lambda_B, \dots, \lambda_Z.$$

Cada modelo se entrena de manera independiente con las observaciones correspondientes a su clase.

La clasificación de una nueva imagen se realiza mediante:

$$\hat{c} = \arg \max_i P(O \mid \lambda_i)$$

donde O es la secuencia obtenida de la imagen y λ_i es el modelo correspondiente a la clase i .

De esta manera, la letra seleccionada es aquella cuyo modelo asigna mayor probabilidad a la secuencia observada.


¿Por qué un modelo para cada letra?

Una posibilidad sería construir un único modelo que representara todo el alfabeto. Sin embargo, en este trabajo se opta por construir un modelo independiente para cada carácter.

Esto permite que cada HMM aprenda las características estadísticas propias de una clase. Por ejemplo:

λ_A aprende la estructura característica de A,
mientras que: λ_T aprende la estructura característica de T.


La clasificación consiste entonces en comparar cómo se comporta la misma observación frente a todos los modelos disponibles:



Topología izquierda–derecha: Modelo Bakis

Para los modelos se emplea una topología **izquierda–derecha**, conocida como modelo de Bakis.

La idea es restringir las transiciones para que el modelo avance progresivamente a través de los estados.



Esta estructura resulta coherente con el recorrido espacial de una imagen de izquierda a derecha.

Interpretación de la topología Bakis

Supongamos que recorremos una letra desde su extremo izquierdo hasta su extremo derecho.

El modelo puede interpretar diferentes regiones mediante diferentes estados:

$$q_1 \rightarrow q_2 \rightarrow q_3 \rightarrow \cdots \rightarrow q_N.$$


Cada estado puede asociarse con determinadas características de la región de la imagen que estamos observando.

La restricción izquierda–derecha evita que el modelo realice transiciones arbitrarias hacia posiciones anteriores.

Por ello, la topología no es solamente una elección computacional, sino que incorpora una hipótesis sobre la estructura espacial del problema.

Flujo completo del sistema


El procedimiento completo puede resumirse de la siguiente manera:



Resultados

El desempeño del sistema se evaluó mediante diferentes métricas de clasificación.

La matriz de confusión permite observar no solamente cuántos caracteres fueron clasificados correctamente, sino también **qué clases tienden a confundirse entre sí.**



¿Qué nos dice la matriz de confusión?

Una matriz de confusión permite identificar dos situaciones:

- Caracteres que el modelo reconoce con mayor facilidad.
- Pares o grupos de caracteres que presentan confusión.

Las principales confusiones pueden estar relacionadas con la **similitud en la estructura visual** de algunos caracteres.

Esto es importante porque un accuracy global no proporciona toda la información sobre el comportamiento del modelo.

Por ello, también resulta necesario analizar el desempeño **individual por letra**.

Exactitud Individual por Letra

Letra	Precisión	Letra	Precisión
Precisión Letra A	83.25 %	Precisión Letra N	66.75 %
Precisión Letra B	64.50 %	Precisión Letra O	81.75 %
Precisión Letra C	64.50 %	Precisión Letra P	79.25 %
Precisión Letra D	72.25 %	Precisión Letra Q	68.00 %
Precisión Letra E	74.75 %	Precisión Letra R	70.00 %
Precisión Letra F	79.50 %	Precisión Letra S	82.25 %
Precisión Letra G	70.75 %	Precisión Letra T	91.00 %
Precisión Letra H	80.00 %	Precisión Letra U	69.25 %
Precisión Letra I	76.50 %	Precisión Letra V	73.75 %
Precisión Letra J	75.00 %	Precisión Letra W	70.50 %
Precisión Letra K	80.37 %	Precisión Letra X	83.75 %
Precisión Letra L	76.75 %	Precisión Letra Y	79.25 %
Precisión Letra M	81.25 %	Precisión Letra Z	84.50 %

Interpretación de la precisión por letra

Podemos observar diferencias importantes entre las clases.

La letra **T** presenta una precisión de:

91.00 %.

Mientras que la letra **N** presenta:

66.75 %.

Esto muestra que el comportamiento del modelo no es uniforme para todas las clases.

Una posible explicación es que algunas letras poseen estructuras espaciales más fáciles de distinguir mediante las características utilizadas, mientras que otras pueden presentar mayor similitud con diferentes caracteres.

Por ello, analizar únicamente el resultado global puede ocultar diferencias importantes entre las clases.

Reporte de Clasificación

	precision	recall	f1-score	support
A	0.73	0.83	0.78	400
B	0.71	0.65	0.68	400
C	0.78	0.65	0.71	400
D	0.78	0.72	0.75	400
E	0.62	0.75	0.67	400
F	0.85	0.80	0.82	400
G	0.73	0.71	0.72	400
H	0.82	0.80	0.81	400
I	0.78	0.77	0.77	400
J	0.80	0.75	0.77	400
K	0.83	0.80	0.82	382
L	0.92	0.77	0.84	400
M	0.70	0.81	0.75	400

	precision	recall	f1-score	support
N	0.63	0.67	0.65	400
O	0.66	0.82	0.73	400
P	0.83	0.79	0.81	400
Q	0.77	0.68	0.72	400
R	0.70	0.70	0.70	400
S	0.76	0.82	0.79	400
T	0.89	0.91	0.90	400
U	0.74	0.69	0.72	400
V	0.74	0.74	0.74	400
W	0.64	0.70	0.67	400
X	0.88	0.84	0.86	400
Y	0.80	0.79	0.80	400
Z	0.82	0.84	0.83	400
accuracy			0.76	10382
macro avg	0.77	0.76	0.76	10382
weighted avg	0.77	0.76	0.76	10382

Accuracy global: 76.12 %

Interpretación de las métricas

El reporte permite analizar diferentes aspectos del desempeño.

- **Precision:** $\frac{VP}{VP + FP}$
Representa qué proporción de las predicciones asignadas a una clase fueron correctas.
- **Recall:** $\frac{VP}{VP + FN}$
Indica qué proporción de los ejemplos reales de una clase fueron correctamente identificados.
- **F1-score:** $2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
Combina precision y recall en una sola medida.

Resultado global

El sistema obtiene un:

$$\text{Accuracy} = 76.12 \%$$

sobre las clases consideradas.

El resultado debe interpretarse considerando que se trata del reconocimiento de:

26 clases

correspondientes a las letras del alfabeto.

A medida que aumenta el número de clases, el problema de clasificación se vuelve más exigente, especialmente cuando existen caracteres con formas visualmente similares.


Por ello, además del resultado global, resulta importante analizar las métricas individuales y la matriz de confusión.

Conclusiones

- 1 Los HMM proporcionan un marco probabilístico sólido para el reconocimiento de caracteres.
- 2 El problema puede formularse como un proceso estocástico con estados ocultos y observaciones asociadas.
- 3 Los algoritmos Forward, Viterbi y Baum–Welch permiten abordar los problemas fundamentales de evaluación, decodificación y aprendizaje.
- 4 La representación secuencial de las imágenes permite aplicar herramientas de teoría de probabilidades al reconocimiento de patrones.

Conclusión final

La idea principal del trabajo puede resumirse en una cadena:



El enfoque permite interpretar el reconocimiento de caracteres no solamente como un problema de clasificación, sino como un problema de **inferencia probabilística sobre una estructura oculta**.

El resultado obtenido muestra que los HMM pueden utilizarse para este tipo de reconocimiento, aunque también deja abierta la posibilidad de mejorar la representación de las observaciones y la arquitectura de los modelos.

Referencias I



Chen, J., Zhang, B., Prasad, R., Cao, H., & Natarajan, P. (2012).

Applying Discriminatively Optimized Feature Transform for HMM-Based Off-Line Handwriting Recognition.

2012 International Conference on Frontiers in Handwriting Recognition. IEEE.



Cohen, G., Afshar, S., Tapson, J., & van Schaik, A. (2017).

EMNIST: An Extension of MNIST to Handwritten Letters.

arXiv preprint arXiv:1702.05373.



Norris, J. R. (1998).

Markov Chains.

Cambridge University Press.



Rabiner, L. R. (1989).

A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition.

Proceedings of the IEEE, 77(2): 257–286.

Referencias II



Rudin, W. (1987).

Real and Complex Analysis (3rd ed.).

McGraw-Hill.

Gracias por su atención.