

¿Por qué estudiar optimización hoy? Teoría, datos y sistemas inteligentes

Yofre H. García

Seminario FCFM
Benemérita Universidad Autónoma de Chiapas

12 de marzo de 2026

Asignación óptima de recursos en una pandemia

Problema

Distribuir recursos limitados durante una epidemia con el objetivo de reducir el impacto de la enfermedad.

Ejemplos de recursos:

- vacunas
- pruebas diagnósticas
- personal médico
- campañas de prevención

Cada región responde de forma distinta a estos recursos.

Variables de decisión

x_i = recursos asignados a la región i , $i = 1, \dots, n$

Parámetros

- B : recursos totales disponibles
- a_i : reducción esperada de contagios por unidad de recurso
- d_i : capacidad máxima de recursos en la región i

Modelo de optimización

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^n a_i x_i \\ \text{s.a.} \quad & \sum_{i=1}^n x_i \leq B \\ & 0 \leq x_i \leq d_i \quad i = 1, \dots, n \end{aligned}$$

Interpretación

- $\sum x_i \leq B$: el total de recursos asignados no puede exceder la disponibilidad global.
- $0 \leq x_i \leq d_i$: cada región tiene una capacidad limitada para utilizar los recursos.

Teorema fundamental de programación lineal

Si el conjunto factible

$$P = \{x \in \mathbb{R}^n : Ax \leq b, x \geq 0\}$$

es no vacío y el problema tiene solución óptima finita, entonces existe una solución óptima que es un **punto extremo** de P .



M. S. Bazaraa, H. D. Sherali, and C. M. Shetty,
Nonlinear Programming: Theory and Algorithms,
3rd ed., Wiley, 2006.


Programación lineal: aplicaciones y métodos

Aplicaciones

- mezcla de recursos
- transporte
- asignación hospitalaria
- cadenas de suministro biomédicas
- reconstrucción de redes biológicas por ILP

Métodos - (Incluso de gran escala)

- Método Big-M (simplex)
- Métodos de punto interior



Karmarkar, N. (1984). *A new polynomial-time algorithm for linear programming.*
DOI: 10.1007/BF02579150

Conexión IA + Optimización

Estimación de probabilidad de colisión

Sensores del vehículo

- x_1 : distancia al obstáculo (LiDAR)
- x_2 : velocidad relativa (radar)

Mediciones normalizadas

$$x_1 = 0,8, \quad x_2 = 0,6$$

Neurona de salida


$$s = w_1 x_1 + w_2 x_2 + b$$

$$s = 2(0,8) + 1,5(0,6) - 1 = 1,5$$

Probabilidad de colisión

$$P_{coll} = \frac{1}{1 + e^{-s}} \Rightarrow P_{coll} \approx 0,82$$

Riesgo alto $\Rightarrow$ el sistema debe reducir velocidad.



Mohseni, F., Voronov, S., Frisk, E. (2018). *Deep Learning Model Predictive Control for Autonomous Driving in Unknown Environments*. DOI: [10.1016/j.ifacol.2018.11.593](https://doi.org/10.1016/j.ifacol.2018.11.593)

Sensores

$$(x_1, x_2, \dots, x_n)$$



Red neuronal profunda

$$P_{coll} \in [0, 1]$$



Función de costo del control óptimo

$$J = (1 - P_{coll})J_{task} + P_{coll}J_{risk}$$



Optimización (MPC)

mín J



Controles óptimos

Proceso nacimiento–muerte

Sistema químico estocástico



Interpretación

- θ_1 : tasa de producción de moléculas
- θ_2 : tasa de degradación
- $X(t)$: número de moléculas de S


Propensiones

$$a_1(x) = \theta_1$$

$$a_2(x) = \theta_2 x$$

$$a_0(x) = \theta_1 + \theta_2 x$$

Esquema del proceso



Interpretación

- nacimiento: $x \rightarrow x + 1$
- muerte: $x \rightarrow x - 1$

Trayectoria

$$z = (\tau_1, j_1, \tau_2, j_2, \dots, \tau_r, j_r)$$

donde

- τ_i es el tiempo entre dos reacciones consecutivas,
- j_i es el índice de la reacción que ocurre en ese salto,
- r es el número total de reacciones observadas en el intervalo de tiempo.

Estimación por máxima verosimilitud

Verosimilitud de una trayectoria

Sea

- r_1 número de nacimientos
- r_2 número de muertes
- T tiempo total

$$L(\theta_1, \theta_2) = \theta_1^{r_1} \theta_2^{r_2} \exp \left(- \sum_{i=1}^{r+1} \tau_i (\theta_1 + \theta_2 x_{i-1}) \right)$$

Log-verosimilitud

$$\ell(\theta_1, \theta_2) = r_1 \log \theta_1 + r_2 \log \theta_2 - \theta_1 T - \theta_2 \sum_{i=1}^{r+1} \tau_i x_{i-1}$$



Daigle, B. J., Roh, M. K., Petzold, L. R., Niemi, J. (2012). *Accelerated maximum likelihood parameter estimation for stochastic biochemical systems*. DOI: 10.1186/1471-2105-13-68

Problema de optimización

$$\max_{\theta_1, \theta_2 > 0} \ell(\theta_1, \theta_2)$$

Estimadores MLE

$$\hat{\theta}_1 = \frac{r_1}{T}$$

$$\hat{\theta}_2 = \frac{r_2}{\sum_{i=1}^{r+1} \tau_i x_{i-1}}$$

Dificultad práctica

- las trayectorias completas no se observan
- sólo hay mediciones discretas
- se requiere inferencia con datos incompletos

Nota

En la práctica no se observa la trayectoria completa del sistema, sino únicamente algunos valores de $X(t)$:

t	0	5	10	15
S	17	19	15	18

Entre dos observaciones pueden ocurrir múltiples combinaciones de nacimientos y muertes que producen el mismo estado final.

Modelo dinámico estocástico

Variables de estado

$$x_t = \begin{bmatrix} d_t - d_t^* \\ \Delta v_t \end{bmatrix}$$

donde

- $d_t - d_t^*$: error de distancia respecto a la separación deseada
- Δv_t : velocidad relativa con el vehículo precedente

Modelo estocástico

$$x_{t+1} = Ax_t + Bu_t + w_t$$

$$y_t = Cx_t + v_t$$


donde

- u_t : aceleración del vehículo controlado
- $w_t \sim \mathcal{N}(0, H)$: perturbación en la dinámica
- $v_t \sim \mathcal{N}(0, M)$: ruido de medición

Interpretación

El vehículo no observa directamente el estado verdadero, sino una medición ruidosa del entorno.

Esquema del sistema



Idea

- el estado evoluciona con incertidumbre
- el sensor observa con error
- el control se calcula a partir de información imperfecta

Problema de control óptimo estocástico

Función objetivo

En un horizonte de predicción T , se busca minimizar

$$J(x, u) = \mathbb{E} \left[\sum_{k=1}^T \left(x_{t+k}^T Q x_{t+k} + u_{t+k-1}^T R u_{t+k-1} \right) \right]$$

Interpretación

- $x_{t+k}^T Q x_{t+k}$: penaliza errores de separación y velocidad relativa. El término cuadrático del costo es

$$x_t^T Q x_t = q_1 (d_t - d_t^*)^2 + q_2 (\Delta v_t)^2,$$

con matriz de ponderación de pesos

$$Q = \begin{bmatrix} q_1 & 0 \\ 0 & q_2 \end{bmatrix}, \quad q_1, q_2 > 0$$

- $u_{t+k-1}^T R u_{t+k-1}$: penaliza aceleraciones bruscas

Objetivo físico

- mantener distancia deseada
- suavizar la conducción
- reducir riesgo de colisión

El problema se resuelve en esquema de **rolling horizon**: optimizar en un horizonte corto, aplicar solo el primer control y volver a optimizar

Restricciones

$$x_{t+1} = A x_t + B u_t + w_t$$

$$y_t = C x_t + v_t$$

Seguridad


$$d_t \geq d_{\text{safe}}$$

Límites físicos

$$u_{\text{mín}} \leq u_t \leq u_{\text{máx}}$$

Control receding horizon

horizonte de predicción



- el costo mide eficiencia y confort
- las restricciones imponen seguridad
- la incertidumbre entra vía w_t y v_t

Resolución eficiente del problema

Principio de separación

El problema de control óptimo estocástico puede dividirse en dos partes:

1. Estimación del estado

$$\hat{x}_{t+1} = A\hat{x}_t + Bu_t + K_t(y_t - C\hat{x}_t)$$

- se utiliza un **filtro de Kalman**
- permite estimar el estado real a partir de mediciones ruidosas

2. Control óptimo


$$u_t = -K\hat{x}_t$$

- solución del problema LQG
- obtenida mediante ecuación de Riccati

Idea clave

- estimar el estado del sistema
- calcular el control óptimo
- aplicar el primer control y repetir el proceso

Arquitectura del controlador



Resultado

- control robusto ante incertidumbre
- conducción suave y segura
- implementación en tiempo real



Zhou, Y., Ahn, S., Chitturi, M., Noyce, D. (2017). *Rolling horizon stochastic optimal control strategy for ACC and CACC under uncertainty*. DOI: 10.1016/j.trc.2017.07.011

Conclusiones y perspectivas

Ideas

- La navegación autónoma puede formularse como un problema de **control óptimo estocástico**.
- El sistema dinámico describe la evolución de distancia y velocidad relativa.
- La incertidumbre proviene de:
 - sensores
 - dinámica del vehículo
 - perturbaciones externas
- El problema se expresa como una optimización cuadrática con restricciones.

Resolución


- estimación del estado mediante **filtro de Kalman**
- cálculo del control óptimo mediante **LQG / MPC**
- implementación en **horizonte deslizante**

Mensaje central

Optimización + Control + Datos

permiten diseñar sistemas autónomos seguros y eficientes.

Intersección de áreas



Temas a seguir

- aprendizaje de modelos dinámicos
- control robusto bajo alta incertidumbre
- integración con aprendizaje profundo

Aplicaciones

- vehículos autónomos
- robótica móvil
- sistemas energéticos
- logística inteligente